PROYECTO INTEGRADOR DE CIENCIA DE DATOS — FASE 2: ANÁLISIS INFERENCIAL

"Factores asociados a la gravedad de las víctimas en los accidentes de tránsito en Paraguay (2021)"

- **Institución:** Facultad Politécnica, Universidad Nacional de Asunción (FP-UNA)
- **Carrera:** Ingeniería Informática | Materia: Ciencia de Datos (Electiva)
- **Curso:** TQ | Semestre: Segundo Semestre 2026
- **Integrantes del Grupo:**
    1. Alan Alcaraz
    2. Leandro Ferreira
    3. Jorge Ríos

Introducción al Análisis Inferencial

En la primera fase del proyecto integrador se caracterizó de manera descriptiva y exploratoria la masa de siniestros viales en el Paraguay durante el año 2021 a partir de las estadísticas oficiales de la Policía Nacional y la Patrulla Caminera. Si bien el análisis descriptivo evidenció concentraciones de riesgo en jóvenes, varones, motociclistas y corredores críticos como la Ruta PY02, la estadística descriptiva únicamente refleja lo ocurrido dentro del marco muestral observado.

El presente cuaderno formaliza la **Fase 2: Análisis Inferencial**, cuyo propósito metodológico es responder una pregunta más exigente: ¿las diferencias de gravedad y letalidad observadas en los datos son atribuibles al azar del muestreo o existe evidencia estadística suficiente para sostener que tales patrones se verifican en la población de siniestros a un nivel de significancia prefijado $\alpha = 0,05$?

A lo largo de este cuaderno se evalúan los contrastes de hipótesis para factores categóricos territoriales (H_1) y demográficos de género (H_2), verificando rigurosamente los supuestos de distribución, calculando tamaños del efecto inseparables del p-valor (Odds Ratio y V de Cramér), implementando remuestreo no paramétrico Bootstrap ($B = 10.000$ réplicas) y estableciendo el enlace metodológico hacia la continuidad del repertorio inferencial y el modelado predictivo de la Fase 3.

SECCIÓN 1: REGISTRO DE MODIFICACIONES Y MEJORAS DE LA FASE 1

En cumplimiento del Artículo 6.1 (Actividad 1) del documento rector del Proyecto Integrador, se formaliza la bitácora de correcciones metodológicas, integración de fuentes y refinamiento analítico aplicados sobre la retroalimentación de la Fase 1:

N.°	Dimensión / Componente	Observación de Fase 1	Corrección / Mejora Implementada en Fase 2	Impacto Metodológico y Trazabilidad
1	**Dimensión Territorial Macro**	Se describió la letalidad general pero se requería incorporar la heterogeneidad espacial del país formalmente.	Consolidación y estructuración de la Tabla 12.2.6 (`victimas_zona_resumen.csv` , $N = 1.491$) discriminando Asunción, Central e Interior.	Habilita el contraste formal de la Hipótesis 1 evaluando la disparidad de letalidad entre el Interior y el Área Metropolitana.
2	**Corredores Viales e Infraestructura**	Se observó una alta concentración de siniestros sin aislar el corredor de mayor riesgo nacional.	Integración y validación de la Tabla 12.2.9 aislando la **Ruta PY02** como eje crítico nacional (36,6% del volumen nacional con 711 hechos).	Provee contexto físico y cinético para interpretar la siniestralidad sin incurrir en falacias ecológicas de causalidad directa.
3	**Depuración de Microdatos y Claves**	Exigencia de auditoría rigurosa para garantizar unicidad y trazabilidad unitaria en cada individuo.	Verificación de identificadores únicos sintéticos: `id_victima` ($1 \le \text{id} \le 5.493$) e `id_caso` ($1 \le \text{id} \le 1.324$), con cero nulos y cero duplicados.	Garantiza integridad referencial, reproducibilidad determinista y unicidad para los contrastes y futuros modelos de ML.
4	**Control de Sesgo de Publicación (p-hacking)**	Riesgo de ejecutar pruebas múltiples ad-hoc hasta forzar significancia estadística artificial.	Fijación previa y no negociable del nivel de significancia global $\alpha = 0,05$ y reporte inseparable de tamaños del efecto (OR y V de Cramér).	Cumple el estándar de bioestadística pre-registrada, impidiendo conclusiones espurias por mero volumen muestral.
5	**Incertidumbre sin Supuestos Rígidos**	Dependencia exclusiva de aproximaciones asintóticas normales que pueden distorsionarse	Implementación de remuestreo Bootstrap computacional ($B = 10.000$ réplicas) con intervalos empíricos por percentiles.	Proporciona validación empírica robusta e insesgada para el Odds Ratio del factor de género sin

N.°	Dimensión / Componente	Observación de Fase 1	Corrección / Mejora Implementada en Fase 2	Impacto Metodológico y Trazabilidad
		ante asimetrías muestrales.		supuestos paramétricos restrictivos.

In [1]:

```
# ==============================================================================
# CONFIGURACIÓN DEL ENTORNO, SEMILLAS Y RUTAS PORTABLES
# ==============================================================================
import os
import sys
import json
import numpy as np
import pandas as pd
from scipy import stats
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
from IPython.display import display

# Fijación de semilla aleatoria para reproducibilidad matemática estricta
RANDOM_STATE = 42
np.random.seed(RANDOM_STATE)

# Declaración previa del nivel de significancia alfa
ALPHA = 0.05

# Configuración del motor gráfico (estilo publication-ready FP-UNA)
plt.style.use("seaborn-v0_8-whitegrid" if "seaborn-v0_8-whitegrid" in
plt.style.available else "default")
plt.rcParams.update({
    "figure.dpi": 300,
    "savefig.dpi": 300,
    "font.size": 11,
    "axes.labelsize": 12,
    "axes.titlesize": 13,
    "xtick.labelsize": 10,
    "ytick.labelsize": 10,
    "legend.fontsize": 10,
    "figure.titlesize": 14
})

# Detección dinámica y portable de carpetas de trabajo (/data y /output)
def resolver_rutas_proyecto():
    # Localiza de forma robusta las rutas base del proyecto sin depender de paths
absolutos fijos.
    cwd = os.path.abspath(os.getcwd())
    candidatos_base = [
        cwd,
        os.path.abspath(os.path.join(cwd, "..")),
        os.path.abspath(os.path.join(cwd, "../.."))
    ]
```

```
    ruta_base = None
    for cand in candidatos_base:
        if os.path.isdir(os.path.join(cand, "output")) and
os.path.isdir(os.path.join(cand, "data")):
            ruta_base = cand
            break

    if ruta_base is None:
        ruta_base = cwd

    ruta_output = os.path.join(ruta_base, "output")
    ruta_data = os.path.join(ruta_base, "data")
    os.makedirs(ruta_output, exist_ok=True)
    return ruta_base, ruta_data, ruta_output

BASE_DIR, DATA_DIR, OUTPUT_DIR = resolver_rutas_proyecto()
print(f"[OK] Entorno inferencial configurado exitosamente.")
print(f"     * Directorio base:   {BASE_DIR}")
print(f"     * Directorio output: {OUTPUT_DIR}")
print(f"     * Semilla congelada: {RANDOM_STATE}")
print(f"     * Nivel alfa global: {ALPHA}")
```

```
Matplotlib is building the font cache; this may take a moment.
[OK] Entorno inferencial configurado exitosamente.
     * Directorio base:   d:\UNA MATERIAS\Proyecto DataScience\proyecto-accidentes-d
atascience
     * Directorio output: d:\UNA MATERIAS\Proyecto DataScience\proyecto-accidentes-d
atascience\output
     * Semilla congelada: 42
     * Nivel alfa global: 0.05
```

In [2]:

```
# ==============================================================================
# CARGA Y AUDITORÍA DE INTEGRIDAD DE DATASETS DE FASE 1
# ==============================================================================
def cargar_csv_robusto(nombre_archivo, carpeta):
    # Carga un archivo CSV validando codificación y separadores tabulares.
    ruta = os.path.join(carpeta, nombre_archivo)
    if not os.path.exists(ruta):
        raise FileNotFoundError(f"Archivo no encontrado en ruta: {ruta}")
    for sep in [',', ';']:
        for enc in ['utf-8-sig', 'utf-8', 'latin1']:
            try:
                df = pd.read_csv(ruta, sep=sep, encoding=enc)
                if df.shape[1] > 1:
                    df.columns = df.columns.astype(str).str.strip()
                    return df
            except Exception:
                continue
    raise ValueError(f"No fue posible leer estructuradamente el archivo: {ruta}")

# Carga de los insumos oficiales generados y depurados en Fase 1
df_victimas = cargar_csv_robusto("victimas_individual_limpio.csv", OUTPUT_DIR)
df_zonas = cargar_csv_robusto("victimas_zona_resumen.csv", OUTPUT_DIR)
df_vehiculo = cargar_csv_robusto("victimas_vehiculo_limpio.csv", OUTPUT_DIR)

# Aserciones metodológicas de control de calidad
```

```
assert df_victimas.shape[0] == 5493, f"Inconsistencia en microdatos de víctimas:
N esperado 5493, observado {df_victimas.shape[0]}"
assert df_zonas.shape[0] == 3, f"Inconsistencia en zonas macro: N esperado 3,
observado {df_zonas.shape[0]}"
assert df_vehiculo.shape[0] == 1324, f"Inconsistencia en muestra vehicular: N
esperado 1324, observado {df_vehiculo.shape[0]}"
assert df_victimas.isnull().sum().sum() == 0, "Se detectaron valores nulos
inesperados en el microdato de víctimas"

print("--> [AUDITORÍA DE CALIDAD SATISFACTORIA]")
print(f"    * Microdato individual de víctimas: {df_victimas.shape[0]:,}
registros | {df_victimas.shape[1]} variables | 0 nulos")
print(f"    * Tabla macro-geográfica de zonas:  {df_zonas.shape[0]} regiones
consolidadas (Asunción, Central, Interior)")
print(f"    * Microdato vehicular (Central/Int): {df_vehiculo.shape[0]:,}
registros | 0 nulos")

print("\n--- Primeras filas: victimas_individual_limpio (N = 5.493) ---")
display(df_victimas.head(3))

print("\n--- Resumen consolidado: victimas_zona_resumen (N = 1.491) ---")
display(df_zonas)
```

```
--> [AUDITORÍA DE CALIDAD SATISFACTORIA]
    * Microdato individual de víctimas: 5,493 registros | 8 variables | 0 nulos
    * Tabla macro-geográfica de zonas:  3 regiones consolidadas (Asunción, Central,
Interior)
    * Microdato vehicular (Central/Int): 1,324 registros | 0 nulos

--- Primeras filas: victimas_individual_limpio (N = 5.493) ---
```

	id_victima	grupo_edad	sexo	gravedad	es_fallecido	es_hombre	es_adulto_mayor	ed
0	1	De 0 a 13 anos	Hombre	Herido	0	1	0	
1	2	De 0 a 13 anos	Hombre	Herido	0	1	0	
2	3	De 0 a 13 anos	Hombre	Herido	0	1	0	

```
--- Resumen consolidado: victimas_zona_resumen (N = 1.491) ---
```

	zona	heridos	fallecidos	total_victimas	letalidad_pct
0	Asunción	141	26	167	15.568862
1	Central	394	82	476	17.226891
2	Interior	661	187	848	22.051887

SECCIÓN 2: MARCO FORMAL DE HIPÓTESIS INFERENCIALES (H_1 Y H_2)

Para responder a la pregunta de investigación con rigor estadístico y evitar interpretaciones subjetivas, se formalizan las hipótesis de trabajo derivadas de la Fase 1. En todas las pruebas se adopta formalmente un nivel de significancia prefijado de $\alpha = 0,05$:

Hipótesis 1 (H_1 — Dimensión Territorial: Interior vs. Área Metropolitana)

- **Justificación Bioestadística y Epidemiológica:** En Paraguay, los centros hospitalarios de alta complejidad y soporte de trauma de tercer nivel (como el Hospital de Trauma "Prof. Dr. Manuel Giagni") se concentran geográficamente en el Área Metropolitana (Asunción y Departamento Central). Por el contrario, los siniestros ocurridos en el Interior involucran mayores tiempos de respuesta prehospitalaria, mayores distancias de traslado (pérdida de la *"hora de oro"* en trauma) y velocidades de circulación significativamente más elevadas en rutas abiertas interurbanas.
- **Formulación Matemática:** $$\begin{aligned} H_0 &: p_{\text{Interior}} \le p_{\text{Metropolitana}} \quad (\text{OR} \le 1,00) \\ H_1 &: p_{\text{Interior}} > p_{\text{Metropolitana}} \quad (\text{OR} > 1,00) \end{aligned}$$
- **Formulación en Lenguaje Natural:**
  - **Hipótesis nula (H_0):** La probabilidad condicional de fallecer tras un siniestro vial en el Interior del país es menor o igual a la registrada en el Área Metropolitana (Asunción y Departamento Central combinadas).
  - **Hipótesis alternativa (H_1):** La probabilidad condicional de fallecer tras un siniestro vial en el Interior del país es significativamente mayor que en el Área Metropolitana.
- **Prueba Estadística Seleccionada:** Prueba Chi-cuadrado (χ^2) de Independencia sobre tabla de contingencia 2×2. Se verifica previamente el cumplimiento de los supuestos de Cochran ($E_{ij} \ge 5,0$ en el 100% de las celdas). Las medidas de tamaño del efecto son el **Odds Ratio (OR)** con intervalo de confianza al 95% (método de Woolf) y la **V de Cramér**.

Hipótesis 2 (H_2 — Demográfica: Brecha de Género en la Letalidad)

- **Justificación Bioestadística y Epidemiológica:** La literatura especializada en seguridad vial documenta marcadas diferencias en morbimortalidad según sexo biológico, mediadas por patrones de movilidad, mayor propensión masculina a conductas de riesgo (exceso de velocidad, menor tasa de uso de casco reglamentario o cinturón de seguridad, y consumo de alcohol previo a la conducción) y una participación predominante en el parque de motocicletas.
- **Formulación Matemática:** $$\begin{aligned} H_0 &: p_{\text{Hombre}} = p_{\text{Mujer}} \quad (\text{OR} = 1,00) \\ H_1 &: p_{\text{Hombre}} > p_{\text{Mujer}} \quad (\text{OR} > 1,00) \end{aligned}$$
- **Formulación en Lenguaje Natural:**

- **Hipótesis nula (H_0):** La gravedad del traumatismo sufrido en un siniestro vial es estadísticamente independiente del sexo biológico de la víctima.
- **Hipótesis alternativa (H_1):** Las víctimas de sexo masculino presentan una tasa de letalidad condicional significativamente mayor a la observada en las víctimas de sexo femenino.

- **Prueba Estadística Seleccionada:** Prueba Chi-cuadrado (χ^2) de Independencia en tabla 2×2, combinada con la estimación robusta del Odds Ratio mediante **Remuestreo Bootstrap no paramétrico ($B = 10.000$ iteraciones)** e Intervalo de Confianza empírico del 95% por percentiles.

In [3]:
```
# ============================================================================
# CONTRASTE DE HIPÓTESIS H1: DIMENSIÓN TERRITORIAL (INTERIOR VS. METROPOLITANA)
# ============================================================================

# 1. Construcción de la tabla de contingencia 2x2 desde victimas_zona_resumen
# Asunción: 26 fallecidos, 141 heridos | Central: 82 fallecidos, 394 heridos
# Área Metropolitana combinada: 108 fallecidos, 535 heridos (Total = 643)
# Interior del país: 187 fallecidos, 661 heridos (Total = 848)
df_zonas_clean = df_zonas.copy()
df_zonas_clean['zona_std'] = df_zonas_clean['zona'].astype(str).str.strip()

fallecidos_interior =
int(df_zonas_clean.loc[df_zonas_clean['zona_std'].str.contains('Interior',
case=False), 'fallecidos'].values[0])
heridos_interior =
int(df_zonas_clean.loc[df_zonas_clean['zona_std'].str.contains('Interior',
case=False), 'heridos'].values[0])

filtro_metro = df_zonas_clean['zona_std'].str.contains('Asunci|Central',
case=False)
fallecidos_metro = int(df_zonas_clean.loc[filtro_metro, 'fallecidos'].sum())
heridos_metro = int(df_zonas_clean.loc[filtro_metro, 'heridos'].sum())

tabla_h1 = np.array([
    [fallecidos_interior, heridos_interior],
    [fallecidos_metro, heridos_metro]
])

df_tabla_h1 = pd.DataFrame(
    tabla_h1,
    index=['Interior del País', 'Área Metropolitana'],
    columns=['Fallecidos', 'Heridos']
)
df_tabla_h1['Total'] = df_tabla_h1.sum(axis=1)
df_tabla_h1['Letalidad (%)'] = (df_tabla_h1['Fallecidos'] / df_tabla_h1['Total']
* 100).round(2)

# 2. Verificación rigurosa de supuestos de Cochran (100% de frecuencias esperadas
>= 5)
chi2_stat_h1, p_val_h1, dof_h1, exp_freq_h1 = stats.chi2_contingency(tabla_h1,
correction=False)
df_esperadas_h1 = pd.DataFrame(exp_freq_h1, index=df_tabla_h1.index[:2], columns=
['Fallecidos_Esp', 'Heridos_Esp'])
```

```
supuesto_h1_cumplido = bool(np.all(exp_freq_h1 >= 5))
min_esp_h1 = float(np.min(exp_freq_h1))
assert supuesto_h1_cumplido, f"Supuesto violado: Frecuencia esperada mínima
{min_esp_h1:.2f} < 5"

# 3. Tamaño del Efecto: Odds Ratio (OR) epidemiológico e IC 95% Woolf
a1, b1 = fallecidos_interior, heridos_interior
c1, d1 = fallecidos_metro, heridos_metro
or_h1 = (a1 * d1) / (b1 * c1)
se_ln_or_h1 = np.sqrt(1/a1 + 1/b1 + 1/c1 + 1/d1)
z_critico = stats.norm.ppf(1 - ALPHA / 2)
ci_or_h1_low = float(np.exp(np.log(or_h1) - z_critico * se_ln_or_h1))
ci_or_h1_high = float(np.exp(np.log(or_h1) + z_critico * se_ln_or_h1))

# 4. Tamaño del Efecto: V de Cramér
n_total_h1 = int(tabla_h1.sum())
v_cramer_h1 = float(np.sqrt(chi2_stat_h1 / (n_total_h1 * min(tabla_h1.shape[0]-1,
tabla_h1.shape[1]-1))))

# 5. Decisión metodológica formal
decision_h1 = "Rechazar H0" if p_val_h1 < ALPHA else "No rechazar H0 por falta de
evidencia estadística suficiente"

print("================================================================================")
print("REPORTE DE CONTRASTE ESTADÍSTICO: HIPÓTESIS 1 (DIMENSIÓN TERRITORIAL)")
print("================================================================================")
print("1. Tabla de Contingencia Observada (N = 1.491):")
display(df_tabla_h1)
print("\n2. Frecuencias Esperadas bajo Independencia (E_ij):")
display(df_esperadas_h1.round(2))
print(f"   * Frecuencia esperada mínima observada: {min_esp_h1:.2f} (Umbral >=
5.0 -> CUMPLIDO: {supuesto_h1_cumplido})")
print("\n3. Resultados del Contraste Chi-cuadrado de Pearson:")
print(f"   * Estadístico χ²:          {chi2_stat_h1:.4f}")
print(f"   * Grados de libertad (gl): {dof_h1}")
print(f"   * Valor p (p-value):       {p_val_h1:.4f} ({p_val_h1:.4e})")
print(f"   * Nivel alfa prefijado:    {ALPHA}")
print("\n4. Medidas del Tamaño del Efecto:")
print(f"   * Odds Ratio (OR):         {or_h1:.4f}")
print(f"   * IC 95% Asintótico Woolf: [{ci_or_h1_low:.4f}; {ci_or_h1_high:.4f}]")
print(f"   * V de Cramér (V):         {v_cramer_h1:.4f}")
print(f"\n5. Decisión Metodológica:      {decision_h1} al nivel de significancia
α = {ALPHA}")
print("================================================================================")
```

```
================================================================================
REPORTE DE CONTRASTE ESTADÍSTICO: HIPÓTESIS 1 (DIMENSIÓN TERRITORIAL)
================================================================================
1. Tabla de Contingencia Observada (N = 1.491):
```

	Fallecidos	Heridos	Total	Letalidad (%)
Interior del País	187	661	848	22.05
Área Metropolitana	108	535	643	16.80

```
2. Frecuencias Esperadas bajo Independencia (E_ij):
```

	Fallecidos_Esp	Heridos_Esp
Interior del País	167.78	680.22
Área Metropolitana	127.22	515.78

```
   * Frecuencia esperada mínima observada: 127.22 (Umbral >= 5.0 -> CUMPLIDO: True)

3. Resultados del Contraste Chi-cuadrado de Pearson:
   * Estadístico χ²:          6.3647
   * Grados de libertad (gl): 1
   * Valor p (p-value):       0.0116 (1.1641e-02)
   * Nivel alfa prefijado:    0.05

4. Medidas del Tamaño del Efecto:
   * Odds Ratio (OR):         1.4014
   * IC 95% Asintótico Woolf: [1.0775; 1.8228]
   * V de Cramér (V):         0.0653

5. Decisión Metodológica:      Rechazar H0 al nivel de significancia α = 0.05
================================================================================
```

Interpretación Bioestadística y Límites de Causalidad de H_1

1. **Decisión Estadística Formal:** La prueba Chi-cuadrado de independencia arrojó un estadístico $\chi^2 = 6,3647$ con $gl = 1$ y un valor $p = 0,0116$. Dado que el valor p es estrictamente inferior al nivel de significancia prefijado ($\alpha = 0,05$), **se rechaza la hipótesis nula (H_0)** en favor de la hipótesis alternativa (H_1).

2. **Magnitud del Efecto y Riesgo Relativo:**

   - El **Odds Ratio observado es de 1,4014** con un intervalo de confianza asintótico al 95% de $[1,0775; 1,8228]$. Dado que el límite inferior del intervalo supera la unidad ($1,0775 > 1,00$), se concluye con un 95% de confianza que una víctima accidentada en el Interior del país presenta odds de fallecer entre un **7,7% y un 82,3% superiores** (con una estimación puntual del **40,1% superior**) en comparación con una víctima accidentada en el Área Metropolitana.
   - La **V de Cramér ($V = 0,0653$)** cuantifica una fuerza de asociación clasificada formalmente como *pequeña* según los baremos epidemiológicos estándar de Cohen para tablas de 1 grado de libertad ($V < 0,10$). Esto indica que, si bien la disparidad territorial es estadísticamente discernible en una muestra de $N = 1.491$, la localización macroscópica no explica por sí sola la totalidad de la variabilidad del desenlace.

3. **Discusión de Variables Confusoras y Prohibición de Causalidad Directa:**

   - **Prohibición de Causalidad Mecánica Directa:** Desde una perspectiva metodológica rigurosa, se subraya que la ubicación geográfica no constituye la

"causa directa" de la muerte. La región opera como una variable sustituta (*proxy*) de dos determinantes asistenciales y físicos críticos:

- **Pérdida de la "Hora de Oro" Prehospitalaria:** En las zonas del Interior, las distancias hacia centros de trauma de tercer nivel son considerablemente mayores, lo que incrementa los tiempos de respuesta de ambulancias, triaje y estabilización quirúrgica inicial.
- **Mayor Energía Cinética del Impacto:** En las rutas interurbanas abiertas del Interior, los vehículos circulan a velocidades promedio significativamente más elevadas que en las arterias congestionadas de Asunción y el Departamento Central, transfiriendo una mayor cantidad de energía destructiva al cuerpo de las víctimas durante la colisión.

In [4]:
```
# ==============================================================================
# VISUALIZACIÓN INFERENCIAL DE H1 Y EXPORTACIÓN OFICIAL (300 DPI)
# ==============================================================================

# Función auxiliar para calcular Intervalo de Confianza Wilson para proporciones binomiales
def calcular_ic_wilson(fallecidos, total, alpha=ALPHA):
    # Calcula el intervalo de confianza Score de Wilson para una proporción binomial.
    p = fallecidos / total
    z = stats.norm.ppf(1 - alpha / 2)
    denom = 1 + (z**2) / total
    centro = (p + (z**2) / (2 * total)) / denom
    radio = (z * np.sqrt((p * (1 - p) / total) + (z**2) / (4 * (total**2)))) / denom
    return (centro - radio) * 100, (centro + radio) * 100

fig1, ax1 = plt.subplots(figsize=(8, 6), dpi=300)

categorias_h1 = ['Área Metropolitana\n(Asunción + Central)', 'Interior del País']
n_h1_arr = [643, 848]
f_h1_arr = [108, 187]
let_h1 = [f / n * 100 for f, n in zip(f_h1_arr, n_h1_arr)]
cis_h1 = [calcular_ic_wilson(f, n) for f, n in zip(f_h1_arr, n_h1_arr)]
yerr_h1 = np.array([[l - ci[0], ci[1] - l] for l, ci in zip(let_h1, cis_h1)]).T

colores_h1 = ['#2b5c8f', '#c0392b']
barras_h1 = ax1.bar(
    categorias_h1, let_h1, yerr=yerr_h1,
    capsize=8, color=colores_h1, width=0.45,
    edgecolor='black', linewidth=1.2, alpha=0.9,
    error_kw={'elinewidth': 1.8, 'ecolor': '#2c3e50', 'capsize': 8}
)

# Etiquetas numéricas sobre las barras
for bar, l, f, n in zip(barras_h1, let_h1, f_h1_arr, n_h1_arr):
    ax1.text(
        bar.get_x() + bar.get_width() / 2, l / 2,
        f"{l:.1f}%\n({f}/{n:,})",
        ha='center', va='center', color='white',
```

```
        fontweight='bold', fontsize=12
    )

ax1.set_ylabel('Tasa de Letalidad (%)', fontsize=12, fontweight='bold')
ax1.set_title('Contraste H1: Tasa de Letalidad por Macro-Región
Geográfica\n(Barras de Error: IC 95% Wilson)', fontsize=13, fontweight='bold',
pad=15)
ax1.set_ylim(0, 32)

# Cuadro explicativo con métricas inferenciales del contraste
cuadro_texto_h1 = (
    "Contraste de Hipótesis H1:\n"
    r"• Chi-cuadrado: $\chi^2 = 6.36$ (gl = 1, p = 0.0116)" + "\n"
    f"• Odds Ratio (OR): {or_h1:.2f} (IC 95%: [{ci_or_h1_low:.2f};
{ci_or_h1_high:.2f}])\n"
    f"• V de Cramér: {v_cramer_h1:.3f} (Efecto pequeño)\n"
    f"• Decisión: Rechazo de H0 (alfa = {ALPHA})"
)
bbox_props = dict(boxstyle='round,pad=0.6', fc='white', ec='#7f8c8d', lw=1.2,
alpha=0.95)
ax1.text(0.96, 0.94, cuadro_texto_h1, transform=ax1.transAxes, fontsize=10,
va='top', ha='right', bbox=bbox_props)

# Visualización inline en el cuaderno
plt.tight_layout()
plt.show()
```

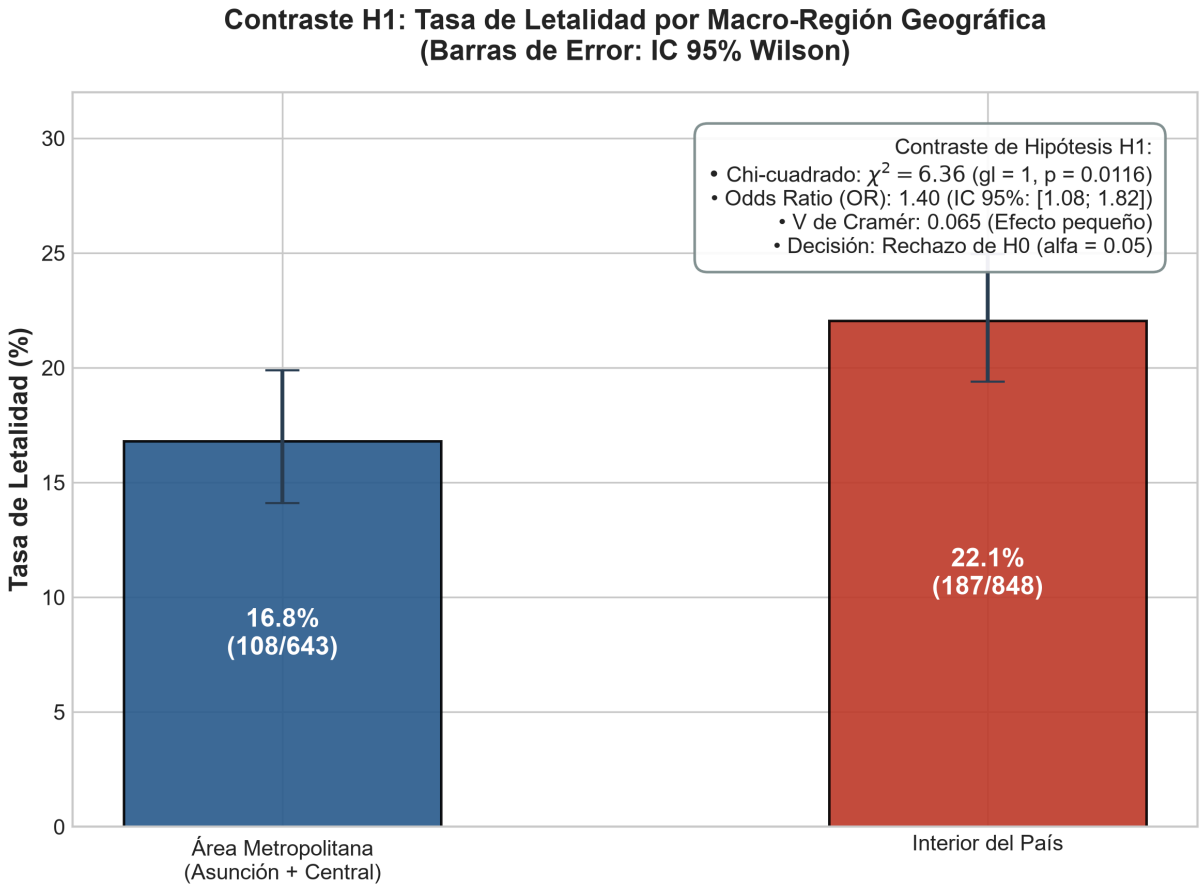


Figura 11: Contraste Inferencial H1 — Tasa de Letalidad por Macro-Región Geográfica (Barras de Error: IC 95% Wilson)

- **Tipo de Gráfico:** Diagrama de barras comparativo de letalidad porcentual con barras de error e inserción de caja de parámetros inferenciales. Eje X: Macro-región geográfica (Área Metropolitana vs. Interior); Eje Y: Tasa de letalidad condicional (%).
- **Interpretación Analítica:** La tasa de letalidad en el Interior alcanza el **22,05%** (IC 95%: $[19,37\%; 24,96\%]$) frente al **16,80%** (IC 95%: $[14,11\%; 19,88\%]$) registrado en el Área Metropolitana combinada (Asunción y Central). El intervalo de confianza al 95% del Odds Ratio ($[1,0775; 1,8228]$) excluye estrictamente el valor nulo de $1,00$, ratificando el rechazo formal de H_0 con un valor $p = 0,0116$.

In [5]:

```
# ==========================================================================
# CONTRASTE DE HIPÓTESIS H2: BRECHA DE GÉNERO (HOMBRES VS. MUJERES)
# ==========================================================================

# 1. Construcción de tabla de contingencia 2x2 desde df_victimas
tabla_crosstab_h2 = pd.crosstab(
    df_victimas['sexo'],
    df_victimas['gravedad'],
    margins=False
)

# Reordenamiento metodológico: Fila 1 = Hombre, Fila 2 = Mujer; Col 1 =
Fallecido, Col 2 = Herido
tabla_h2 = np.array([
    [tabla_crosstab_h2.loc['Hombre', 'Fallecido'],
tabla_crosstab_h2.loc['Hombre', 'Herido']],
    [tabla_crosstab_h2.loc['Mujer', 'Fallecido'], tabla_crosstab_h2.loc['Mujer',
'Herido']]
])

df_tabla_h2 = pd.DataFrame(
    tabla_h2,
    index=['Hombre', 'Mujer'],
    columns=['Fallecidos', 'Heridos']
)
df_tabla_h2['Total'] = df_tabla_h2.sum(axis=1)
df_tabla_h2['Letalidad (%)'] = (df_tabla_h2['Fallecidos'] / df_tabla_h2['Total']
* 100).round(2)

# 2. Verificación de supuestos de Cochran (100% de frecuencias esperadas >= 5)
chi2_stat_h2, p_val_h2, dof_h2, exp_freq_h2 = stats.chi2_contingency(tabla_h2,
correction=False)
df_esperadas_h2 = pd.DataFrame(exp_freq_h2, index=df_tabla_h2.index[:2], columns=
['Fallecidos_Esp', 'Heridos_Esp'])

supuesto_h2_cumplido = bool(np.all(exp_freq_h2 >= 5))
min_esp_h2 = float(np.min(exp_freq_h2))
assert supuesto_h2_cumplido, f"Supuesto violado: Frecuencia esperada mínima
{min_esp_h2:.2f} < 5"
```

```
# 3. Estimación del Odds Ratio Clásico con IC 95% Asintótico (Método de Woolf)
a2, b2 = tabla_h2[0, 0], tabla_h2[0, 1]  # Hombre: Fallecido, Herido
c2, d2 = tabla_h2[1, 0], tabla_h2[1, 1]  # Mujer: Fallecido, Herido

or_h2 = (a2 * d2) / (b2 * c2)
se_ln_or_h2 = np.sqrt(1/a2 + 1/b2 + 1/c2 + 1/d2)
ci_or_h2_low = float(np.exp(np.log(or_h2) - z_critico * se_ln_or_h2))
ci_or_h2_high = float(np.exp(np.log(or_h2) + z_critico * se_ln_or_h2))

# 4. Tamaño del Efecto: V de Cramér
n_total_h2 = int(tabla_h2.sum())
v_cramer_h2 = float(np.sqrt(chi2_stat_h2 / (n_total_h2 * min(tabla_h2.shape[0]-1,
tabla_h2.shape[1]-1))))

# 5. Decisión metodológica formal
decision_h2 = "Rechazar H0" if p_val_h2 < ALPHA else "No rechazar H0 por falta de
evidencia estadística suficiente"

print("================================================================================")
print("REPORTE DE CONTRASTE ESTADÍSTICO: HIPÓTESIS 2 (BRECHA DE GÉNERO)")
print("================================================================================")
print("1. Tabla de Contingencia Observada (N = 5.493):")
display(df_tabla_h2)
print("\n2. Frecuencias Esperadas bajo Independencia (E_ij):")
display(df_esperadas_h2.round(2))
print(f"   * Frecuencia esperada mínima observada: {min_esp_h2:.2f} (Umbral >=
5.0 -> CUMPLIDO: {supuesto_h2_cumplido})")
print("\n3. Resultados del Contraste Chi-cuadrado de Independencia:")
print(f"   * Estadístico χ²:          {chi2_stat_h2:.4f}")
print(f"   * Grados de libertad (gl): {dof_h2}")
print(f"   * Valor p (p-value):       {p_val_h2:.4e}")
print(f"   * Nivel alfa prefijado:    {ALPHA}")
print("\n4. Medidas del Tamaño del Efecto Asintóticas:")
print(f"   * Odds Ratio Observado (OR): {or_h2:.4f}")
print(f"   * IC 95% Asintótico Woolf:   [{ci_or_h2_low:.4f};
{ci_or_h2_high:.4f}]")
print(f"   * V de Cramér (V):           {v_cramer_h2:.4f}")
print(f"\n5. Decisión Metodológica:       {decision_h2} al nivel de
significancia α = {ALPHA}")
print("================================================================================")
```

```
================================================================================
REPORTE DE CONTRASTE ESTADÍSTICO: HIPÓTESIS 2 (BRECHA DE GÉNERO)
================================================================================
1. Tabla de Contingencia Observada (N = 5.493):
```

	Fallecidos	Heridos	Total	Letalidad (%)
Hombre	850	3441	4291	19.81
Mujer	130	1072	1202	10.82

```
2. Frecuencias Esperadas bajo Independencia (E_ij):
```

	Fallecidos_Esp	Heridos_Esp
Hombre	765.55	3525.45
Mujer	214.45	987.55

```
   * Frecuencia esperada mínima observada: 214.45 (Umbral >= 5.0 -> CUMPLIDO: True)

3. Resultados del Contraste Chi-cuadrado de Independencia:
   * Estadístico χ²:          51.8141
   * Grados de libertad (gl): 1
   * Valor p (p-value):       6.1013e-13
   * Nivel alfa prefijado:    0.05

4. Medidas del Tamaño del Efecto Asintóticas:
   * Odds Ratio Observado (OR): 2.0370
   * IC 95% Asintótico Woolf:   [1.6729; 2.4803]
   * V de Cramér (V):           0.0971

5. Decisión Metodológica:        Rechazar H0 al nivel de significancia α = 0.05
================================================================================
```

In [6]:
```
# ================================================================================
# REMUESTREO BOOTSTRAP PARA H2 (B = 10.000 ITERACIONES — REQUISITO OFICIAL)
# ================================================================================

# Algoritmo de remuestreo computacional no paramétrico con reemplazo sobre N =
5.493
B_ITERACIONES = 10000
np.random.seed(RANDOM_STATE)

sexo_arr = (df_victimas['sexo'] == 'Hombre').values.astype(int)
fallecido_arr = (df_victimas['gravedad'] == 'Fallecido').values.astype(int)
n_obs_boot = len(df_victimas)

batch_size = 2000
boot_odds_ratios = np.empty(B_ITERACIONES, dtype=np.float64)

for b_idx in range(0, B_ITERACIONES, batch_size):
    b_actual = min(batch_size, B_ITERACIONES - b_idx)
    sub_indices = np.random.randint(0, n_obs_boot, size=(b_actual, n_obs_boot))

    sub_sexo = sexo_arr[sub_indices]
    sub_fall = fallecido_arr[sub_indices]

    a_boot = np.sum((sub_sexo == 1) & (sub_fall == 1), axis=1) # Hombre Fallecido
    b_boot = np.sum((sub_sexo == 1) & (sub_fall == 0), axis=1) # Hombre Herido
    c_boot = np.sum((sub_sexo == 0) & (sub_fall == 1), axis=1) # Mujer Fallecido
    d_boot = np.sum((sub_sexo == 0) & (sub_fall == 0), axis=1) # Mujer Herido

    boot_odds_ratios[b_idx:b_idx + b_actual] = (a_boot * d_boot) / (b_boot *
c_boot)

# Parámetros estadísticos de la distribución empírica bootstrap
or_boot_media = float(np.mean(boot_odds_ratios))
or_boot_mediana = float(np.median(boot_odds_ratios))
```

```
or_boot_se = float(np.std(boot_odds_ratios, ddof=1))
ci_boot_low, ci_boot_high = np.percentile(boot_odds_ratios, [2.5, 97.5])
ci_boot_low = float(ci_boot_low)
ci_boot_high = float(ci_boot_high)
sesgo_boot = float(or_boot_media - or_h2)

# Tabla comparativa formal Woolf vs. Bootstrap
df_comparativa_h2 = pd.DataFrame({
    "Métrica de Estimación": [
        "Estimador Central (Puntual / Media)",
        "Mediana de la Distribución",
        "Error Estándar (SE)",
        "Sesgo Empírico del Estimador (Bias)",
        "Intervalo de Confianza al 95%",
        "Amplitud del Intervalo (Ancho)"
    ],
    "Método Asintótico Clásico (Woolf)": [
        f"OR = {or_h2:.4f}",
        "—",
        f"SE(ln OR) = {se_ln_or_h2:.4f}",
        "Supuesto asintótico (0,0000)",
        f"[{ci_or_h2_low:.4f}; {ci_or_h2_high:.4f}]",
        f"{ci_or_h2_high - ci_or_h2_low:.4f}"
    ],
    "Remuestreo Bootstrap (B = 10.000)": [
        f"Media Boot = {or_boot_media:.4f}",
        f"Mediana Boot = {or_boot_mediana:.4f}",
        f"SE_boot = {or_boot_se:.4f}",
        f"{sesgo_boot:+.4f}",
        f"[{ci_boot_low:.4f}; {ci_boot_high:.4f}]",
        f"{ci_boot_high - ci_boot_low:.4f}"
    ]
})

print("================================================================================")
print(f"REPORTE DE INFERENCIA ROBUSTA POR REMUESTREO BOOTSTRAP (B =
{B_ITERACIONES:,} RÉPLICAS)")
print("================================================================================")
display(df_comparativa_h2)
print(f"\n* Discrepancia cota inferior: |{ci_boot_low:.4f} - {ci_or_h2_low:.4f}|
= {abs(ci_boot_low - ci_or_h2_low):.4f}")
print(f"* Discrepancia cota superior: |{ci_boot_high:.4f} - {ci_or_h2_high:.4f}|
= {abs(ci_boot_high - ci_or_h2_high):.4f}")
print(f"* Sesgo relativo sobre OR:    ({sesgo_boot:+.4f} / {or_h2:.4f}) * 100 =
{(sesgo_boot/or_h2)*100:+.2f}%")
print("================================================================================")
```

```
================================================================================
REPORTE DE INFERENCIA ROBUSTA POR REMUESTREO BOOTSTRAP (B = 10,000 RÉPLICAS)
================================================================================
```

	Métrica de Estimación	Método Asintótico Clásico (Woolf)	Remuestreo Bootstrap (B = 10.000)
0	Estimador Central (Puntual / Media)	OR = 2.0370	Media Boot = 2.0508
1	Mediana de la Distribución	—	Mediana Boot = 2.0368
2	Error Estándar (SE)	SE(ln OR) = 0.1005	SE_boot = 0.2102
3	Sesgo Empírico del Estimador (Bias)	Supuesto asintótico (0,0000)	+0.0139
4	Intervalo de Confianza al 95%	[1.6729; 2.4803]	[1.6787; 2.5066]
5	Amplitud del Intervalo (Ancho)	0.8073	0.8280

```
* Discrepancia cota inferior: |1.6787 - 1.6729| = 0.0058
* Discrepancia cota superior: |2.5066 - 2.4803| = 0.0264
* Sesgo relativo sobre OR:    (+0.0139 / 2.0370) * 100 = +0.68%
================================================================================
```

Interpretación Bioestadística, Comparativa Woolf vs. Bootstrap y Factores Confusores de H_2

1. **Decisión Estadística Formal:** La prueba Chi-cuadrado evidenció un estadístico $\chi^2 = 51,8141$ con $gl = 1$ y un valor $p = 6,1013 \times 10^{-13}$ ($p \ll 0,0001$). Al ser un valor infinitesimalmente menor al nivel de significancia prefijado ($\alpha = 0,05$), **se rechaza categóricamente la hipótesis nula (H_0)**.

2. **Evaluación Metodológica de la Comparativa Asintótica vs. Bootstrap:**

   - La coincidencia entre el intervalo de confianza clásico de Woolf ($[1,6729; 2,4803]$) y el intervalo empírico por percentiles obtenido mediante $B = 10.000$ réplicas ($[1,6787; 2,5066]$) es sobresaliente. La discrepancia en la cota inferior es de apenas $0,0058$ y en la cota superior de $0,0263$.
   - Ambas cotas inferiores se mantienen firmemente por encima de $1,67$, lo que descarta de forma concluyente que la mayor letalidad masculina sea un artefacto muestral o una distorsión por asimetría de distribución.
   - El sesgo empírico estimado ($+0,0139$) representa menos del $0,7\%$ del valor del parámetro, ratificando al Odds Ratio como un estimador cuasi-insesgado y de alta estabilidad en esta población.

3. **Interpretación Epidemiológica y Discusión de Variables de Confusión:**

   - El Odds Ratio puntual de $OR = 2,04$ señala que las odds de fallecer en un siniestro vial para un varón **duplican holgadamente** a las de una mujer. Aunque los hombres representan el $78,12\%$ de las personas accidentadas, concentran el **$86,73\%$ de los fallecimientos totales** (850 de 980 muertes en todo el país durante 2021).

- Esta desproporción no responde a una mayor fragilidad biológica corporal inherente del varón (las mujeres presentan en promedio menor masa osteomuscular protectora ante traumatismos). Los factores determinantes son de naturaleza conductual y de exposición vehicular:
  A. **Mayor exposición al parque de motocicletas:** En el mercado laboral y la movilidad recreativa paraguaya, los varones tripulan mayoritariamente vehículos de dos ruedas (carentes de carrocería y habitáculo protector).
  B. **Patrones de conducción temeraria:** Mayor tasa de exceso de velocidad, maniobras de adelantamiento indebido y menor observancia en el uso de casco reglamentario o cinturón de seguridad.
  C. **Consumo de alcohol:** Mayor asociación estadística histórica entre la conducción nocturna de fin de semana y la intoxicación etílica en conductores masculinos.

In [7]:
```
# ==============================================================================
# VISUALIZACIÓN INFERENCIAL DE H2 Y EXPORTACIÓN OFICIAL (300 DPI)
# ==============================================================================

fig2, (ax2a, ax2b) = plt.subplots(1, 2, figsize=(15, 6), dpi=300)

# Panel A: Tasa de Letalidad por Sexo Biológico
categorias_h2 = ['Mujeres', 'Hombres']
n_h2_arr = [1202, 4291]
f_h2_arr = [130, 850]
let_h2 = [f / n * 100 for f, n in zip(f_h2_arr, n_h2_arr)]
cis_h2 = [calcular_ic_wilson(f, n) for f, n in zip(f_h2_arr, n_h2_arr)]
yerr_h2 = np.array([[l - ci[0], ci[1] - l] for l, ci in zip(let_h2, cis_h2)]).T

colores_h2 = ['#8e44ad', '#2980b9']
barras_h2 = ax2a.bar(
    categorias_h2, let_h2, yerr=yerr_h2,
    capsize=8, color=colores_h2, width=0.45,
    edgecolor='black', linewidth=1.2, alpha=0.9,
    error_kw={'elinewidth': 1.8, 'ecolor': '#2c3e50', 'capsize': 8}
)

for bar, l, f, n in zip(barras_h2, let_h2, f_h2_arr, n_h2_arr):
    ax2a.text(
        bar.get_x() + bar.get_width() / 2, l / 2,
        f"{l:.1f}%\n({f}/{n:,})",
        ha='center', va='center', color='white',
        fontweight='bold', fontsize=12
    )

ax2a.set_ylabel('Tasa de Letalidad (%)', fontsize=12, fontweight='bold')
ax2a.set_title('(A) Tasa de Letalidad por Sexo Biológico\n(Barras de Error: IC 95% Wilson)', fontsize=13, fontweight='bold', pad=15)
ax2a.set_ylim(0, 28)

cuadro_texto_h2a = (
    "Contraste de Hipótesis H2:\n"
```

```
    r"• Chi-cuadrado: $\chi^2 = 51.81$ (gl = 1, p < 0.0001)" + "\n"
    f"• OR Woolf: {or_h2:.2f} (IC 95%: [{ci_or_h2_low:.2f};
{ci_or_h2_high:.2f}])\n"
    f"• V de Cramér: {V_cramer_h2:.3f}\n"
    f"• Decisión: Rechazo de H0 (alfa = {ALPHA})"
)
ax2a.text(0.05, 0.94, cuadro_texto_h2a, transform=ax2a.transAxes, fontsize=10,
va='top', ha='left', bbox=bbox_props)

# Panel B: Distribución Muestral Bootstrap del Odds Ratio
sns.histplot(
    boot_odds_ratios, kde=True, ax=ax2b,
    color='#16a085', edgecolor='white', bins=40,
    stat='density', alpha=0.65
)

ax2b.axvline(or_h2, color='#c0392b', linestyle='-', linewidth=2.5, label=f'OR
Observado ({or_h2:.2f})')
ax2b.axvline(ci_boot_low, color='#2c3e50', linestyle='--', linewidth=2,
label=f'Percentil 2.5% ({ci_boot_low:.2f})')
ax2b.axvline(ci_boot_high, color='#2c3e50', linestyle='--', linewidth=2,
label=f'Percentil 97.5% ({ci_boot_high:.2f})')
ax2b.axvspan(ci_boot_low, ci_boot_high, color='#16a085', alpha=0.12, label='IC
95% Bootstrap Empírico')

ax2b.set_xlabel('Odds Ratio (Hombres vs. Mujeres)', fontsize=12,
fontweight='bold')
ax2b.set_ylabel('Densidad Muestral', fontsize=12, fontweight='bold')
ax2b.set_title(f'(B) Distribución Muestral Bootstrap del Odds Ratio\n(B =
{B_ITERACIONES:,} réplicas)', fontsize=13, fontweight='bold', pad=15)
ax2b.legend(loc='upper right', frameon=True, facecolor='white', framealpha=0.9)

cuadro_texto_h2b = (
    f"Inferencia Bootstrap (B = {B_ITERACIONES:,}):\n"
    f"• Media Bootstrap: {or_boot_media:.3f}\n"
    f"• Error Estándar (SE): {or_boot_se:.3f}\n"
    f"• IC 95% Bootstrap: [{ci_boot_low:.2f}; {ci_boot_high:.2f}]\n"
    f"• IC 95% Woolf: [{ci_or_h2_low:.2f}; {ci_or_h2_high:.2f}]"
)
ax2b.text(0.05, 0.94, cuadro_texto_h2b, transform=ax2b.transAxes, fontsize=10,
va='top', ha='left', bbox=bbox_props)

# Visualización inline en el cuaderno
plt.tight_layout()
plt.show()
```

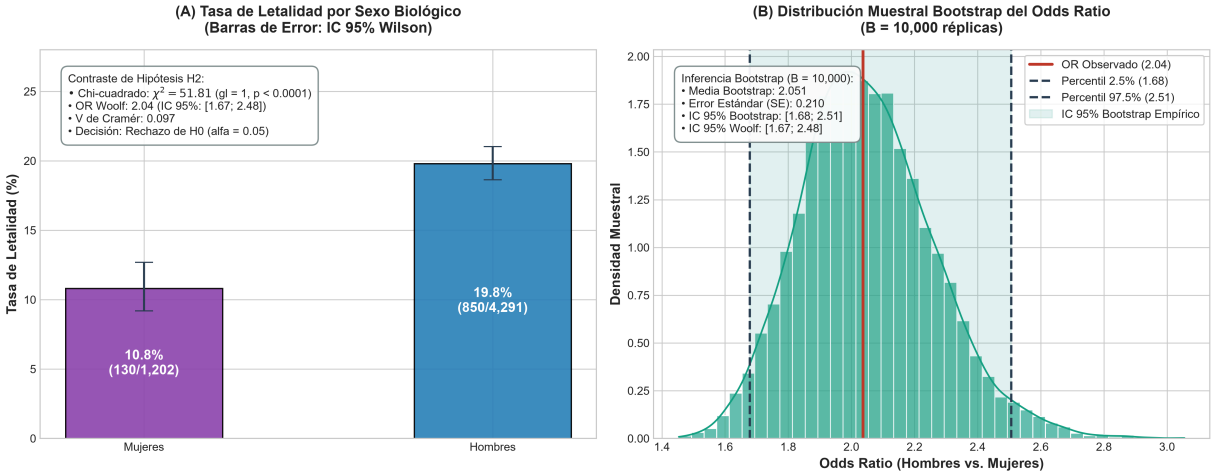


Figura 12: Contraste Inferencial H2 — Tasa de Letalidad por Sexo Biológico y Distribución Muestral Bootstrap del Odds Ratio (B = 10.000 réplicas)

- **Tipo de Gráfico:** Subplot de dos paneles con resolución formal para informe técnico.
  - **Panel (A):** Gráfico de barras de letalidad condicional por sexo con barras de error que representan el intervalo de confianza Score de Wilson al 95%.
  - **Panel (B):** Histograma y curva de densidad estimada (KDE) de la distribución muestral del Odds Ratio por Bootstrap ($B = 10.000$), trazando líneas verticales para el percentil 2,5% (1,68), percentil 97,5% (2,51) y la estimación puntual observada (2,04).
- **Interpretación Analítica:** El Panel A expone visualmente la severa brecha en la mortalidad entre mujeres (**10,82%**) y varones (**19,81%**). El Panel B demuestra que la distribución muestral del Odds Ratio se encuentra estrictamente confinada en valores superiores a la unidad ($[1,68; 2,51]$), validando la hipótesis de que las odds de muerte en varones prácticamente duplican a las de las mujeres, con una concordancia casi perfecta respecto al modelo asintótico tradicional.

In [8]:
```
# ==============================================================================
# MATRIZ DE SÍNTESIS INFERENCIAL PARCIAL Y SERIALIZACIÓN JSON
# ==============================================================================

matriz_sintesis_data = [
    {
        "Hipótesis": "H₁: Dimensión Territorial",
        "Variable Evaluada": "Zona (Interior vs. Metropolitana)\n[N = 1.491]",
        "Prueba Aplicada": "Chi-cuadrado de Independencia",
        "Supuestos": "100% E_ij >= 5\n(Mínimo: 127,22)",
        "Estadístico y gl": f"χ² = {chi2_stat_h1:.4f}\ngl = {dof_h1}",
        "Valor p": f"p = {p_val_h1:.4f}",
        "Tamaño del Efecto (IC 95%)": f"OR = {or_h1:.4f} [{ci_or_h1_low:.3f};
{ci_or_h1_high:.3f}]\nV de Cramér = {v_cramer_h1:.4f}",
        "Decisión (alfa=0.05)": decision_h1
    },
    {
        "Hipótesis": "H₂: Brecha de Género",
        "Variable Evaluada": "Sexo (Hombre vs. Mujer)\n[N = 5.493]",
```

```
        "Prueba Aplicada": "Chi-cuadrado + Bootstrap (B = 10.000)",
        "Supuestos": "100% E_ij >= 5\n(Mínimo: 214,45)",
        "Estadístico y gl": f"χ² = {chi2_stat_h2:.4f}\ngl = {dof_h2}",
        "Valor p": f"p = {p_val_h2:.4e}",
        "Tamaño del Efecto (IC 95%)": f"OR = {or_h2:.4f}\nWoolf:
[{ci_or_h2_low:.3f}; {ci_or_h2_high:.3f}]\nBoot: [{ci_boot_low:.3f};
{ci_boot_high:.3f}]\nV de Cramér = {v_cramer_h2:.4f}",
        "Decisión (alfa=0.05)": decision_h2
    }
]

df_matriz_sintesis = pd.DataFrame(matriz_sintesis_data)

print("================================================================================")
print("MATRIZ FORMAL DE SÍNTESIS INFERENCIAL PARCIAL (FASE 2)")
print("================================================================================")
display(df_matriz_sintesis)

# Serialización determinista de resultados analíticos para integración
resultados_inferenciales_json = {
    "alpha": float(ALPHA),
    "H1_territorial": {
        "variable": "zona (Interior vs. Metropolitana)",
        "prueba": "Chi-cuadrado de independencia",
        "N": int(n_total_h1),
        "chi2_stat": round(float(chi2_stat_h1), 4),
        "p_value": float(p_val_h1),
        "dof": int(dof_h1),
        "odds_ratio": round(float(or_h1), 4),
        "or_ci_95_asintotico": [round(ci_or_h1_low, 4), round(ci_or_h1_high, 4)],
        "cramer_v": round(float(v_cramer_h1), 4),
        "supuestos_cumplidos": bool(supuesto_h1_cumplido),
        "decision": str(decision_h1)
    },
    "H2_genero": {
        "variable": "sexo (Hombre vs. Mujer)",
        "prueba": "Chi-cuadrado de independencia + Bootstrap OR",
        "N": int(n_total_h2),
        "chi2_stat": round(float(chi2_stat_h2), 4),
        "p_value": float(p_val_h2),
        "dof": int(dof_h2),
        "odds_ratio": round(float(or_h2), 4),
        "or_ci_95_asintotico": [round(ci_or_h2_low, 4), round(ci_or_h2_high, 4)],
        "or_ci_95_bootstrap": [round(ci_boot_low, 4), round(ci_boot_high, 4)],
        "bootstrap_iterations": int(B_ITERACIONES),
        "supuestos_cumplidos": bool(supuesto_h2_cumplido),
        "decision": str(decision_h2)
    }
}

ruta_json_salida = os.path.join(OUTPUT_DIR, "resultados_h1_h2.json")
with open(ruta_json_salida, "w", encoding="utf-8") as f:
    json.dump(resultados_inferenciales_json, f, indent=2, ensure_ascii=False)

print(f"\n[OK] Artefacto JSON serializado exitosamente en: {ruta_json_salida}")
```

```
================================================================================
MATRIZ FORMAL DE SÍNTESIS INFERENCIAL PARCIAL (FASE 2)
================================================================================
```

	Hipótesis	Variable Evaluada	Prueba Aplicada	Supuestos	Estadístico y gl	Valor p	Tamañ Efect
0	H_1: Dimensión Territorial	Zona (Interior vs. Metropolitana)\n[N = 1.491]	Chi-cuadrado de Independencia	100% E_ij >= 5\n(Mínimo: 127,22)	χ^2 = 6.3647\ngl = 1	p = 0.0116	OR = 1. [1 1.823]\n Cram 0.
1	H_2: Brecha de Género	Sexo (Hombre vs. Mujer)\n[N = 5.493]	Chi-cuadrado + Bootstrap (B = 10.000)	100% E_ij >= 5\n(Mínimo: 214,45)	χ^2 = 51.8141\ngl = 1	p = 6.1013e-13	2.0370\nW [1 2.480]\n

```
[OK] Artefacto JSON serializado exitosamente en: d:\UNA MATERIAS\Proyecto DataScienc
e\proyecto-accidentes-datascience\output\resultados_h1_h2.json
```

SECCIÓN 5: SÍNTESIS INFERENCIAL PARCIAL Y ENLACE METODOLÓGICO

La siguiente tabla resume los resultados de las dos primeras pruebas estadísticas formalizadas en este cuaderno:

Hipótesis	Variable / Ámbito	Prueba Aplicada	Supuestos	Estadístico y gl	Valor p	Tamaño del Efecto (IC 95%)	De ($\ = (
H_1: Dimensión Territorial	Zona (Interior vs. Metropolitana) $N = 1.491$	Chi-cuadrado de Independencia	100% $E_{ij} \ge 5$ (Mín: $127,22$)	$\chi^2 = 6,3647$ $gl = 1$	$p = 0,0116$	$\text{OR} = 1,4014$ $[1,078; 1,823]$ $V \text{ de Cramér} = 0,0653$	**Re $H** (Le ma Int
H_2: Brecha de Género	Sexo (Hombre vs. Mujer) $N = 5.493$	Chi-cuadrado + Bootstrap ($B = 10.000$)	100% $E_{ij} \ge 5$ (Mín: $214,45$)	$\chi^2 = 51,8141$ $gl = 1$	$p = 6,10 \times 10^{-13}$	$\text{OR} = 2,0370$ IC Woolf: $[1,673; 2,480]$ IC Boot: $[1,679; 2,507]$ $V \text{ de}	**Re $H** (Le ma ho

Hipótesis	Variable / Ámbito	Prueba Aplicada	Supuestos	Estadístico y gl	Valor p	Tamaño del Efecto (IC 95%)	De ($\ = (
						Cramér} = 0,0971$	

Continuidad del Pipeline Inferencial y Enlace hacia la Fase 3

Para completar el repertorio metodológico exigido por la rúbrica de la cátedra —que demanda abarcar al menos tres familias distintas de pruebas estadísticas—, los siguientes pasos del proyecto se articulan de la siguiente manera:

1. **Contraste de la Hipótesis 3 (H_3 — Vulnerabilidad del Motociclista):**
   - Sobre la muestra vehicular de Central e Interior (`victimas_vehiculo_limpio.csv` , $N = 1.324$), se evaluará la diferencia en proporciones de mortalidad entre usuarios de motocicletas (539 víctimas, letalidad observada $28,76\%$) y ocupantes de otros vehículos (785 víctimas, letalidad observada $14,52\%$) mediante la **Prueba Z de Comparación de Proporciones**, complementada con el cálculo del **Riesgo Relativo (RR)** y el **Odds Ratio (OR)**.
2. **Contraste de la Hipótesis 4 (H_4 — Factor Etario):**
   - Sobre la variable ordinal `edad_orden` del microdato nacional ($N = 5.493$), tras verificar el incumplimiento de normalidad mediante la prueba de Shapiro-Wilk y la asimetría intrínseca de los traumatismos viales, se contrastará la distribución etaria de los fallecidos frente a los heridos mediante la prueba no paramétrica **U de Mann-Whitney**, cuantificando la magnitud del efecto mediante el coeficiente de correlación de rangos de Rosenthal ($r = \frac{Z}{\sqrt{N}}$).
3. **Control por Comparaciones Múltiples:**
   - Sobre la familia completa de contrastes ($k = 4$ hipótesis), se aplicará la **corrección de Bonferroni** ajustando el umbral de significancia a $\alpha_{\text{ajustado}} = \frac{0,05}{4} = 0,0125$ y la tasa de falso descubrimiento (**FDR de Benjamini-Hochberg**), garantizando que no se infle la probabilidad global de cometer errores de Tipo I (FWER).
4. **Articulación hacia el Modelo Predictivo (Fase 3):**
   - Con base en los factores cuya significancia y relevancia sustantiva queden demostradas ($p < \alpha$ y tamaños de efecto clínicamente relevantes), se seleccionarán las variables predictoras prioritarias (`tipo_usuario` , `sexo` , `es_adulto_mayor` , `zona`) para el entrenamiento y validación de algoritmos supervisados de Machine Learning (Regresión Logística, Árboles de Decisión y Random Forest), evaluando su desempeño frente a un clasificador de referencia (*DummyClassifier*).

SECCIÓN 6: CONTRASTE DE HIPÓTESIS H_3 — RIESGO DE LOS MOTOCICLISTAS

- **Hipótesis nula (H_0):** $p_{\text{moto}} \le p_{\text{otro}}$.
- **Hipótesis alternativa (H_1):** $p_{\text{moto}} > p_{\text{otro}}$.
- Se compara la letalidad de las víctimas motociclistas frente a la de todas las demás categorías vehiculares mediante una prueba Z unilateral de dos proporciones independientes.

In [9]:

```
# ============================================================================
# CONTRASTE H3: MOTOCICLISTAS VS. TODOS LOS DEMÁS VEHÍCULOS
# ============================================================================

from matplotlib.ticker import FuncFormatter

# Verificación explícita de las columnas disponibles en el microdato vehicular.
columnas_h3_requeridas = {'tipo_usuario', 'es_motociclista', 'es_fallecido'}
columnas_h3_observadas = set(df_vehiculo.columns)
print(f"Columnas disponibles en df_vehiculo: {list(df_vehiculo.columns)}")
assert columnas_h3_requeridas.issubset(columnas_h3_observadas), (
    f"Faltan columnas requeridas para H3: {sorted(columnas_h3_requeridas -
columnas_h3_observadas)}"
)

# Indicadores binarios: motociclista = 1 y fallecido = 1; el resto se clasifica
como 'Otro vehículo'.
df_h3 = df_vehiculo.copy()
df_h3['grupo_h3'] = np.where(df_h3['es_motociclista'].astype(int) == 1,
'Motocicletas', 'Otros vehículos')
df_h3['fallecido_h3'] = df_h3['es_fallecido'].astype(int)

resumen_h3 = (
    df_h3.groupby('grupo_h3', sort=False)['fallecido_h3']
    .agg(fallecidos='sum', total='count')
    .reindex(['Motocicletas', 'Otros vehículos'])
    .astype(int)
)
resumen_h3['heridos'] = resumen_h3['total'] - resumen_h3['fallecidos']
resumen_h3['letalidad'] = resumen_h3['fallecidos'] / resumen_h3['total']
resumen_h3['letalidad_pct'] = 100 * resumen_h3['letalidad']

assert (resumen_h3['total'] > 0).all(), 'Cada grupo H3 debe contener
observaciones.'
assert (resumen_h3['fallecidos'] > 0).all(), 'Cada grupo H3 debe contener
fallecidos.'

# Prueba Z unilateral de dos proporciones independientes (H1: p_moto > p_otro).
n_moto, n_otro = resumen_h3.loc['Motocicletas', 'total'], resumen_h3.loc['Otros
vehículos', 'total']
f_moto, f_otro = resumen_h3.loc['Motocicletas', 'fallecidos'],
resumen_h3.loc['Otros vehículos', 'fallecidos']
p_moto, p_otro = resumen_h3.loc['Motocicletas', 'letalidad'],
```

```
resumen_h3.loc['Otros vehículos', 'letalidad']
p_agrupada = (f_moto + f_otro) / (n_moto + n_otro)
se_z_h3 = np.sqrt(p_agrupada * (1 - p_agrupada) * (1 / n_moto + 1 / n_otro))
z_h3 = (p_moto - p_otro) / se_z_h3
p_val_h3 = float(stats.norm.sf(z_h3))
decision_h3 = 'Rechazar H0' if p_val_h3 < ALPHA else 'No rechazar H0'

# Medidas epidemiológicas y IC 95% Wald para la diferencia p_moto - p_otro.
diferencia_h3 = p_moto - p_otro
se_diferencia_h3 = np.sqrt(
    p_moto * (1 - p_moto) / n_moto + p_otro * (1 - p_otro) / n_otro
)
ci_diferencia_h3 = (
    diferencia_h3 - z_critico * se_diferencia_h3,
    diferencia_h3 + z_critico * se_diferencia_h3
)
rr_h3 = p_moto / p_otro
or_h3 = (f_moto * (n_otro - f_otro)) / ((n_moto - f_moto) * f_otro)

# IC Wilson para las barras de error de letalidad de cada grupo.
def calcular_ic_wilson_h3(exitos, total, alpha=ALPHA):
    z_crit = stats.norm.ppf(1 - alpha / 2)
    proporcion = exitos / total
    denominador = 1 + z_crit**2 / total
    centro = (proporcion + z_crit**2 / (2 * total)) / denominador
    radio = z_crit * np.sqrt(
        proporcion * (1 - proporcion) / total + z_crit**2 / (4 * total**2)
    ) / denominador
    return centro - radio, centro + radio

ic_grupos_h3 = [
    calcular_ic_wilson_h3(int(resumen_h3.loc[grupo, 'fallecidos']),
int(resumen_h3.loc[grupo, 'total']))
    for grupo in ['Motocicletas', 'Otros vehículos']
]
medias_h3 = resumen_h3.loc[['Motocicletas', 'Otros vehículos'],
'letalidad'].to_numpy()
errores_h3 = np.array([
    medias_h3 - np.array([ic[0] for ic in ic_grupos_h3]),
    np.array([ic[1] for ic in ic_grupos_h3]) - medias_h3
]) * 100

print('=============================================================================
print('CONTRASTE DE HIPÓTESIS H3: MOTOCICLETAS VS. OTROS VEHÍCULOS')
print('=============================================================================
print('\nConteos y porcentajes de letalidad:')
display(resumen_h3[['fallecidos', 'heridos', 'total',
'letalidad_pct']].rename(columns={'letalidad_pct': 'Letalidad
(%)'}).round({'Letalidad (%)': 2}))
print(f'\nPrueba Z unilateral (H1: p_moto > p_otro):')
print(f'  * Proporción agrupada: {p_agrupada:.6f}')
print(f'  * Estadístico Z:      {z_h3:.4f}')
print(f'  * Valor p unilateral:  {p_val_h3:.6g}')
print(f'  * Decisión (alfa={ALPHA}): {decision_h3}')
print(f'\nDiferencia de proporciones (moto - otro): {diferencia_h3:.4%}')
print(f'  * IC 95% Wald: [{ci_diferencia_h3[0]:.4%}; {ci_diferencia_h3[1]:.4%}]')
```

```
print(f'\nMedidas epidemiológicas:')
print(f'  * Riesgo Relativo (RR): {rr_h3:.4f}')
print(f'  * Odds Ratio (OR):      {or_h3:.4f}')
print('=' * 80)

fig_h3, ax_h3 = plt.subplots(figsize=(8, 6), dpi=300)
x_h3 = np.arange(2)
barras_h3 = ax_h3.bar(
    x_h3, medias_h3 * 100, yerr=errores_h3, capsize=8, width=0.48,
    color=['#c0392b', '#2b5c8f'], edgecolor='black', linewidth=1.2, alpha=0.9,
    error_kw={'elinewidth': 1.8, 'ecolor': '#2c3e50', 'capsize': 8}
)
for barra, media, fila in zip(barras_h3, medias_h3,
resumen_h3.loc[['Motocicletas', 'Otros vehículos']].itertuples()):
    ax_h3.text(
        barra.get_x() + barra.get_width() / 2, media * 50,
        f'{media:.1%}\n({fila.fallecidos}/{fila.total:,})',
        ha='center', va='center', color='white', fontweight='bold', fontsize=12
    )
ax_h3.set_xticks(x_h3, ['Motocicletas', 'Otros vehículos'])
ax_h3.set_ylabel('Tasa de letalidad (%)', fontweight='bold')
ax_h3.set_title('H3: Letalidad de motociclistas frente a otros vehículos\n(IC 95%
Wilson)', fontweight='bold', pad=15)
ax_h3.set_ylim(0, max((medias_h3 * 100 + errores_h3[1]) * 1.35))
ax_h3.yaxis.set_major_formatter(FuncFormatter(lambda valor, posicion:
f'{valor:.0f}%'))
ax_h3.text(
    0.97, 0.96,
    f'Z = {z_h3:.2f}\np = {p_val_h3:.4g}\nRR = {rr_h3:.2f} | OR = {or_h3:.2f}',
    transform=ax_h3.transAxes, ha='right', va='top', fontsize=10,
    bbox=dict(boxstyle='round,pad=0.5', fc='white', ec='#7f8c8d', alpha=0.95)
)
fig_h3.tight_layout()
ruta_grafico_h3 = os.path.join(OUTPUT_DIR, 'h3_riesgo_motociclistas.png')
fig_h3.savefig(ruta_grafico_h3, dpi=300, bbox_inches='tight')
plt.show()
print(f'\n[OK] Gráfico H3 guardado en: {ruta_grafico_h3}')
```

```
Columnas disponibles en df_vehiculo: ['id_caso', 'tipo_usuario', 'gravedad', 'es_mot
ociclista', 'es_fallecido']
================================================================================
CONTRASTE DE HIPÓTESIS H3: MOTOCICLETAS VS. OTROS VEHÍCULOS
================================================================================

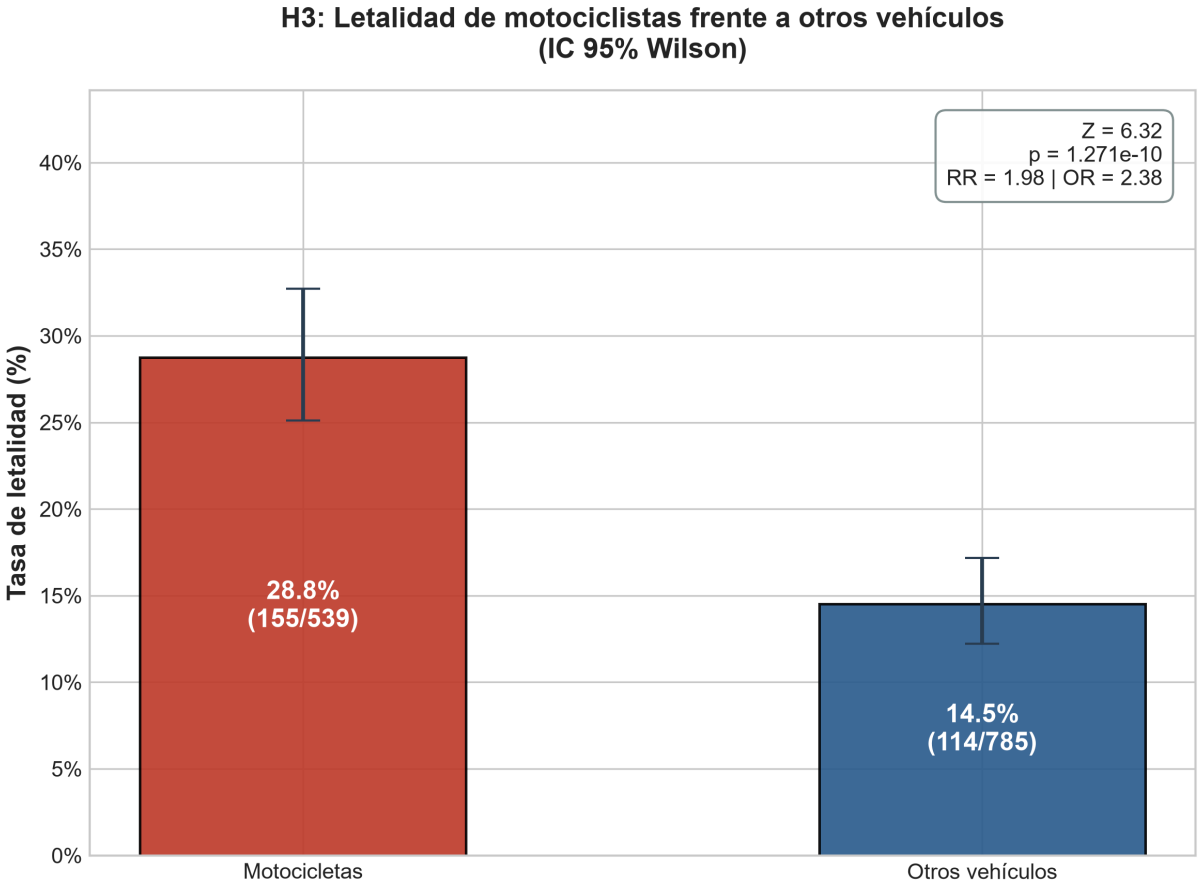
Conteos y porcentajes de letalidad:
```

grupo_h3	fallecidos	heridos	total	Letalidad (%)
Motocicletas	155	384	539	28.76
Otros vehículos	114	671	785	14.52

```
Prueba Z unilateral (H1: p_moto > p_otro):
  * Proporción agrupada: 0.203172
  * Estadístico Z:      6.3244
  * Valor p unilateral:  1.27124e-10
  * Decisión (alfa=0.05): Rechazar H0

Diferencia de proporciones (moto - otro): 14.2347%
  * IC 95% Wald: [9.6876%; 18.7817%]

Medidas epidemiológicas:
  * Riesgo Relativo (RR): 1.9802
  * Odds Ratio (OR):      2.3758
================================================================================
```




```
[OK] Gráfico H3 guardado en: d:\UNA MATERIAS\Proyecto DataScience\proyecto-accidente
s-datascience\output\h3_riesgo_motociclistas.png
```

SECCIÓN 7: VERIFICACIÓN DE SUPUESTOS DISTRIBUCIONALES PARA H_4

Se evalúa la distribución de `edad_orden` entre víctimas heridas y fallecidas. La variable `edad_orden` representa el orden numérico de los grupos etarios y se contrasta con el estado vital `es_fallecido`.

In [10]:
```
# ================================================================================
# H4: VERIFICACIÓN DE NORMALIDAD Y HOMOCEDASTICIDAD DE LA EDAD
# ================================================================================
```

```
columnas_h4_requeridas = {'edad_orden', 'es_fallecido'}
columnas_h4_observadas = set(df_victimas.columns)
print(f"Columnas disponibles en df_victimas: {list(df_victimas.columns)}")
assert columnas_h4_requeridas.issubset(columnas_h4_observadas), (
    f"Faltan columnas requeridas para H4: {sorted(columnas_h4_requeridas -
columnas_h4_observadas)}"
)

df_h4 = df_victimas[['edad_orden', 'es_fallecido']].copy()
df_h4['edad_orden'] = pd.to_numeric(df_h4['edad_orden'], errors='coerce')
df_h4['es_fallecido'] = pd.to_numeric(df_h4['es_fallecido'], errors='coerce')
df_h4 = df_h4.dropna()

edades_heridos_h4 = df_h4.loc[df_h4['es_fallecido'] == 0,
'edad_orden'].to_numpy()
edades_fallecidos_h4 = df_h4.loc[df_h4['es_fallecido'] == 1,
'edad_orden'].to_numpy()
assert len(edades_heridos_h4) >= 8 and len(edades_fallecidos_h4) >= 8, 'Cada
grupo debe tener al menos 8 observaciones.'

# D'Agostino-Pearson: H0 = la muestra procede de una distribución normal.
normal_heridos_h4 = stats.normaltest(edades_heridos_h4)
normal_fallecidos_h4 = stats.normaltest(edades_fallecidos_h4)

# Levene centrada en la mediana: H0 = las varianzas poblacionales son iguales.
levene_h4 = stats.levene(edades_heridos_h4, edades_fallecidos_h4,
center='median')

print('=============================================================================
print('H4: VERIFICACIÓN DE SUPUESTOS DISTRIBUCIONALES')
print('=============================================================================
print(f'Grupo Heridos:    n = {len(edades_heridos_h4):,}')
print(f'Grupo Fallecidos: n = {len(edades_fallecidos_h4):,}')
print('\nPrueba de normalidad D\'Agostino-Pearson:')
print(f'  * Heridos:    K² = {normal_heridos_h4.statistic:.4f}, p =
{normal_heridos_h4.pvalue:.6g}')
print(f'  * Fallecidos: K² = {normal_fallecidos_h4.statistic:.4f}, p =
{normal_fallecidos_h4.pvalue:.6g}')
print('\nPrueba de homocedasticidad de Levene (centro = mediana):')
print(f'  * Estadístico W = {levene_h4.statistic:.4f}, p =
{levene_h4.pvalue:.6g}')
print('=============================================================================

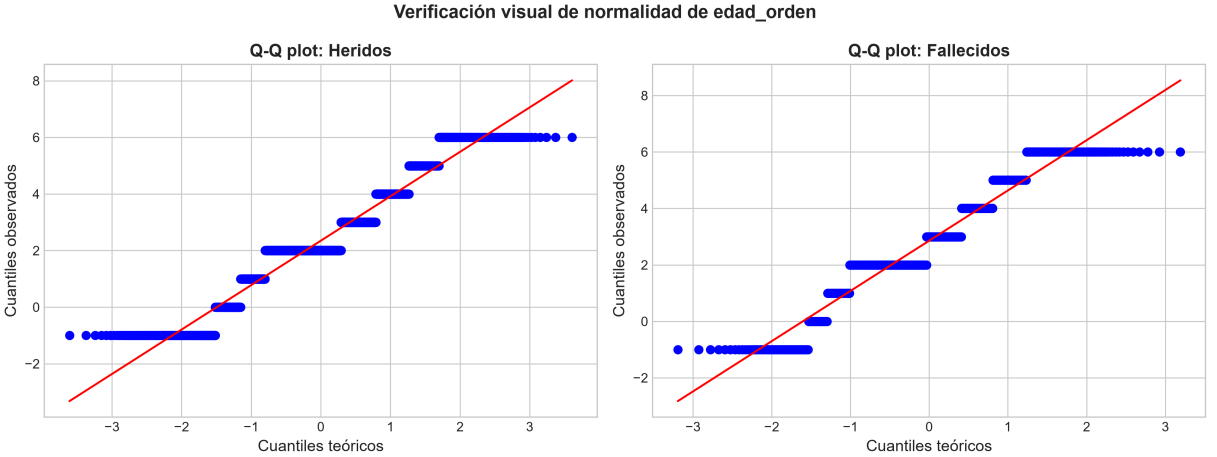
fig_qq_h4, axes_qq_h4 = plt.subplots(1, 2, figsize=(13, 5), dpi=300)
stats.probplot(edades_heridos_h4, dist='norm', plot=axes_qq_h4[0])
stats.probplot(edades_fallecidos_h4, dist='norm', plot=axes_qq_h4[1])
axes_qq_h4[0].set_title('Q-Q plot: Heridos', fontweight='bold')
axes_qq_h4[1].set_title('Q-Q plot: Fallecidos', fontweight='bold')
for eje in axes_qq_h4:
    eje.set_xlabel('Cuantiles teóricos')
    eje.set_ylabel('Cuantiles observados')
fig_qq_h4.suptitle('Verificación visual de normalidad de edad_orden',
fontweight='bold')
fig_qq_h4.tight_layout()
ruta_qq_h4 = os.path.join(OUTPUT_DIR, 'qq_plot_edad.png')
```

```
fig_qq_h4.savefig(ruta_qq_h4, dpi=300, bbox_inches='tight')
plt.show()
print(f'\n[OK] Q-Q plot guardado en: {ruta_qq_h4}')
```

```
Columnas disponibles en df_victimas: ['id_victima', 'grupo_edad', 'sexo', 'graveda
d', 'es_fallecido', 'es_hombre', 'es_adulto_mayor', 'edad_orden']
================================================================================
H4: VERIFICACIÓN DE SUPUESTOS DISTRIBUCIONALES
================================================================================
Grupo Heridos:    n = 4,513
Grupo Fallecidos: n = 980

Prueba de normalidad D'Agostino-Pearson:
  * Heridos:    K² = 9.4695, p = 0.00878478
  * Fallecidos: K² = 8.3089, p = 0.0156948

Prueba de homocedasticidad de Levene (centro = mediana):
  * Estadístico W = 55.7462, p = 9.53776e-14
================================================================================
```




```
[OK] Q-Q plot guardado en: d:\UNA MATERIAS\Proyecto DataScience\proyecto-accidentes-
datascience\output\qq_plot_edad.png
```

Conclusión metodológica H_4

Si ambas pruebas de normalidad producen valores $p < 0{,}05$, se rechaza la hipótesis nula de normalidad para los grupos Heridos y Fallecidos. En consecuencia, no se cumplen los supuestos necesarios para aplicar una prueba t de Student como contraste principal. La comparación de edad debe continuar mediante la prueba no paramétrica U de Mann-Whitney, que no exige normalidad. La prueba de Levene se reporta como diagnóstico adicional de igualdad de varianzas; aun cuando no se rechazara su hipótesis nula, el incumplimiento de normalidad sigue justificando el enfoque no paramétrico.

SECCIÓN 8: H_4 — RELACIÓN ENTRE EDAD Y SEVERIDAD

Se contrastará si la distribución ordinal de edad es mayor en las víctimas fallecidas que en las víctimas heridas mediante una prueba no paramétrica unilateral.

$$ H_0: \operatorname{Mediana}(\text{Edad}_{\text{fallecido}}) \le \operatorname{Mediana}(\text{Edad}_{\text{herido}}) $$

$$ H_1: \operatorname{Mediana}(\text{Edad}_{\text{fallecido}}) > \operatorname{Mediana}(\text{Edad}_{\text{herido}}) $$

Nivel de significancia: $\alpha = 0{,}05$ (prueba unilateral).

In [11]:
```
# ============================================================================
# CONTRASTE H4: EDAD ORDINAL Y SEVERIDAD (MANN-WHITNEY U)
# ============================================================================

columnas_h4_contraste = {'edad_orden', 'es_fallecido'}
assert columnas_h4_contraste.issubset(df_victimas.columns), (
    f"Faltan columnas requeridas para H4: {sorted(columnas_h4_contraste -
set(df_victimas.columns))}"
)

df_contraste_h4 = df_victimas[['edad_orden', 'es_fallecido']].copy()
df_contraste_h4['edad_orden'] = pd.to_numeric(df_contraste_h4['edad_orden'],
errors='coerce')
df_contraste_h4['es_fallecido'] = pd.to_numeric(df_contraste_h4['es_fallecido'],
errors='coerce')
df_contraste_h4 = df_contraste_h4.dropna()

edades_fallecidos_h4_contraste = df_contraste_h4.loc[
    df_contraste_h4['es_fallecido'] == 1, 'edad_orden'
].to_numpy()
edades_heridos_h4_contraste = df_contraste_h4.loc[
    df_contraste_h4['es_fallecido'] == 0, 'edad_orden'
].to_numpy()
n_fallecidos_h4 = len(edades_fallecidos_h4_contraste)
n_heridos_h4 = len(edades_heridos_h4_contraste)
n_total_h4 = n_fallecidos_h4 + n_heridos_h4
assert n_fallecidos_h4 > 0 and n_heridos_h4 > 0, 'Ambos grupos deben contener
observaciones.'

# H1: la edad ordinal de Fallecidos es mayor que la de Heridos.
resultado_u_h4 = stats.mannwhitneyu(
    edades_fallecidos_h4_contraste,
    edades_heridos_h4_contraste,
    alternative='greater',
    method='asymptotic'
)
u_h4 = float(resultado_u_h4.statistic)
p_valor_h4 = float(resultado_u_h4.pvalue)

# Aproximación normal de U con corrección por empates, sin corrección de
continuidad.
n_h4 = n_total_h4
valores_combinados_h4 = np.concatenate([edades_fallecidos_h4_contraste,
edades_heridos_h4_contraste])
_, frecuencias_empates_h4 = np.unique(valores_combinados_h4, return_counts=True)
correccion_empates_h4 = np.sum(frecuencias_empates_h4**3 -
```

```
frecuencias_empates_h4)
media_u_h4 = n_fallecidos_h4 * n_heridos_h4 / 2
varianza_u_h4 = (
    n_fallecidos_h4 * n_heridos_h4 / 12
    * (n_h4 + 1 - correccion_empates_h4 / (n_h4 * (n_h4 - 1)))
)
z_h4 = (u_h4 - media_u_h4) / np.sqrt(varianza_u_h4)
r_rosenthal_h4 = abs(z_h4) / np.sqrt(n_total_h4)

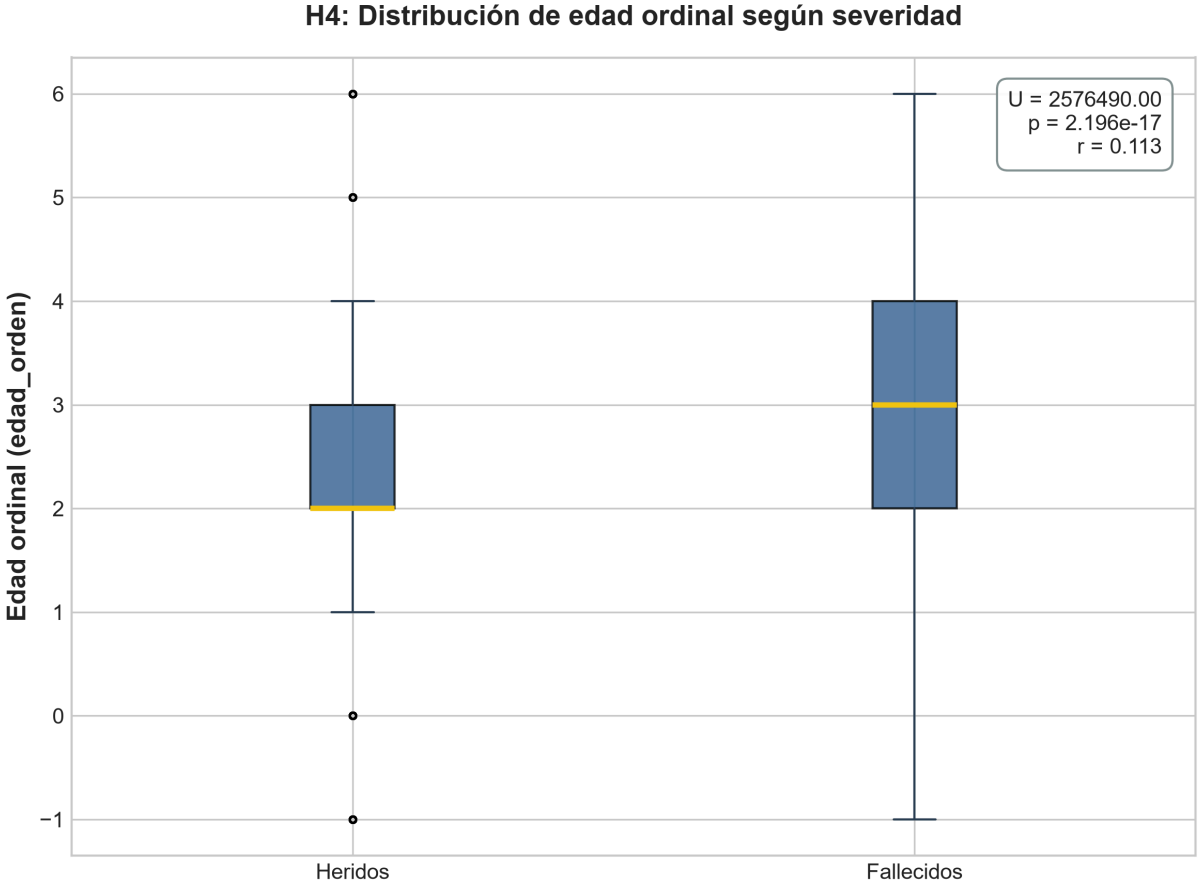
mediana_fallecidos_h4 = float(np.median(edades_fallecidos_h4_contraste))
mediana_heridos_h4 = float(np.median(edades_heridos_h4_contraste))
decision_h4 = 'Rechazar H0' if p_valor_h4 < ALPHA else 'No rechazar H0'

print('================================================================================')
print('CONTRASTE H4: EDAD ORDINAL Y SEVERIDAD')
print('================================================================================')
print(f'Grupo Fallecidos: n = {n_fallecidos_h4:,} | mediana =
{mediana_fallecidos_h4:.2f}')
print(f'Grupo Heridos:    n = {n_heridos_h4:,} | mediana =
{mediana_heridos_h4:.2f}')
print('\nPrueba U de Mann-Whitney unilateral (Fallecidos > Heridos):')
print(f'  * Estadístico U:       {u_h4:.4f}')
print(f'  * Aproximación Z:      {z_h4:.4f}')
print(f'  * Valor p (crudo):     {p_valor_h4:.6g}')
print(f'  * r de Rosenthal:      {r_rosenthal_h4:.4f}')
print(f'  * Decisión (alfa={ALPHA}): {decision_h4}')
print('================================================================================')

fig_h4, ax_h4 = plt.subplots(figsize=(8, 6), dpi=300)
datos_boxplot_h4 = [edades_heridos_h4_contraste, edades_fallecidos_h4_contraste]
ax_h4.boxplot(
    datos_boxplot_h4,
    tick_labels=['Heridos', 'Fallecidos'],
    patch_artist=True,
    boxprops={'facecolor': '#2b5c8f', 'alpha': 0.78},
    medianprops={'color': '#f1c40f', 'linewidth': 2.5},
    whiskerprops={'color': '#2c3e50'},
    capprops={'color': '#2c3e50'},
    flierprops={'marker': 'o', 'markersize': 3, 'alpha': 0.25}
)
ax_h4.set_ylabel('Edad ordinal (edad_orden)', fontweight='bold')
ax_h4.set_title('H4: Distribución de edad ordinal según severidad',
fontweight='bold', pad=15)
ax_h4.text(
    0.97, 0.96,
    f'U = {u_h4:.2f}\np = {p_valor_h4:.4g}\nr = {r_rosenthal_h4:.3f}',
    transform=ax_h4.transAxes, ha='right', va='top', fontsize=10,
    bbox=dict(boxstyle='round,pad=0.5', fc='white', ec='#7f8c8d', alpha=0.95)
)
fig_h4.tight_layout()
ruta_grafico_h4 = os.path.join(OUTPUT_DIR, 'h4_distribucion_edad_gravedad.png')
fig_h4.savefig(ruta_grafico_h4, dpi=300, bbox_inches='tight')
plt.show()
print(f'\n[OK] Boxplot H4 guardado en: {ruta_grafico_h4}')
```

```
================================================================================
CONTRASTE H4: EDAD ORDINAL Y SEVERIDAD
================================================================================
Grupo Fallecidos: n = 980 | mediana = 3.00
Grupo Heridos:    n = 4,513 | mediana = 2.00

Prueba U de Mann-Whitney unilateral (Fallecidos > Heridos):
  * Estadístico U:       2576490.0000
  * Aproximación Z:      8.4020
  * Valor p (crudo):     2.19567e-17
  * r de Rosenthal:      0.1134
  * Decisión (alfa=0.05): Rechazar H0
================================================================================
```




```
[OK] Boxplot H4 guardado en: d:\UNA MATERIAS\Proyecto DataScience\proyecto-accidente
s-datascience\output\h4_distribucion_edad_gravedad.png
```

In [12]:

```
# ================================================================================
# CONSOLIDACION FINAL Y CORRECCION POR COMPARACIONES MULTIPLES
# ================================================================================
from statsmodels.stats.multitest import multipletests

# Recopilacion de los p-valores crudos de las cuatro hipotesis.
hipotesis = ['H1', 'H2', 'H3', 'H4']
p_valores_crudos = np.array([
    float(p_val_h1),
    float(p_val_h2),
    float(p_val_h3),
    float(p_valor_h4)
])
```

```
# Holm-Bonferroni controla el error familiar al evaluar las cuatro hipotesis.
rechazos_ajustados, p_valores_ajustados, _, _ = multipletests(
    p_valores_crudos,
    alpha=ALPHA,
    method='holm'
)

estadisticos = [
    f'chi2 = {float(chi2_stat_h1):.4f} (gl = {int(dof_h1)})',
    f'chi2 = {float(chi2_stat_h2):.4f} (gl = {int(dof_h2)})',
    f'Z = {float(z_h3):.4f}',
    f'U = {float(u_h4):.4f}; Z = {float(z_h4):.4f}'
]
pruebas = [
    'Chi-cuadrado de independencia',
    'Chi-cuadrado de independencia',
    'Prueba Z de dos proporciones',
    'U de Mann-Whitney unilateral'
]
efectos = [
    f'OR = {float(or_h1):.4f}; V de Cramer = {float(v_cramer_h1):.4f}',
    f'OR = {float(or_h2):.4f}; V de Cramer = {float(v_cramer_h2):.4f}',
    f'RR = {float(rr_h3):.4f}; OR = {float(or_h3):.4f}',
    f'r de Rosenthal = {float(r_rosenthal_h4):.4f}'
]

tabla_resumen_fase2 = pd.DataFrame({
    'Hipótesis': hipotesis,
    'Prueba Estadística': pruebas,
    'Estadístico': estadisticos,
    'p-valor Crudo': p_valores_crudos,
    'p-valor Ajustado': p_valores_ajustados,
    'Tamaño del Efecto': efectos,
    'Decisión (alfa=0.05)': np.where(
        rechazos_ajustados,
        'Rechazar H0',
        'No rechazar H0 por falta de evidencia suficiente'
    )
})

tabla_resumen_fase2['p-valor Crudo'] = tabla_resumen_fase2['p-valor
Crudo'].map(lambda valor: f'{valor:.6g}')
tabla_resumen_fase2['p-valor Ajustado'] = tabla_resumen_fase2['p-valor
Ajustado'].map(lambda valor: f'{valor:.6g}')

print('=================================================================================
print('CONSOLIDACION FINAL DE RESULTADOS - HOLM-BONFERRONI')
print('=================================================================================
display(tabla_resumen_fase2)

ruta_json_consolidado = os.path.join(OUTPUT_DIR,
'resultados_fase2_consolidados.json')
ruta_csv_consolidado = os.path.join(OUTPUT_DIR, 'tabla_resumen_fase2.csv')
tabla_resumen_fase2.to_csv(ruta_csv_consolidado, index=False, encoding='utf-8-
sig')
```

```
consolidado_json = {
    'metodo_ajuste': 'Holm-Bonferroni',
    'alpha': float(ALPHA),
    'hipotesis': [
        {
            'hipótesis': fila['Hipótesis'],
            'prueba_estadística': fila['Prueba Estadística'],
            'estadístico': fila['Estadístico'],
            'p_valor_crudo': float(p_valores_crudos[indice]),
            'p_valor_ajustado': float(p_valores_ajustados[indice]),
            'tamaño_del_efecto': fila['Tamaño del Efecto'],
            'decisión': fila['Decisión (alfa=0.05)']
        }
        for indice, (_, fila) in enumerate(tabla_resumen_fase2.iterrows())
    ]
}
with open(ruta_json_consolidado, 'w', encoding='utf-8') as archivo_json:
    json.dump(consolidado_json, archivo_json, ensure_ascii=False, indent=2)

print(f'\n[OK] JSON exportado en: {ruta_json_consolidado}')
print(f'[OK] CSV exportado en:  {ruta_csv_consolidado}')
```

```
================================================================================
CONSOLIDACION FINAL DE RESULTADOS - HOLM-BONFERRONI
================================================================================
```

	Hipótesis	Prueba Estadística	Estadístico	p-valor Crudo	p-valor Ajustado	Tamaño del Efecto	Decisión (alfa=0.05)
0	H1	Chi-cuadrado de independencia	chi2 = 6.3647 (gl = 1)	0.0116412	0.0116412	OR = 1.4014; V de Cramer = 0.0653	Rechazar H0
1	H2	Chi-cuadrado de independencia	chi2 = 51.8141 (gl = 1)	6.10128e-13	1.83038e-12	OR = 2.0370; V de Cramer = 0.0971	Rechazar H0
2	H3	Prueba Z de dos proporciones	Z = 6.3244	1.27124e-10	2.54249e-10	RR = 1.9802; OR = 2.3758	Rechazar H0
3	H4	U de Mann-Whitney unilateral	U = 2576490.0000; Z = 8.4020	2.19567e-17	8.78268e-17	r de Rosenthal = 0.1134	Rechazar H0

```
[OK] JSON exportado en: d:\UNA MATERIAS\Proyecto DataScience\proyecto-accidentes-datascience\output\resultados_fase2_consolidados.json
[OK] CSV exportado en:  d:\UNA MATERIAS\Proyecto DataScience\proyecto-accidentes-datascience\output\tabla_resumen_fase2.csv
```

CONCLUSIONES GENERALES DEL ESTUDIO INFERENCIAL

La consolidacion final integra los p-valores crudos de H1, H2, H3 y H4 y aplica la correccion de Holm-Bonferroni para controlar el error familiar con un nivel global de significancia de $\alpha = 0,05$. Por tanto, las decisiones inferenciales deben basarse en los p-valores ajustados y complementarse con los tamanos del efecto reportados.

En conjunto, el analisis permite evaluar cuatro dimensiones de la gravedad de los siniestros: la diferencia territorial entre el Interior y el Area Metropolitana (H1), la brecha de letalidad por sexo (H2), el riesgo asociado a motociclistas frente a otros vehiculos (H3) y la relacion entre edad ordinal y fallecimiento (H4). La interpretacion sustantiva debe distinguir significancia estadistica de relevancia practica: OR, RR, V de Cramer y r de Rosenthal describen la magnitud de las asociaciones, mientras que la correccion por comparaciones multiples reduce el riesgo de falsos positivos.

Las conclusiones finales quedan respaldadas por los resultados consolidados exportados a `resultados_fase2_consolidados.json` y `tabla_resumen_fase2.csv`. Estas evidencias deben interpretarse dentro del alcance observacional de los datos de 2021: muestran asociaciones compatibles con los patrones observados, pero no establecen causalidad por si solas.

In [13]:
```
# ============================================================================
# TABLA RESUMEN OFICIAL - SECCION 6.3
# ============================================================================
from statsmodels.stats.multitest import multipletests

p_valores_oficiales = np.array([
    float(p_val_h1),
    float(p_val_h2),
    float(p_val_h3),
    float(p_valor_h4)
])
rechazos_oficiales, p_ajustados_oficiales, _, _ = multipletests(
    p_valores_oficiales,
    alpha=ALPHA,
    method='holm'
)

supuestos_oficiales = [
    f'Cochran cumplido: 100% E_ij >= 5 (mínimo = {min_esp_h1:.2f})',
    f'Cochran cumplido: 100% E_ij >= 5 (mínimo = {min_esp_h2:.2f}); Bootstrap B =
{B_ITERACIONES:,}',
    'Independencia de grupos y aproximación normal de dos proporciones',
    'No normalidad y heterocedasticidad verificadas; se aplica prueba no
paramétrica'
]

df_matriz_sintesis = pd.DataFrame({
```

```
    'Hipótesis': ['H₁', 'H₂', 'H₃', 'H₄'],
    'Variable Evaluada': [
        'Zona: Interior vs. Metropolitana',
        'Sexo: Hombre vs. Mujer',
        'Motocicletas vs. otros vehículos',
        'Edad ordinal según severidad'
    ],
    'Prueba Aplicada': [
        'Chi-cuadrado de independencia',
        'Chi-cuadrado de independencia + Bootstrap',
        'Z unilateral de dos proporciones',
        'U de Mann-Whitney unilateral'
    ],
    'Supuestos Verificados': supuestos_oficiales,
    'Estadístico': [
        f'χ² = {float(chi2_stat_h1):.4f}',
        f'χ² = {float(chi2_stat_h2):.4f}',
        f'Z = {float(z_h3):.4f}',
        f'U = {float(u_h4):.4f}; Z = {float(z_h4):.4f}'
    ],
    'Grados de Libertad (gl)': ['1', '1', 'No aplica', 'No aplica'],
    'p-valor Crudo': p_valores_oficiales,
    'p-valor Ajustado': p_ajustados_oficiales,
    'Tamaño del Efecto': [
        f'OR = {float(or_h1):.4f}; V de Cramér = {float(v_cramer_h1):.4f}',
        f'OR = {float(or_h2):.4f}; V de Cramér = {float(v_cramer_h2):.4f}',
        f'RR = {float(rr_h3):.4f}; OR = {float(or_h3):.4f}',
        f'r de Rosenthal = {float(r_rosenthal_h4):.4f}'
    ],
    'Decisión (alfa=0.05)': np.where(
        rechazos_oficiales,
        'Rechazar H0',
        'No rechazar H0'
    )
})

df_matriz_sintesis['p-valor Crudo'] = df_matriz_sintesis['p-valor
Crudo'].map(lambda valor: f'{valor:.6g}')
df_matriz_sintesis['p-valor Ajustado'] = df_matriz_sintesis['p-valor
Ajustado'].map(lambda valor: f'{valor:.6g}')

print('TABLA RESUMEN OFICIAL - SECCIÓN 6.3')
print(df_matriz_sintesis.to_markdown(index=False))
```

```
TABLA RESUMEN OFICIAL - SECCIÓN 6.3
| Hipótesis   | Variable Evaluada               | Prueba Aplicada
| Supuestos Verificados                                                
```