UNIVERSIDAD NACIONAL DE ASUNCIÓN

Facultad Politécnica · Ingeniería Informática

Factores asociados a la gravedad de las víctimas en los accidentes de tránsito en Paraguay (2021)

Fase 3 · Análisis predictivo

Asignatura: Ciencia de Datos (Electiva) · Curso TQ

Integrantes: Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos: no proporcionados para esta revisión. Deben incorporarse antes de presentar.

Fecha de la versión: 16 de octubre de 2026

Resultados reproducidos. Integración de hipótesis para revisión final del grupo.

Índice

1. Introducción, datos y correcciones 3
2. Preparación y diseño experimental 4
3. Modelos e hiperparámetros 5
4. Validación y comparación de resultados 6
5. Discriminación y brecha de rendimiento 7
6. Análisis de errores por perfil 8
7. Interpretabilidad y continuidad inferencial 9
8. Sensibilidad y calibración 10
9. H1: gravedad registrada por zona 11
10. H3: siniestros con motociclistas 12
11. Integración de las cuatro hipótesis y edad desconocida 13
12. Discusión y conclusiones académicas 14
13. Reproducibilidad, referencias y uso de IA 15

1. Introducción, datos y correcciones

Objetivo: comparar modelos supervisados de desenlace fatal con una línea base en los conteos de Paraguay de 2021, dando continuidad a CRISP-DM.

Se seleccionó Árbol de Decisión por F1 macro de validación cruzada 0.5416. En la reserva interna obtuvo F1 macro 0.5299, frente a 0.4510 del Dummy (diferencia +0.0788); recall de fallecidos 0.4541, precisión 0.2324 y AUC 0.5809. La mejora es descriptiva del protocolo, sin prueba de superioridad poblacional ni validación externa.

Las 5.493 filas reconstruyen frecuencias de sexo, grupo de edad y desenlace, no son microdatos originales. Solo existen 16 perfiles predictivos. La partición aleatoria distribuye frecuencias de esos mismos perfiles en train y test. No acredita capacidad para anticipar desenlaces de personas o siniestros nuevos. La reserva ya fue inspeccionada en versiones anteriores; no se presenta como holdout virgen. Ninguna unión artificial vincula demografía, zona y vehículo.

No hubo devolución docente de Fase 2, confirmado por el grupo. Aclaraciones propias de esta revisión: H1 conserva el contraste Interior/Metropolitana y explicita su cobertura y efecto pequeño; H3 audita las fuentes sin acreditar categorías individuales por vehículo; H4 separa 353 edades ignoradas y advierte que el contraste ordinal anterior conservó -1. Se mantiene la reserva históricamente inspeccionada y el alcance retrospectivo del modelo. Los notebooks de Fases 1 y 2 se preservan.

La tabla 12.2.1 procede de la Policía Nacional; 12.2.5 y 12.2.10 citan a Patrulla Caminera; 12.2.6 también cita a Policía Nacional. Comparten año, pero no necesariamente universo o unidad de registro.

2. Preparación y diseño experimental

Se utilizan únicamente sexo y grupo_edad. Se excluyen id_victima y gravedad por ser identificador y objetivo directo; es_hombre, es_adulto_mayor y edad_orden duplican las variables disponibles. Las 353 víctimas de edad ignorada permanecen separadas; -1 significa desconocido y el indicador de adulto mayor en 0 no acredita edad menor de 60. OneHotEncoder(drop=first, handle_unknown=ignore) se ajusta dentro de los pipelines de los tres modelos originales. No se requiere escalado de indicadores binarios o árboles. No se silencian advertencias globalmente.

Se conservó la partición 80/20 estratificada por desenlace, con semilla 42: 4.394 filas de entrenamiento y 1.099 de prueba (196 fallecidos). En entrenamiento se fijaron cinco pliegues estratificados idénticos para todos. GridSearchCV optimiza F1 macro; se cierra la selección antes de calcular las métricas de test en esta ejecución. No se cambian umbrales ni hiperparámetros a partir de la reserva. Las medias CV de la mejor grilla tienen sesgo de selección; no equivalen a una evaluación anidada. No existen fechas individuales que permitan una partición cronológica válida.

La prevalencia es 980/5.493 = 17,84 %. Los tres modelos originales usan class_weight=balanced; Naive Bayes usa prior 0,5/0,5 para dar igual prioridad a las clases, conservando conteos condicionales naturales. El umbral permanece en la regla predict del estimador. Los puntajes no se presentan como probabilidades absolutas calibradas. No se utiliza SMOTE.

Calidad: reconstrucción desde 12.2.1 idéntica al CSV histórico, incluidos orden e identificador; comprobación de 4.513 heridos, 980 fallecidos, dos sexos, ocho edades y 16 perfiles. Se verifica consistencia entre gravedad y es_fallecido y ausencia de nulos en predictores/objetivo. Solo se conserva el orden para reproducir la partición, sin usarlo como predictor.

3. Modelos e hiperparámetros

Logística: modelo discriminativo con efectos aditivos en log-odds, regularización L2. Árbol: reglas con interacciones y control de complejidad por profundidad y hojas mínimas. Random Forest: ensamble de árboles para reducir varianza; pertenece a la familia de árboles. Naive Bayes categórico: modelo generativo que supone independencia de sexo y edad dado el desenlace. OrdinalEncoder asigna índices nominales; sumar uno reserva el cero para categorías desconocidas. No hay interpretación ordinal de esos números. Suavizado alpha evita frecuencias condicionales nulas; min_categories=[3,9] reserva el dominio conocido más desconocido.

Tabla F3-1. Configuraciones seleccionadas.

Modelo	Hiperparámetros elegidos por CV
Naive Bayes	{'alpha': 0.1}
Bosque	{'max_depth': 3, 'min_samples_leaf': 25, 'n_estimators': 100}
Logística	{'C': 5.0, 'solver': 'lbfgs'}
Árbol	{'max_depth': 6, 'min_samples_leaf': 50}

Grillas: logística C={0,01; 0,1; 1; 5; 10}, lbfgs, max_iter=1000; árbol profundidad={2;3;4;5;6}, hoja mínima={10;25;50}; bosque n_estimators={50;100;150}, profundidad={3;4;5}, hoja={10;25}; NB alpha={0,1;1;10}. Semilla 42 y n_jobs=1. Se conservó el experimento previo, sin ampliar grillas para perseguir test.

4. Validación y comparación de resultados

Tabla F3-2. F1 macro en los cinco pliegues de entrenamiento.

Modelo	Train CV	Validación CV	Desvío CV
Dummy	0.4510	0.4510	0.0001
Logística	0.5330	0.5278	0.0169
Árbol	0.5444	0.5416	0.0106
Bosque	0.5235	0.5234	0.0133
Naive Bayes	0.5374	0.5347	0.0137

Tabla F3-3. Evaluación en la misma reserva interna (n=1.099).

Modelo	Accuracy	Prec. 1	Recall 1	F1 clase 1	F1 macro	AUC
Dummy	0.8217	0.0000	0.0000	0.0000	0.4510	0.5000
Logística	0.6069	0.2306	0.5153	0.3186	0.5212	0.5869
Árbol	0.6351	0.2324	0.4541	0.3074	0.5299	0.5809
Bosque	0.5723	0.2134	0.5204	0.3027	0.4971	0.5816
Naive Bayes	0.6069	0.2306	0.5153	0.3186	0.5212	0.5989

Se seleccionó Árbol de Decisión por F1 macro de validación cruzada 0.5416. En la reserva interna obtuvo F1 macro 0.5299, frente a 0.4510 del Dummy (diferencia +0.0788); recall de fallecidos 0.4541, precisión 0.2324 y AUC 0.5809. La mejora es descriptiva del protocolo, sin prueba de superioridad poblacional ni validación externa.

Accuracy mide aciertos totales; precisión de clase 1 mide la fracción de fatalidades entre predicciones positivas; recall mide la fracción de fatalidades detectadas; F1 combina precisión y recall. F1 macro promedia los F1 de ambas clases. AUC mide ordenamiento de puntuaciones, no calibración. Specificity y balanced accuracy complementan el desbalance. Brier evalúa error cuadrático de la puntuación; Average Precision resume la curva PR. Las tablas completas quedan embebidas en el notebook ejecutado.

5. Discriminación y brecha de rendimiento

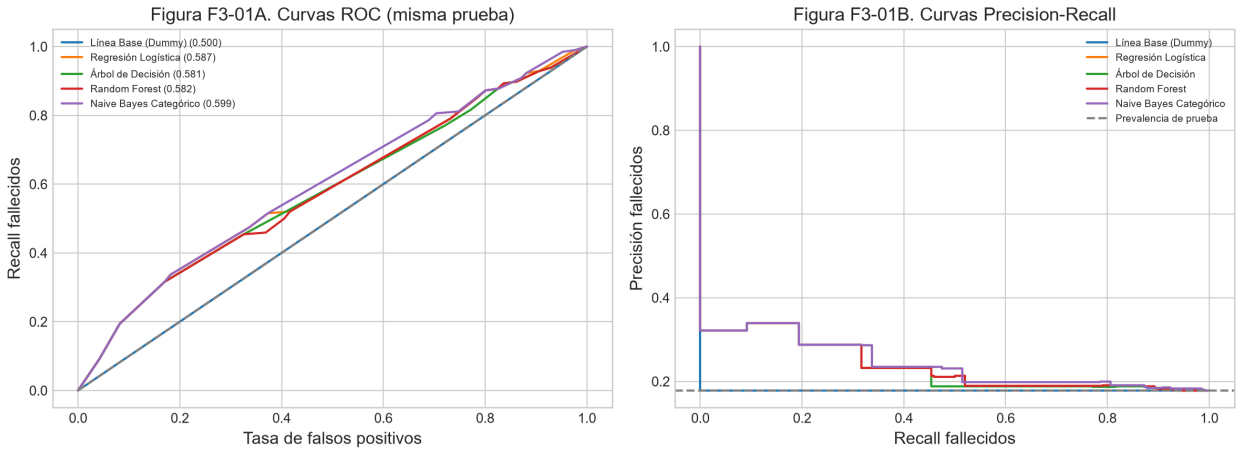


Figura F3-01. ROC y Precision-Recall de todos los modelos en la misma prueba. Las leyendas ROC incluyen AUC; la línea PR representa prevalencia.

Las curvas revelan capacidad de ordenamiento limitada. La exactitud de la mayoría puede ser elevada sin detectar ninguna fatalidad. El gráfico PR debe interpretarse en relación con la prevalencia de fallecidos y no como curva de calibración.

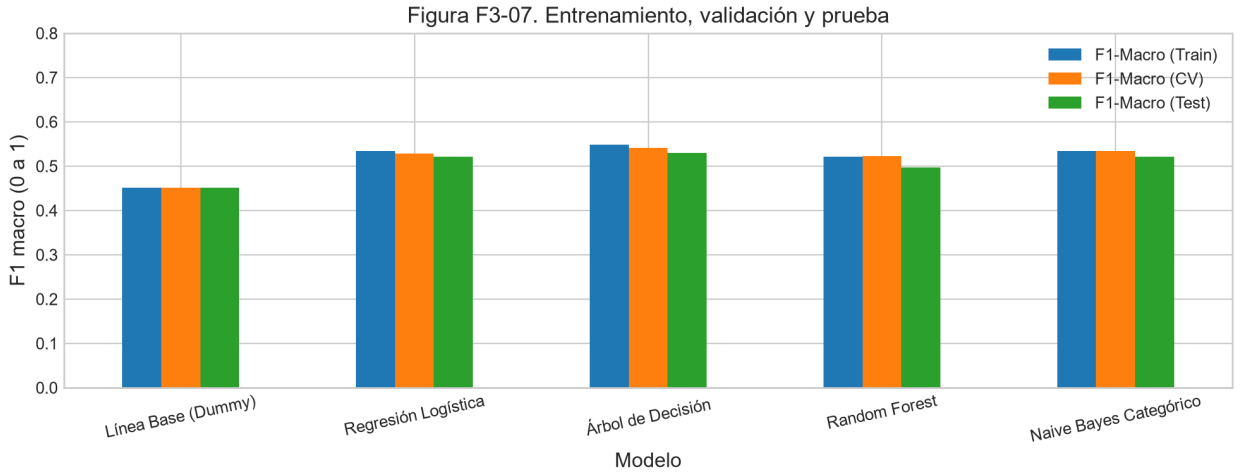


Figura F3-07. F1 macro de entrenamiento, validación y prueba.

El seleccionado tiene F1 macro train 0.5490, CV 0.5416 y test 0.5299. Train menos test = +0.0191; train CV menos validación CV = +0.0029. Una brecha pequeña puede resultar de repetir perfiles, no de generalización robusta. Los pliegues no son réplicas independientes de otras poblaciones.

6. Análisis de errores por perfil

En el seleccionado: TN=609, FP=294, FN=107, TP=89. TN: lesión clasificada herido; TP: fatalidad clasificada fallecido; FP: lesión clasificada fallecido; FN: fatalidad clasificada herido. El FN tiene prioridad académica al estudiar omisiones de fatalidad; no se asigna un costo clínico ni se optimiza un umbral en test. La mayor tasa global de error por edad aparece en De 30 a 39 anos: 68.54%, con n=213. Tasa de error global y tasa FN entre fallecidos tienen denominadores diferentes. El árbol omite 33 de 33 fatalidades entre mujeres (recall=0.0000), frente a recall 0.5460 en hombres. En 0-29 años omite 81 de 81 fatalidades. Este fallo sistemático hace especialmente inadecuado utilizar la clasificación para decisiones individuales. Los dos grupos se superponen: 15 omisiones son mujeres de 0-29 años. La unión contiene 33+81-15=99 filas, no la suma directa. Los 8 FN restantes son hombres con edad ignorada. Son conteos del protocolo sobre frecuencias reconstruidas, no expedientes individuales.

Tabla F3-4A. Matriz de confusión del seleccionado en prueba.

Real / Predicho	Herido (0)	Fallecido (1)
Herido (0)	609	294
Fallecido (1)	107	89

Tabla F3-4B. Errores por sexo, con denominadores.

Sexo	N	FN	FP	Error global	Recall fatal
Hombre	862	74	294	0.4269	0.5460
Mujer	237	33	0	0.1392	0.0000

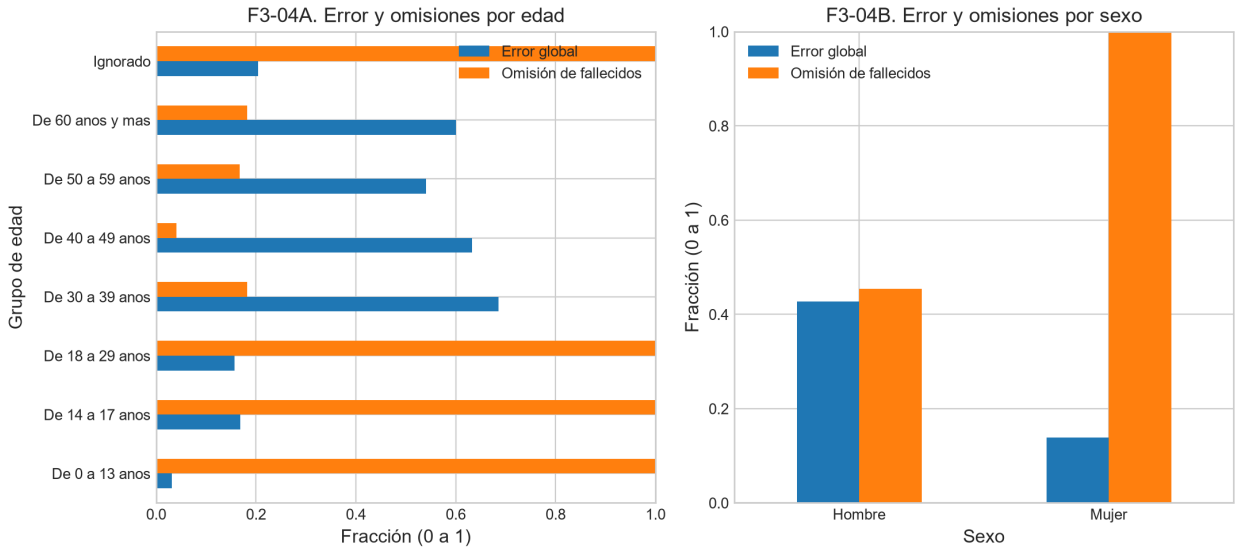


Figura F3-04. Tasa de clasificación errónea y tasa de omisión entre fallecidos, por edad y sexo.

Las tablas del notebook detallan los errores por perfil y sus residuos absolutos. Si el modelo asigna una sola clase a un perfil, falla en el desenlace contrario a su predicción, que puede ser mayoritario por la ponderación de clases. Con dos predictores no distingue gravedad del choque, protección o atención dentro del perfil; no puede explicar historias individuales.

7. Interpretabilidad y continuidad inferencial

En el árbol, grupo_edad tiene la mayor importancia Gini (0.5267). Esta importancia suma reducciones de impureza de sus indicadores y no tiene signo. Random Forest ofrece otra agregación, no una medida causal. La permutación desordena cada variable original y cuantifica caída de F1 macro con 30 repeticiones. Puede generar combinaciones artificiales y verse afectada por dependencia entre variables. Sus desvíos son de permutación, no intervalos poblacionales. Ninguna importancia demuestra que sexo o edad causen fatalidades.

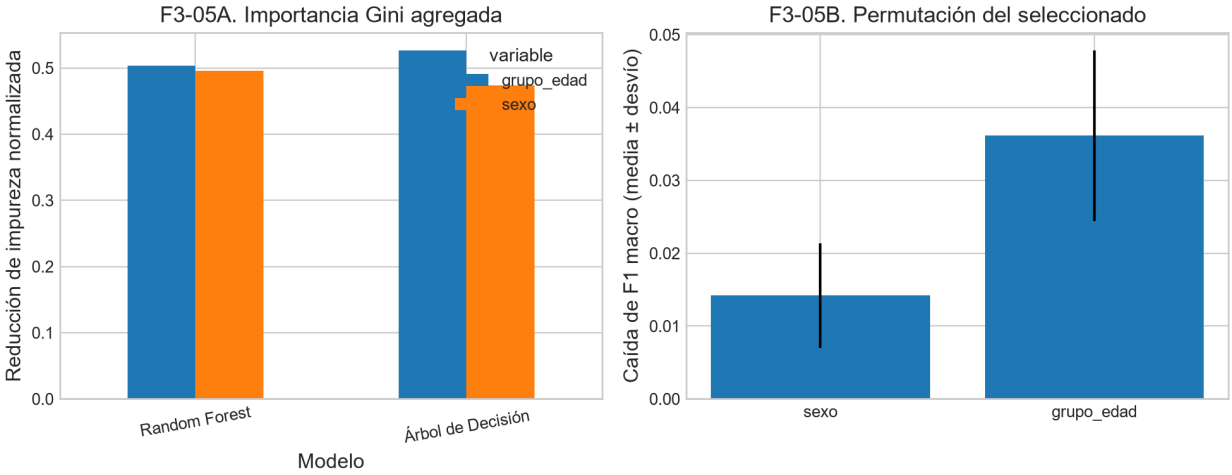


Figura F3-05. Importancia Gini por variable y permutación del seleccionado. Las barras de error de permutación son desvíos de 30 repeticiones.

Los coeficientes logísticos se interpretan respecto de Hombre y De 0 a 13 anos, referencias del encoder. exp(beta) representa un odds ratio del modelo regularizado y ponderado, condicionado por sus otras covariables; no es el OR sin ajuste de la Fase 2, ni una razón de riesgos ni una prueba de significancia. La coincidencia de señales por sexo y edad con Fase 2 no hace equivalentes asociación e importancia predictiva.

La Fase 2 informó OR por sexo 2,0370 y V de Cramér 0,0971. La dirección de asociación es compatible con señal demográfica, pero un efecto pequeño y perfiles compartidos limitan discriminación. Importancia predictiva no es una estimación del mecanismo causal ni del riesgo en población general.

8. Sensibilidad y calibración

GroupKFold de cuatro pliegues deja perfiles completos fuera del entrenamiento. Para Árbol de Decisión, F1 macro medio = 0.4556 y AUC media = 0.5248. Se repite con todos los candidatos manteniendo hiperparámetros fijos. Se ajusta cada transformación dentro del pliegue; una categoría desconocida carece de señal aprendida (OHE la representa por ceros; NB usa el índice reservado y suavizado). La búsqueda previa vio todos los perfiles de train; este análisis condicionado no es una validación anidada de perfiles. Con OHE drop=first, una categoría desconocida queda además indistinguible de la referencia en ese bloque de indicadores.

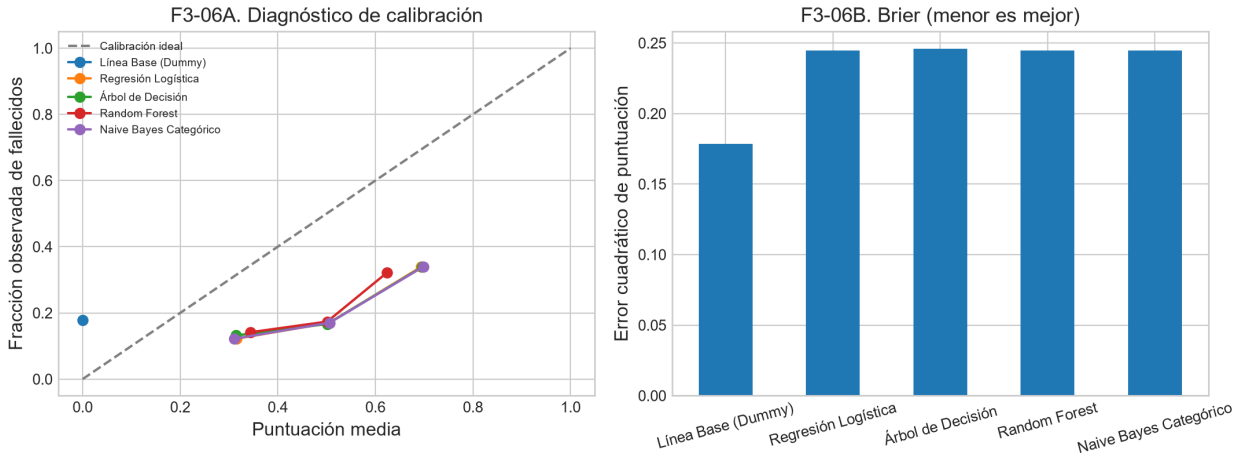


Figura F3-06. Diagnóstico de calibración y Brier de las puntuaciones originales, sin reajuste.

El Brier del seleccionado es 0.2457; el Dummy obtiene 0.1783. La gráfica compara puntuación media y fracción observada usando cinco intervalos uniformes; puede haber intervalos vacíos porque existen pocas puntuaciones distintas. No se ajusta calibración con test. La mejora de F1 o recall no garantiza calibración ni utilidad para decisiones individuales.

La equivalencia entre logística expandida y frecuencias ponderadas se comprobó mediante un ajuste adicional solo en train; sus diferencias numéricas quedan en las salidas del notebook. No es una validación independiente: demuestra que expandir no crea nueva información.

9. H1: gravedad registrada por zona

Tabla H1. Frecuencias territoriales cotejadas con 12.2.6.

Zona	Heridos	Fallecidos	Víctimas	Fallecidos (%)
Asunción	141	26	167	15.5689
Central	394	82	476	17.2269
Interior	661	187	848	22.0519

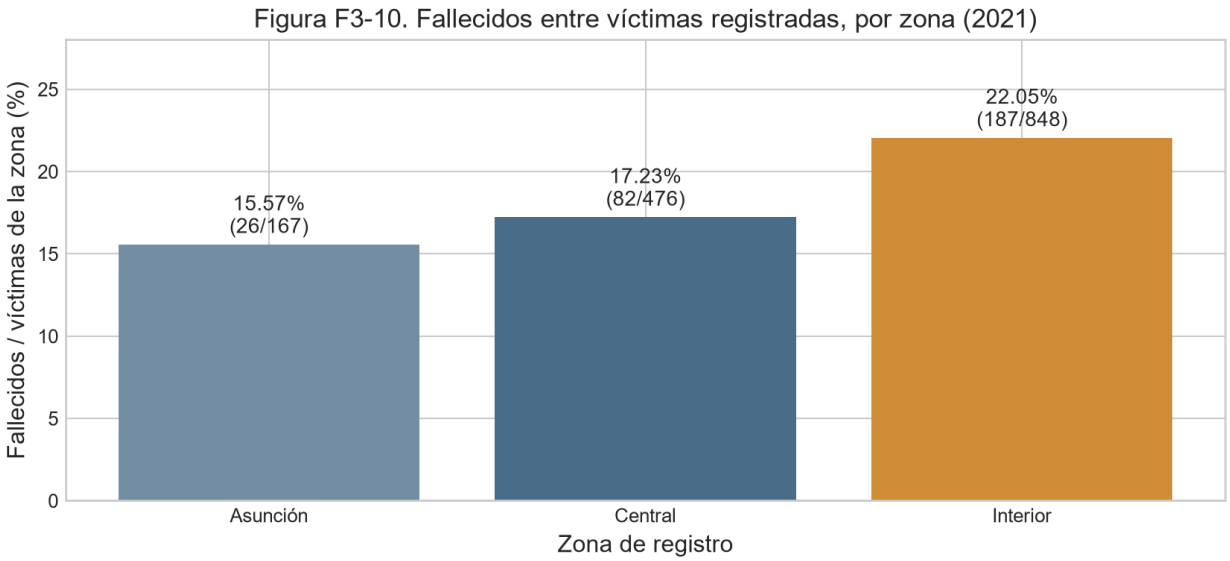


Figura F3-10. Fracción de fallecidos por zona; cada barra indica fallecidos/total de víctimas.

Las fracciones de fallecidos entre víctimas registradas son Asunción 15.57 %, Central 17.23 % e Interior 22.05 %. Metropolitana agrupa Asunción y Central: 108/643 = 16.80 %; Interior la supera en 5.26 puntos porcentuales. H1 de Fase 2 informó $\chi^2 = 6.3647$ (gl = 1), p crudo 0.011641 y p Bonferroni 0.046565; OR = 1.4014; V de Cramér = 0.0653. El efecto es pequeño y el p ajustado queda cerca de 0,05. La decisión corresponde a esa agrupación y familia de cuatro contrastes, no a todas las comparaciones entre zonas. Mostrar tres tasas revela la heterogeneidad que la dicotomía oculta; no se buscan nuevos p-valores. La cobertura institucional, el registro, la exposición y la atención pueden influir. Son proporciones entre víctimas, no riesgo poblacional de accidente ni un efecto causal de residir en una zona. Tres agregados no justifican un predictor individual generalizable; no se expanden ni se enlazan con los perfiles demográficos.

10. H3: siniestros con motociclistas

Tabla H3. Dos fuentes y una resta histórica: las filas no son categorías oficiales excluyentes.

Fuente / operación	Heridos	Fallecidos	Fallecidos (%)
12.2.10: siniestros con motociclistas	384	155	28.7570
12.2.5: cobertura total	1055	269	20.3172
Resta condicionada	671	114	14.5223

Figura F3-11. Frecuencias documentadas y variación mensual; sin atribución del vehículo individual

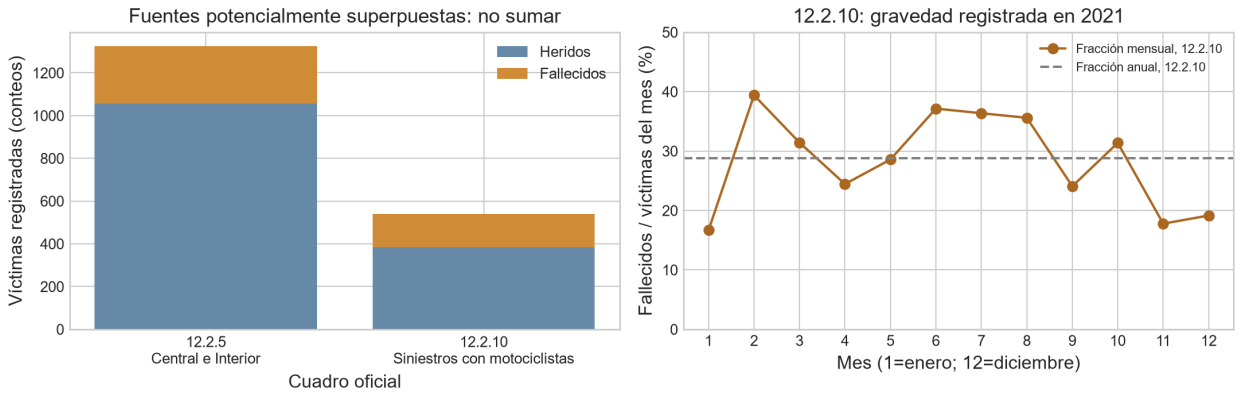


Figura F3-11. Conteos documentados y fracción mensual de fallecidos en 12.2.10; las fuentes no deben sumarse.

12.2.10 documenta 539 víctimas de siniestros protagonizados por motociclistas: 384 heridos y 155 fallecidos (28.76 %). 12.2.5 registra 1324 víctimas: 1055 heridos y 269 fallecidos (20.32 %) en Central e Interior. Se selecciona 2021 en ambas y se verifican los doce meses. La resta histórica da 671 heridos y 114 fallecidos; es la procedencia numérica del CSV vehicular, no una validación de sus etiquetas. Aunque ambos cuadros citan a Patrulla Caminera y las restas mensuales son no negativas, no se acredita que cada víctima viajara en moto ni que sean subconjuntos de cobertura idéntica. Las barras representan fuentes posiblemente superpuestas y no deben sumarse. La serie mensual describe esa cobertura, sin demostrar estacionalidad ni causas. H3 histórico informó RR = 1.9802; OR = 2.3758 y p Bonferroni 5.085e-10; se conserva como contraste condicionado. Ni RR, OR ni significación acreditan mayor riesgo individual de motociclistas si las categorías no están validadas. No se entrena un segundo predictor ni se unen estas filas expandidas con la base demográfica.

11. Integración de las cuatro hipótesis y edad desconocida

Tabla H1-H4. Relación entre antecedentes, predictor y límites de las fuentes.

Hipótesis	Factor	Evidencia disponible	Límite principal
H1	Zona	Tasas y contraste histórico territorial	Cobertura y agrupación; no vínculo individual
H2	Sexo	Asociación histórica y predictor demográfico	Señal limitada; no causa ni riesgo individual
H3	Motocicletas	Descripción y contraste histórico condicionado	Rol de víctima y subconjunto no acreditados
H4	Edad	Categoría nominal en modelo; antecedente ordinal	Histórico incluyó -1; desconocidos separados

H4: 353 víctimas de edad ignorada (292 heridas y 61 fallecidas) se conservan como categoría nominal independiente. edad_orden = -1 significa edad desconocida, no inferior a la de los niños. es_adulto_mayor = 0 en esos registros no acredita edad menor de 60 años. Los grupos separados son 4.832 menores de 60 con edad conocida, 308 de 60 años o más y 353 desconocidos. El modelo usa únicamente sexo y grupo_edad. El contraste ordinal histórico de Fase 2 eliminó nulos pero conservó -1; sus resultados no validan una comparación entre mayores y menores de 60. No se recalcula aquí: un nuevo análisis ordinal debe excluir los desconocidos del orden y reportarlos aparte.

H1 aporta diferencias territoriales descriptivas y un contraste histórico de efecto pequeño, condicionado por agrupación y cobertura. H2 aporta una asociación por sexo y H4 patrones por categorías de edad, incorporadas como los únicos predictores del experimento demográfico; el antecedente ordinal de H4 conserva la limitación de -1. H3 aporta conteos de siniestros con motociclistas y un contraste anterior condicionado a categorías no acreditadas. Se responde parcialmente la pregunta original: existe señal demográfica retrospectiva limitada y evidencia territorial separada; no se acredita un riesgo individual por vehículo ni el efecto conjunto de los cuatro factores. No se predice ocurrencia de siniestros, no se vinculan artificialmente registros y no se afirma causalidad.

12. Discusión y conclusiones académicas

Se seleccionó Árbol de Decisión por F1 macro de validación cruzada 0.5416. En la reserva interna obtuvo F1 macro 0.5299, frente a 0.4510 del Dummy (diferencia +0.0788); recall de fallecidos 0.4541, precisión 0.2324 y AUC 0.5809. La mejora es descriptiva del protocolo, sin prueba de superioridad poblacional ni validación externa.

H1 aporta diferencias territoriales descriptivas y un contraste histórico de efecto pequeño, condicionado por agrupación y cobertura. H2 aporta una asociación por sexo y H4 patrones por categorías de edad, incorporadas como los únicos predictores del experimento demográfico; el antecedente ordinal de H4 conserva la limitación de -1. H3 aporta conteos de siniestros con motociclistas y un contraste anterior condicionado a categorías no acreditadas. Se responde parcialmente la pregunta original: existe señal demográfica retrospectiva limitada y evidencia territorial separada; no se acredita un riesgo individual por vehículo ni el efecto conjunto de los cuatro factores. No se predice ocurrencia de siniestros, no se vinculan artificialmente registros y no se afirma causalidad.

El uso admisible de estos artefactos es docente, retrospectivo y de comparación de procedimientos. Se excluyen triaje, seguros y vigilancia por perfil. Para avanzar se necesitan registros genuinos vinculados de víctima y siniestro con vehículo real, fechas, casco/cinturón, velocidad, lesión inicial y tiempos de atención; diccionarios de cobertura; validación externa temporal y de calibración. Se debe controlar subregistro, selección de víctimas registradas y sesgos por sexo, edad y territorio.

La prueba ya observada y la optimización dentro de CV impiden presentar estas métricas como garantía externa. El ejercicio demuestra un proceso reproducible y expone su límite informativo. El grupo validó la interpretación acotada: mejora de F1 macro dentro del protocolo, capacidad limitada y ausencia de uso individual o generalización externa.

13. Reproducibilidad, referencias y uso de IA

Ejecutar desde la raíz con Python 3.12.1 y las versiones declaradas: preparar_datos.py, ejecutar_fase3.py, unittest y generar_documentos.py --pdf. El notebook conserva resultados, grillas, particiones y figuras embebidas; output/fase3 contiene el HTML y el modelo ganador serializado. El CLI inferencia.py valida categorías y carga el joblib sin abrir Jupyter. README documenta comandos.

Faltan legajos y revisión personal de las conclusiones. Los Word históricos anunciados por el grupo se incorporarán cuando estén disponibles; el integrador actual usa notebooks y resultados existentes. La fecha del campus debe confirmarse: la consigna dice viernes 24 de octubre sin año compatible con el contexto 2026.

INE. Anuario 2021 - Estadísticas policiales y de accidentes de tránsito. Cuadros 12.2.5/12.2.6, p. 307, y 12.2.10, p. 311. PDF: https://www.ine.gov.py/Publicaciones/Biblioteca/documento/240/Anuario%20Estadistico%202021.pdf . Catálogo: https://www.datos.gov.py/dataset/anuario-2021-estadisticas-policiales-y-de-accidentes-de-transito

Scikit-learn. Documentación oficial: https://scikit-learn.org/stable/modules/naive_bayes.html ; https://scikit-learn.org/stable/modules/cross_validation.html ; https://scikit-learn.org/stable/modules/permutation_importance.html ; https://scikit-learn.org/stable/modules/calibration.html . Consulta: 16/10/2026.

Consigna académica Proyecto_DataScience_Tres_Fases.pdf, apartados 7, 9.3, 9.5, 10, 11 y 12. Antecedentes: notebooks Fase1_Accidentes_Transito y Fase2_Analisis_Inferencial; tabla y JSON consolidados de Fase 2.

Se utilizó Codex como apoyo en auditoría, implementación, depuración, documentación y propuestas de interpretación. El grupo validó el alcance retrospectivo, la incorporación de Naive Bayes y la interpretación acotada de los resultados. Debe revisar y comprender personalmente las decisiones, métricas e interpretaciones; esa validación no acredita automáticamente el dominio personal de todo el contenido. La asistencia excedió sintaxis y redacción: corresponde al grupo comprobar la compatibilidad con el apartado 11 y consultar al docente si procede. No se atribuyen a los integrantes decisiones o validaciones que no hayan comunicado.