UNIVERSIDAD NACIONAL DE ASUNCIÓN

Facultad Politécnica · Ingeniería Informática

Factores asociados a la gravedad de las víctimas en los accidentes de tránsito en Paraguay (2021)

Informe integrador · Fases 1, 2 y 3

Asignatura: Ciencia de Datos (Electiva) · Curso TQ

Integrantes: Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos: no proporcionados para esta revisión. Deben incorporarse antes de presentar.

Fecha de la versión: 16 de octubre de 2026

Resultados reproducidos. Integración de hipótesis para revisión final del grupo.

Índice

1. Problema y pregunta de investigación 3
2. Fuentes, cobertura y calidad 4
3. Fase 1: preparación y descripción demográfica 5
4. Fase 1: contexto temporal y territorial 6
5. Fase 2: contrastes y tamaños del efecto 7
6. Fase 2: alcance de la inferencia 8
7. H1: gravedad registrada por zona 9
8. H3: siniestros con motociclistas 10
9. Integración de las cuatro hipótesis y edad desconocida 11
10. Fase 3: diseño y familias 12
11. Fase 3: resultados reproducidos 13
12. Fase 3: errores y sobreajuste 14
13. Fase 3: interpretación y sensibilidad 15
14. Integración de los tres niveles de evidencia 16
15. Conclusión general y recomendaciones 17
16. Reproducción, referencias y uso de IA 18

1. Problema y pregunta de investigación

Los siniestros viales generan lesiones y fallecimientos. El proyecto caracteriza las víctimas registradas en Paraguay en 2021 y distingue descripción, asociación y clasificación retrospectiva. No dispone de población expuesta o kilómetros recorridos para estimar incidencia de accidentes.

Pregunta original: ¿En qué medida la condición de usuario (motociclista frente a otros vehículos), el perfil biológico (sexo, grupo etario) y la localización geográfica (Asunción, Central e Interior) se asocian con una mayor probabilidad de fallecer en un siniestro vial en Paraguay durante 2021?

Objetivo general: examinar asociaciones del desenlace en las tablas disponibles. Objetivos específicos: preparar fuentes y describir distribuciones; contrastar asociaciones en sus universos separados; comparar clasificadores del desenlace demográfico frente a una base; comunicar límites y necesidades de información.

CRISP-DM articula comprensión del problema, comprensión y preparación de datos, análisis, modelado, evaluación y comunicación. La Fase 3 acota el objetivo predictivo inicial al alcance que permiten datos agregados.

Las 5.493 filas reconstruyen frecuencias de sexo, grupo de edad y desenlace, no son microdatos originales. Solo existen 16 perfiles predictivos. La partición aleatoria distribuye frecuencias de esos mismos perfiles en train y test. No acredita capacidad para anticipar desenlaces de personas o siniestros nuevos. La reserva ya fue inspeccionada en versiones anteriores; no se presenta como holdout virgen. Ninguna unión artificial vincula demografía, zona y vehículo.

2. Fuentes, cobertura y calidad

Fuente pública: INE, Anuario 2021. 12.2.1: conteos demográficos de Policía Nacional (5.493 víctimas). 12.2.2 a 12.2.12: cuadros viales; 12.2.6 cita a Patrulla Caminera, MOPC y Policía Nacional en el PDF original. 12.2.5: 1.324 víctimas Central/Interior; 12.2.6: 1.491 víctimas incluidas Asunción, Central e Interior. Los totales distintos no se fusionan ni se imputan como faltantes de una tabla común.

Los originales únicos se conservan en data/; se retiraron doce copias idénticas de data/raw/. Se parsean separadores de miles, filas TOTAL y encabezados repetidos. Los guiones requieren contexto: no son una edad o un valor individual. Ignorado conserva edad desconocida. Las filas repetidas de la expansión son esperadas y no se deduplican como si fueran errores.

Se utilizan únicamente sexo y grupo_edad. Se excluyen id_victima y gravedad por ser identificador y objetivo directo; es_hombre, es_adulto_mayor y edad_orden duplican las variables disponibles. Las 353 víctimas de edad ignorada permanecen separadas; -1 significa desconocido y el indicador de adulto mayor en 0 no acredita edad menor de 60. OneHotEncoder(drop=first, handle_unknown=ignore) se ajusta dentro de los pipelines de los tres modelos originales. No se requiere escalado de indicadores binarios o árboles. No se silencian advertencias globalmente.

La verificación nueva reconstruye íntegramente 12.2.1 sin ejecutar los notebooks históricos, de modo que las entregas previas no se alteran. Las pruebas verifican por SHA-256 que las Fases 1 y 2 permanecen intactas.

3. Fase 1: preparación y descripción demográfica

Se resume el desenlace en la tabla demográfica expandida, cuya unidad sustantiva es el conteo de cada combinación. Los identificadores consecutivos son auxiliares, sin identidad personal.

Tabla I-1. Conteos demográficos por sexo, recalculados desde el CSV auditado.

Sexo	Víctimas	Fallecidos	Fracción fatal
Hombre	4291	850	0.1981
Mujer	1202	130	0.1082

Tabla I-2. Conteos por edad; Ignorado no representa una edad inferior.

Grupo etario	Víctimas	Fallecidos	Fracción fatal
De 0 a 13 anos	306	35	0.1144
De 14 a 17 anos	449	57	0.1269
De 18 a 29 anos	2143	324	0.1512
De 30 a 39 anos	940	169	0.1798
De 40 a 49 anos	633	129	0.2038
De 50 a 59 anos	361	99	0.2742
De 60 anos y mas	308	106	0.3442
Ignorado	353	61	0.1728

Los jóvenes pueden concentrar mayor volumen de víctimas sin presentar la mayor proporción fatal. La interpretación separa carga absoluta y composición del desenlace. Las proporciones corresponden a víctimas registradas, no al riesgo por habitante o usuario vial.

4. Fase 1: contexto temporal y territorial

El archivo siniestros_mensual_2021.csv contiene los 12 meses de 2021. La tabla 12.2.2 totaliza 1.942 siniestros y octubre alcanza 201. La Ruta PY02 registra 711 hechos, 36,61 % de ese total. Son estadísticas descriptivas de su cobertura; no se prueban mecanismos de movilidad, pandemia o velocidad con estas tablas.

Tabla I-3. Contexto territorial de 12.2.6, universo de 1.491 víctimas.

zona	heridos	fallecidos	total_victimas	letalidad_pct
Asunción	141	26	167	15.5689
Central	394	82	476	17.2269
Interior	661	187	848	22.0519

La concentración del volumen y la diferencia territorial justifican investigar condiciones de vía, exposición y atención. No prueban que una ruta o lugar cause mayor gravedad, ni permiten trasladar la localización de una tabla al perfil demográfico de otra.

Las visualizaciones históricas permanecen en las Fases 1 y 2. Este integrador resume sus conteos, corrige el alcance interpretativo en esta versión y no reescribe sus entregas.

5. Fase 2: contrastes y tamaños del efecto

Se conservan como antecedentes los cuatro contrastes de resultados_fase2_consolidados.json y tabla_resumen_fase2.csv. Nivel alpha 0,05, corrección principal Bonferroni de cuatro pruebas y ajuste complementario Benjamini-Hochberg. La tabla siguiente transcribe resultados históricos: no se afirma una reejecución completa de Fase 2 en esta revisión.

Tabla I-4. Resultados inferenciales históricos, con efecto y p ajustado.

Hipótesis	Estadístico	p Bonferroni	Efecto histórico
H1	χ^2 = 6.3647 (gl = 1)	0.0466	OR = 1.4014; V de Cramér = 0.0653
H2	χ^2 = 51.8141 (gl = 1)	2.44e-12	OR = 2.0370; V de Cramér = 0.0971
H3	Z = 6.3244	5.08e-10	RR = 1.9802; OR = 2.3758
H4	U = 2576490.0000; Z = 8.4020	8.78e-17	r de Rosenthal = 0.1134

H1 compara Interior y Metropolitana; H2 sexo; H3 grupos vehiculares derivados; H4 edad codificada y desenlace. En H2 el intervalo bootstrap del OR histórico es [1,6787; 2,5066], con 10.000 remuestreos; el clásico [1,6729; 2,4803]. Ambos acompañan OR 2,0370, con V de Cramér 0,0971. Evidencia estadística no equivale a asociación grande o relevancia predictiva.

6. Fase 2: alcance de la inferencia

Para tablas de contingencia, la Fase 2 verificó frecuencias esperadas; Shapiro y Levene no son requisitos de chi-cuadrado. Para edad codificada se reportaron Shapiro, Levene y una alternativa de rangos. La codificación representa intervalos de diferente amplitud, no edades exactas. El contraste histórico conservó -1 tras eliminar nulos: no valida una comparación de mayores y menores de 60. Un nuevo contraste ordinal requiere excluir del orden las edades ignoradas y reportarlas aparte.

La expansión reproduce exactamente las frecuencias de contingencia: el tamaño de la tabla no equivale al número de perfiles. Las pruebas clásicas suponen un mecanismo de muestreo y unidades generadoras cuya independencia no se acredita solo con expandir conteos. Un bootstrap de filas expandidas reproduce un supuesto multinomial sobre la tabla, sin capturar subregistro, agrupación por siniestro o incertidumbre de cobertura. Por ello los p e intervalos históricos son resultados condicionados, no garantías sobre toda la población.

Posibles confusores: exposición vial, casco y cinturón, velocidad, tipo de vía, lesión inicial, acceso a atención y cobertura institucional. Ninguno puede controlarse conjuntamente con los datos disponibles. No hubo devolución formal docente de Fase 2; esta revisión contextualiza sin atribuir correcciones inexistentes.

7. H1: gravedad registrada por zona

Tabla H1. Frecuencias territoriales cotejadas con 12.2.6.

Zona	Heridos	Fallecidos	Víctimas	Fallecidos (%)
Asunción	141	26	167	15.5689
Central	394	82	476	17.2269
Interior	661	187	848	22.0519

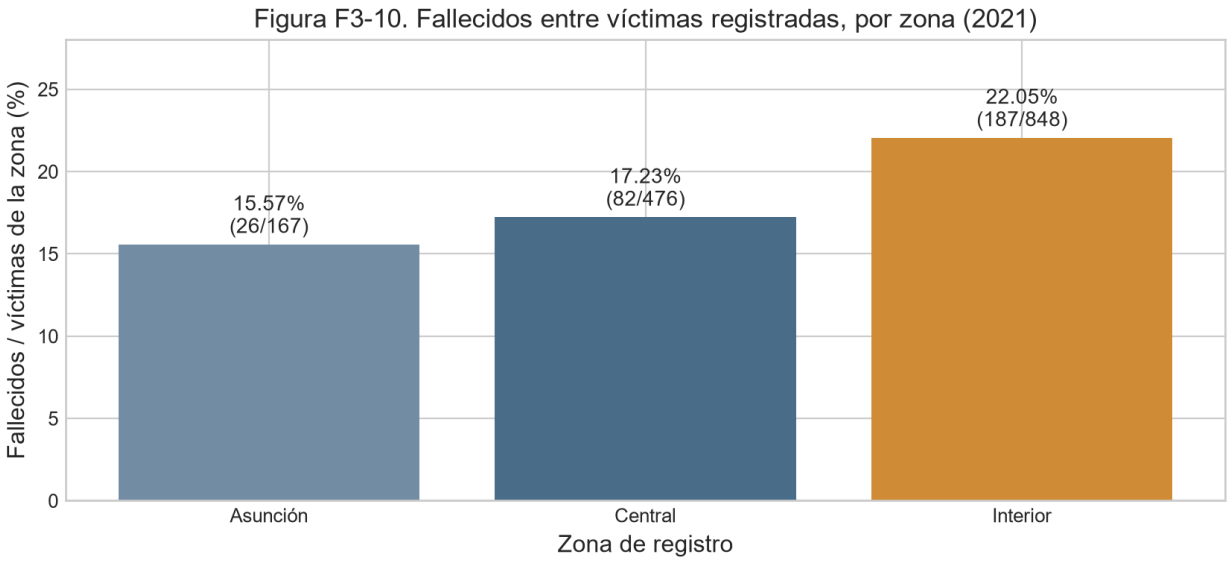


Figura F3-10. Fracción de fallecidos por zona; cada barra indica fallecidos/total de víctimas.

Las fracciones de fallecidos entre víctimas registradas son Asunción 15.57 %, Central 17.23 % e Interior 22.05 %. Metropolitana agrupa Asunción y Central: 108/643 = 16.80 %; Interior la supera en 5.26 puntos porcentuales. H1 de Fase 2 informó $\chi^2 = 6.3647$ (gl = 1), p crudo 0.011641 y p Bonferroni 0.046565; OR = 1.4014; V de Cramér = 0.0653. El efecto es pequeño y el p ajustado queda cerca de 0,05. La decisión corresponde a esa agrupación y familia de cuatro contrastes, no a todas las comparaciones entre zonas. Mostrar tres tasas revela la heterogeneidad que la dicotomía oculta; no se buscan nuevos p-valores. La cobertura institucional, el registro, la exposición y la atención pueden influir. Son proporciones entre víctimas, no riesgo poblacional de accidente ni un efecto causal de residir en una zona. Tres agregados no justifican un predictor individual generalizable; no se expanden ni se enlazan con los perfiles demográficos.

8. H3: siniestros con motociclistas

Tabla H3. Dos fuentes y una resta histórica: las filas no son categorías oficiales excluyentes.

Fuente / operación	Heridos	Fallecidos	Fallecidos (%)
12.2.10: siniestros con motociclistas	384	155	28.7570
12.2.5: cobertura total	1055	269	20.3172
Resta condicionada	671	114	14.5223

Figura F3-11. Frecuencias documentadas y variación mensual; sin atribución del vehículo individual

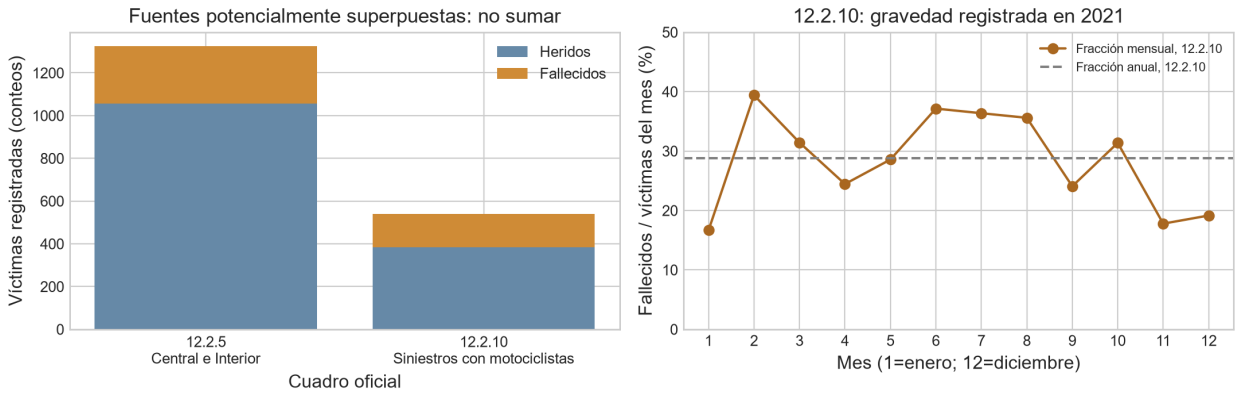


Figura F3-11. Conteos documentados y fracción mensual de fallecidos en 12.2.10; las fuentes no deben sumarse.

12.2.10 documenta 539 víctimas de siniestros protagonizados por motociclistas: 384 heridos y 155 fallecidos (28.76 %). 12.2.5 registra 1324 víctimas: 1055 heridos y 269 fallecidos (20.32 %) en Central e Interior. Se selecciona 2021 en ambas y se verifican los doce meses. La resta histórica da 671 heridos y 114 fallecidos; es la procedencia numérica del CSV vehicular, no una validación de sus etiquetas. Aunque ambos cuadros citan a Patrulla Caminera y las restas mensuales son no negativas, no se acredita que cada víctima viajara en moto ni que sean subconjuntos de cobertura idéntica. Las barras representan fuentes posiblemente superpuestas y no deben sumarse. La serie mensual describe esa cobertura, sin demostrar estacionalidad ni causas. H3 histórico informó RR = 1.9802; OR = 2.3758 y p Bonferroni 5.085e-10; se conserva como contraste condicionado. Ni RR, OR ni significación acreditan mayor riesgo individual de motociclistas si las categorías no están validadas. No se entrena un segundo predictor ni se unen estas filas expandidas con la base demográfica.

9. Integración de las cuatro hipótesis y edad desconocida

Tabla H1-H4. Relación entre antecedentes, predictor y límites de las fuentes.

Hipótesis	Factor	Evidencia disponible	Límite principal
H1	Zona	Tasas y contraste histórico territorial	Cobertura y agrupación; no vínculo individual
H2	Sexo	Asociación histórica y predictor demográfico	Señal limitada; no causa ni riesgo individual
H3	Motocicletas	Descripción y contraste histórico condicionado	Rol de víctima y subconjunto no acreditados
H4	Edad	Categoría nominal en modelo; antecedente ordinal	Histórico incluyó -1; desconocidos separados

H4: 353 víctimas de edad ignorada (292 heridas y 61 fallecidas) se conservan como categoría nominal independiente. edad_orden = -1 significa edad desconocida, no inferior a la de los niños. es_adulto_mayor = 0 en esos registros no acredita edad menor de 60 años. Los grupos separados son 4.832 menores de 60 con edad conocida, 308 de 60 años o más y 353 desconocidos. El modelo usa únicamente sexo y grupo_edad. El contraste ordinal histórico de Fase 2 eliminó nulos pero conservó -1; sus resultados no validan una comparación entre mayores y menores de 60. No se recalcula aquí: un nuevo análisis ordinal debe excluir los desconocidos del orden y reportarlos aparte.

H1 aporta diferencias territoriales descriptivas y un contraste histórico de efecto pequeño, condicionado por agrupación y cobertura. H2 aporta una asociación por sexo y H4 patrones por categorías de edad, incorporadas como los únicos predictores del experimento demográfico; el antecedente ordinal de H4 conserva la limitación de -1. H3 aporta conteos de siniestros con motociclistas y un contraste anterior condicionado a categorías no acreditadas. Se responde parcialmente la pregunta original: existe señal demográfica retrospectiva limitada y evidencia territorial separada; no se acredita un riesgo individual por vehículo ni el efecto conjunto de los cuatro factores. No se predice ocurrencia de siniestros, no se vinculan artificialmente registros y no se afirma causalidad.

10. Fase 3: diseño y familias

Se conservó la partición 80/20 estratificada por desenlace, con semilla 42: 4.394 filas de entrenamiento y 1.099 de prueba (196 fallecidos). En entrenamiento se fijaron cinco pliegues estratificados idénticos para todos. GridSearchCV optimiza F1 macro; se cierra la selección antes de calcular las métricas de test en esta ejecución. No se cambian umbrales ni hiperparámetros a partir de la reserva. Las medias CV de la mejor grilla tienen sesgo de selección; no equivalen a una evaluación anidada. No existen fechas individuales que permitan una partición cronológica válida.

Logística: modelo discriminativo con efectos aditivos en log-odds, regularización L2. Árbol: reglas con interacciones y control de complejidad por profundidad y hojas mínimas. Random Forest: ensamble de árboles para reducir varianza; pertenece a la familia de árboles. Naive Bayes categórico: modelo generativo que supone independencia de sexo y edad dado el desenlace. OrdinalEncoder asigna índices nominales; sumar uno reserva el cero para categorías desconocidas. No hay interpretación ordinal de esos números. Suavizado alpha evita frecuencias condicionales nulas; min_categories=[3,9] reserva el dominio conocido más desconocido.

La prevalencia es 980/5.493 = 17,84 %. Los tres modelos originales usan class_weight=balanced; Naive Bayes usa prior 0,5/0,5 para dar igual prioridad a las clases, conservando conteos condicionales naturales. El umbral permanece en la regla predict del estimador. Los puntajes no se presentan como probabilidades absolutas calibradas. No se utiliza SMOTE.

Tabla I-5. Hiperparámetros ganadores del experimento demográfico.

Modelo	Hiperparámetros elegidos por CV
Naive Bayes	{'alpha': 0.1}
Bosque	{'max_depth': 3, 'min_samples_leaf': 25, 'n_estimators': 100}
Logística	{'C': 5.0, 'solver': 'lbfgs'}
Árbol	{'max_depth': 6, 'min_samples_leaf': 50}

11. Fase 3: resultados reproducidos

Tabla I-6. F1 macro de validación cruzada.

Modelo	Train CV	Validación CV	Desvío CV
Dummy	0.4510	0.4510	0.0001
Logística	0.5330	0.5278	0.0169
Árbol	0.5444	0.5416	0.0106
Bosque	0.5235	0.5234	0.0133
Naive Bayes	0.5374	0.5347	0.0137

Tabla I-7. Resultados en la reserva interna de 1.099 filas.

Modelo	Accuracy	Prec. 1	Recall 1	F1 clase 1	F1 macro	AUC
Dummy	0.8217	0.0000	0.0000	0.0000	0.4510	0.5000
Logística	0.6069	0.2306	0.5153	0.3186	0.5212	0.5869
Árbol	0.6351	0.2324	0.4541	0.3074	0.5299	0.5809
Bosque	0.5723	0.2134	0.5204	0.3027	0.4971	0.5816
Naive Bayes	0.6069	0.2306	0.5153	0.3186	0.5212	0.5989

Se seleccionó Árbol de Decisión por F1 macro de validación cruzada 0.5416. En la reserva interna obtuvo F1 macro 0.5299, frente a 0.4510 del Dummy (diferencia +0.0788); recall de fallecidos 0.4541, precisión 0.2324 y AUC 0.5809. La mejora es descriptiva del protocolo, sin prueba de superioridad poblacional ni validación externa.

Accuracy mide aciertos totales; precisión de clase 1 mide la fracción de fatalidades entre predicciones positivas; recall mide la fracción de fatalidades detectadas; F1 combina precisión y recall. F1 macro promedia los F1 de ambas clases. AUC mide ordenamiento de puntuaciones, no calibración. Specificity y balanced accuracy complementan el desbalance. Brier evalúa error cuadrático de la puntuación; Average Precision resume la curva PR. Las tablas completas quedan embebidas en el notebook ejecutado.

12. Fase 3: errores y sobreajuste

En el seleccionado: TN=609, FP=294, FN=107, TP=89. TN: lesión clasificada herido; TP: fatalidad clasificada fallecido; FP: lesión clasificada fallecido; FN: fatalidad clasificada herido. El FN tiene prioridad académica al estudiar omisiones de fatalidad; no se asigna un costo clínico ni se optimiza un umbral en test. La mayor tasa global de error por edad aparece en De 30 a 39 anos: 68.54%, con n=213. Tasa de error global y tasa FN entre fallecidos tienen denominadores diferentes. El árbol omite 33 de 33 fatalidades entre mujeres (recall=0.0000), frente a recall 0.5460 en hombres. En 0-29 años omite 81 de 81 fatalidades. Este fallo sistemático hace especialmente inadecuado utilizar la clasificación para decisiones individuales. Los dos grupos se superponen: 15 omisiones son mujeres de 0-29 años. La unión contiene 33+81-15=99 filas, no la suma directa. Los 8 FN restantes son hombres con edad ignorada. Son conteos del protocolo sobre frecuencias reconstruidas, no expedientes individuales.

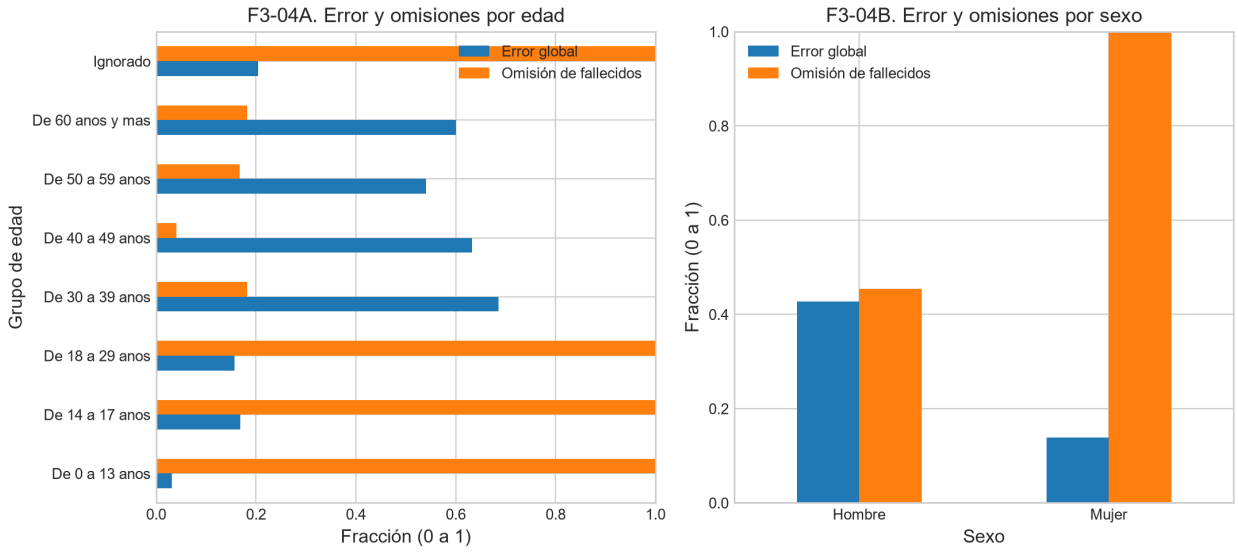


Figura F3-04. Errores por sexo y grupo etario.

El seleccionado tiene F1 macro train 0.5490, CV 0.5416 y test 0.5299. Train menos test = +0.0191; train CV menos validación CV = +0.0029. Una brecha pequeña puede resultar de repetir perfiles, no de generalización robusta. Los pliegues no son réplicas independientes de otras poblaciones.

Las tablas por perfil completo del notebook muestran las combinaciones con clasificación sistemática de una clase. No corresponden a expedientes individuales. La escasez de predictores impide distinguir circunstancias entre víctimas del mismo perfil.

13. Fase 3: interpretación y sensibilidad

En el árbol, grupo_edad tiene la mayor importancia Gini (0.5267). Esta importancia suma reducciones de impureza de sus indicadores y no tiene signo. Random Forest ofrece otra agregación, no una medida causal. La permutación desordena cada variable original y cuantifica caída de F1 macro con 30 repeticiones. Puede generar combinaciones artificiales y verse afectada por dependencia entre variables. Sus desvíos son de permutación, no intervalos poblacionales. Ninguna importancia demuestra que sexo o edad causen fatalidades.

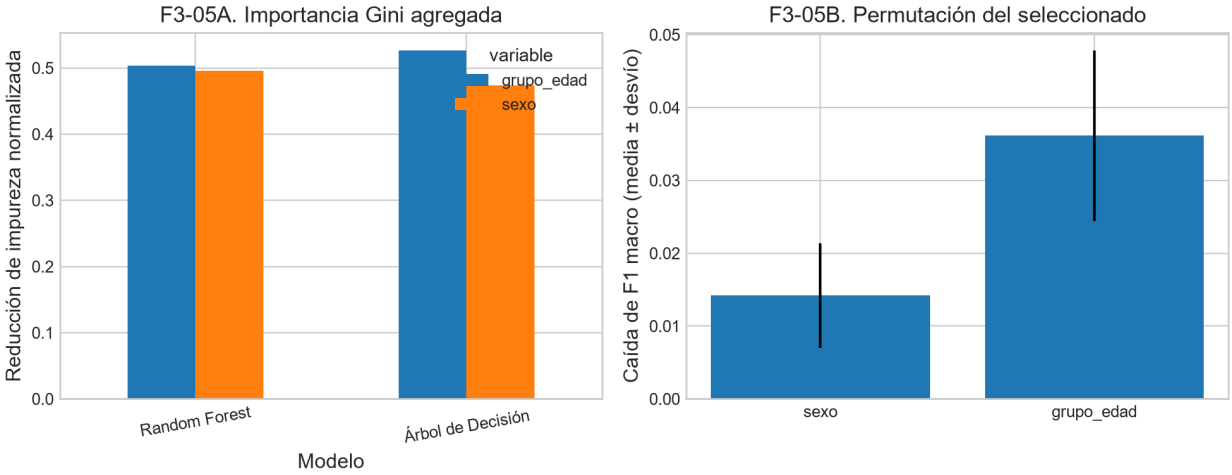


Figura F3-05. Dos medidas de relevancia predictiva con alcances distintos.

Los coeficientes logísticos se interpretan respecto de Hombre y De 0 a 13 anos, referencias del encoder. exp(beta) representa un odds ratio del modelo regularizado y ponderado, condicionado por sus otras covariables; no es el OR sin ajuste de la Fase 2, ni una razón de riesgos ni una prueba de significancia. La coincidencia de señales por sexo y edad con Fase 2 no hace equivalentes asociación e importancia predictiva.

GroupKFold de cuatro pliegues deja perfiles completos fuera del entrenamiento. Para Árbol de Decisión, F1 macro medio = 0.4556 y AUC media = 0.5248. Se repite con todos los candidatos manteniendo hiperparámetros fijos. Se ajusta cada transformación dentro del pliegue; una categoría desconocida carece de señal aprendida (OHE la representa por ceros; NB usa el índice reservado y suavizado). La búsqueda previa vio todos los perfiles de train; este análisis condicionado no es una validación anidada de perfiles. Con OHE drop=first, una categoría desconocida queda además indistinguible de la referencia en ese bloque de indicadores.

14. Integración de los tres niveles de evidencia

Descripción: los conteos caracterizan víctimas y siniestros dentro de cada fuente. Inferencia: los contrastes históricos cuantifican asociaciones bajo supuestos y corrección múltiple. Predicción: los modelos asignan clases/puntajes y se comparan mediante un protocolo interno fijo. Una asociación significativa puede coexistir con AUC limitada; ni los p-valores ni las importancias prueban causalidad.

H1 aporta diferencias territoriales descriptivas y un contraste histórico de efecto pequeño, condicionado por agrupación y cobertura. H2 aporta una asociación por sexo y H4 patrones por categorías de edad, incorporadas como los únicos predictores del experimento demográfico; el antecedente ordinal de H4 conserva la limitación de -1. H3 aporta conteos de siniestros con motociclistas y un contraste anterior condicionado a categorías no acreditadas. Se responde parcialmente la pregunta original: existe señal demográfica retrospectiva limitada y evidencia territorial separada; no se acredita un riesgo individual por vehículo ni el efecto conjunto de los cuatro factores. No se predice ocurrencia de siniestros, no se vinculan artificialmente registros y no se afirma causalidad.

El Brier del seleccionado es 0.2457; el Dummy obtiene 0.1783. La gráfica compara puntuación media y fracción observada usando cinco intervalos uniformes; puede haber intervalos vacíos porque existen pocas puntuaciones distintas. No se ajusta calibración con test. La mejora de F1 o recall no garantiza calibración ni utilidad para decisiones individuales.

Figura F3-01A. Curvas ROC (misma prueba)

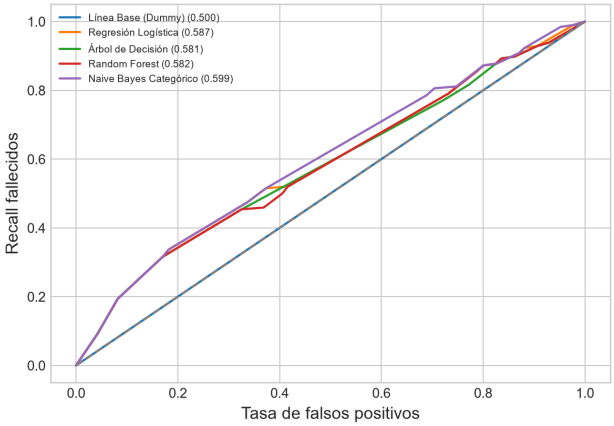


Figura F3-01B. Curvas Precision-Recall

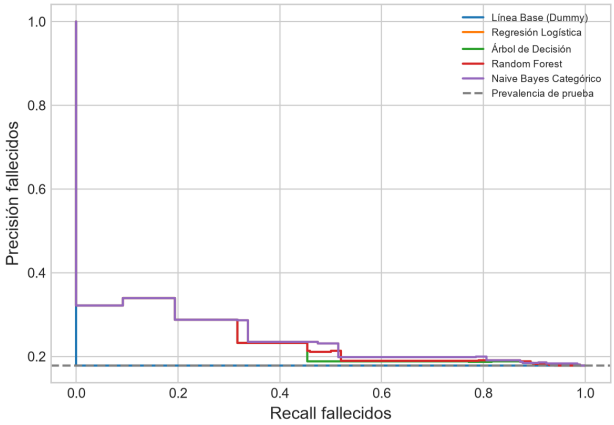


Figura F3-01. Discriminación limitada en los mismos perfiles reconstruidos; no equivale a validación externa.

15. Conclusión general y recomendaciones

Se seleccionó Árbol de Decisión por F1 macro de validación cruzada 0.5416. En la reserva interna obtuvo F1 macro 0.5299, frente a 0.4510 del Dummy (diferencia +0.0788); recall de fallecidos 0.4541, precisión 0.2324 y AUC 0.5809. La mejora es descriptiva del protocolo, sin prueba de superioridad poblacional ni validación externa.

La contribución defendible es una cadena trazable desde conteos oficiales hasta evaluación comparativa, acompañada de un reconocimiento explícito de cobertura, repetición y revisión histórica del test. El objetivo de superar una base puede cumplirse en F1 macro dentro del protocolo, mientras la utilidad fuera de esa tabla permanece sin demostrar.

El uso admisible de estos artefactos es docente, retrospectivo y de comparación de procedimientos. Se excluyen triaje, seguros y vigilancia por perfil. Para avanzar se necesitan registros genuinos vinculados de víctima y siniestro con vehículo real, fechas, casco/cinturón, velocidad, lesión inicial y tiempos de atención; diccionarios de cobertura; validación externa temporal y de calibración. Se debe controlar subregistro, selección de víctimas registradas y sesgos por sexo, edad y territorio.

El grupo debe revisar los errores por sexo y edad sin estigmatizar categorías, y distinguir incertidumbre de datos de incertidumbre algorítmica. Priorizar obtención y enlace legítimo de microdatos aporta más información potencial que aumentar la complejidad de modelos sobre 16 perfiles.

El grupo validó el alcance y la interpretación acotada de estos resultados; debe revisar personalmente todo el código y texto para su defensa. Los Word históricos anunciados por el grupo aún no estaban disponibles al generar esta versión.

16. Reproducción, referencias y uso de IA

El repositorio conserva data/, notebooks/, src/ y output/, y añade docs/ y tests/. README registra instalación, reconstrucción, kernel nuevo, HTML, inferencia, pruebas y documentos. Las versiones exactas y la partición reproducible se documentan dentro del notebook; los informes se componen a partir de tablas calculadas. Esta revisión no realiza nuevos commits ni pushes.

INE. Anuario 2021 - Estadísticas policiales y de accidentes de tránsito. Cuadros 12.2.5/12.2.6, p. 307, y 12.2.10, p. 311. PDF: https://www.ine.gov.py/Publicaciones/Biblioteca/documento/240/Anuario%20Estadistico%202021.pdf . Catálogo: https://www.datos.gov.py/dataset/anuario-2021-estadisticas-policiales-y-de-accidentes-de-transito

Scikit-learn. Documentación oficial: https://scikit-learn.org/stable/modules/naive_bayes.html ; https://scikit-learn.org/stable/modules/cross_validation.html ; https://scikit-learn.org/stable/modules/permutation_importance.html ; https://scikit-learn.org/stable/modules/calibration.html . Consulta: 16/10/2026.

Consigna académica Proyecto_DataScience_Tres_Fases.pdf, apartados 7, 9.3, 9.5, 10, 11 y 12. Antecedentes: notebooks Fase1_Accidentes_Transito y Fase2_Analisis_Inferencial; tabla y JSON consolidados de Fase 2.

Se utilizó Codex como apoyo en auditoría, implementación, depuración, documentación y propuestas de interpretación. El grupo validó el alcance retrospectivo, la incorporación de Naive Bayes y la interpretación acotada de los resultados. Debe revisar y comprender personalmente las decisiones, métricas e interpretaciones; esa validación no acredita automáticamente el dominio personal de todo el contenido. La asistencia excedió sintaxis y redacción: corresponde al grupo comprobar la compatibilidad con el apartado 11 y consultar al docente si procede. No se atribuyen a los integrantes decisiones o validaciones que no hayan comunicado.

Antes de presentar: incorporar legajos, verificar apellidos y nomenclatura ZIP, confirmar fecha del campus y revisar personalmente las conclusiones. Los límites de 15 páginas para Fase 3 y 30 para integrador se comprueban sobre los PDF exportados, no sobre estimaciones de Word.