CIENCIA DE DATOS - PROYECTO INTEGRADOR

Comprensión del problema

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Alcance del trabajo

Analizamos registros individuales de PRF para estudiar la gravedad y comparar modelos predictivos. Usamos herramientas de IA como apoyo en programación, análisis y redacción. El equipo debe revisar y comprender el contenido antes de presentarlo.

El modelo distingue entre víctimas heridas y fallecidas registradas por PRF. Parte de un accidente que ya ocurrió: no predice quién tendrá un accidente ni cuántos accidentes habrá el próximo año. Su evaluación es académica, no médica.

Fecha: 2 de noviembre de 2026.

Pregunta y objetivos

Contexto y relevancia

La Policía Rodoviaria Federal de Brasil (PRF) publica datos de accidentes ocurridos en carreteras federales. Elegimos esta fuente porque permite relacionar a cada persona con su vehículo y accidente. En el trabajo anterior de Paraguay teníamos cantidades agrupadas: repetir esas cantidades como filas no creaba información individual nueva.

Pregunta principal

¿Qué características personales, vehiculares y del siniestro se asocian con el fallecimiento registrado frente a lesiones no fatales en víctimas de siniestros de PRF Brasil entre 2017 y 2025, y qu? desempeño alcanza su clasificación en el período posterior de 2026?

Objetivo general

Analizar qué características se relacionan con la gravedad y evaluar qué tan bien permiten distinguir entre víctimas heridas y fallecidas en un período posterior.

Objetivos específicos

- Unir los registros de víctimas, vehículos y accidentes mediante sus identificadores reales, sin inventar ni duplicar personas.
- Revisar la calidad de los datos y describir diferencias por edad, sexo, vehículo, lugar y horario.
- Comprobar cuatro hipótesis con pruebas estadísticas, considerando que varias víctimas pueden pertenecer al mismo accidente.
- Comparar distintas familias de modelos y evaluar cómo trabajan con muchos más heridos que fallecidos.
- Medir el resultado en datos posteriores al entrenamiento, explicar los errores y responder la pregunta de investigación.

Alcance y método previsto

Usamos 20 ZIP con tablas CSV y dos diccionarios oficiales, descargados el 31/10/2026. Los archivos 2017-2025 tienen 632.713 accidentes y 1.654.197 filas en personas. El corte 2026 añade 54.895 accidentes y 148.868 filas en personas. No todas esas filas sirven para nuestro objetivo: hay ilesos, estados desconocidos y registros sin identificador de persona. En 2017-2025 hay 144.628 filas con pesid=0 que no contamos como personas identificadas.

Después de seleccionar heridos y fallecidos, 2017-2025 tiene 754.098 víctimas: 703.273 heridas y 50.825 fallecidas. El corte de 2026 agrega 67.591 víctimas, con 4.610 fallecidos. El archivo limpio reúne 821.689 participaciones reales. Usamos id para unir cada persona con un solo accidente. Verificamos que la unión no añadiera filas ni dejara víctimas sin pareja. Los datos del vehículo ya vienen en personas: no inventamos una tercera fuente.

El modelo final usa 31 características: edad, sexo, rol de la persona, vehículo, antigüedad, horario, ubicación y condiciones del accidente, entre otras. Las siete características añadidas describen los otros vehículos presentes. Para construirlas usamos todos los vehículos identificados antes de seleccionar las víctimas y contamos una sola vez a un vehículo con varios ocupantes. No usamos identificadores, cantidades de muertos o heridos ni la causa atribuida después de investigar el accidente como entradas del modelo principal.

Revisamos los cambios de categorías entre años y no borramos un valor extremo solo por estar alejado de los demás si sigue siendo posible. No tenemos velocidad de impacto, casco, cinturón ni seguimiento clínico completo. Tampoco conocemos todos los viajes realizados. Por eso este estudio no estima la probabilidad de que una persona cualquiera tenga un accidente.

El objetivo es distinguir heridos y fallecidos registrados en Brasil, no pronosticar la cantidad de accidentes del próximo año. Las tres fases trabajan con la misma base individual y sus decisiones deben poder explicarse durante la exposición.