CIENCIA DE DATOS - PROYECTO INTEGRADOR

# Comprensión del problema

## Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026


### Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.


### Qué contiene este material

Resultados calculados con registros individuales y evaluación temporal. Borrador de apoyo académico con asistencia de IA: el equipo debe revisar, comprender y asumir las decisiones metodológicas y las interpretaciones antes de presentar.

El modelo estima un desenlace registrado entre víctimas lesionadas atendidas por PRF. No predice quién sufrirá un accidente, no establece causas y no está validado para uso médico ni para Paraguay.

Fecha: 31 de octubre de 2026.

# Pregunta y objetivos

## Contexto y relevancia

PRF publica registros administrativos de siniestros en carreteras federales y sus involucrados. Comprender qué características distinguen lesiones no fatales y fallecimientos registrados permite formular hipótesis y evaluar predicción académica. El trabajo anterior de Paraguay solo disponía de totales agrupados: expandirlos no creaba información individual.

## Pregunta principal

¿Qué características personales, vehiculares y del siniestro se asocian con el fallecimiento registrado frente a lesiones no fatales en víctimas de siniestros de PRF Brasil entre 2017 y 2025, y qu? desempeño alcanza su clasificación en el período posterior de 2026?

## Objetivo general

Analizar asociaciones entre características individuales y del siniestro con el desenlace y evaluar la capacidad de modelos para clasificar víctimas heridas o fallecidas registradas, mediante un procedimiento reproducible y sin filtraciones del resultado.

## Objetivos específicos

- Construir una tabla individual de víctimas con sus características personales, vehiculares y del siniestro mediante claves reales y controles de unión.
- Evaluar la calidad, las ausencias y los patrones de edad, sexo, vehículo, lugar y tiempo en 2017-2023.
- Contrastar cuatro hipótesis con tamaños de efecto, intervalos y corrección de multiplicidad, considerando víctimas del mismo accidente.
- Comparar modelos de varias familias con validación temporal, calibración y tratamiento explícito del desbalance.
- Medir en 2025 el aporte de las nuevas variables frente a sexo/edad y referencias triviales, comunicando errores y límites.

# Alcance y método previsto

Se conservan 20 ZIP CSV y 2 diccionarios PDF oficiales del corte descargado el 31/10/2026. En 2017-2025 hay 632.713 accidentes distintos y 1.654.197 filas en personas; el corte 2026 agrega 54.895 ocurrencias y 148.868 filas en personas. Se descartaron del objetivo ilesos y desenlaces desconocidos; 144.628 filas con pesid=0 de 2017-2025 no se cuentan como individuos identificados.

La base principal 2017-2025 tiene 754.098 víctimas con desenlace válido: 703.273 heridas y 50.825 fallecidas. El corte posterior 2026 agrega 67.591 víctimas (4.610 fallecidas). El dataset limpio consolidado contiene 821.689 participaciones. La unión personas.id a accidentes.id es muchos a uno, sin expansión ni víctimas sin pareja. Las claves de víctimas son únicas; los datos de vehículo ya están asociados en personas. No se inventó una tercera fuente independiente.

El modelo final usa 31 predictores. Los 24 iniciales incluyen edad, antigüedad de vehículo, hora y ciclos, ubicación, sexo, rol, tipo de vehículo, UF, BR, municipio, tipo de evento, fase del día, sentido, clima, calzada, trazado, suelo y día semanal. Se agregan seis cantidades de contexto vehicular y la familia del único otro vehículo identificado. El contexto se obtiene de TODOS los vehículos antes de seleccionar víctimas, incluidos ilesos y filas sin persona, deduplicando claves positivas. Se excluyen IDs, desenlace, conteos de víctimas y atribución posterior de causa.

Columnas iguales entre años no garantizan categorías idénticas: las causas y trazados cambian. No se borra un extremo plausible solo por exceder un umbral IQR. Falta exposición por viaje, velocidad previa, casco/cinturón y atención posterior; no se estima riesgo de accidente por usuario.

La evaluación se refiere a víctimas de Brasil; cambiar el país exige actualizar título, contexto y alcance. Las fases son acumulativas sobre el mismo dataset individual y las decisiones deben ser defendidas por el grupo.