CIENCIA DE DATOS - PROYECTO INTEGRADOR

Fase 1 - Preparación y exploración

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Alcance del trabajo

Analizamos registros individuales de PRF para estudiar la gravedad y comparar modelos predictivos. Usamos herramientas de IA como apoyo en programación, análisis y redacción. El equipo debe revisar y comprender el contenido antes de presentarlo.

El modelo distingue entre víctimas heridas y fallecidas registradas por PRF. Parte de un accidente que ya ocurrió: no predice quién tendrá un accidente ni cuántos accidentes habrá el próximo año. Su evaluación es académica, no médica.

Fecha: 2 de noviembre de 2026.

Índice de secciones

1. Problema, pregunta y objetivos

2. Fuentes, claves y unidad de análisis

3. Preparación y calidad

4. Estadística descriptiva en desarrollo

5. Gráfico 1: Cantidad de heridos y fallecidos

6. Gráfico 2: Cómo se distribuyen las edades

7. Gráfico 3: Comparación de edades entre los grupos

8. Gráfico 4: Cambios a lo largo del tiempo

9. Gráfico 5: Diferencias según el vehículo

10. Gráfico 6: Edad y antigüedad del vehículo

11. Gráfico 7: Relaciones entre variables numéricas

12. Gráfico 8: Diferencias por día y horario

13. Gráfico 9: Información que falta en los registros

14. Gráfico 10: Otros vehículos en el accidente

15. Conclusión y puente a inferencia

16. Diccionario final: campos 1-15

17. Diccionario final: campos 16-30

18. Diccionario final: campos 31-37

Problema, pregunta y objetivos

Contexto y relevancia

La Policía Rodoviaria Federal de Brasil (PRF) publica datos de accidentes ocurridos en carreteras federales. Elegimos esta fuente porque permite relacionar a cada persona con su vehículo y accidente. En el trabajo anterior de Paraguay teníamos cantidades agrupadas: repetir esas cantidades como filas no creaba información individual nueva.

Pregunta principal

¿Qué características personales, vehiculares y del siniestro se asocian con el fallecimiento registrado frente a lesiones no fatales en víctimas de siniestros de PRF Brasil entre 2017 y 2025, y qu? desempeño alcanza su clasificación en el período posterior de 2026?

Objetivo general

Analizar qué características se relacionan con la gravedad y evaluar qué tan bien permiten distinguir entre víctimas heridas y fallecidas en un período posterior.

Objetivos específicos

- Unir los registros de víctimas, vehículos y accidentes mediante sus identificadores reales, sin inventar ni duplicar personas.
- Revisar la calidad de los datos y describir diferencias por edad, sexo, vehículo, lugar y horario.
- Comprobar cuatro hipótesis con pruebas estadísticas, considerando que varias víctimas pueden pertenecer al mismo accidente.
- Comparar distintas familias de modelos y evaluar cómo trabajan con muchos más heridos que fallecidos.
- Medir el resultado en datos posteriores al entrenamiento, explicar los errores y responder la pregunta de investigación.

Fuentes, claves y unidad de análisis

Usamos 20 ZIP con tablas CSV y dos diccionarios oficiales, descargados el 31/10/2026. Los archivos 2017-2025 tienen 632.713 accidentes y 1.654.197 filas en personas. El corte 2026 añade 54.895 accidentes y 148.868 filas en personas. No todas esas filas sirven para nuestro objetivo: hay ilesos, estados desconocidos y registros sin identificador de persona. En 2017-2025 hay 144.628 filas con pesid=0 que no contamos como personas identificadas.

Después de seleccionar heridos y fallecidos, 2017-2025 tiene 754.098 víctimas: 703.273 heridas y 50.825 fallecidas. El corte de 2026 agrega 67.591 víctimas, con 4.610 fallecidos. El archivo limpio reúne 821.689 participaciones reales. Usamos id para unir cada persona con un solo accidente. Verificamos que la unión no añadiera filas ni dejara víctimas sin pareja. Los datos del vehículo ya vienen en personas: no inventamos una tercera fuente.

Partición	Víctimas	Fallecidos	Accidentes
calibracion_2024_H1	43.522	2.911	29.517
comparacion_retrospectiva_2025	89.593	6.043	61.391
desarrollo_2017_2023	573.747	38.619	383.598
prueba_posterior_2026_ene_sep	67.591	4.610	46.337
umbral_2024_H2	47.236	3.252	31.903

Cada accidente queda en un solo grupo de evaluación. Una fila representa a una persona en un accidente; pesid no permite seguir su identidad a lo largo de toda su vida. Comenzamos en 2017 por el cambio al sistema BAT. La exploración y las pruebas estadísticas usan 2017-2023. Los datos de 2026 cubren enero-septiembre y se reservan para la evaluación posterior.

PRF presenta estos archivos como datos abiertos y reutilizables. Conservamos la atribución a la fuente. En data/fuentes.json guardamos sus enlaces, tamaños y huellas SHA-256, que permiten comprobar que seguimos usando los mismos archivos.

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes

Preparación y calidad

Los archivos originales usan punto y coma y codificación Latin-1; las salidas usan UTF-8. Unificamos mayúsculas, espacios y categorías con el mismo significado. Convertimos fechas y números a sus tipos correctos. También comprobamos identificadores y cantidad de filas antes y después de la unión. La bitácora registra cada decisión y cuántos casos afecta.

Una edad cero no permite saber si se trata de un bebé o de un dato sin completar. Por eso la marcamos como faltante, igual que edades negativas o mayores de 110, sin borrar a la víctima. Revisamos años de fabricación imposibles y coordenadas fuera de límites razonables. No usamos cero como reemplazo automático de la información ausente.

Conservamos las categorías desconocidas. LightGBM admite números faltantes; los modelos que necesitan completarlos aprenden ese reemplazo solo con entrenamiento. Que falte información puede depender de la víctima o de cómo se registró el accidente, por lo que no suponemos que esas ausencias ocurran totalmente al azar.

El modelo final usa 31 características: edad, sexo, rol de la persona, vehículo, antigüedad, horario, ubicación y condiciones del accidente, entre otras. Las siete características añadidas describen los otros vehículos presentes. Para construirlas usamos todos los vehículos identificados antes de seleccionar las víctimas y contamos una sola vez a un vehículo con varios ocupantes. No usamos identificadores, cantidades de muertos o heridos ni la causa atribuida después de investigar el accidente como entradas del modelo principal.

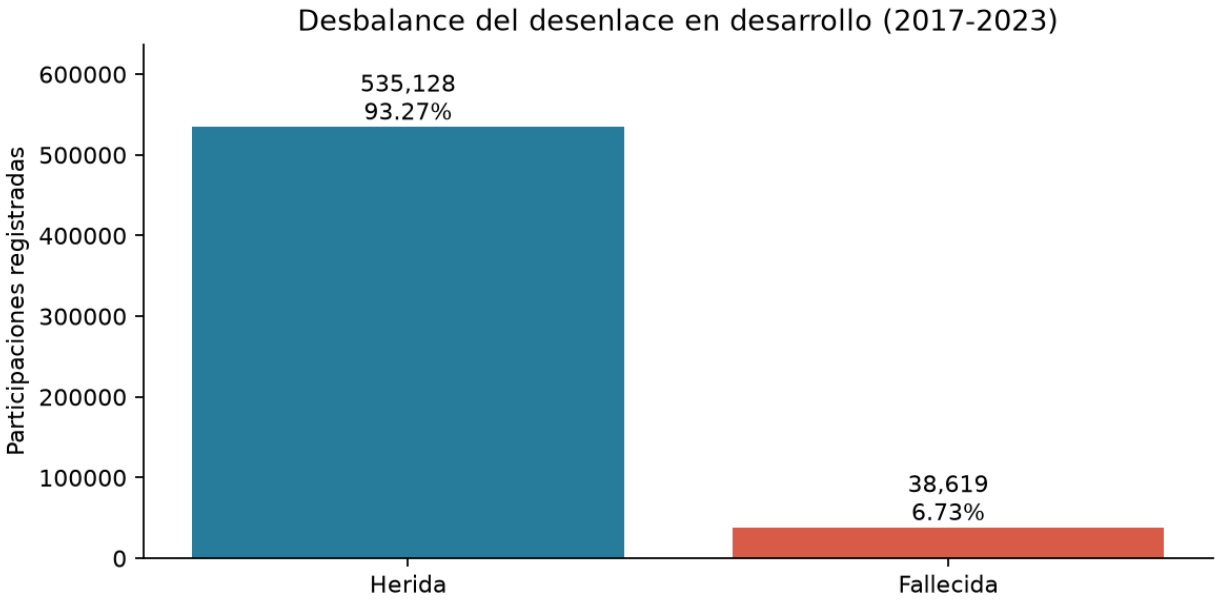
Revisamos los cambios de categorías entre años y no borramos un valor extremo solo por estar alejado de los demás si sigue siendo posible. No tenemos velocidad de impacto, casco, cinturón ni seguimiento clínico completo. Tampoco conocemos todos los viajes realizados. Por eso este estudio no estima la probabilidad de que una persona cualquiera tenga un accidente.

Estadística descriptiva en desarrollo

Variable	Media	Mediana	SD	P5 / P95	Asimetría
idade	36,91	35,00	15,43	16,00 / 65,00	0,50
idade_veiculo	9,84	9,00	7,44	1,00 / 24,00	1,86
hora	13,42	14,25	6,02	2,67 / 22,17	-0,31
km	264,88	200,70	228,46	7,10 / 717,00	0,96
latitude	-18,65	-20,23	7,74	-29,02 / -4,72	0,56
longitude	-46,52	-47,36	6,19	-55,71 / -35,88	-0,26
n_vehiculos_declarados	2,05	2,00	1,40	1,00 / 4,00	25,68
n_otros_vehiculos	0,99	1,00	1,38	0,00 / 3,00	27,03
otros_pesados	0,24	0,00	0,56	0,00 / 1,00	15,49
otras_motos	0,07	0,00	0,28	0,00 / 1,00	12,48
otros_ligeros	0,47	0,00	0,74	0,00 / 1,00	7,30

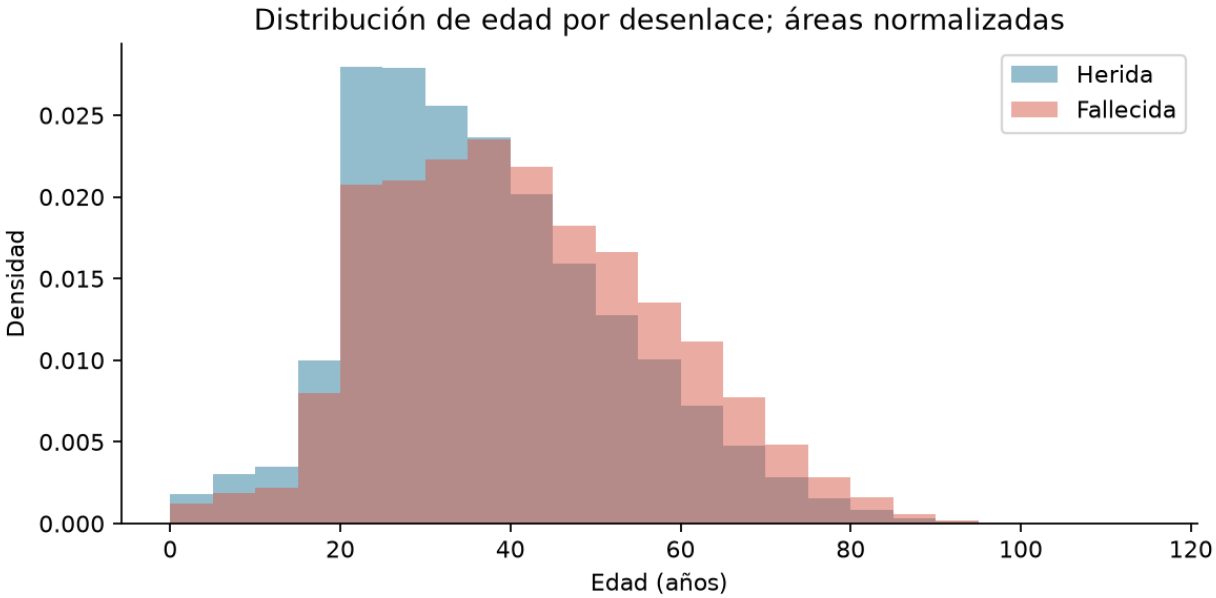
La media es el promedio; la mediana es el valor central; el desvío estándar indica cuánto se dispersan los valores. P5 y P95 dejan entre ambos al 90 % central de los casos. Cuando hay valores extremos, la mediana ayuda a no depender solo del promedio. Los CSV incluyen además moda, percentiles, asimetría, curtosis, frecuencias y correlaciones de Pearson y Spearman.

Gráfico 1: Cantidad de heridos y fallecidos



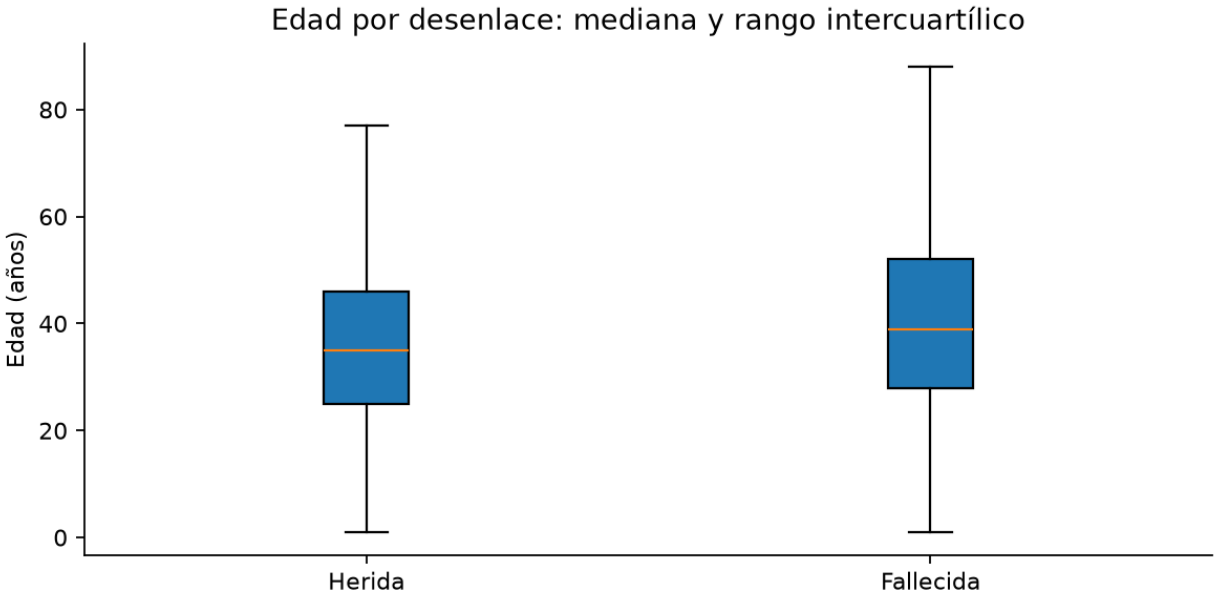
En los datos de desarrollo hay 38.619 fallecidos entre 573.747 víctimas: alrededor del 7 %. Los heridos son muchos más. Por eso, en la fase 3 no alcanza con contar los aciertos totales: también debemos revisar si el modelo identifica a los fallecidos.

Gráfico 2: Cómo se distribuyen las edades



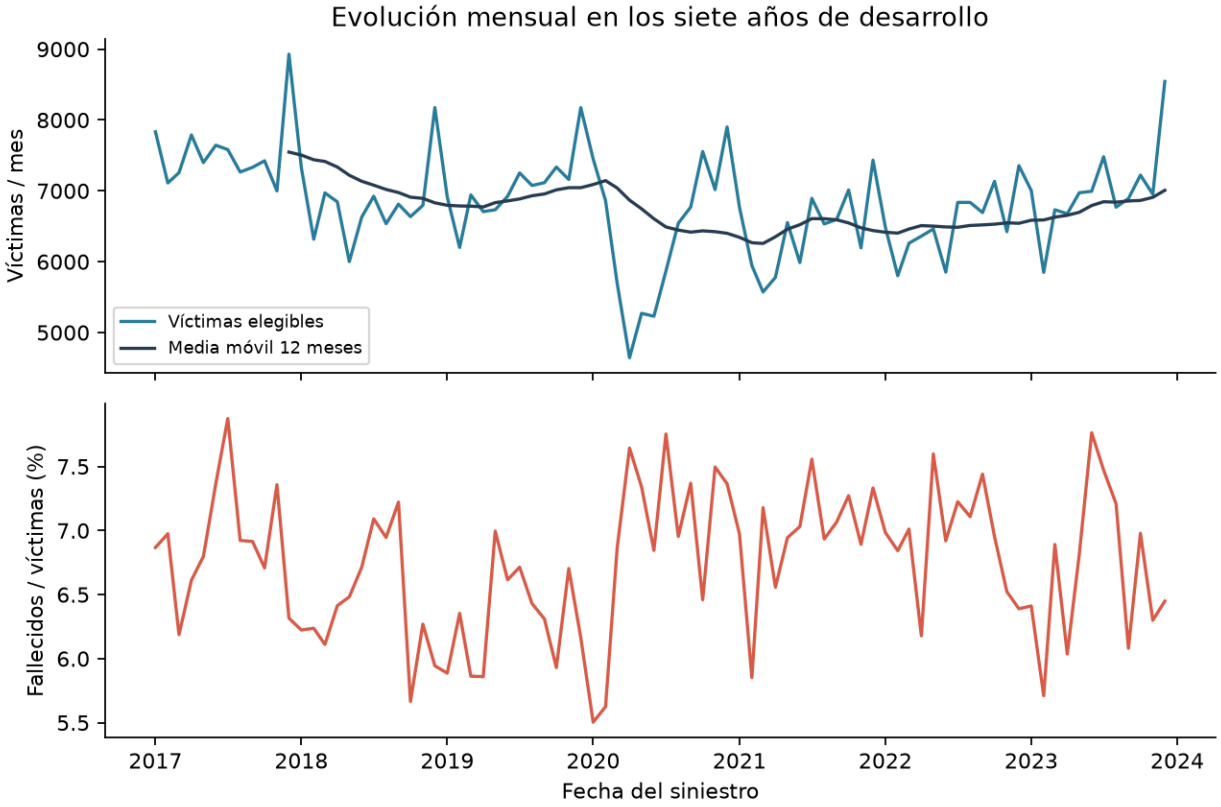
La edad mediana es de 35 años en heridos y 39 en fallecidos. La mediana deja la mitad de los casos a cada lado. Usamos proporciones para comparar los grupos sin que la mayor cantidad de heridos tape a los fallecidos.

Gráfico 3: Comparación de edades entre los grupos



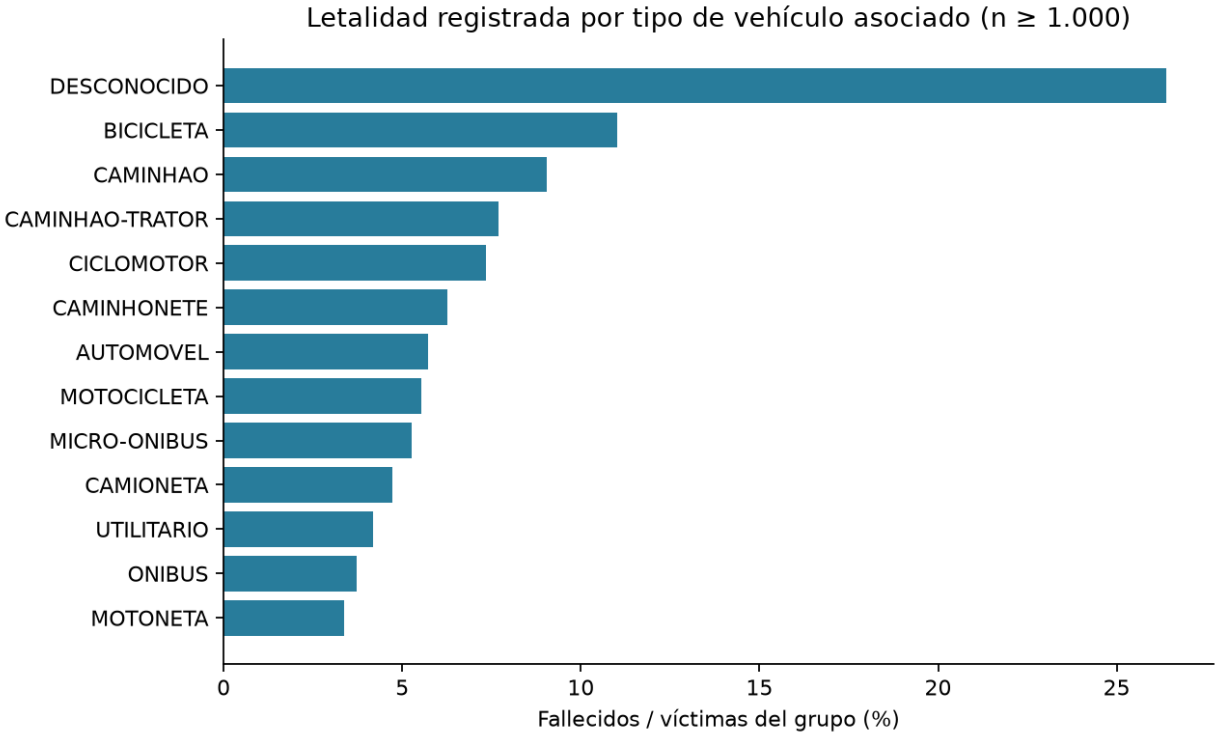
Los dos grupos comparten muchas edades. Aunque los fallecidos tienen una edad central algo mayor, conocer la edad no alcanza para saber cómo terminará un caso. No eliminamos una edad válida solo por estar alejada de las demás.

Gráfico 4: Cambios a lo largo del tiempo



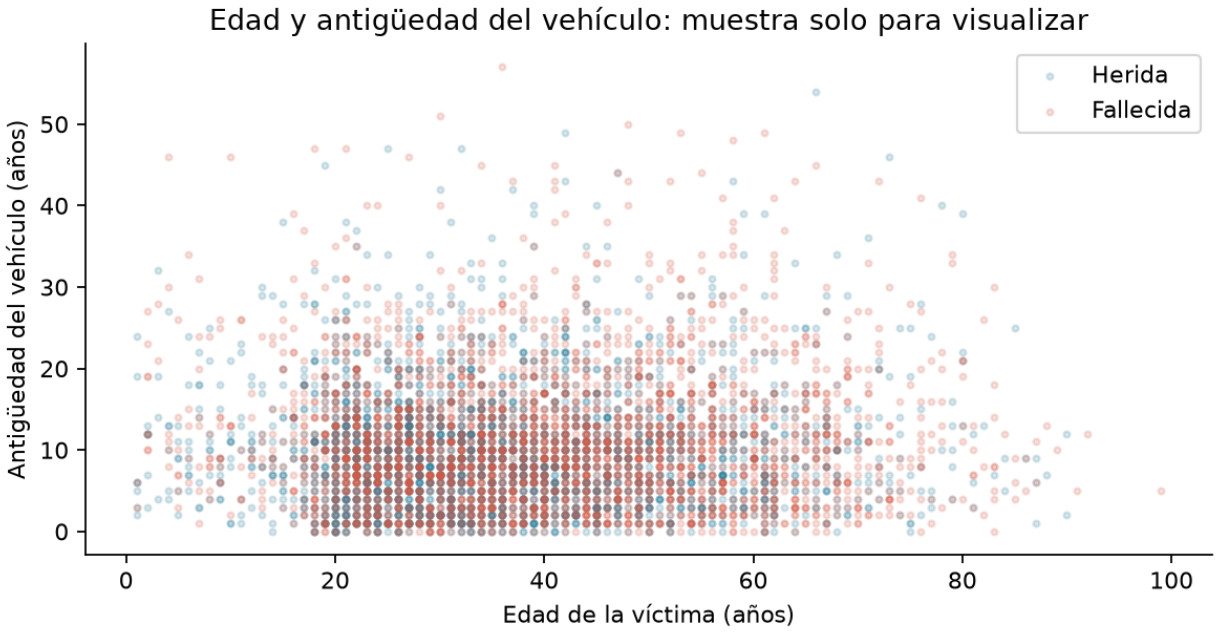
La cantidad de víctimas y la proporción de fallecidos cambian entre meses y años. Esto puede relacionarse con la circulación y con la forma de registrar los casos. El gráfico cuenta víctimas registradas, no todos los viajes. Por eso evaluamos respetando el orden de los años.

Gráfico 5: Diferencias según el vehículo



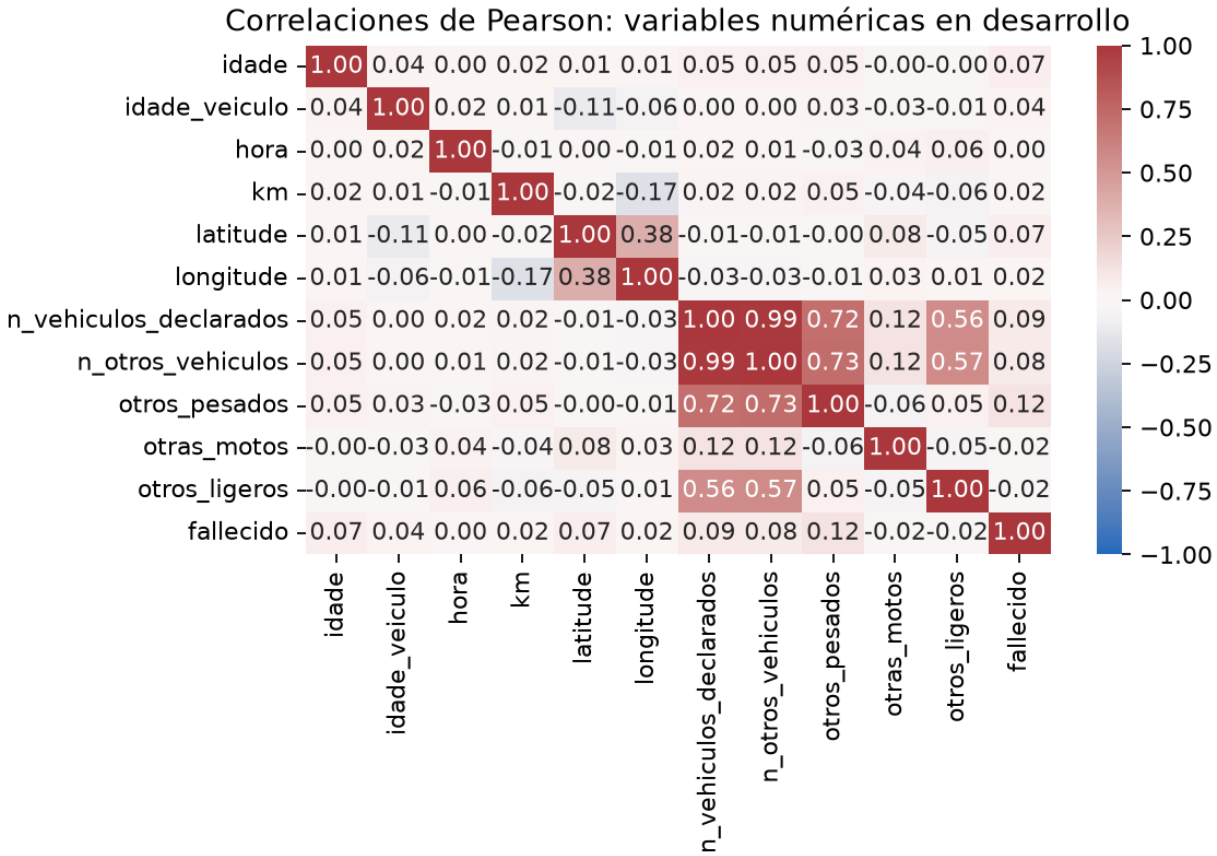
La proporción de fallecidos cambia según el vehículo. Calculamos cada porcentaje dentro de su grupo. Esto no demuestra que un vehículo sea más seguro por viaje: aquí observamos personas que ya resultaron heridas o fallecidas.

Gráfico 6: Edad y antigüedad del vehículo



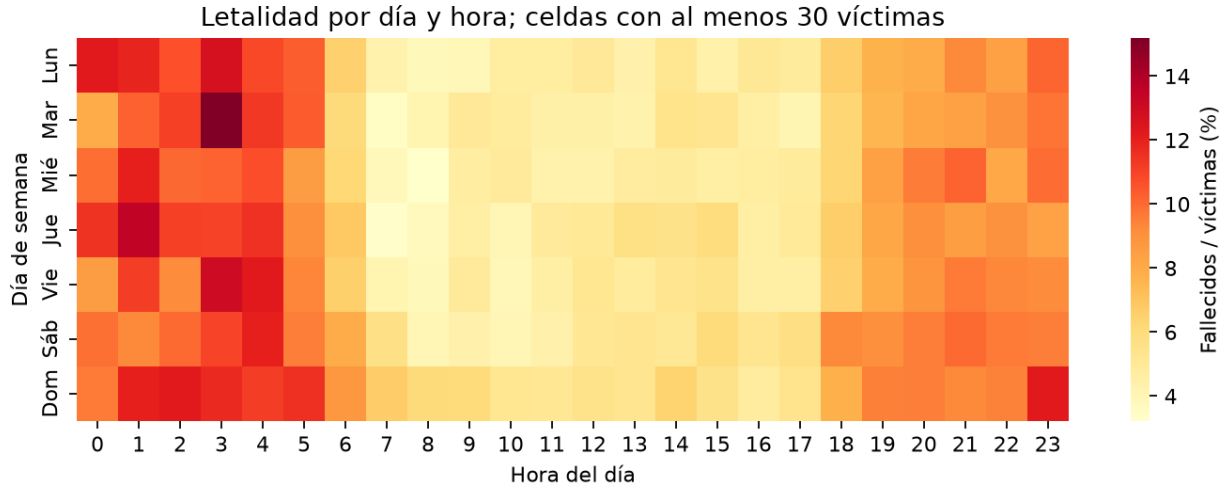
Cada punto representa un caso. Mostramos 3.000 heridos y 3.000 fallecidos para que ambos grupos se vean; esa selección solo se usa en el gráfico. Los puntos se mezclan bastante: estas dos características no separan completamente los resultados.

Gráfico 7: Relaciones entre variables numéricas



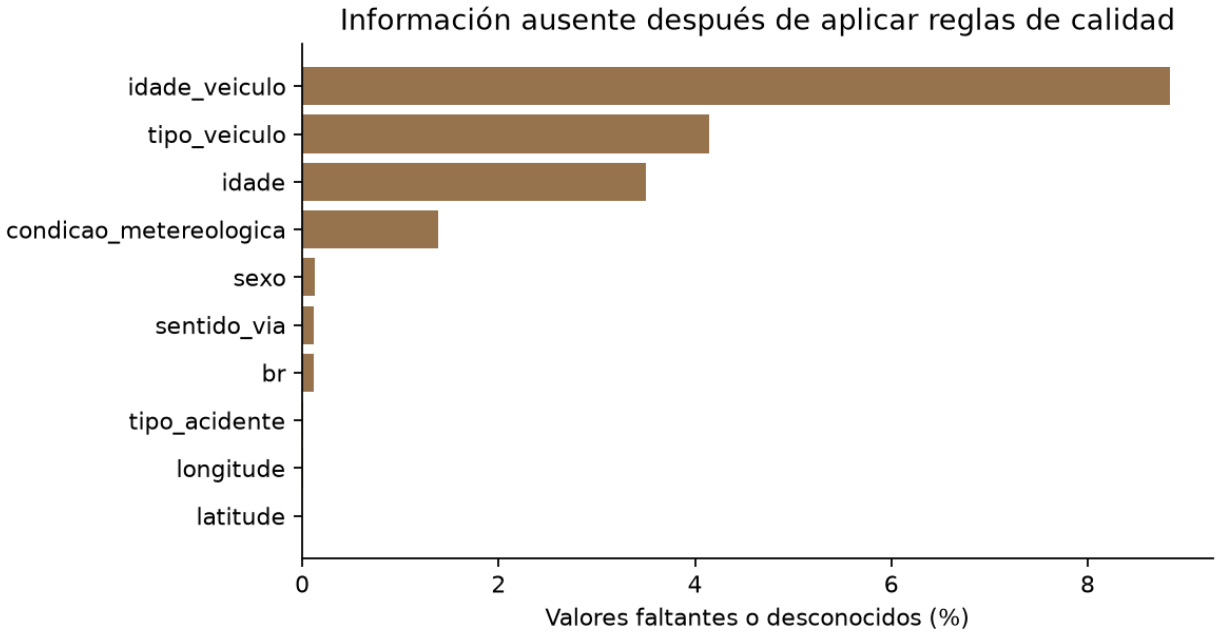
El mapa resume qué variables tienden a cambiar juntas de forma lineal. Las coordenadas indican ubicación, no una característica personal. Una correlación no demuestra que una variable cause el resultado ni garantiza que ayude a predecir.

Gráfico 8: Diferencias por día y horario



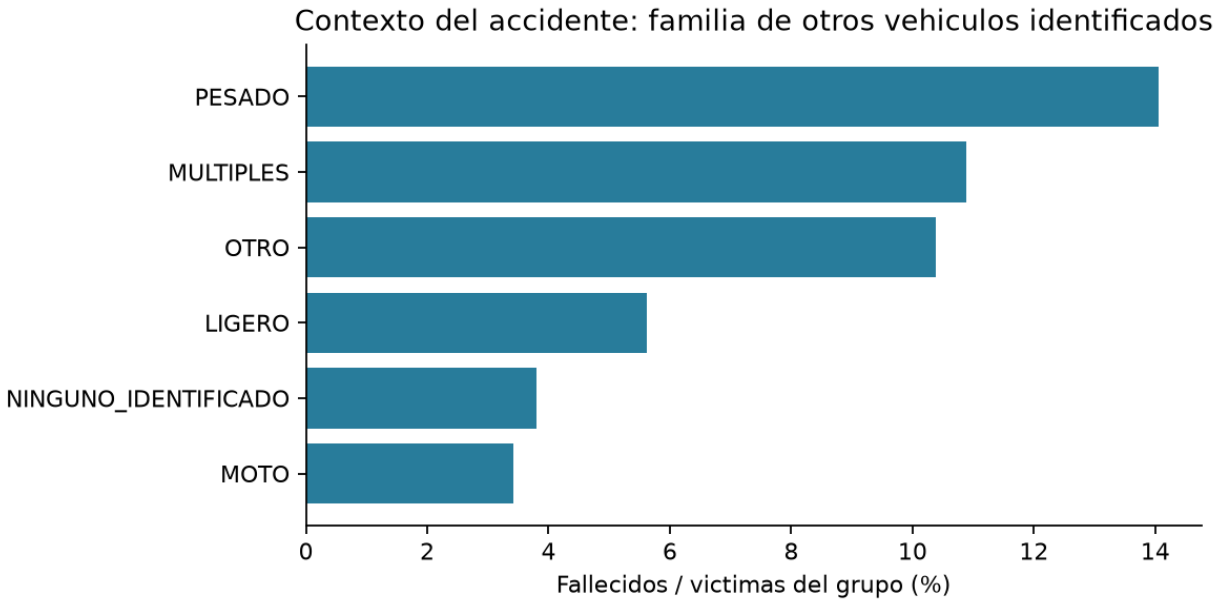
Los colores muestran la proporción de fallecidos por día y hora, usando celdas con al menos 30 víctimas. Estas diferencias nos llevan a estudiar la noche en la fase 2. No podemos separar aquí el horario de otros factores, como cuánto se circula o qué choques ocurren.

Gráfico 9: Información que falta en los registros



No todos los registros tienen la misma información. Conservamos las víctimas y marcamos lo desconocido. LightGBM admite números faltantes; en los modelos que necesitan completarlos, aprendemos el reemplazo solo con entrenamiento.

Gráfico 10: Otros vehículos en el accidente



Relacionamos los vehículos mediante el identificador real del accidente. Así sabemos si aparecen otros vehículos pesados, motos o vehículos ligeros. La categoría de varios vehículos no indica exactamente quién chocó con quién. Estas diferencias no prueban causas.

Conclusión y puente a inferencia

Ahora podemos estudiar conjuntamente información real de personas, vehículos y accidentes. Hay diferencias entre grupos, pero también mucha superposición de edades. Estos patrones no demuestran causas ni garantizan que una característica aislada alcance para predecir la gravedad.

Exploramos 573.747 víctimas de 2017-2023. En los años posteriores revisamos cobertura y calidad, pero no los usamos para buscar los patrones de esta fase. La fase 1 muestra qué información tenemos y cómo se comporta; la capacidad predictiva se comprueba en la fase 3.

Llevamos cuatro preguntas a la fase 2: si sexo y gravedad están relacionados, si las edades difieren, si cambia la proporción de fallecidos entre motos y otros vehículos, y si la noche se relaciona con la gravedad al considerar otras características. No elegimos variables únicamente porque una prueba dé un valor p pequeño.

Los resultados corresponden a las víctimas registradas por PRF. Faltan casos que no se registraron, información de seguridad y seguimiento completo de fallecimientos posteriores. Las víctimas de un mismo accidente comparten condiciones. No podemos trasladar automáticamente los resultados a todo Brasil o a Paraguay.

Diccionario final: campos 1-15

Campo	Significado / unidad	Tipo	Faltante %
id	Identificador real del accidente; clave de union, nunca predictor	int64	0,00
pesid	Identificador positivo de participacion; no identidad civil longitudinal	int64	0,00
id_veiculo	Identificador del vehiculo, cero desconocido/no aplicable; nunca predictor	int64	3,98
fecha	Fecha del siniestro; permite particion cronologica	datetime64[us]	0,00
ano	Anio de siniestro; particion y auditoria	int16	0,00
fallecido	Objetivo binario; 1 obito, 0 lesiones leves/graves	int8	0,00
idade	Edad en anios; 0 ambiguo, negativos y >110 a faltante	float32	3,29
idade_veiculo	Antiguedad del vehiculo en anios al siniestro	float32	8,77
hora	Hora del dia decimal 0..24	float32	0,00
hora_sin	Seno del ciclo horario, sin unidad	float32	0,00
hora_cos	Coseno del ciclo horario, sin unidad	float32	0,00
mes_sin	Seno del ciclo mensual, sin unidad	float32	0,00
mes_cos	Coseno del ciclo mensual, sin unidad	float32	0,00
latitude	Latitud decimal en grados	float32	0,00
longitude	Longitud decimal en grados	float32	0,01

Los nombres de campos permiten ubicar las columnas en el código. Los diccionarios original y final completos están en output/tables/. Un id_veiculo igual a cero indica información ausente o no aplicable, no un vehículo real.

Diccionario final: campos 16-30

Campo	Significado / unidad	Tipo	Faltante %
km	Kilometro de carretera BR	float32	0,00
n_vehiculos_declarados	Cantidad de vehiculos declarada por accidente; no cantidad de victimas	float32	0,00
n_vehiculos_identificados	Vehiculos con ID positivo distintos en la exportacion completa	float32	0,00
n_otros_vehiculos	Vehiculos identificados descontando el propio cuando existe	float32	0,00
otros_pesados	Otros camiones, camiones-tractor, omnibus o micro-omnibus identificados	float32	0,00
otras_motos	Otras motocicletas, motonetas o ciclomotores identificados	float32	0,00
otros_ligeros	Otros automoviles, camionetas o utilitarios identificados	float32	0,00
sexo	Sexo registrado	category	0,11
tipo_envolvido	Rol de participacion: conductor, pasajero, peaton, etc.	category	0,00
tipo_veiculo	Tipo de vehiculo asociado	category	3,99
uf	Unidad federativa del siniestro	category	0,00
br	Identificador de carretera federal, categoria	category	0,10
municipio	Municipio del siniestro	category	0,00
tipo_acidente	Tipo principal del evento, conocido al observar el siniestro	category	0,01
fase_dia	Fase del dia registrada	category	0,00

Los nombres de campos permiten ubicar las columnas en el código. Los diccionarios original y final completos están en output/tables/. Un id_veiculo igual a cero indica información ausente o no aplicable, no un vehículo real.

Diccionario final: campos 31-37

Campo	Significado / unidad	Tipo	Faltante %
sentido_via	Sentido de circulacion	category	0,10
condicao_metereologica	Condicion meteorologica observada	category	1,32
tipo_pista	Tipo de calzada	category	0,00
tracado_via	Trazado, a veces compuesto por varios elementos separados por punto y coma	category	0,00
uso_solo	SIM urbano; NAO rural	category	0,00
dia_semana	Dia de semana calculado: 0 lunes, 6 domingo	category	0,00
familia_otro_vehiculo	Familia del unico otro vehiculo identificado; ninguno o multiples en los demas casos	category	0,00

Los nombres de campos permiten ubicar las columnas en el código. Los diccionarios original y final completos están en output/tables/. Un id_veiculo igual a cero indica información ausente o no aplicable, no un vehículo real.