CIENCIA DE DATOS - PROYECTO INTEGRADOR

Fase 1 - Preparación y exploración

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Qué contiene este material

Resultados calculados con registros individuales y evaluación temporal. Borrador de apoyo académico con asistencia de IA: el equipo debe revisar, comprender y asumir las decisiones metodológicas y las interpretaciones antes de presentar.

El modelo estima un desenlace registrado entre víctimas lesionadas atendidas por PRF. No predice quién sufrirá un accidente, no establece causas y no está validado para uso médico ni para Paraguay.

Fecha: 31 de octubre de 2026.

Índice de secciones

1. Problema, pregunta y objetivos

2. Fuentes, claves y unidad de análisis

3. Preparación y calidad

4. Estadística descriptiva en desarrollo

5. Exploración 1: clases

6. Exploración 2: histograma edad

7. Exploración 3: cajas edad

8. Exploración 4: serie temporal

9. Exploración 5: vehiculos

10. Exploración 6: dispersion

11. Exploración 7: correlaciones

12. Exploración 8: dia hora

13. Exploración 9: faltantes

14. Exploración 10: contexto

15. Conclusión y puente a inferencia

16. Diccionario final: campos 1-15

17. Diccionario final: campos 16-30

18. Diccionario final: campos 31-37

Problema, pregunta y objetivos

Contexto y relevancia

PRF publica registros administrativos de siniestros en carreteras federales y sus involucrados. Comprender qué características distinguen lesiones no fatales y fallecimientos registrados permite formular hipótesis y evaluar predicción académica. El trabajo anterior de Paraguay solo disponía de totales agrupados: expandirlos no creaba información individual.

Pregunta principal

¿Qué características personales, vehiculares y del siniestro se asocian con el fallecimiento registrado frente a lesiones no fatales en víctimas de siniestros de PRF Brasil entre 2017 y 2025, y qu? desempeño alcanza su clasificación en el período posterior de 2026?

Objetivo general

Analizar asociaciones entre características individuales y del siniestro con el desenlace y evaluar la capacidad de modelos para clasificar víctimas heridas o fallecidas registradas, mediante un procedimiento reproducible y sin filtraciones del resultado.

Objetivos específicos

- Construir una tabla individual de víctimas con sus características personales, vehiculares y del siniestro mediante claves reales y controles de unión.
- Evaluar la calidad, las ausencias y los patrones de edad, sexo, vehículo, lugar y tiempo en 2017-2023.
- Contrastar cuatro hipótesis con tamaños de efecto, intervalos y corrección de multiplicidad, considerando víctimas del mismo accidente.
- Comparar modelos de varias familias con validación temporal, calibración y tratamiento explícito del desbalance.
- Medir en 2025 el aporte de las nuevas variables frente a sexo/edad y referencias triviales, comunicando errores y límites.

Fuentes, claves y unidad de análisis

Se conservan 20 ZIP CSV y 2 diccionarios PDF oficiales del corte descargado el 31/10/2026. En 2017-2025 hay 632.713 accidentes distintos y 1.654.197 filas en personas; el corte 2026 agrega 54.895 ocurrencias y 148.868 filas en personas. Se descartaron del objetivo ilesos y desenlaces desconocidos; 144.628 filas con pesid=0 de 2017-2025 no se cuentan como individuos identificados.

La base principal 2017-2025 tiene 754.098 víctimas con desenlace válido: 703.273 heridas y 50.825 fallecidas. El corte posterior 2026 agrega 67.591 víctimas (4.610 fallecidas). El dataset limpio consolidado contiene 821.689 participaciones. La unión personas.id a accidentes.id es muchos a uno, sin expansión ni víctimas sin pareja. Las claves de víctimas son únicas; los datos de vehículo ya están asociados en personas. No se inventó una tercera fuente independiente.

Partición	Víctimas	Fallecidos	Accidentes
calibracion_2024_H1	43.522	2.911	29.517
comparacion_retrospectiva_2025	89.593	6.043	61.391
desarrollo_2017_2023	573.747	38.619	383.598
prueba_posterior_2026_ene_sep	67.591	4.610	46.337
umbral_2024_H2	47.236	3.252	31.903

No hay accidentes compartidos entre particiones. pesid identifica una participación, no identidad civil longitudinal. Se inicia en 2017 por el cambio al sistema BAT. El corte 2026 se utiliza exclusivamente como validación posterior: no es un año completo y no integra la exploración o inferencia.

Fuente y licencia de datos: PRF los presenta como datos abiertos reutilizables. Se conserva atribución; la licencia del sitio web no se confunde con una licencia adicional de cada CSV. URLs exactas, tamaños y SHA-256 están en data/fuentes.json.

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes

Preparación y calidad

El CSV original usa Latin-1 y punto y coma; las salidas usan UTF-8. Se normalizan mayúsculas, espacios y acentos de categorías, conservando la semántica. Se verifican hashes, claves, fechas y cardinalidad de la unión. La bitácora registra afectados por regla y por año.

Edad cero se considera ambigua y se trata como faltante sin eliminar la víctima, al igual que edades negativas o mayores de 110. Se invalida año de vehículo cero o posterior al siniestro y se calcula antigüedad. Coordenadas fuera de límites geográficos amplios y posiciones imposibles se conservan como ausencia, no se imputan como cero.

Las categorías desconocidas se conservan. Medianas, escalado, categorías y discretización se aprenden dentro de cada entrenamiento. Los faltantes pueden depender de gravedad, rol y calidad de registro; no se presume mecanismo completamente aleatorio.

El modelo final usa 31 predictores. Los 24 iniciales incluyen edad, antigüedad de vehículo, hora y ciclos, ubicación, sexo, rol, tipo de vehículo, UF, BR, municipio, tipo de evento, fase del día, sentido, clima, calzada, trazado, suelo y día semanal. Se agregan seis cantidades de contexto vehicular y la familia del único otro vehículo identificado. El contexto se obtiene de TODOS los vehículos antes de seleccionar víctimas, incluidos ilesos y filas sin persona, deduplicando claves positivas. Se excluyen IDs, desenlace, conteos de víctimas y atribución posterior de causa.

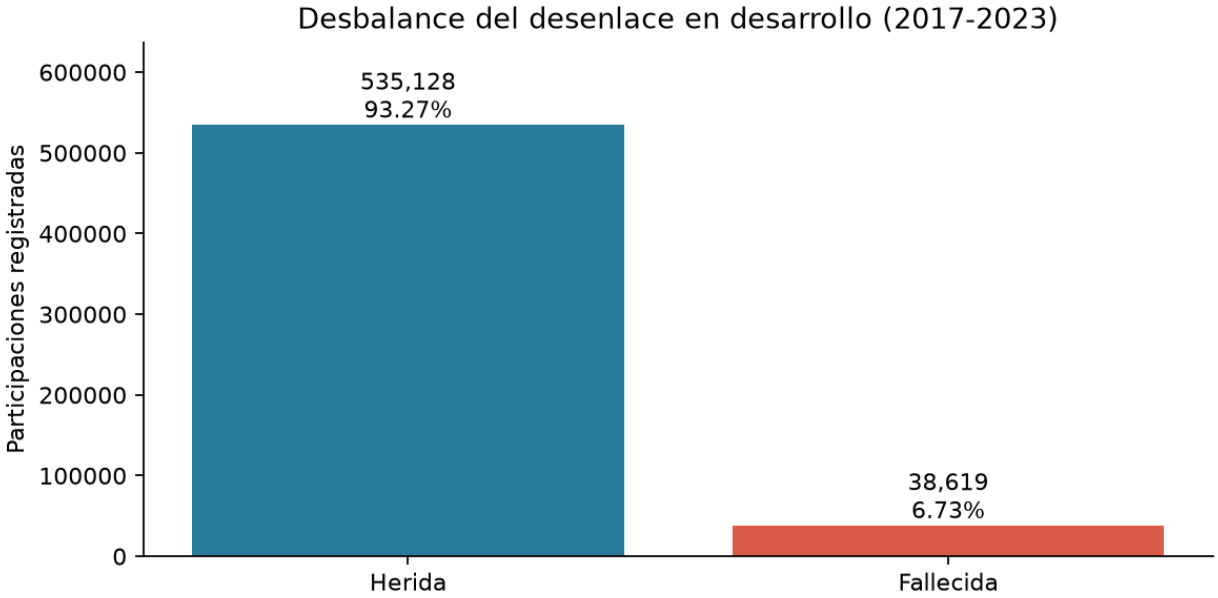
Columnas iguales entre años no garantizan categorías idénticas: las causas y trazados cambian. No se borra un extremo plausible solo por exceder un umbral IQR. Falta exposición por viaje, velocidad previa, casco/cinturón y atención posterior; no se estima riesgo de accidente por usuario.

Estadística descriptiva en desarrollo

Variable	Media	Mediana	SD	P5 / P95	Asimetría
idade	36,91	35,00	15,43	16,00 / 65,00	0,50
idade_veiculo	9,84	9,00	7,44	1,00 / 24,00	1,86
hora	13,42	14,25	6,02	2,67 / 22,17	-0,31
km	264,88	200,70	228,46	7,10 / 717,00	0,96
latitude	-18,65	-20,23	7,74	-29,02 / -4,72	0,56
longitude	-46,52	-47,36	6,19	-55,71 / -35,88	-0,26
n_vehiculos_declarados	2,05	2,00	1,40	1,00 / 4,00	25,68
n_otros_vehiculos	0,99	1,00	1,38	0,00 / 3,00	27,03
otros_pesados	0,24	0,00	0,56	0,00 / 1,00	15,49
otras_motos	0,07	0,00	0,28	0,00 / 1,00	12,48
otros_ligeros	0,47	0,00	0,74	0,00 / 1,00	7,30

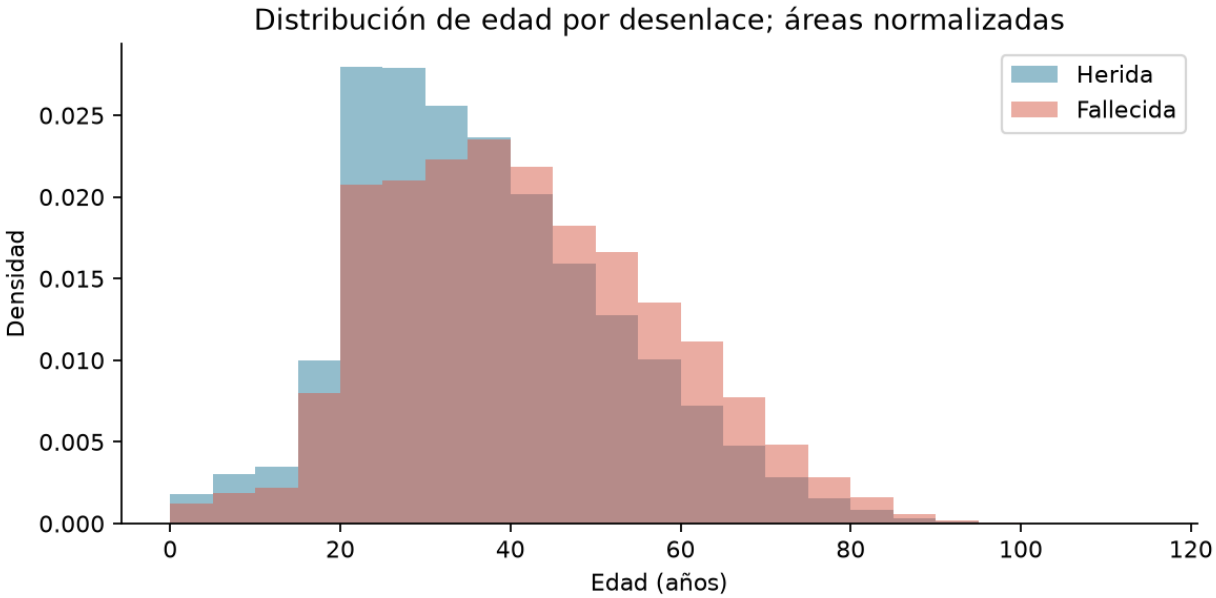
El anexo CSV añade moda, CV, IQR, mínimo, máximo, percentiles y curtosis. Las distribuciones asimétricas requieren acompañar medias con medianas y dispersión. Los IDs no son medidas sustantivas. Las matrices Pearson/Spearman y las contingencias absolutas y por fila/columna se conservan como CSV.

Exploración 1: clases



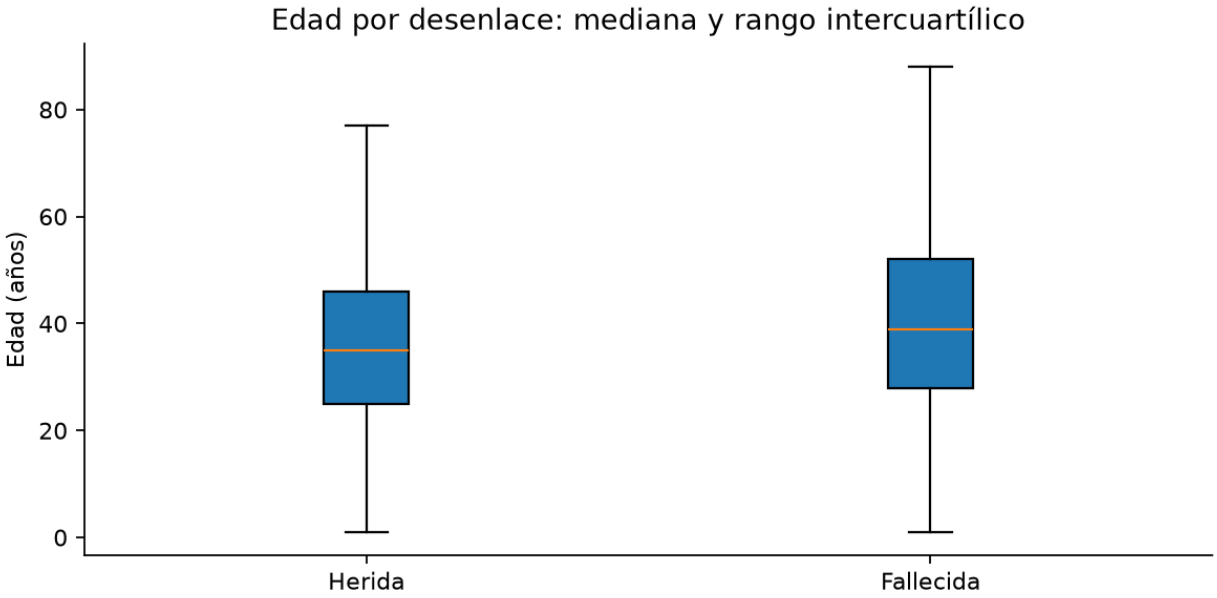
En desarrollo hay 38,619 fallecidos entre 573,747 víctimas (6.73%). La clase mayoritaria domina el total de aciertos, por lo que evaluar solo exactitud ocultaría los errores de fallecidos.

Exploración 2: histograma edad



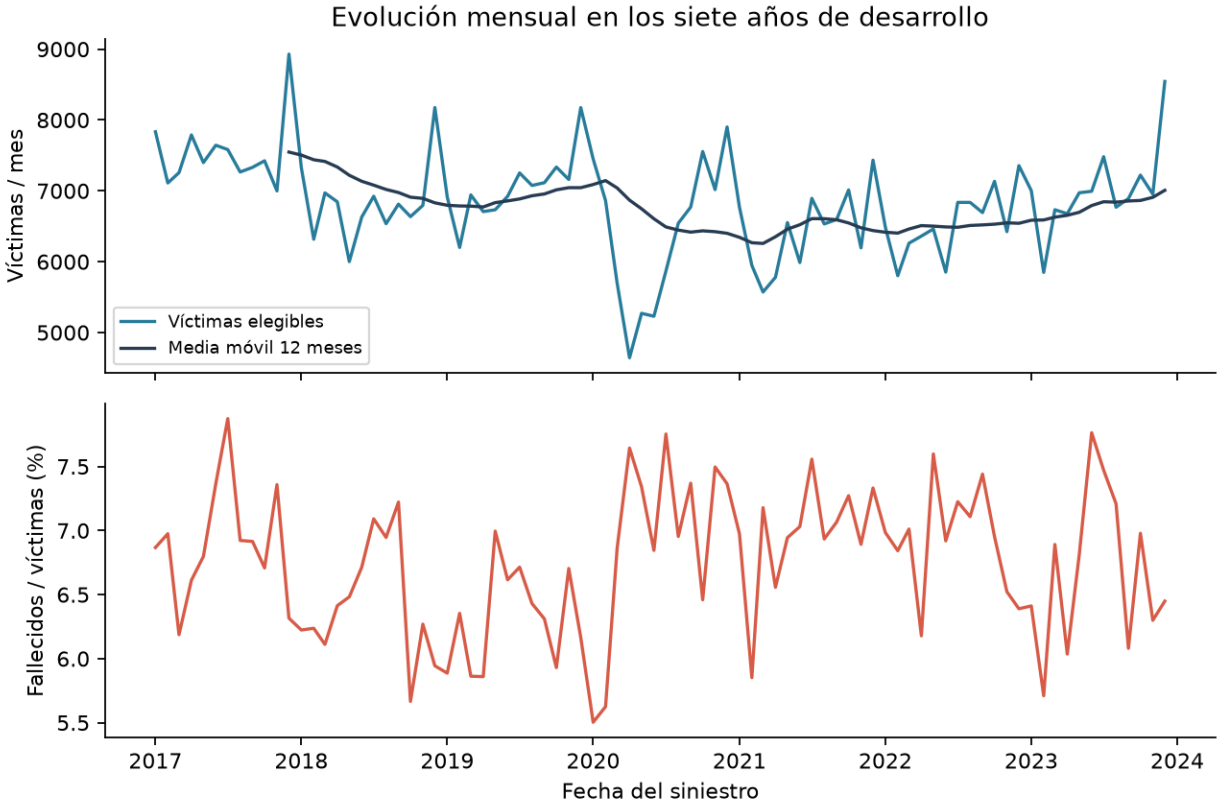
La mediana de edad registrada es 35 años en heridos y 39 en fallecidos. Se comparan densidades para que la mayor cantidad de heridos no oculte la distribución de fallecidos; edad faltante se conserva en los modelos mediante imputación.

Exploración 3: cajas edad



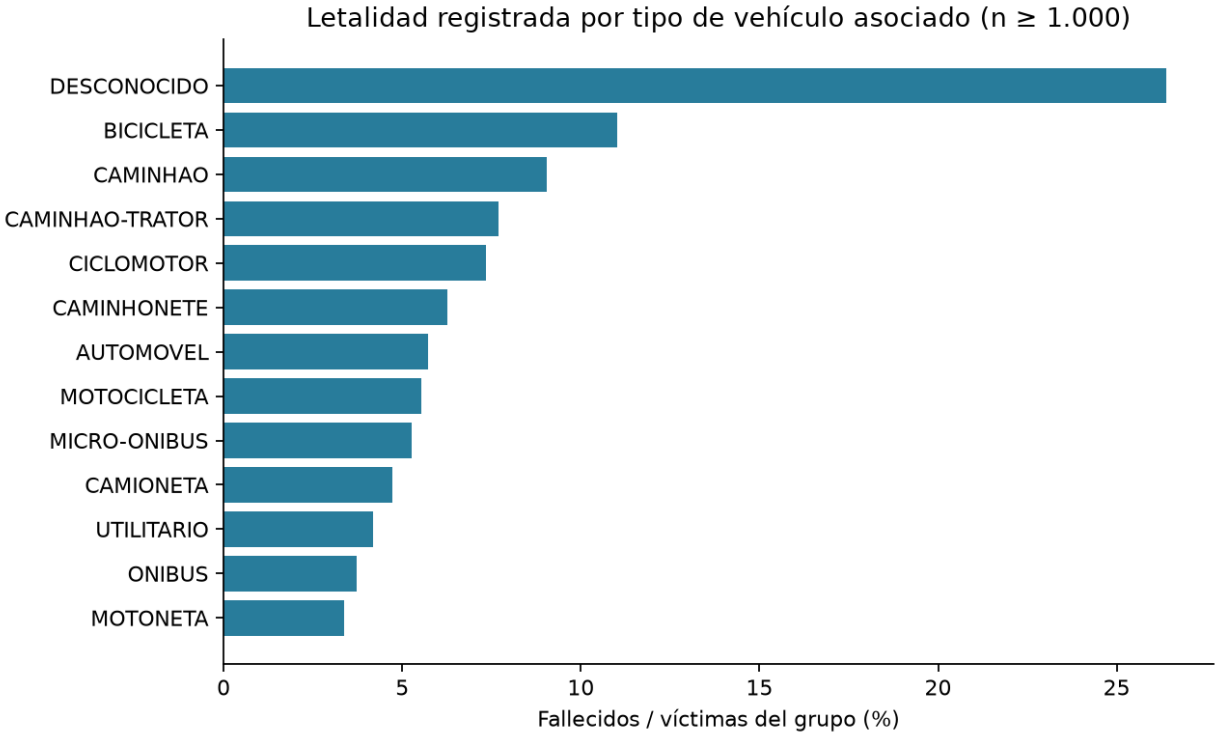
Las cajas muestran dispersión y superposición de edades. Una diferencia de centros entre grupos no permite clasificar perfectamente individuos; los bigotes no se usan para borrar edades plausibles.

Exploración 4: serie temporal



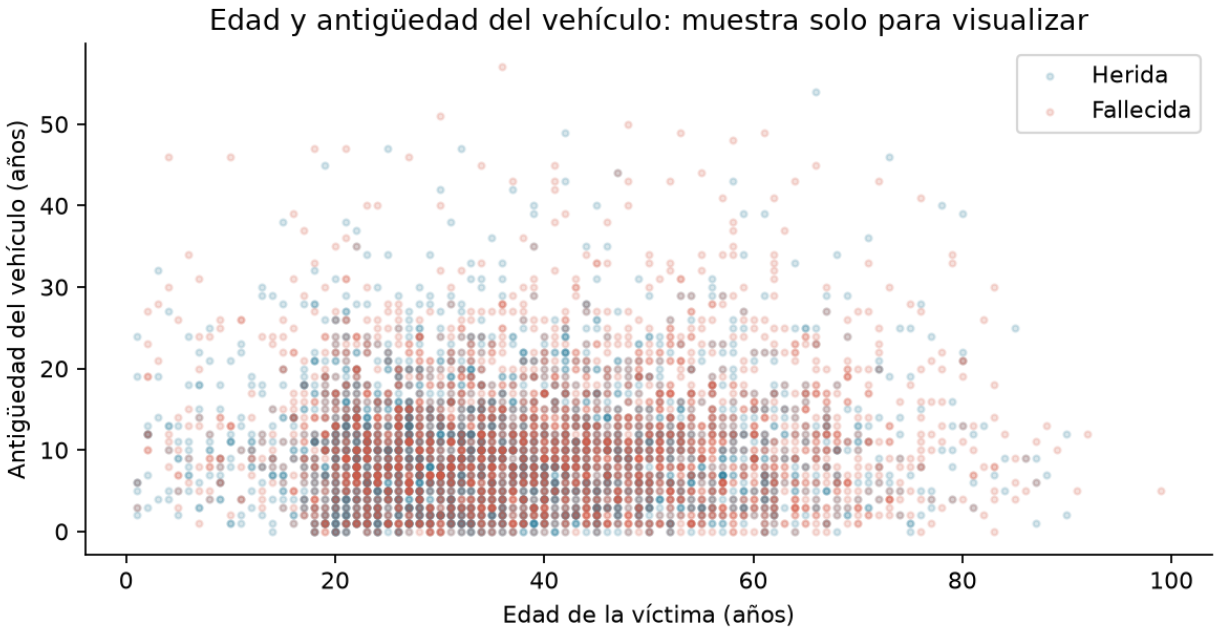
El volumen y la proporción de fallecimientos no permanecen idénticos todos los años. La serie corresponde a víctimas heridas o fallecidas registradas, sin medir exposición al tránsito; cambios de movilidad y registro pueden afectar las diferencias. Se respeta el orden temporal al validar.

Exploración 5: vehiculos



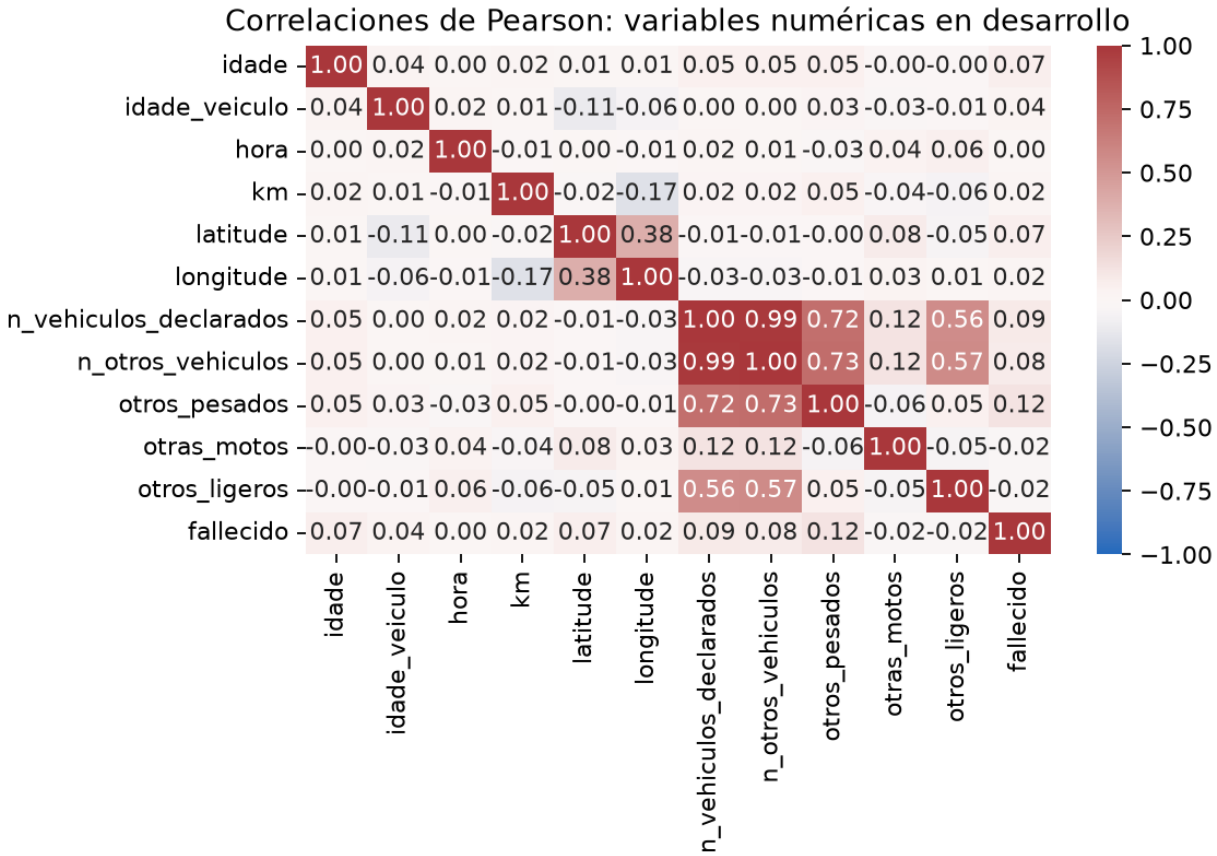
Los tipos de vehículo muestran proporciones diferentes, calculadas con las víctimas de cada grupo como denominador. No representan riesgo por viaje ni una comparación causal; peatones y vehículo desconocido requieren interpretar el rol de participación.

Exploración 6: dispersion



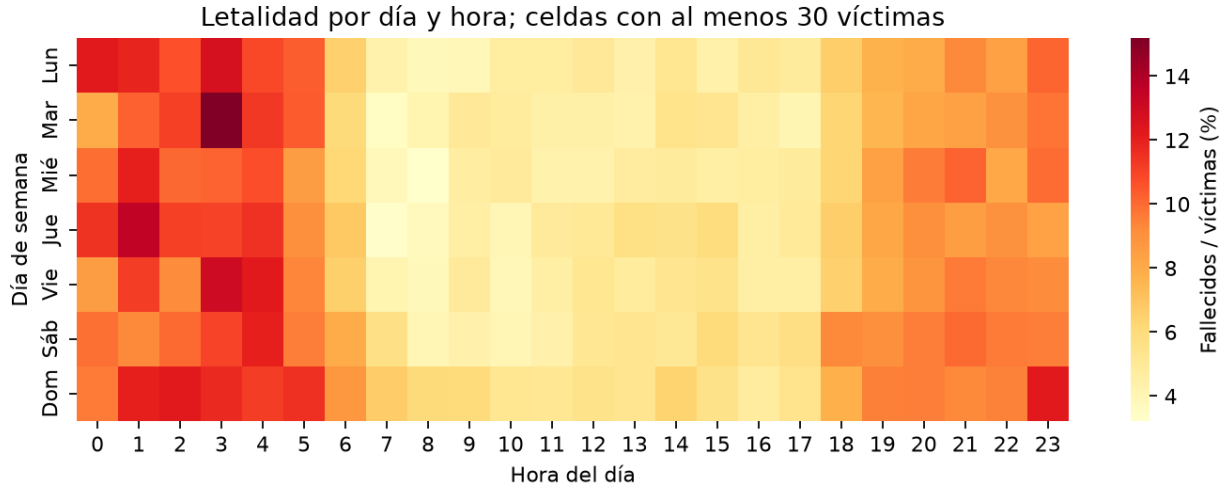
Se muestran 3.000 casos por clase únicamente para que ambas sean visibles. Este balance visual no modifica el entrenamiento ni la prueba. La superposición indica que dos características aisladas no separan completamente los desenlaces.

Exploración 7: correlaciones



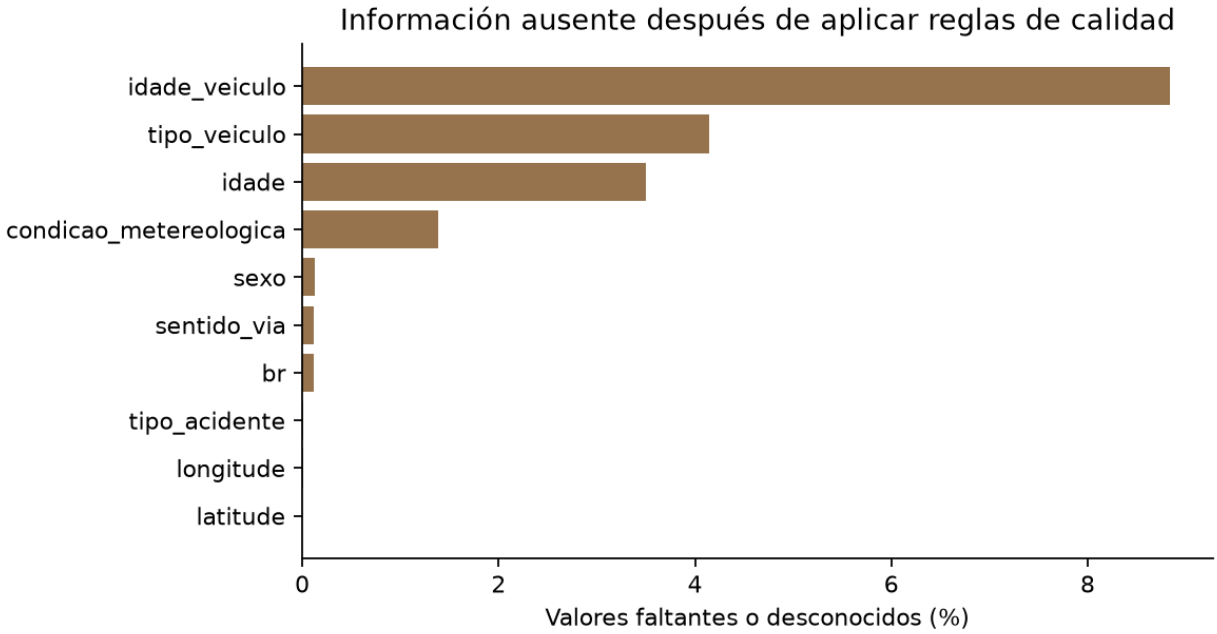
La correlación lineal resume solo una parte de la relación. Latitud y longitud describen localización, y la variable binaria de desenlace permite una lectura descriptiva, sin demostrar causalidad ni sustituir la evaluación predictiva.

Exploración 8: dia hora



El patrón horario justifica estudiar nocturnidad, con diferencias de exposición y tipo de siniestro como posibles confusores. Las celdas contienen víctimas, no conteos independientes de accidentes; un mapa más intenso no mide riesgo por kilómetro recorrido.

Exploración 9: faltantes



Las ausencias pueden relacionarse con el tipo de víctima y la calidad del registro; no se supone que falten completamente al azar. Se conservan filas y categorías desconocidas, con imputación numérica aprendida exclusivamente dentro de cada entrenamiento.

Exploración 10: contexto



El contexto de otros vehiculos permite caracterizar el mismo siniestro con claves reales. Las proporciones estan condicionadas a victimas lesionadas registradas; no son riesgo por viaje ni prueba causal. La categoria multiples no identifica parejas de colision.

Conclusión y puente a inferencia

La información ya permite analizar conjuntamente características de personas, vehículos y siniestros; las tablas comparten claves reales. Se observan desbalance marcado, superposición de edades y diferencias entre tipos de evento y vehículo. Estas asociaciones descriptivas no prueban causas ni aseguran capacidad predictiva.

La exploración utiliza únicamente 573.747 víctimas de 2017-2023. El perfilado previo de los años posteriores se limitó a auditar cobertura y calidad; no es un estudio externo completamente ciego. La respuesta parcial es que los datos permiten investigar la pregunta, mientras que la utilidad para predecir debe medirse separadamente.

La fase 2 lleva cuatro hipótesis: sexo y desenlace; distribución de edad; letalidad de usuarios de moto frente a otros vehículos; nocturnidad condicionada a otros factores. En fase 3 se conservan predictores por plausibilidad y disponibilidad, sin hacer selección automática por valores p.

Las limitaciones son cobertura institucional, desenlace registrado sin seguimiento a 30 días, falta de exposición y datos de seguridad, ausencias informativas, cambios de registro y dependencia entre víctimas. Los resultados no representan todos los accidentes de Brasil y no se trasladan directamente a Paraguay.

Diccionario final: campos 1-15

Campo	Significado / unidad	Tipo	Faltante %
id	Identificador real del accidente; clave de union, nunca predictor	int64	0,00
pesid	Identificador positivo de participacion; no identidad civil longitudinal	int64	0,00
id_veiculo	Identificador del vehiculo, cero desconocido/no aplicable; nunca predictor	int64	3,98
fecha	Fecha del siniestro; permite particion cronologica	datetime64[us]	0,00
ano	Anio de siniestro; particion y auditoria	int16	0,00
fallecido	Objetivo binario; 1 obito, 0 lesiones leves/graves	int8	0,00
idade	Edad en anios; 0 ambiguo, negativos y >110 a faltante	float32	3,29
idade_veiculo	Antiguedad del vehiculo en anios al siniestro	float32	8,77
hora	Hora del dia decimal 0..24	float32	0,00
hora_sin	Seno del ciclo horario, sin unidad	float32	0,00
hora_cos	Coseno del ciclo horario, sin unidad	float32	0,00
mes_sin	Seno del ciclo mensual, sin unidad	float32	0,00
mes_cos	Coseno del ciclo mensual, sin unidad	float32	0,00
latitude	Latitud decimal en grados	float32	0,00
longitude	Longitud decimal en grados	float32	0,01

Categorías y rangos observados, tipos, trazabilidad y perfil original se acompañan en las tablas y en los diccionarios oficiales. Cero de id_veiculo es ausencia/no aplicable aunque sea numérico.

Diccionario final: campos 16-30

Campo	Significado / unidad	Tipo	Faltante %
km	Kilometro de carretera BR	float32	0,00
n_vehiculos_declarados	Cantidad de vehiculos declarada por accidente; no cantidad de victimas	float32	0,00
n_vehiculos_identificados	Vehiculos con ID positivo distintos en la exportacion completa	float32	0,00
n_otros_vehiculos	Vehiculos identificados descontando el propio cuando existe	float32	0,00
otros_pesados	Otros camiones, camiones-tractor, omnibus o micro-omnibus identificados	float32	0,00
otras_motos	Otras motocicletas, motonetas o ciclomotores identificados	float32	0,00
otros_ligeros	Otros automoviles, camionetas o utilitarios identificados	float32	0,00
sexo	Sexo registrado	category	0,11
tipo_envolvido	Rol de participacion: conductor, pasajero, peaton, etc.	category	0,00
tipo_veiculo	Tipo de vehiculo asociado	category	3,99
uf	Unidad federativa del siniestro	category	0,00
br	Identificador de carretera federal, categoria	category	0,10
municipio	Municipio del siniestro	category	0,00
tipo_acidente	Tipo principal del evento, conocido al observar el siniestro	category	0,01
fase_dia	Fase del dia registrada	category	0,00

Categorías y rangos observados, tipos, trazabilidad y perfil original se acompañan en las tablas y en los diccionarios oficiales. Cero de id_veiculo es ausencia/no aplicable aunque sea numérico.

Diccionario final: campos 31-37

Campo	Significado / unidad	Tipo	Faltante %
sentido_via	Sentido de circulacion	category	0,10
condicao_metereologica	Condicion meteorologica observada	category	1,32
tipo_pista	Tipo de calzada	category	0,00
tracado_via	Trazado, a veces compuesto por varios elementos separados por punto y coma	category	0,00
uso_solo	SIM urbano; NAO rural	category	0,00
dia_semana	Dia de semana calculado: 0 lunes, 6 domingo	category	0,00
familia_otro_vehiculo	Familia del unico otro vehiculo identificado; ninguno o multiples en los demas casos	category	0,00

Categorías y rangos observados, tipos, trazabilidad y perfil original se acompañan en las tablas y en los diccionarios oficiales. Cero de id_veiculo es ausencia/no aplicable aunque sea numérico.