CIENCIA DE DATOS - PROYECTO INTEGRADOR

Fase 2 - Inferencia estadística

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Alcance del trabajo

Analizamos registros individuales de PRF para estudiar la gravedad y comparar modelos predictivos. Usamos herramientas de IA como apoyo en programación, análisis y redacción. El equipo debe revisar y comprender el contenido antes de presentarlo.

El modelo distingue entre víctimas heridas y fallecidas registradas por PRF. Parte de un accidente que ya ocurrió: no predice quién tendrá un accidente ni cuántos accidentes habrá el próximo año. Su evaluación es académica, no médica.

Fecha: 2 de noviembre de 2026.

Índice de secciones

1. Correcciones y diseño inferencial
2. Hipótesis nulas y alternativas
3. Resultados y tamaños de efecto
4. Verificación de supuestos
5. Bootstrap frente al intervalo clásico
6. Asociación ajustada y límites
7. Conclusión de la fase 2

Correcciones y diseño inferencial

Mantenemos las reglas de limpieza y las uniones de la fase 1. La mejora frente al proyecto anterior es que usamos registros individuales reales. Conservamos las edades ausentes sin inventarlas y tenemos en cuenta que varias víctimas comparten un accidente. No inventamos una nueva devolución de la profesora.

Para las tres primeras pruebas elegimos una víctima al azar por accidente, con semilla 42. Así evitamos contar a varios pasajeros como si fueran casos totalmente independientes. Esta selección da el mismo peso a cada accidente; no representa a todas las víctimas con el mismo peso.

La muestra contiene 383.598 accidentes. H4 utiliza 494.806 víctimas con todas las variables necesarias. Ajustamos el cálculo de incertidumbre para los 334.129 accidentes. Suponemos que accidentes distintos son aproximadamente independientes, aunque pueden compartir condiciones de tiempo y lugar.

Usamos cuatro tipos de pruebas: chi cuadrado para sexo, Mann-Whitney para edad, comparación de proporciones para vehículos y regresión logística para estudiar la noche considerando otras características. Las pruebas se eligen según el tipo de variable y sus supuestos; no aplicamos una prueba de normalidad al resultado binario herido/fallecido.

Hipótesis nulas y alternativas

H0 plantea igualdad o ausencia de asociación; H1 plantea una diferencia. Fijamos un nivel de significancia de 0,05 y usamos pruebas bilaterales, que permiten diferencias en ambas direcciones. Como hacemos cuatro contrastes, aplicamos Holm, una variante de Bonferroni, para reducir las diferencias encontradas solo por repetir pruebas. Cada intervalo del 95 % corresponde a su efecto por separado.

H1

H0: Sexo y desenlace son independientes en una victima aleatoria por accidente. H1: Existe asociacion entre sexo y desenlace.

Unidad / cobertura: Una victima aleatoria por accidente; sexo conocido; IC bootstrap multinomial.

H2

H0: Distribuciones de edad iguales entre fallecidos y heridos. H1: Las distribuciones de edad difieren.

Unidad / cobertura: Una victima por accidente con edad 1..110; IC bootstrap estratificado por desenlace.

H3

H0: Proporcion de fallecimiento igual en usuarios de moto y otros vehiculos. H1: Las proporciones difieren.

Unidad / cobertura: Una victima por accidente; conductores/pasajeros con vehiculo conocido.

H4

H0: Coeficiente de noche igual a cero condicionado a los controles. H1: Coeficiente de noche distinto de cero.

Unidad / cobertura: Todas las victimas de desarrollo con covariables completas; dependencia dentro de accidente ajustada.

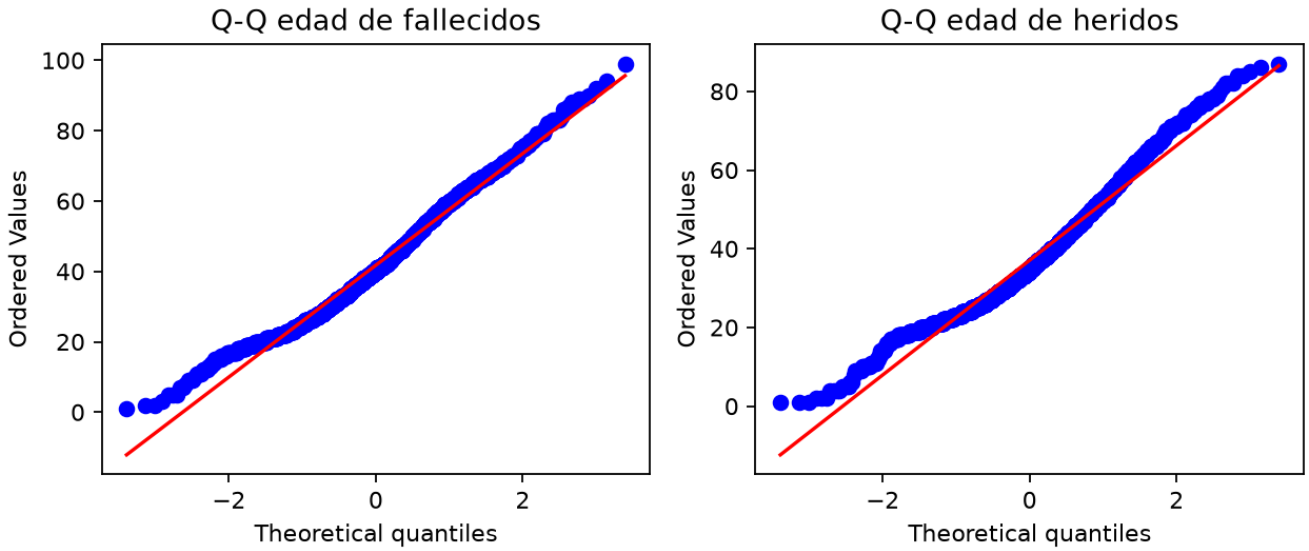
Resultados y tamaños de efecto

Hip. / prueba	Efecto	IC 95 %	p Holm	Decisión
H1 / Chi cuadrado independencia	V de Cramer: 0,073	0,071 a 0,075	< 1e-300	Rechazar H0
H2 / Mann-Whitney bilateral, correccion de empates	Correlacion biserial de rangos: 0,161	0,153 a 0,168	< 1e-300	Rechazar H0
H3 / Z bilateral de dos proporciones	Diferencia de riesgos moto menos otros: -0,004	-0,005 a -0,002	1.93e-06	Rechazar H0
H4 / Wald z de GLM binomial; SE agrupados por accidente	Odds ratio ajustado noche frente a pleno dia: 1,849	1,799 a 1,902	< 1e-300	Rechazar H0

El efecto describe la magnitud de la relación; el intervalo muestra su incertidumbre. Los estadísticos, grados de libertad y cantidades de casos están en contrastes_fase2.csv. Un valor p pequeño no mide el tamaño de la diferencia. Cuando el programa guarda p como cero por su límite numérico, lo presentamos como extremadamente pequeño, no como una probabilidad exactamente cero.

Prueba	Estadistico	Grados de libertad	Casos
H1	2.041,346	1	383.153
H2	4.825.352.704,000	-	370.413
H3	-4,761	-	363.320
H4	43,420	-	494.806

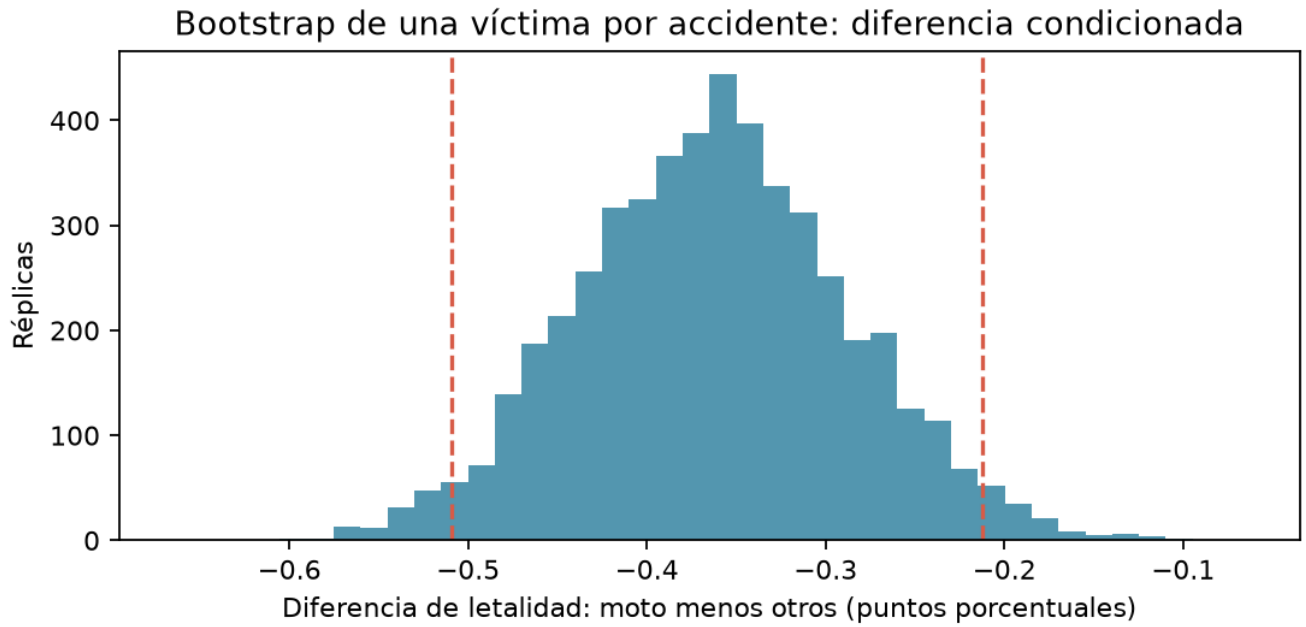
Verificación de supuestos



Revisamos las edades con gráficos Q-Q y Shapiro-Wilk, usando hasta 5.000 casos por grupo. No encontramos normalidad, por eso usamos Mann-Whitney para comparar las distribuciones. Esa prueba no mide únicamente diferencias de medianas. Levene revisa la dispersión, aunque su igualdad no es un requisito de Mann-Whitney.

Para chi cuadrado comprobamos que hubiera suficientes casos esperados. En la comparación de proporciones revisamos los recuentos de ambos resultados. La regresión terminó correctamente y ajustamos sus errores por accidente. Estos controles no eliminan todos los posibles sesgos del registro policial.

Bootstrap frente al intervalo clásico



Para la diferencia de letalidad moto menos otros, IC bootstrap: -0,51 % a -0,21 % puntos porcentuales; IC clásico: -0,51 % a -0,21 %. Bootstrap consiste en volver a tomar muestras con reemplazo de los resultados observados. Lo repetimos 5.000 veces por grupo, después de elegir una víctima por accidente. No añadimos personas al dataset ni entrenamos el modelo con esas remuestras.

La diferencia entre motos y otros vehículos es pequeña. Entre las víctimas seleccionadas hay alrededor de 5,32 % de fallecidos en motos y 5,68 % en otros vehículos. Esto no significa que viajar en moto sea más seguro: no tenemos la cantidad de viajes ni todos los accidentes, y los grupos pueden diferir en otros aspectos.

Asociación ajustada y límites

Variable	OR	IC 95 %	p
intercepto	0,010	0,009 a 0,011	< 1e-300
noche	1,849	1,799 a 1,902	< 1e-300
edad_por_10	1,095	1,059 a 1,132	7.65e-08
edad_por_10_cuadrado	1,007	1,003 a 1,010	0.00039
masculino	1,736	1,684 a 1,790	3.43e-272
usuario_moto	1,134	1,099 a 1,169	3.02e-15
peaton	5,728	5,490 a 5,977	< 1e-300
rural	2,398	2,325 a 2,474	< 1e-300
anio_desde_2017	0,999	0,992 a 1,005	0.676

La noche presenta un OR ajustado de aproximadamente 1,85 frente al pleno día. Consideramos edad, edad al cuadrado, sexo, moto, peatón, zona rural y año. OR compara la relación entre fallecidos y heridos: no significa que la probabilidad individual se multiplique directamente por 1,85. Pueden faltar otras variables importantes. Esta regresión estudia asociaciones; no es el modelo predictivo final.

Conclusión de la fase 2

Las cuatro pruebas permiten rechazar H0 después de la corrección. Esto respalda la existencia de asociaciones bajo los supuestos usados, pero sus magnitudes son distintas. Sexo tiene una asociación pequeña; las edades se superponen; la diferencia por moto es pequeña; y la noche conserva una asociación al considerar otras variables.

Los registros no son una muestra aleatoria de todos los usuarios del tránsito. Los intervalos y valores p no corrigen casos sin registrar ni garantizan que el resultado se repita en cualquier población. Con muchos casos, una diferencia pequeña puede ser estadísticamente detectable. Eso no implica que sirva mucho para predecir.

En la fase 3 combinamos edad, sexo, vehículo, rol, ubicación, tiempo y condiciones del accidente. Excluimos las columnas que revelan el resultado y los identificadores. La selección se basa en su disponibilidad y sentido para el problema, además de los resultados estadísticos.