CIENCIA DE DATOS - PROYECTO INTEGRADOR

Fase 3 - Modelado y evaluación

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Alcance del trabajo

Analizamos registros individuales de PRF para estudiar la gravedad y comparar modelos predictivos. Usamos herramientas de IA como apoyo en programación, análisis y redacción. El equipo debe revisar y comprender el contenido antes de presentarlo.

El modelo distingue entre víctimas heridas y fallecidas registradas por PRF. Parte de un accidente que ya ocurrió: no predice quién tendrá un accidente ni cuántos accidentes habrá el próximo año. Su evaluación es académica, no médica.

Fecha: 2 de noviembre de 2026.

Índice de secciones

1. Qué predecimos y cómo dividimos los datos
2. Comparación inicial de familias: 24 variables
3. Cómo elegimos LightGBM
4. Resultado final: modelo de 31 variables
5. Curvas ROC y precisión-recall
6. Aciertos y errores del modelo final
7. ¿Aprendió o memorizó los datos?
8. Calibración: ajustar los porcentajes de riesgo
9. Interpretación y relación con inferencia
10. Heridos, fallecidos y punto de decisión
11. Casos mal predichos e incertidumbre
12. Conclusión general y límites

Qué predecimos y cómo dividimos los datos

Nuestra tarea es una clasificación: estimamos fallecimiento registrado (1) frente a lesión leve o grave (0). Una fila corresponde a una persona en un accidente. El modelo parte de un accidente que ya ocurrió: no estima quién tendrá un accidente en su vida cotidiana. No recibe identificadores ni cantidades de muertos o heridos que le darían parte de la respuesta.

Primero comparamos regresión logística, árbol, Naive Bayes y LightGBM, además de Dummy, con 24 características. Probamos 13 configuraciones en cortes temporales de 2021, 2022 y 2023. Después añadimos contexto de los vehículos y probamos ocho configuraciones de LightGBM, también con esos cortes. En cada caso entrenamos solo con años anteriores.

Entrenamos con 2017-2023. Usamos enero-junio de 2024 para calibrar los porcentajes de riesgo y julio-diciembre para elegir desde qué porcentaje clasificar un caso como fallecido. Ese punto de decisión busca el mejor F1 de fallecidos en validación. Para elegir el modelo usamos AP media, que evalúa cómo se priorizan los fallecidos considerando las falsas alarmas. La elección quedó fijada antes de abrir 2026.

Los resultados de 2025 ya eran conocidos cuando mejoramos el modelo, así que su comparación final es retrospectiva. La prueba posterior original fue enero-septiembre de 2026. Guardamos los protocolos y las decisiones de ese momento. Volver a ejecutar hoy los resultados conocidos no crea una nueva prueba independiente.

Elegimos LightGBM con 31 características, 400 árboles, tasa de aprendizaje 0,04, máximo de 15 hojas, mínimo de 300 casos por hoja, regularización L2=25 y semilla 42. Estas restricciones ayudan a evitar reglas demasiado específicas del entrenamiento. Solo conservamos este modelo entrenado como opción final; las tablas y el código de comparación permiten justificar y repetir la elección.

Comparación inicial de familias: 24 variables

Familia inicial	AP	AUC	Precisión	Recall	F1 macro
LightGBM	0,302	0,806	31,78 %	40,58 %	0,651
Logistica	0,285	0,801	27,68 %	46,57 %	0,641
Arbol	0,276	0,779	27,92 %	42,55 %	0,638
Bayes	0,240	0,775	27,13 %	34,62 %	0,623
Dummy	0,067	0,500	0,00 %	0,00 %	0,483

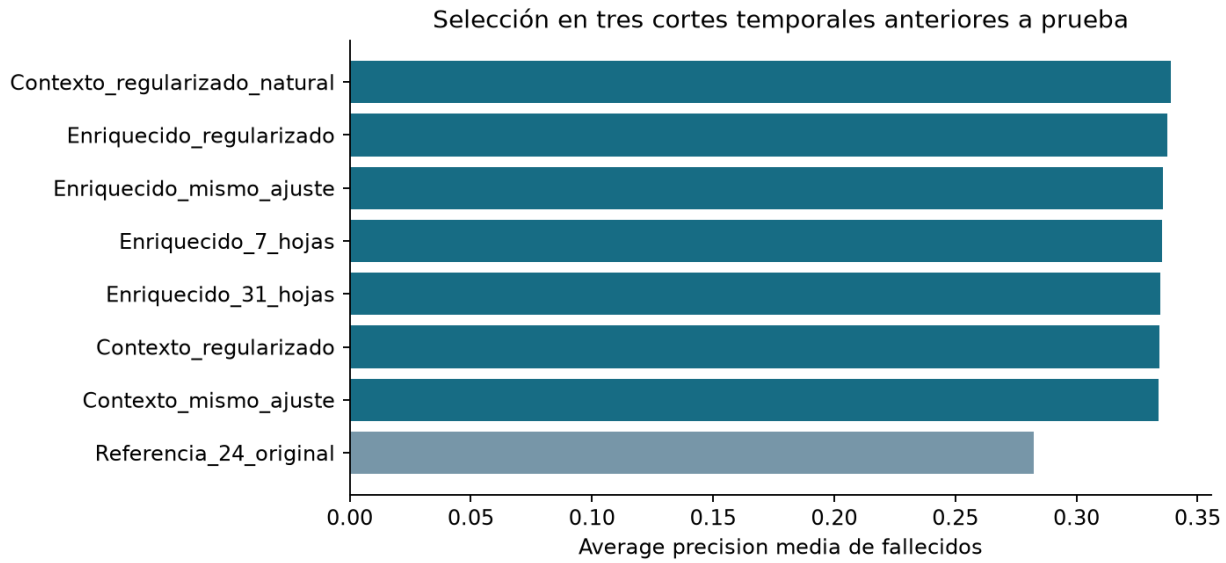
Esta tabla es la comparación INICIAL con 24 características y las mismas 89.593 víctimas de 2025; no es el resultado final. La regresión logística combina características, el árbol aprende reglas, Naive Bayes usa probabilidades y LightGBM combina muchos árboles. Dummy responde siempre herido y sirve como referencia mínima.

Consideramos distintos pesos para los fallecidos y distintas complejidades. El modelo final conservó la proporción natural, sin duplicar personas ni crear víctimas sintéticas. La validación y la prueba mantienen la proporción real. Dar más peso a una clase no garantiza que el modelo mejore.

Cómo elegimos LightGBM

Configuración	AP CV	AUC CV	Cortes mejores
Contexto_regularizado_natural	0,339	0,832	3 / 3
Enriquecido_regularizado	0,337	0,831	3 / 3
Enriquecido_mismo_ajuste	0,336	0,830	3 / 3
Enriquecido_7_hojas	0,336	0,830	3 / 3
Enriquecido_31_hojas	0,335	0,828	3 / 3
Contexto_regularizado	0,334	0,830	3 / 3
Contexto_mismo_ajuste	0,334	0,829	3 / 3
Referencia_24_original	0,283	0,791	0 / 3

La configuración elegida fue Contexto_regularizado_natural. Mejoró a la referencia en los tres cortes de validación. Los nombres de esta tabla identifican configuraciones probadas, no proyectos diferentes para entregar. Las pruebas con marca y más detalle del trazado no quedaron en el ganador. Sus resultados completos siguen en CSV.



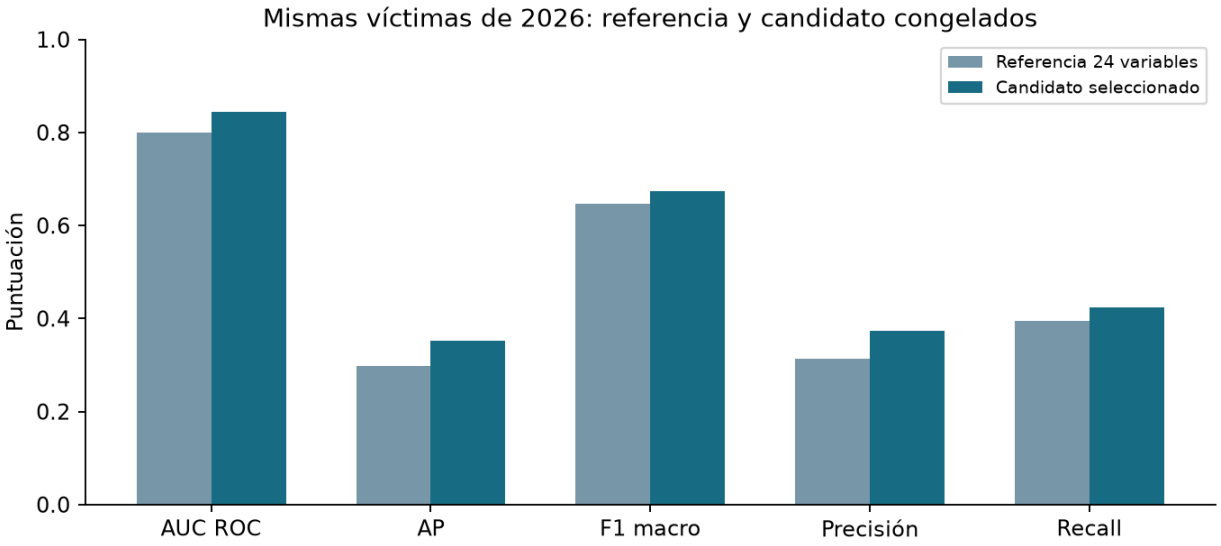
Probamos ocho configuraciones en tres cortes de tiempo. En cada corte entrenamos con años anteriores y evaluamos en el siguiente. Elegimos según la validación, sin usar 2026 para ajustar parámetros.

Resultado final: modelo de 31 variables

Evaluación / modelo	AUC	AP	F1 macro	Precisión	Recall
2025 retrospectivo / Referencia	0,806	0,302	0,651	31,78 %	40,58 %
2026 posterior / Referencia	0,799	0,297	0,647	31,32 %	39,50 %
2025 retrospectivo / Final	0,847	0,361	0,679	38,26 %	42,98 %
2026 posterior / Final	0,845	0,352	0,675	37,34 %	42,36 %

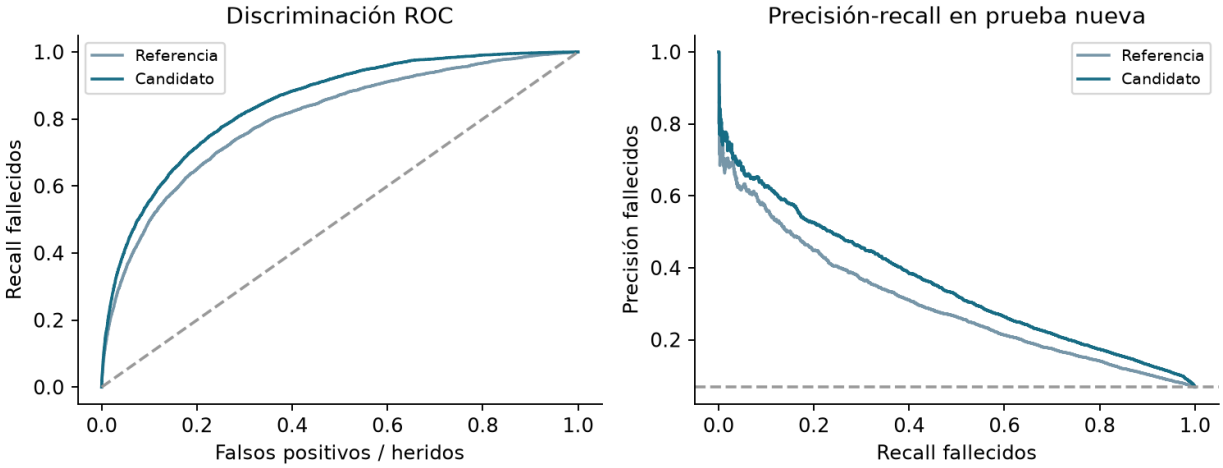
La exactitud, o porcentaje total de aciertos, es 91,22 %. La exactitud balanceada es 68,58 % y el F1 de fallecidos es 0,397. También calculamos Brier (0,0526) y log loss (0,1906), que evalúan los porcentajes de riesgo: un valor menor es mejor.

La prueba final tiene 67.591 víctimas y 4.610 fallecidos. AUC evalúa si el modelo suele asignar mayor riesgo a fallecidos que a heridos. F1 macro evalúa la clasificación de ambos grupos con igual peso. Precisión indica cuántas alertas acierta; recall o detección indica cuántos fallecidos encuentra. AUC 0,845 no significa 84,5 % de aciertos. El punto de decisión elegido es 0,214245, alrededor del 21,4 % de riesgo estimado.



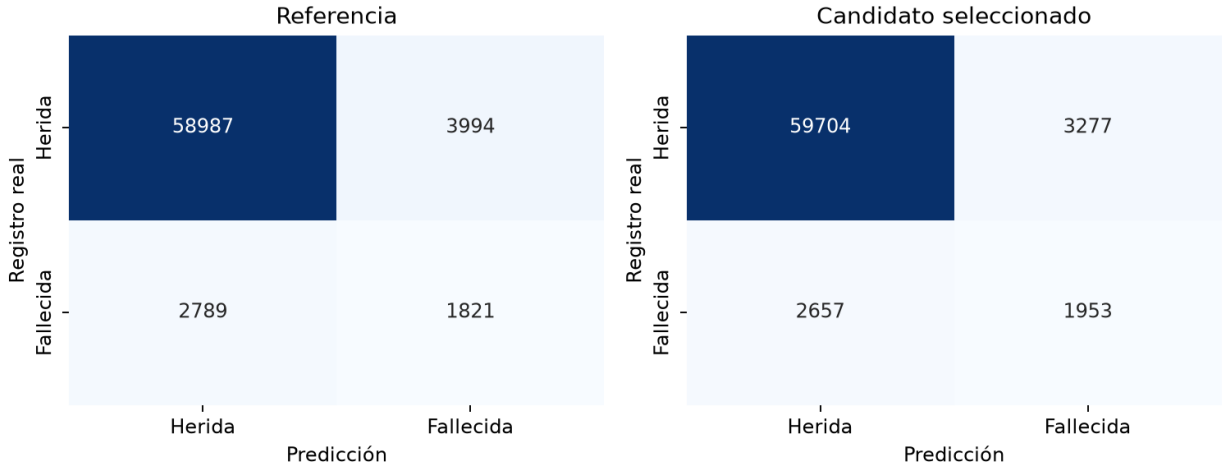
Evaluamos ambos modelos sobre las mismas víctimas de enero a septiembre de 2026. El modelo final de 31 variables mejora a la referencia de 24 variables. Los dos mantienen sus puntos de decisión elegidos con 2024.

Curvas ROC y precisión-recall



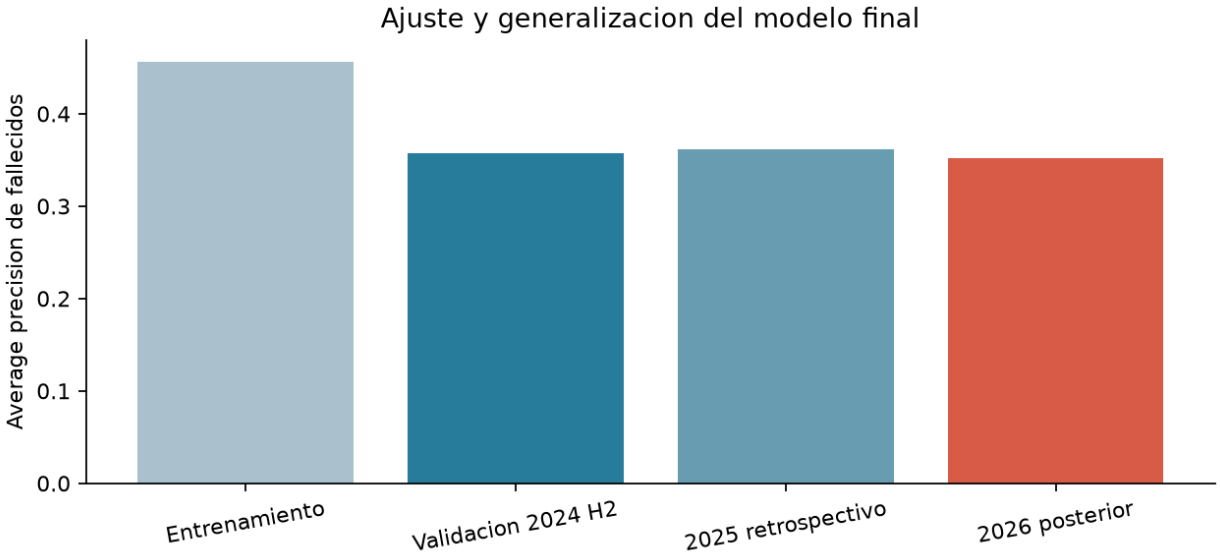
Las curvas permiten comparar distintos puntos de decisión. AUC resume si el modelo suele asignar mayor riesgo a fallecidos que a heridos. La curva precisión-recall combina cuántos fallecidos encuentra y cuántas alertas acierta. AUC 0,845 no significa 84,5 % de aciertos.

Aciertos y errores del modelo final



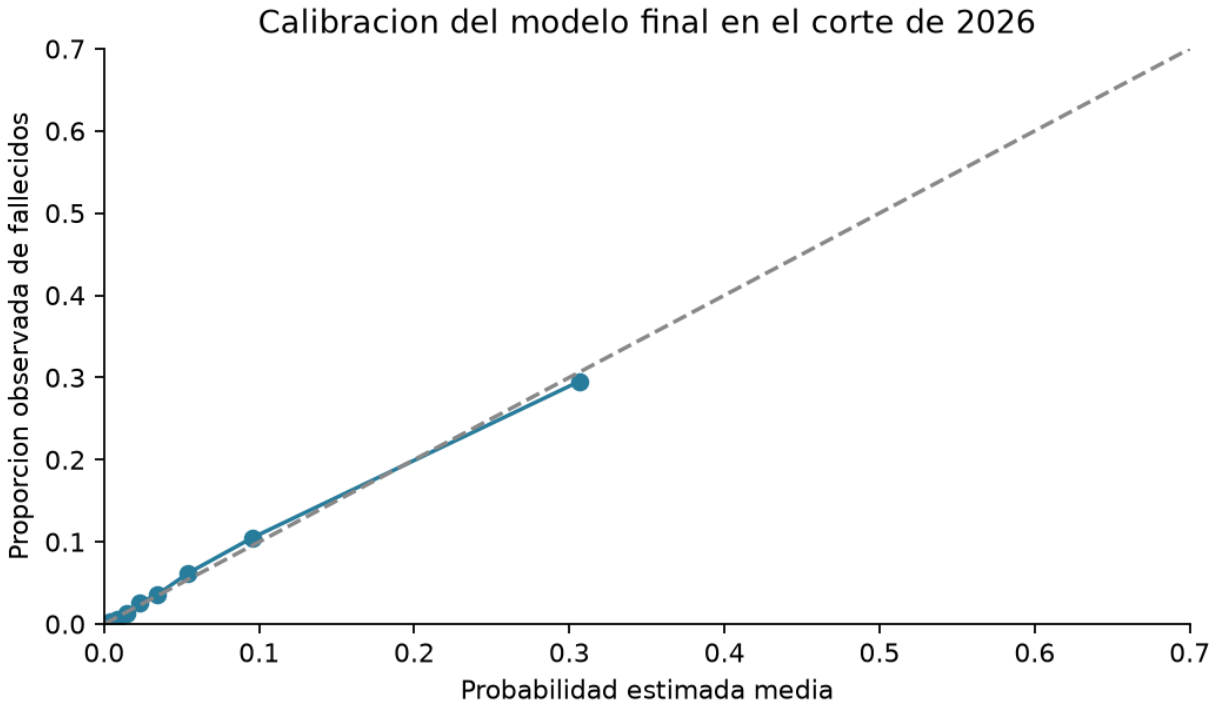
De 4.610 fallecidos, identificamos 1.953 y clasificamos 2.657 como heridos. Además, el modelo marca como fallecidos a 3.277 heridos: esas son las falsas alarmas. Frente a la referencia encuentra 132 fallecidos más y genera 717 falsas alarmas menos.

¿Aprendió o memorizó los datos?



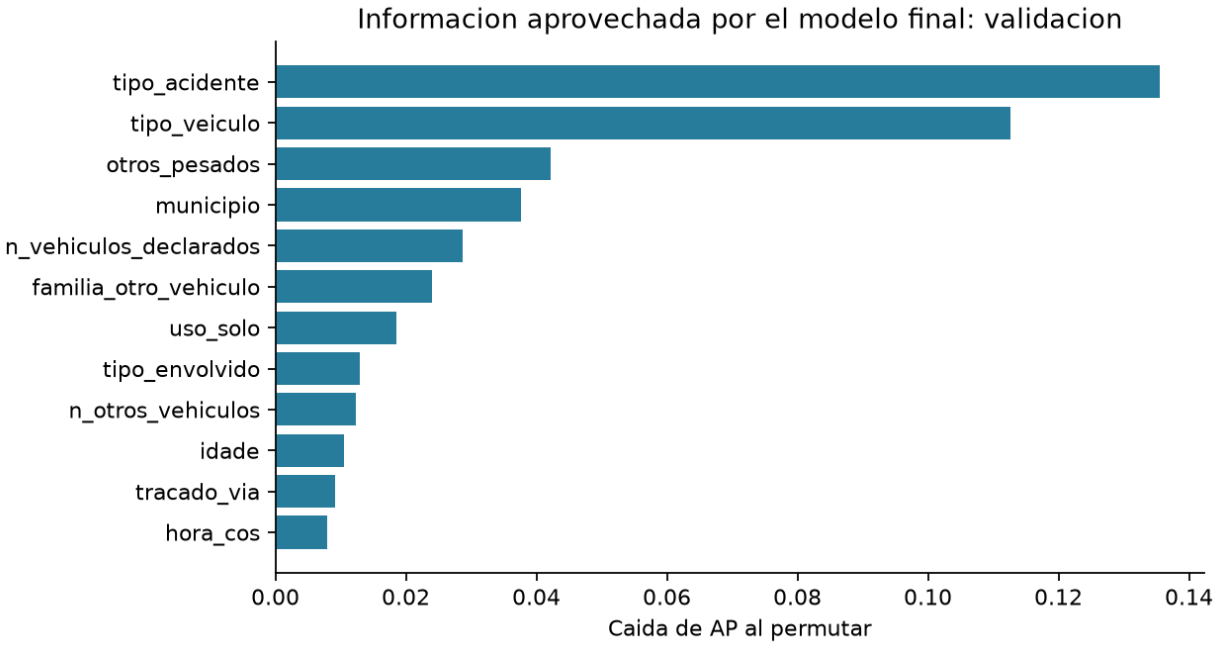
El modelo rinde mejor con los datos usados para aprender: AP es 0,456 en entrenamiento, 0,358 en validación y 0,352 en 2026. Parte del rendimiento de entrenamiento no se mantiene en casos posteriores. La cercanía entre validación y prueba es favorable, pero no garantiza el mismo resultado en cualquier año.

Calibración: ajustar los porcentajes de riesgo



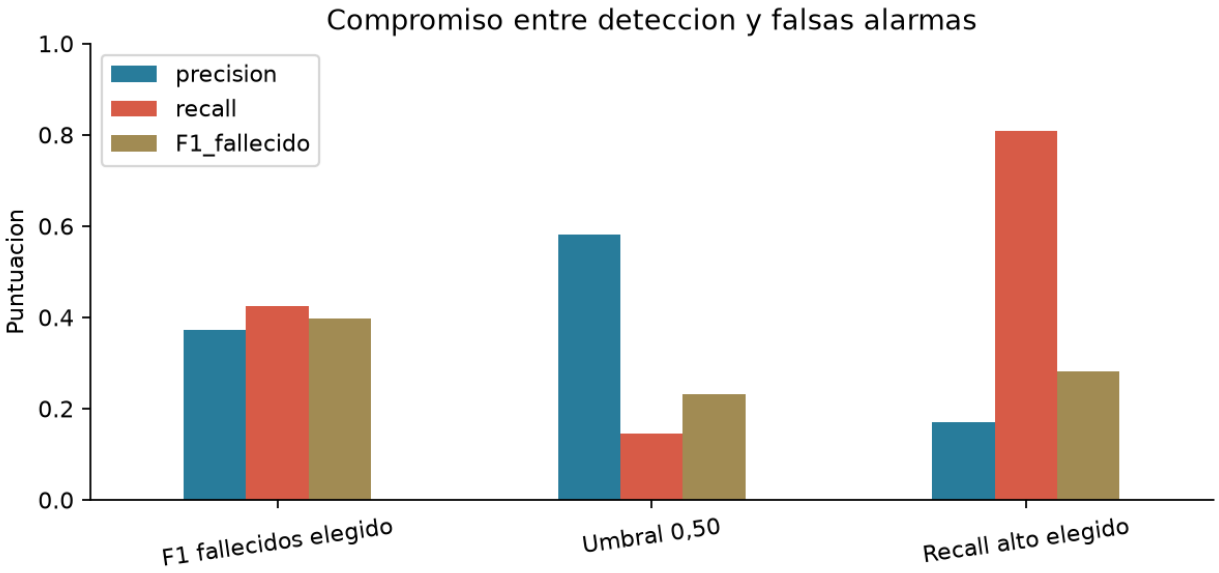
Calibrar significa ajustar los porcentajes de riesgo. Si muchos casos reciben un riesgo del 20 %, buscamos que cerca de 20 de cada 100 hayan terminado en fallecimiento. Usamos enero-junio de 2024 para ese ajuste. La curva revisa grupos; no garantiza lo que le pasará a una persona.

Interpretación y relación con inferencia



Mezclamos los valores de una variable en una muestra de validación y observamos cuánto empeora el modelo. Una caída mayor indica que esa información ayudaba más. Dos variables parecidas pueden reemplazarse parcialmente. Importancia para predecir no significa que sea una causa.

Heridos, fallecidos y punto de decisión



Con la decisión elegida encontramos cerca de 42 de cada 100 fallecidos y acertamos cerca de 37 de cada 100 alertas de fallecimiento. Al bajar la exigencia para alertar encontramos cerca de 81 de cada 100 fallecidos, pero solo unas 17 de cada 100 alertas son correctas. Detectar más implica aceptar más falsas alarmas.

Casos mal predichos e incertidumbre

Error	Edad	Rol	Vehículo	P(fallecido)
FN	25.0	CONDUTOR	MOTOCICLETA	0,002
FN	31.0	CONDUTOR	MOTOCICLETA	0,003
FN	25.0	CONDUTOR	MOTOCICLETA	0,003
FN	22.0	PASSAGEIRO	AUTOMOVEL	0,004
FN	20.0	PASSAGEIRO	MOTOCICLETA	0,004
FN	40.0	CONDUTOR	MOTONETA	0,004

Son errores cometidos aunque el modelo asignaba un riesgo alto o bajo con mucha confianza. Los revisamos para reconocer sus límites, no para explicar qué causó el resultado. Las tablas completas incluyen veinte casos y evaluaciones por sexo, edad, rol, vehículo y ubicación. No cambiamos decisiones por grupo mirando la prueba.

Cambio final - referencia	IC 95% inferior	IC 95% superior
delta_AP	0,0473	0,0624
delta_ROC_AUC	0,0412	0,0499
delta_F1_macro	0,0216	0,0327
delta_precision	0,0501	0,0698
delta_recall	0,0165	0,0413

Los intervalos se obtuvieron repitiendo 300 veces la selección de accidentes completos con reemplazo. Comparamos ambos modelos sobre las mismas víctimas. Los cinco cambios son positivos en esos intervalos, pero eso no elimina posibles problemas del registro o diferencias entre lugares y años.

Conclusión general y límites

La respuesta final es que combinar información de la persona, el vehículo y el accidente permite distinguir heridos y fallecidos mejor que referencias sencillas. El mejor modelo fue LightGBM con 31 características: AUC 0,845 y F1 macro 0,675 en 2026. Sobre las mismas víctimas, la referencia obtuvo 0,799 y 0,647. Detectamos 132 fallecidos más y generamos 717 falsas alarmas menos.

El modelo todavía clasifica como heridos a 2.657 de los 4.610 fallecidos y genera 3.277 falsas alarmas. Con la decisión principal detecta cerca de 42 de cada 100 fallecidos. Si bajamos la exigencia podemos detectar más, pero aumentan mucho las falsas alarmas. No hay una decisión perfecta para todos los usos.

El rendimiento es mejor en entrenamiento que en datos posteriores: AP es 0,456, frente a 0,358 en validación y 0,352 en 2026. Parte de lo aprendido no se mantiene fuera del entrenamiento. También faltan velocidad de impacto, casco, cinturón y seguimiento clínico completo. El modelo no está validado para decisiones médicas ni para aplicarlo automáticamente a Paraguay.

Usamos IA como apoyo en programación, análisis y redacción. El grupo debe revisar y comprender el trabajo y asumir sus decisiones antes de presentarlo. Los legajos y las contribuciones de cada integrante deben completarse por el grupo; no inventamos aprobaciones docentes ni participación individual.