CIENCIA DE DATOS - PROYECTO INTEGRADOR

Informe integrador - Tres fases

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Alcance del trabajo

Analizamos registros individuales de PRF para estudiar la gravedad y comparar modelos predictivos. Usamos herramientas de IA como apoyo en programación, análisis y redacción. El equipo debe revisar y comprender el contenido antes de presentarlo.

El modelo distingue entre víctimas heridas y fallecidas registradas por PRF. Parte de un accidente que ya ocurrió: no predice quién tendrá un accidente ni cuántos accidentes habrá el próximo año. Su evaluación es académica, no médica.

Fecha: 2 de noviembre de 2026.

Índice de secciones

1. Problema y objetivos

2. Fuentes y construcción

3. Calidad de los datos

4. Desbalance y edad

5. Cambios temporales

6. Inferencia: diseño

7. Inferencia: hipótesis

8. Inferencia: resultados

9. Inferencia: conclusión

10. Qué predecimos y cómo dividimos los datos

11. Comparación inicial de familias: 24 variables

12. Cómo elegimos LightGBM

13. Resultado final: modelo de 31 variables

14. Curvas ROC y precisión-recall

15. Aciertos y errores del modelo final

16. ¿Aprendió o memorizó los datos?

17. Calibración: ajustar los porcentajes de riesgo

18. Interpretación y relación con inferencia

19. Heridos, fallecidos y punto de decisión

20. Casos mal predichos e incertidumbre

21. Conclusión general y límites

Problema y objetivos

Contexto y relevancia

La Policía Rodoviaria Federal de Brasil (PRF) publica datos de accidentes ocurridos en carreteras federales. Elegimos esta fuente porque permite relacionar a cada persona con su vehículo y accidente. En el trabajo anterior de Paraguay teníamos cantidades agrupadas: repetir esas cantidades como filas no creaba información individual nueva.

Pregunta principal

¿Qué características personales, vehiculares y del siniestro se asocian con el fallecimiento registrado frente a lesiones no fatales en víctimas de siniestros de PRF Brasil entre 2017 y 2025, y qu? desempeño alcanza su clasificación en el período posterior de 2026?

Objetivo general

Analizar qué características se relacionan con la gravedad y evaluar qué tan bien permiten distinguir entre víctimas heridas y fallecidas en un período posterior.

Objetivos específicos

- Unir los registros de víctimas, vehículos y accidentes mediante sus identificadores reales, sin inventar ni duplicar personas.
- Revisar la calidad de los datos y describir diferencias por edad, sexo, vehículo, lugar y horario.
- Comprobar cuatro hipótesis con pruebas estadísticas, considerando que varias víctimas pueden pertenecer al mismo accidente.
- Comparar distintas familias de modelos y evaluar cómo trabajan con muchos más heridos que fallecidos.
- Medir el resultado en datos posteriores al entrenamiento, explicar los errores y responder la pregunta de investigación.

Fuentes y construcción

Usamos 20 ZIP con tablas CSV y dos diccionarios oficiales, descargados el 31/10/2026. Los archivos 2017-2025 tienen 632.713 accidentes y 1.654.197 filas en personas. El corte 2026 añade 54.895 accidentes y 148.868 filas en personas. No todas esas filas sirven para nuestro objetivo: hay ilesos, estados desconocidos y registros sin identificador de persona. En 2017-2025 hay 144.628 filas con pesid=0 que no contamos como personas identificadas.

Después de seleccionar heridos y fallecidos, 2017-2025 tiene 754.098 víctimas: 703.273 heridas y 50.825 fallecidas. El corte de 2026 agrega 67.591 víctimas, con 4.610 fallecidos. El archivo limpio reúne 821.689 participaciones reales. Usamos id para unir cada persona con un solo accidente. Verificamos que la unión no añadiera filas ni dejara víctimas sin pareja. Los datos del vehículo ya vienen en personas: no inventamos una tercera fuente.

Partición	Víctimas	Fallecidos	Accidentes
calibracion_2024_H1	43.522	2.911	29.517
comparacion_retrospectiva_2025	89.593	6.043	61.391
desarrollo_2017_2023	573.747	38.619	383.598
prueba_posterior_2026_ene_sep	67.591	4.610	46.337
umbral_2024_H2	47.236	3.252	31.903

Cada accidente queda en un solo grupo de evaluación. Una fila representa a una persona en un accidente; pesid no permite seguir su identidad a lo largo de toda su vida. Comenzamos en 2017 por el cambio al sistema BAT. La exploración y las pruebas estadísticas usan 2017-2023. Los datos de 2026 cubren enero-septiembre y se reservan para la evaluación posterior.

PRF presenta estos archivos como datos abiertos y reutilizables. Conservamos la atribución a la fuente. En data/fuentes.json guardamos sus enlaces, tamaños y huellas SHA-256, que permiten comprobar que seguimos usando los mismos archivos.

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes

Calidad de los datos

Los archivos originales usan punto y coma y codificación Latin-1; las salidas usan UTF-8. Unificamos mayúsculas, espacios y categorías con el mismo significado. Convertimos fechas y números a sus tipos correctos. También comprobamos identificadores y cantidad de filas antes y después de la unión. La bitácora registra cada decisión y cuántos casos afecta.

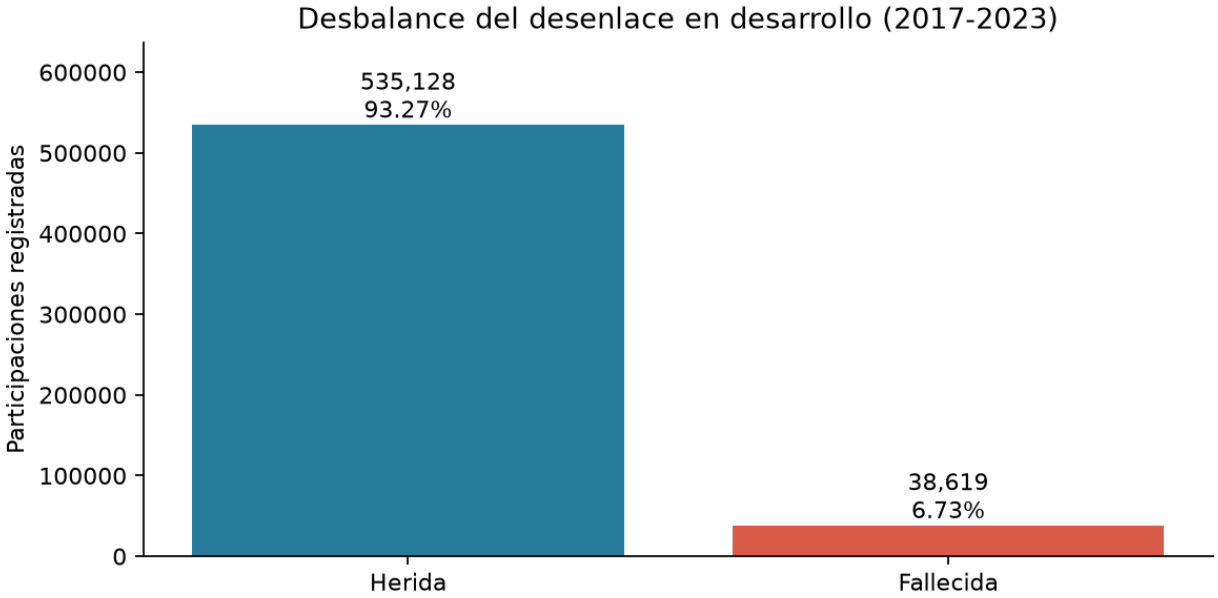
Una edad cero no permite saber si se trata de un bebé o de un dato sin completar. Por eso la marcamos como faltante, igual que edades negativas o mayores de 110, sin borrar a la víctima. Revisamos años de fabricación imposibles y coordenadas fuera de límites razonables. No usamos cero como reemplazo automático de la información ausente.

Conservamos las categorías desconocidas. LightGBM admite números faltantes; los modelos que necesitan completarlos aprenden ese reemplazo solo con entrenamiento. Que falte información puede depender de la víctima o de cómo se registró el accidente, por lo que no suponemos que esas ausencias ocurran totalmente al azar.

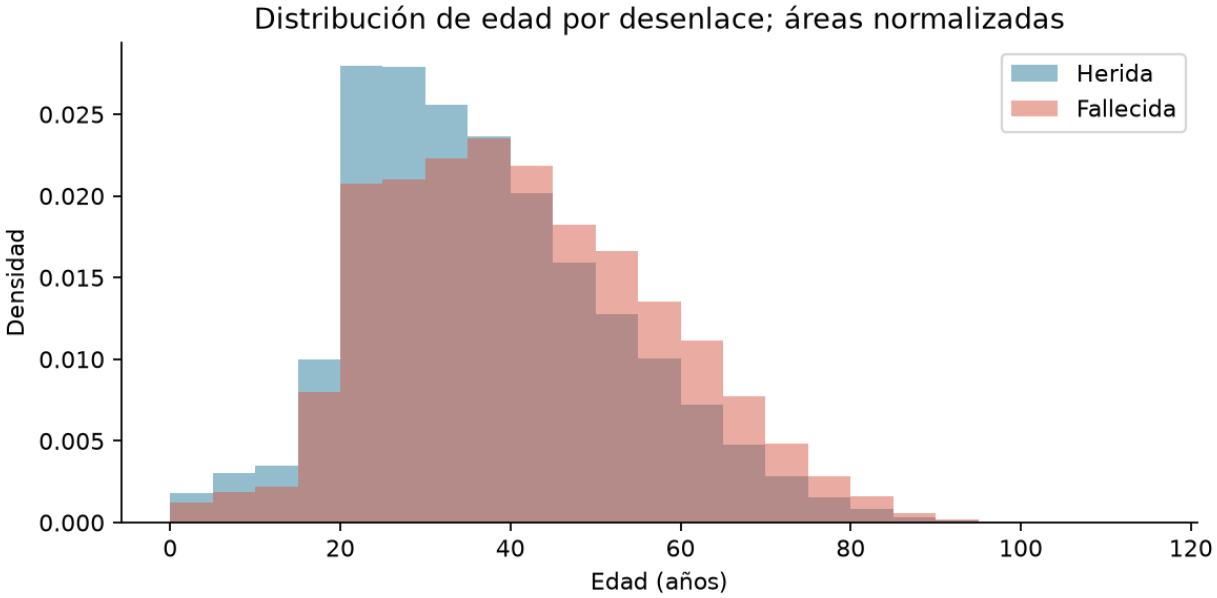
El modelo final usa 31 características: edad, sexo, rol de la persona, vehículo, antigüedad, horario, ubicación y condiciones del accidente, entre otras. Las siete características añadidas describen los otros vehículos presentes. Para construirlas usamos todos los vehículos identificados antes de seleccionar las víctimas y contamos una sola vez a un vehículo con varios ocupantes. No usamos identificadores, cantidades de muertos o heridos ni la causa atribuida después de investigar el accidente como entradas del modelo principal.

Revisamos los cambios de categorías entre años y no borramos un valor extremo solo por estar alejado de los demás si sigue siendo posible. No tenemos velocidad de impacto, casco, cinturón ni seguimiento clínico completo. Tampoco conocemos todos los viajes realizados. Por eso este estudio no estima la probabilidad de que una persona cualquiera tenga un accidente.

Desbalance y edad

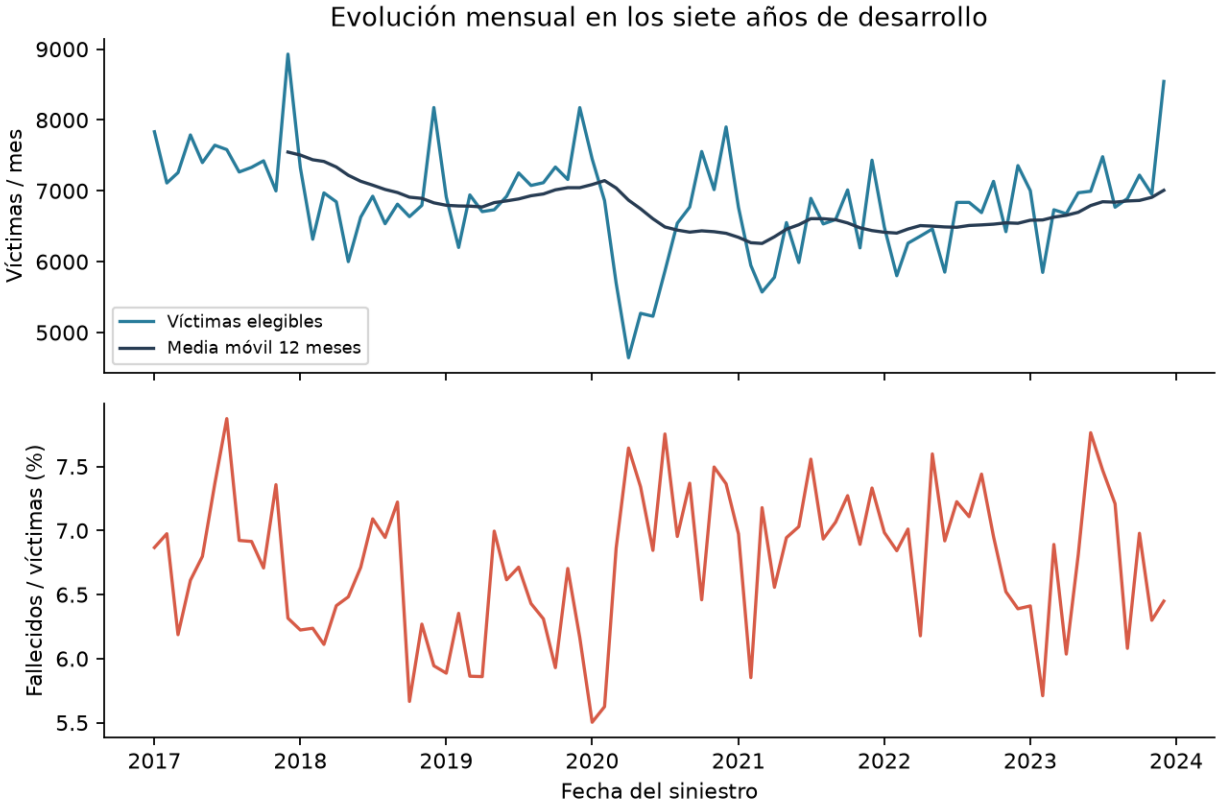


En los datos de desarrollo hay 38.619 fallecidos entre 573.747 víctimas: alrededor del 7 %. Los heridos son muchos más. Por eso, en la fase 3 no alcanza con contar los aciertos totales: también debemos revisar si el modelo identifica a los fallecidos.



La edad mediana es de 35 años en heridos y 39 en fallecidos. La mediana deja la mitad de los casos a cada lado. Usamos proporciones para comparar los grupos sin que la mayor cantidad de heridos tape a los fallecidos.

Cambios temporales



La cantidad de víctimas y la proporción de fallecidos cambian entre meses y años. Esto puede relacionarse con la circulación y con la forma de registrar los casos. El gráfico cuenta víctimas registradas, no todos los viajes. Por eso evaluamos respetando el orden de los años.

Inferencia: diseño

Mantenemos las reglas de limpieza y las uniones de la fase 1. La mejora frente al proyecto anterior es que usamos registros individuales reales. Conservamos las edades ausentes sin inventarlas y tenemos en cuenta que varias víctimas comparten un accidente. No inventamos una nueva devolución de la profesora.

Para las tres primeras pruebas elegimos una víctima al azar por accidente, con semilla 42. Así evitamos contar a varios pasajeros como si fueran casos totalmente independientes. Esta selección da el mismo peso a cada accidente; no representa a todas las víctimas con el mismo peso.

La muestra contiene 383.598 accidentes. H4 utiliza 494.806 víctimas con todas las variables necesarias. Ajustamos el cálculo de incertidumbre para los 334.129 accidentes. Suponemos que accidentes distintos son aproximadamente independientes, aunque pueden compartir condiciones de tiempo y lugar.

Usamos cuatro tipos de pruebas: chi cuadrado para sexo, Mann-Whitney para edad, comparación de proporciones para vehículos y regresión logística para estudiar la noche considerando otras características. Las pruebas se eligen según el tipo de variable y sus supuestos; no aplicamos una prueba de normalidad al resultado binario herido/fallecido.

Inferencia: hipótesis

H0 plantea igualdad o ausencia de asociación; H1 plantea una diferencia. Fijamos un nivel de significancia de 0,05 y usamos pruebas bilaterales, que permiten diferencias en ambas direcciones. Como hacemos cuatro contrastes, aplicamos Holm, una variante de Bonferroni, para reducir las diferencias encontradas solo por repetir pruebas. Cada intervalo del 95 % corresponde a su efecto por separado.

H1

H0: Sexo y desenlace son independientes en una victima aleatoria por accidente. H1: Existe asociacion entre sexo y desenlace.

Unidad / cobertura: Una victima aleatoria por accidente; sexo conocido; IC bootstrap multinomial.

H2

H0: Distribuciones de edad iguales entre fallecidos y heridos. H1: Las distribuciones de edad difieren.

Unidad / cobertura: Una victima por accidente con edad 1..110; IC bootstrap estratificado por desenlace.

H3

H0: Proporcion de fallecimiento igual en usuarios de moto y otros vehiculos. H1: Las proporciones difieren.

Unidad / cobertura: Una victima por accidente; conductores/pasajeros con vehiculo conocido.

H4

H0: Coeficiente de noche igual a cero condicionado a los controles. H1: Coeficiente de noche distinto de cero.

Unidad / cobertura: Todas las victimas de desarrollo con covariables completas; dependencia dentro de accidente ajustada.

Inferencia: resultados

Hip. / prueba	Efecto	IC 95 %	p Holm	Decisión
H1 / Chi cuadrado independencia	V de Cramer: 0,073	0,071 a 0,075	< 1e-300	Rechazar H0
H2 / Mann-Whitney bilateral, correccion de empates	Correlacion biserial de rangos: 0,161	0,153 a 0,168	< 1e-300	Rechazar H0
H3 / Z bilateral de dos proporciones	Diferencia de riesgos moto menos otros: -0,004	-0,005 a -0,002	1.93e-06	Rechazar H0
H4 / Wald z de GLM binomial; SE agrupados por accidente	Odds ratio ajustado noche frente a pleno dia: 1,849	1,799 a 1,902	< 1e-300	Rechazar H0

El efecto describe la magnitud de la relación; el intervalo muestra su incertidumbre. Los estadísticos, grados de libertad y cantidades de casos están en contrastes_fase2.csv. Un valor p pequeño no mide el tamaño de la diferencia. Cuando el programa guarda p como cero por su límite numérico, lo presentamos como extremadamente pequeño, no como una probabilidad exactamente cero.

Prueba	Estadistico	Grados de libertad	Casos
H1	2.041,346	1	383.153
H2	4.825.352.704,000	-	370.413
H3	-4,761	-	363.320
H4	43,420	-	494.806

Inferencia: conclusión

Las cuatro pruebas permiten rechazar H0 después de la corrección. Esto respalda la existencia de asociaciones bajo los supuestos usados, pero sus magnitudes son distintas. Sexo tiene una asociación pequeña; las edades se superponen; la diferencia por moto es pequeña; y la noche conserva una asociación al considerar otras variables.

Los registros no son una muestra aleatoria de todos los usuarios del tránsito. Los intervalos y valores p no corrigen casos sin registrar ni garantizan que el resultado se repita en cualquier población. Con muchos casos, una diferencia pequeña puede ser estadísticamente detectable. Eso no implica que sirva mucho para predecir.

En la fase 3 combinamos edad, sexo, vehículo, rol, ubicación, tiempo y condiciones del accidente. Excluimos las columnas que revelan el resultado y los identificadores. La selección se basa en su disponibilidad y sentido para el problema, además de los resultados estadísticos.

Qué predecimos y cómo dividimos los datos

Nuestra tarea es una clasificación: estimamos fallecimiento registrado (1) frente a lesión leve o grave (0). Una fila corresponde a una persona en un accidente. El modelo parte de un accidente que ya ocurrió: no estima quién tendrá un accidente en su vida cotidiana. No recibe identificadores ni cantidades de muertos o heridos que le darían parte de la respuesta.

Primero comparamos regresión logística, árbol, Naive Bayes y LightGBM, además de Dummy, con 24 características. Probamos 13 configuraciones en cortes temporales de 2021, 2022 y 2023. Después añadimos contexto de los vehículos y probamos ocho configuraciones de LightGBM, también con esos cortes. En cada caso entrenamos solo con años anteriores.

Entrenamos con 2017-2023. Usamos enero-junio de 2024 para calibrar los porcentajes de riesgo y julio-diciembre para elegir desde qué porcentaje clasificar un caso como fallecido. Ese punto de decisión busca el mejor F1 de fallecidos en validación. Para elegir el modelo usamos AP media, que evalúa cómo se priorizan los fallecidos considerando las falsas alarmas. La elección quedó fijada antes de abrir 2026.

Los resultados de 2025 ya eran conocidos cuando mejoramos el modelo, así que su comparación final es retrospectiva. La prueba posterior original fue enero-septiembre de 2026. Guardamos los protocolos y las decisiones de ese momento. Volver a ejecutar hoy los resultados conocidos no crea una nueva prueba independiente.

Elegimos LightGBM con 31 características, 400 árboles, tasa de aprendizaje 0,04, máximo de 15 hojas, mínimo de 300 casos por hoja, regularización L2=25 y semilla 42. Estas restricciones ayudan a evitar reglas demasiado específicas del entrenamiento. Solo conservamos este modelo entrenado como opción final; las tablas y el código de comparación permiten justificar y repetir la elección.

Comparación inicial de familias: 24 variables

Familia inicial	AP	AUC	Precisión	Recall	F1 macro
LightGBM	0,302	0,806	31,78 %	40,58 %	0,651
Logistica	0,285	0,801	27,68 %	46,57 %	0,641
Arbol	0,276	0,779	27,92 %	42,55 %	0,638
Bayes	0,240	0,775	27,13 %	34,62 %	0,623
Dummy	0,067	0,500	0,00 %	0,00 %	0,483

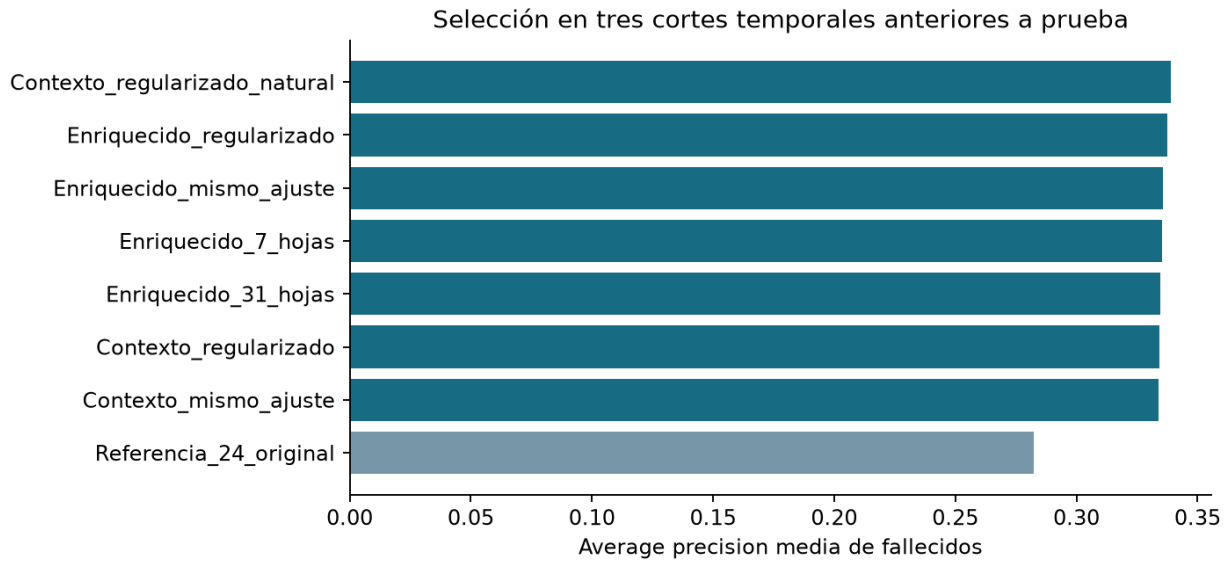
Esta tabla es la comparación INICIAL con 24 características y las mismas 89.593 víctimas de 2025; no es el resultado final. La regresión logística combina características, el árbol aprende reglas, Naive Bayes usa probabilidades y LightGBM combina muchos árboles. Dummy responde siempre herido y sirve como referencia mínima.

Consideramos distintos pesos para los fallecidos y distintas complejidades. El modelo final conservó la proporción natural, sin duplicar personas ni crear víctimas sintéticas. La validación y la prueba mantienen la proporción real. Dar más peso a una clase no garantiza que el modelo mejore.

Cómo elegimos LightGBM

Configuración	AP CV	AUC CV	Cortes mejores
Contexto_regularizado_natural	0,339	0,832	3 / 3
Enriquecido_regularizado	0,337	0,831	3 / 3
Enriquecido_mismo_ajuste	0,336	0,830	3 / 3
Enriquecido_7_hojas	0,336	0,830	3 / 3
Enriquecido_31_hojas	0,335	0,828	3 / 3
Contexto_regularizado	0,334	0,830	3 / 3
Contexto_mismo_ajuste	0,334	0,829	3 / 3
Referencia_24_original	0,283	0,791	0 / 3

La configuración elegida fue Contexto_regularizado_natural. Mejoró a la referencia en los tres cortes de validación. Los nombres de esta tabla identifican configuraciones probadas, no proyectos diferentes para entregar. Las pruebas con marca y más detalle del trazado no quedaron en el ganador. Sus resultados completos siguen en CSV.



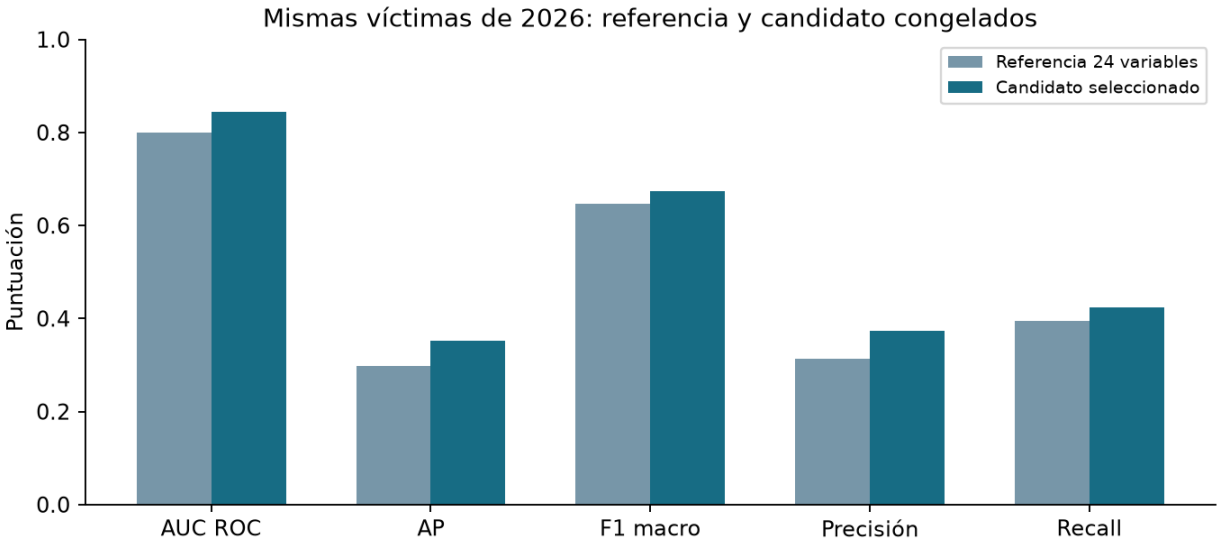
Probamos ocho configuraciones en tres cortes de tiempo. En cada corte entrenamos con años anteriores y evaluamos en el siguiente. Elegimos según la validación, sin usar 2026 para ajustar parámetros.

Resultado final: modelo de 31 variables

Evaluación / modelo	AUC	AP	F1 macro	Precisión	Recall
2025 retrospectivo / Referencia	0,806	0,302	0,651	31,78 %	40,58 %
2026 posterior / Referencia	0,799	0,297	0,647	31,32 %	39,50 %
2025 retrospectivo / Final	0,847	0,361	0,679	38,26 %	42,98 %
2026 posterior / Final	0,845	0,352	0,675	37,34 %	42,36 %

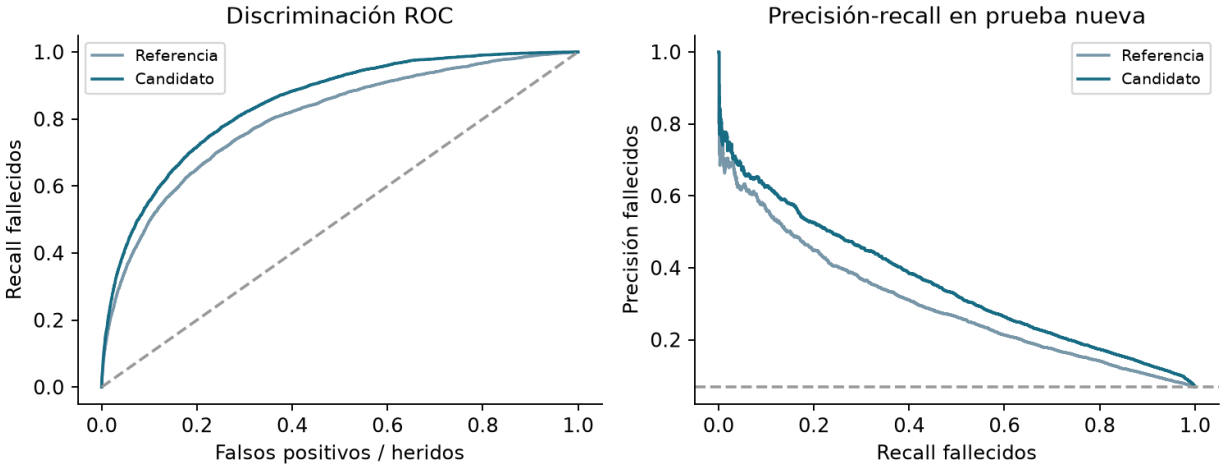
La exactitud, o porcentaje total de aciertos, es 91,22 %. La exactitud balanceada es 68,58 % y el F1 de fallecidos es 0,397. También calculamos Brier (0,0526) y log loss (0,1906), que evalúan los porcentajes de riesgo: un valor menor es mejor.

La prueba final tiene 67.591 víctimas y 4.610 fallecidos. AUC evalúa si el modelo suele asignar mayor riesgo a fallecidos que a heridos. F1 macro evalúa la clasificación de ambos grupos con igual peso. Precisión indica cuántas alertas acierta; recall o detección indica cuántos fallecidos encuentra. AUC 0,845 no significa 84,5 % de aciertos. El punto de decisión elegido es 0,214245, alrededor del 21,4 % de riesgo estimado.



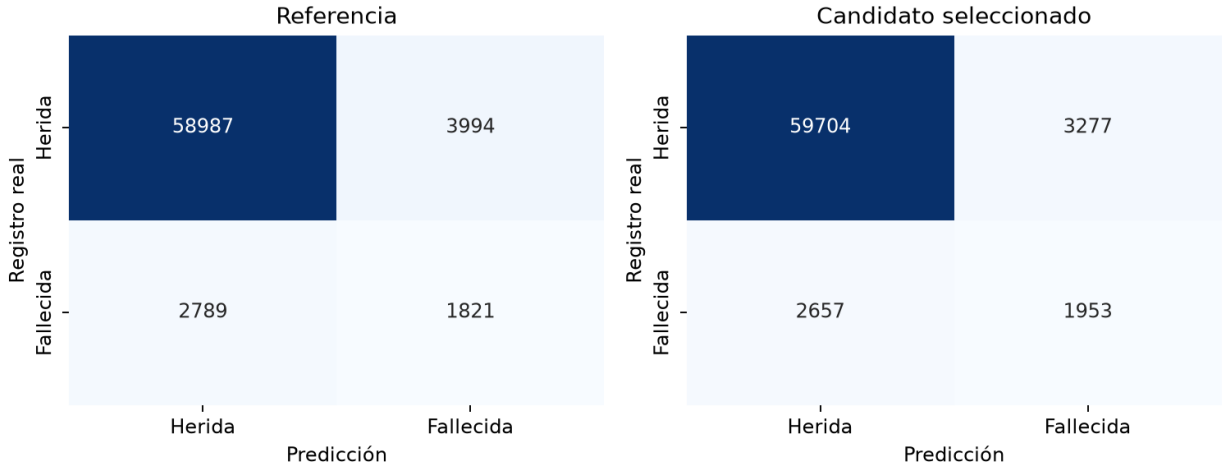
Evaluamos ambos modelos sobre las mismas víctimas de enero a septiembre de 2026. El modelo final de 31 variables mejora a la referencia de 24 variables. Los dos mantienen sus puntos de decisión elegidos con 2024.

Curvas ROC y precisión-recall



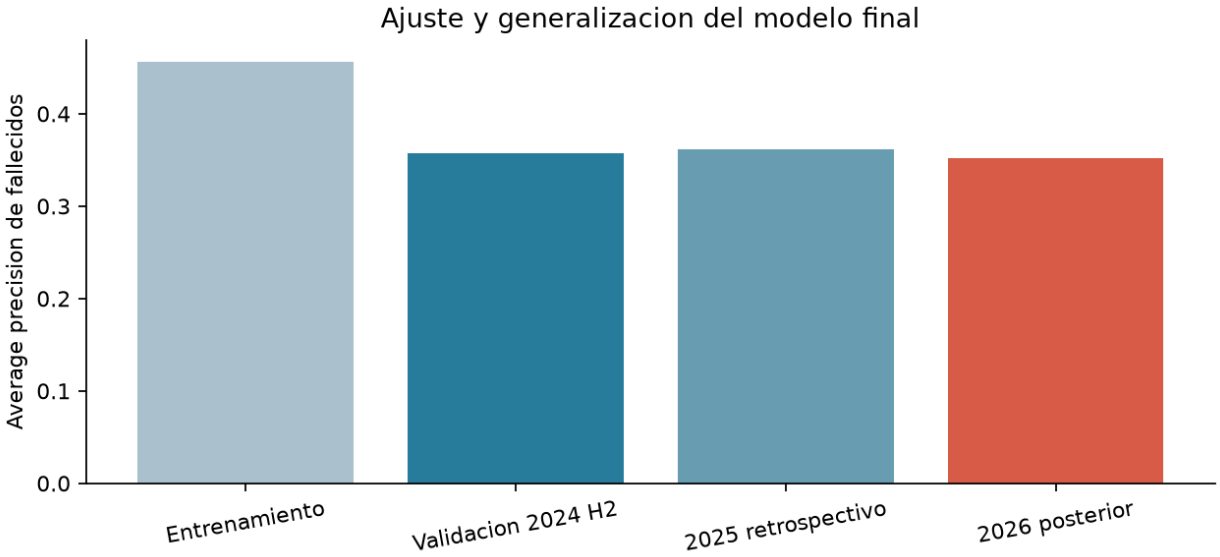
Las curvas permiten comparar distintos puntos de decisión. AUC resume si el modelo suele asignar mayor riesgo a fallecidos que a heridos. La curva precisión-recall combina cuántos fallecidos encuentra y cuántas alertas acierta. AUC 0,845 no significa 84,5 % de aciertos.

Aciertos y errores del modelo final



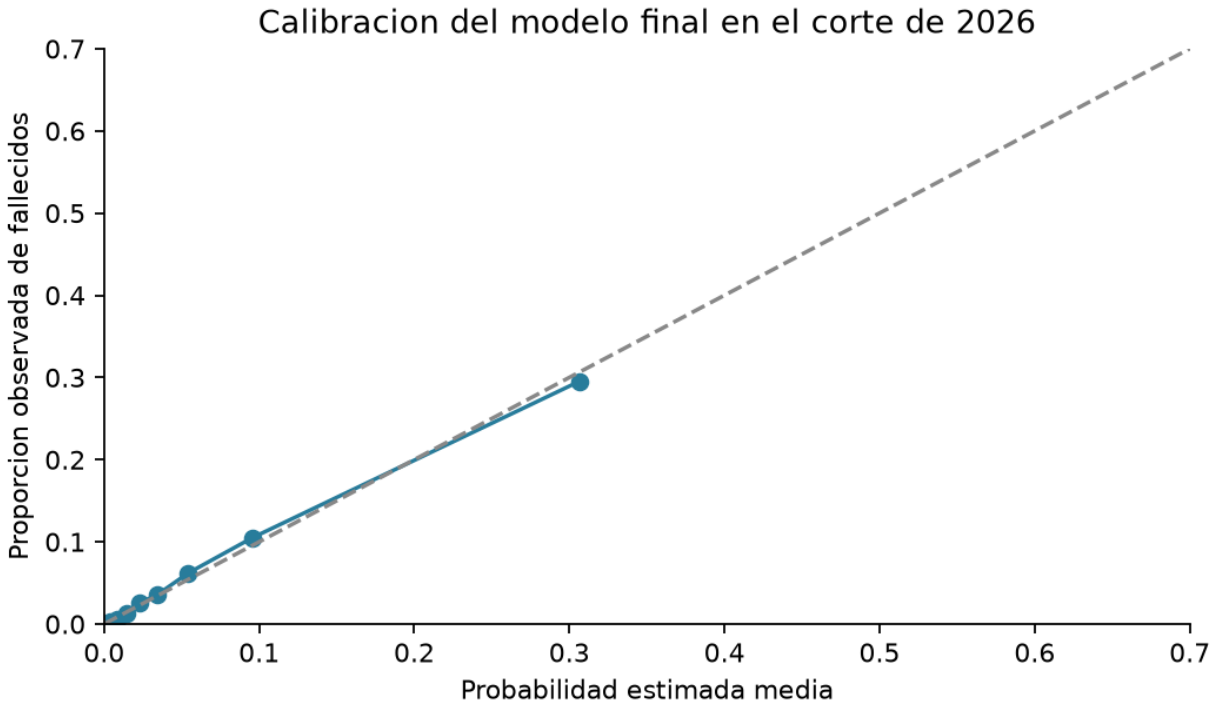
De 4.610 fallecidos, identificamos 1.953 y clasificamos 2.657 como heridos. Además, el modelo marca como fallecidos a 3.277 heridos: esas son las falsas alarmas. Frente a la referencia encuentra 132 fallecidos más y genera 717 falsas alarmas menos.

¿Aprendió o memorizó los datos?



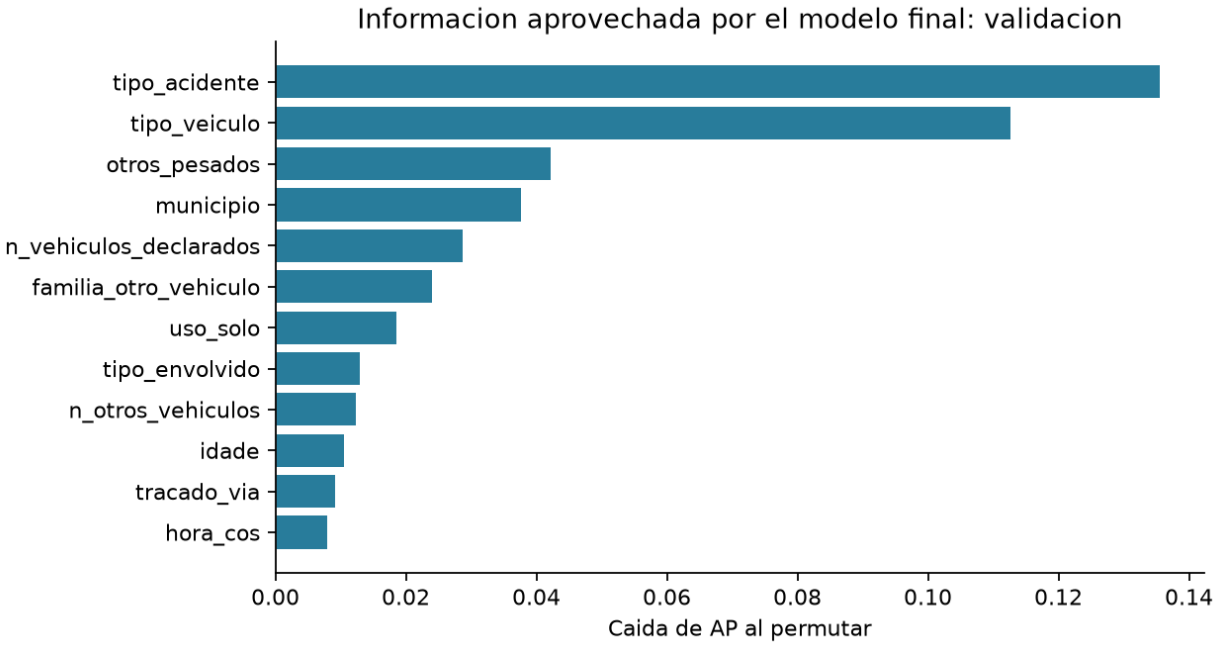
El modelo rinde mejor con los datos usados para aprender: AP es 0,456 en entrenamiento, 0,358 en validación y 0,352 en 2026. Parte del rendimiento de entrenamiento no se mantiene en casos posteriores. La cercanía entre validación y prueba es favorable, pero no garantiza el mismo resultado en cualquier año.

Calibración: ajustar los porcentajes de riesgo



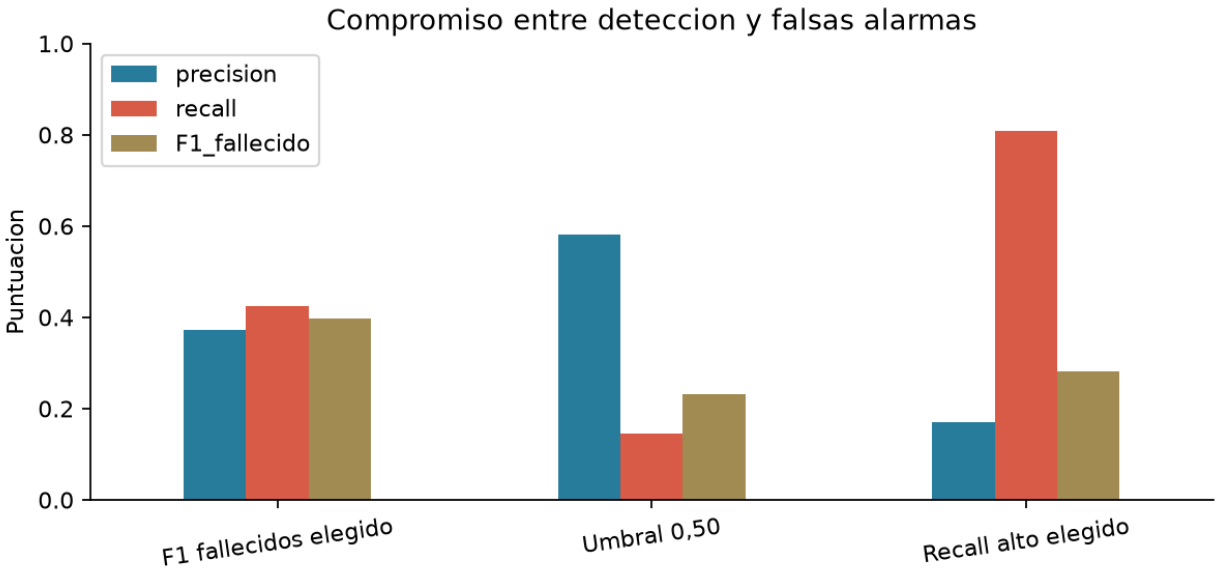
Calibrar significa ajustar los porcentajes de riesgo. Si muchos casos reciben un riesgo del 20 %, buscamos que cerca de 20 de cada 100 hayan terminado en fallecimiento. Usamos enero-junio de 2024 para ese ajuste. La curva revisa grupos; no garantiza lo que le pasará a una persona.

Interpretación y relación con inferencia



Mezclamos los valores de una variable en una muestra de validación y observamos cuánto empeora el modelo. Una caída mayor indica que esa información ayudaba más. Dos variables parecidas pueden reemplazarse parcialmente. Importancia para predecir no significa que sea una causa.

Heridos, fallecidos y punto de decisión



Con la decisión elegida encontramos cerca de 42 de cada 100 fallecidos y acertamos cerca de 37 de cada 100 alertas de fallecimiento. Al bajar la exigencia para alertar encontramos cerca de 81 de cada 100 fallecidos, pero solo unas 17 de cada 100 alertas son correctas. Detectar más implica aceptar más falsas alarmas.

Casos mal predichos e incertidumbre

Error	Edad	Rol	Vehículo	P(fallecido)
FN	25.0	CONDUTOR	MOTOCICLETA	0,002
FN	31.0	CONDUTOR	MOTOCICLETA	0,003
FN	25.0	CONDUTOR	MOTOCICLETA	0,003
FN	22.0	PASSAGEIRO	AUTOMOVEL	0,004
FN	20.0	PASSAGEIRO	MOTOCICLETA	0,004
FN	40.0	CONDUTOR	MOTONETA	0,004

Son errores cometidos aunque el modelo asignaba un riesgo alto o bajo con mucha confianza. Los revisamos para reconocer sus límites, no para explicar qué causó el resultado. Las tablas completas incluyen veinte casos y evaluaciones por sexo, edad, rol, vehículo y ubicación. No cambiamos decisiones por grupo mirando la prueba.

Cambio final - referencia	IC 95% inferior	IC 95% superior
delta_AP	0,0473	0,0624
delta_ROC_AUC	0,0412	0,0499
delta_F1_macro	0,0216	0,0327
delta_precision	0,0501	0,0698
delta_recall	0,0165	0,0413

Los intervalos se obtuvieron repitiendo 300 veces la selección de accidentes completos con reemplazo. Comparamos ambos modelos sobre las mismas víctimas. Los cinco cambios son positivos en esos intervalos, pero eso no elimina posibles problemas del registro o diferencias entre lugares y años.

Conclusión general y límites

La respuesta final es que combinar información de la persona, el vehículo y el accidente permite distinguir heridos y fallecidos mejor que referencias sencillas. El mejor modelo fue LightGBM con 31 características: AUC 0,845 y F1 macro 0,675 en 2026. Sobre las mismas víctimas, la referencia obtuvo 0,799 y 0,647. Detectamos 132 fallecidos más y generamos 717 falsas alarmas menos.

El modelo todavía clasifica como heridos a 2.657 de los 4.610 fallecidos y genera 3.277 falsas alarmas. Con la decisión principal detecta cerca de 42 de cada 100 fallecidos. Si bajamos la exigencia podemos detectar más, pero aumentan mucho las falsas alarmas. No hay una decisión perfecta para todos los usos.

El rendimiento es mejor en entrenamiento que en datos posteriores: AP es 0,456, frente a 0,358 en validación y 0,352 en 2026. Parte de lo aprendido no se mantiene fuera del entrenamiento. También faltan velocidad de impacto, casco, cinturón y seguimiento clínico completo. El modelo no está validado para decisiones médicas ni para aplicarlo automáticamente a Paraguay.

Usamos IA como apoyo en programación, análisis y redacción. El grupo debe revisar y comprender el trabajo y asumir sus decisiones antes de presentarlo. Los legajos y las contribuciones de cada integrante deben completarse por el grupo; no inventamos aprobaciones docentes ni participación individual.