CIENCIA DE DATOS - PROYECTO INTEGRADOR

# Informe integrador - Tres fases

## Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Estudio 2017-2025; validación enero-septiembre 2026


### Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.


### Qué contiene este material

Resultados calculados con registros individuales y evaluación temporal. Borrador de apoyo académico con asistencia de IA: el equipo debe revisar, comprender y asumir las decisiones metodológicas y las interpretaciones antes de presentar.

El modelo estima un desenlace registrado entre víctimas lesionadas atendidas por PRF. No predice quién sufrirá un accidente, no establece causas y no está validado para uso médico ni para Paraguay.

Fecha: 31 de octubre de 2026.

# Índice de secciones

1. Problema y objetivos

2. Fuentes y construcción

3. Calidad de los datos

4. Desbalance y edad

5. Cambios temporales

6. Inferencia: diseño

7. Inferencia: hipótesis

8. Inferencia: resultados

9. Inferencia: conclusión

10. Diseño experimental y correcciones

11. Comparación de familias y línea base

12. Búsqueda temporal de la opción final

13. Evaluación posterior y comparación

14. Curvas ROC y precisión-recall

15. Aciertos y errores del modelo final

16. Sobreajuste y generalización

17. Calibración

18. Interpretación y relación con inferencia

19. Desbalance y umbrales

20. Casos mal predichos e incertidumbre

21. Conclusión general y límites

# Problema y objetivos

## Contexto y relevancia

PRF publica registros administrativos de siniestros en carreteras federales y sus involucrados. Comprender qué características distinguen lesiones no fatales y fallecimientos registrados permite formular hipótesis y evaluar predicción académica. El trabajo anterior de Paraguay solo disponía de totales agrupados: expandirlos no creaba información individual.

## Pregunta principal

¿Qué características personales, vehiculares y del siniestro se asocian con el fallecimiento registrado frente a lesiones no fatales en víctimas de siniestros de PRF Brasil entre 2017 y 2025, y qu? desempeño alcanza su clasificación en el período posterior de 2026?

## Objetivo general

Analizar asociaciones entre características individuales y del siniestro con el desenlace y evaluar la capacidad de modelos para clasificar víctimas heridas o fallecidas registradas, mediante un procedimiento reproducible y sin filtraciones del resultado.

## Objetivos específicos

- Construir una tabla individual de víctimas con sus características personales, vehiculares y del siniestro mediante claves reales y controles de unión.
- Evaluar la calidad, las ausencias y los patrones de edad, sexo, vehículo, lugar y tiempo en 2017-2023.
- Contrastar cuatro hipótesis con tamaños de efecto, intervalos y corrección de multiplicidad, considerando víctimas del mismo accidente.
- Comparar modelos de varias familias con validación temporal, calibración y tratamiento explícito del desbalance.
- Medir en 2025 el aporte de las nuevas variables frente a sexo/edad y referencias triviales, comunicando errores y límites.

# Fuentes y construcción

Se conservan 20 ZIP CSV y 2 diccionarios PDF oficiales del corte descargado el 31/10/2026. En 2017-2025 hay 632.713 accidentes distintos y 1.654.197 filas en personas; el corte 2026 agrega 54.895 ocurrencias y 148.868 filas en personas. Se descartaron del objetivo ilesos y desenlaces desconocidos; 144.628 filas con pesid=0 de 2017-2025 no se cuentan como individuos identificados.

La base principal 2017-2025 tiene 754.098 víctimas con desenlace válido: 703.273 heridas y 50.825 fallecidas. El corte posterior 2026 agrega 67.591 víctimas (4.610 fallecidas). El dataset limpio consolidado contiene 821.689 participaciones. La unión personas.id a accidentes.id es muchos a uno, sin expansión ni víctimas sin pareja. Las claves de víctimas son únicas; los datos de vehículo ya están asociados en personas. No se inventó una tercera fuente independiente.

| Partición | Víctimas | Fallecidos | Accidentes |
|---|---|---|---|
| calibracion_2024_H1 | 43.522 | 2.911 | 29.517 |
| comparacion_retrospectiva_2025 | 89.593 | 6.043 | 61.391 |
| desarrollo_2017_2023 | 573.747 | 38.619 | 383.598 |
| prueba_posterior_2026_ene_sep | 67.591 | 4.610 | 46.337 |
| umbral_2024_H2 | 47.236 | 3.252 | 31.903 |

No hay accidentes compartidos entre particiones. pesid identifica una participación, no identidad civil longitudinal. Se inicia en 2017 por el cambio al sistema BAT. El corte 2026 se utiliza exclusivamente como validación posterior: no es un año completo y no integra la exploración o inferencia.

Fuente y licencia de datos: PRF los presenta como datos abiertos reutilizables. Se conserva atribución; la licencia del sitio web no se confunde con una licencia adicional de cada CSV. URLs exactas, tamaños y SHA-256 están en data/fuentes.json.

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes

## Calidad de los datos

El CSV original usa Latin-1 y punto y coma; las salidas usan UTF-8. Se normalizan mayúsculas, espacios y acentos de categorías, conservando la semántica. Se verifican hashes, claves, fechas y cardinalidad de la unión. La bitácora registra afectados por regla y por año.

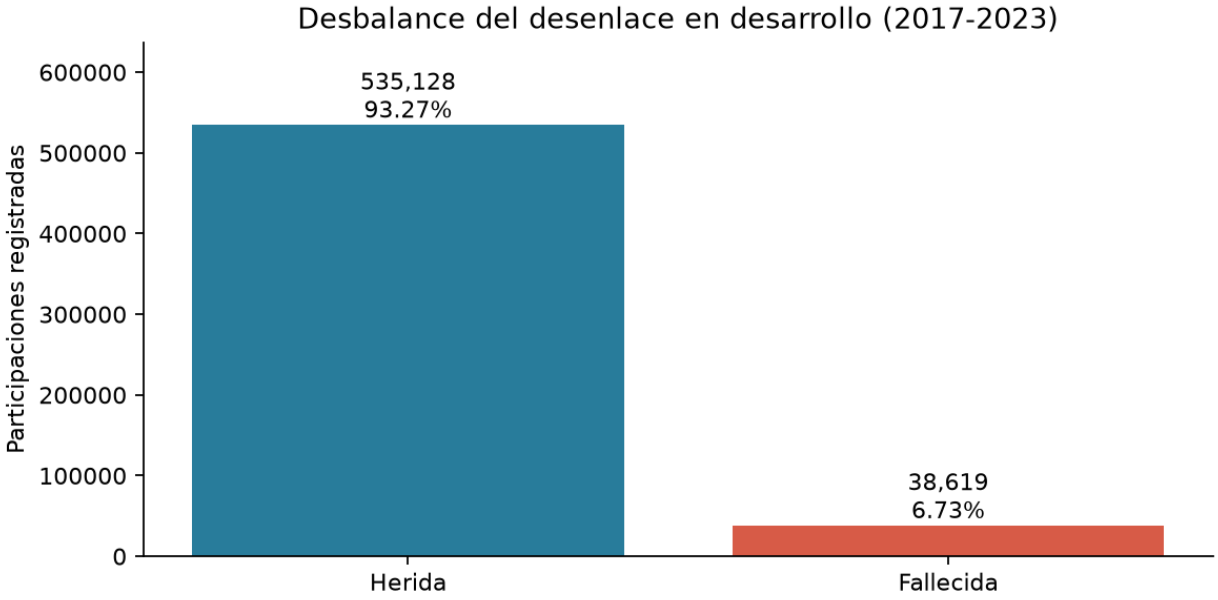
Edad cero se considera ambigua y se trata como faltante sin eliminar la víctima, al igual que edades negativas o mayores de 110. Se invalida año de vehículo cero o posterior al siniestro y se calcula antigüedad. Coordenadas fuera de límites geográficos amplios y posiciones imposibles se conservan como ausencia, no se imputan como cero.

Las categorías desconocidas se conservan. Medianas, escalado, categorías y discretización se aprenden dentro de cada entrenamiento. Los faltantes pueden depender de gravedad, rol y calidad de registro; no se presume mecanismo completamente aleatorio.

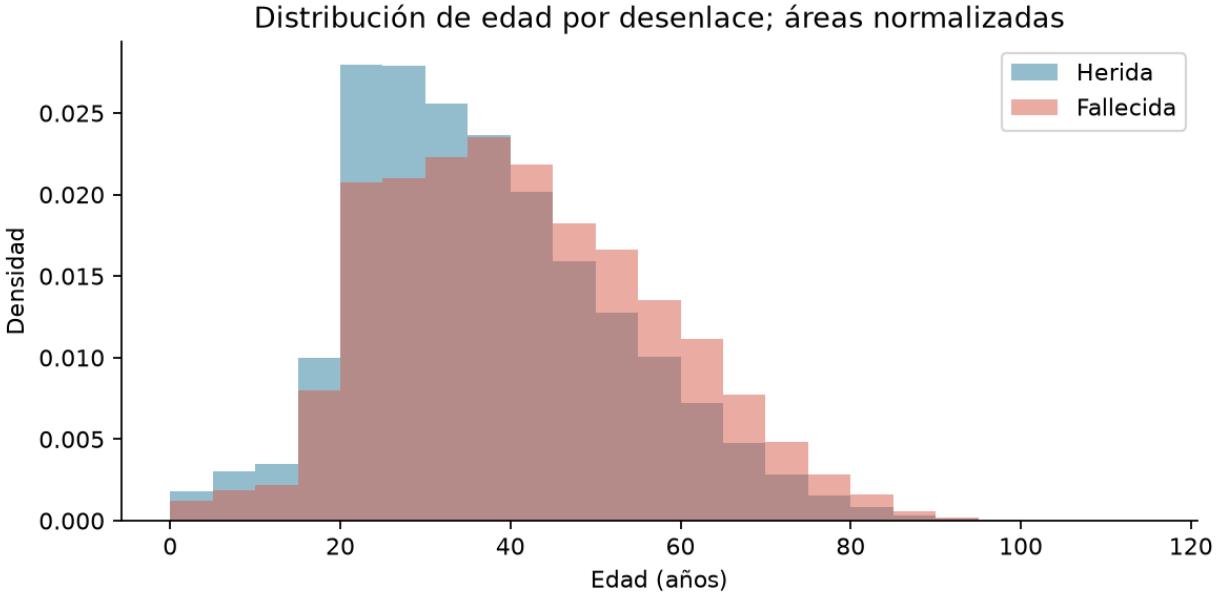
El modelo final usa 31 predictores. Los 24 iniciales incluyen edad, antigüedad de vehículo, hora y ciclos, ubicación, sexo, rol, tipo de vehículo, UF, BR, municipio, tipo de evento, fase del día, sentido, clima, calzada, trazado, suelo y día semanal. Se agregan seis cantidades de contexto vehicular y la familia del único otro vehículo identificado. El contexto se obtiene de TODOS los vehículos antes de seleccionar víctimas, incluidos ilesos y filas sin persona, deduplicando claves positivas. Se excluyen IDs, desenlace, conteos de víctimas y atribución posterior de causa.

Columnas iguales entre años no garantizan categorías idénticas: las causas y trazados cambian. No se borra un extremo plausible solo por exceder un umbral IQR. Falta exposición por viaje, velocidad previa, casco/cinturón y atención posterior; no se estima riesgo de accidente por usuario.

## Desbalance y edad

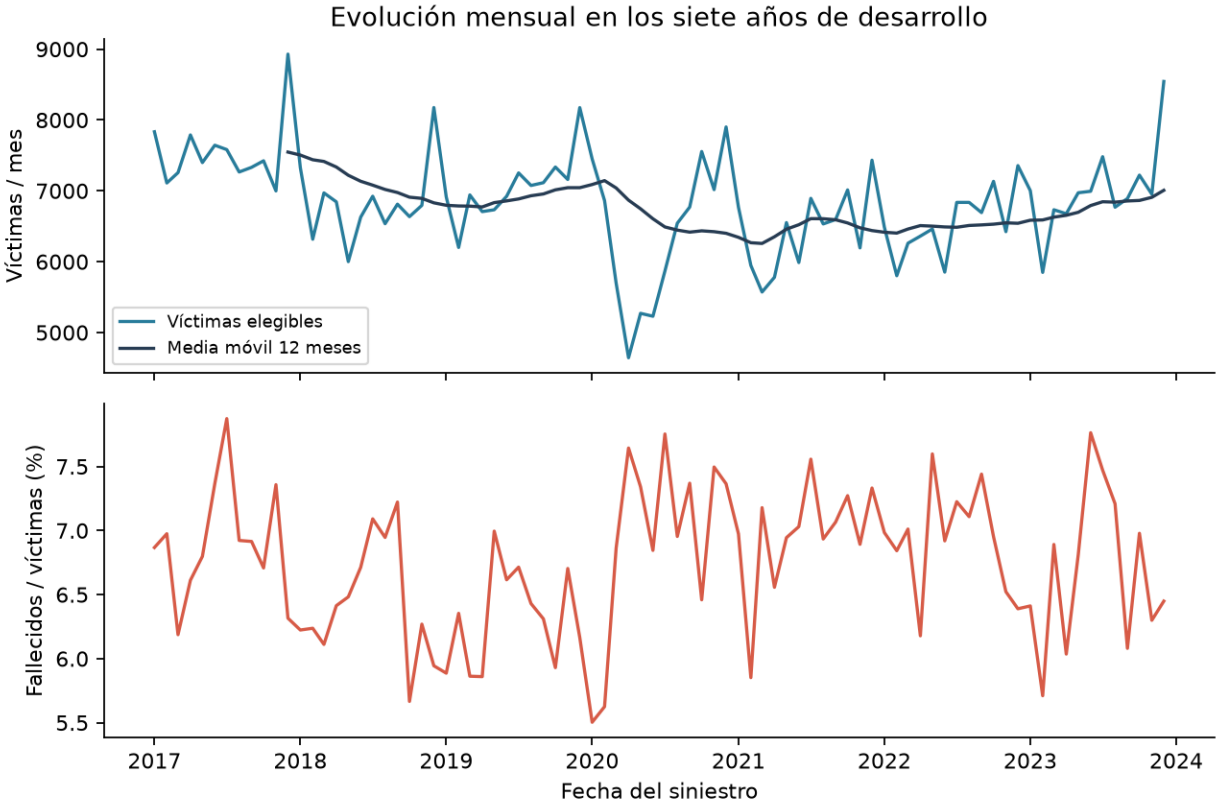



En desarrollo hay 38,619 fallecidos entre 573,747 víctimas (6.73%). La clase mayoritaria domina el total de aciertos, por lo que evaluar solo exactitud ocultaría los errores de fallecidos.




La mediana de edad registrada es 35 años en heridos y 39 en fallecidos. Se comparan densidades para que la mayor cantidad de heridos no oculte la distribución de fallecidos; edad faltante se conserva en los modelos mediante imputación.

## Cambios temporales




El volumen y la proporción de fallecimientos no permanecen idénticos todos los años. La serie corresponde a víctimas heridas o fallecidas registradas, sin medir exposición al tránsito; cambios de movilidad y registro pueden afectar las diferencias. Se respeta el orden temporal al validar.

# Inferencia: diseño

Correcciones y continuidad con la fase 1: se usan fichas reales, se conserva edad ausente sin inventar edades, se enlazan vehículo y accidente por claves y se considera dependencia entre víctimas. No se atribuye al docente una devolución nueva que no fue proporcionada.

H1-H3 usan una víctima elegida al azar por accidente, con semilla 42 y selección independiente del desenlace. Esto evita tratar pasajeros del mismo siniestro como muestras independientes, pero cambia la ponderación: representa una víctima aleatoria por accidente con lesionados, no cada víctima del total con igual peso.

La muestra contiene 383.598 accidentes. H4 utiliza 494.806 víctimas con covariables completas y errores robustos agrupados por 334.129 accidentes. Se requiere independencia aproximada entre accidentes; puede quedar dependencia temporal y geográfica.

Se cubren cuatro familias: chi cuadrado de independencia, comparación de rangos Mann-Whitney, diferencia de proporciones y regresión binomial ajustada. No se fuerzan pruebas de normalidad sobre una respuesta binaria.

# Inferencia: hipótesis

Alfa 0,05 y familia de cuatro contrastes declarados antes del cálculo, con corrección de Holm. Pruebas bilaterales; intervalos del 95 % marginales, no simultáneos. No se afirma aceptación de H0 ni se deduce causalidad.

### H1

H0: Sexo y desenlace son independientes en una victima aleatoria por accidente. H1: Existe asociacion entre sexo y desenlace.

Unidad / cobertura: Una victima aleatoria por accidente; sexo conocido; IC bootstrap multinomial.

### H2

H0: Distribuciones de edad iguales entre fallecidos y heridos. H1: Las distribuciones de edad difieren.

Unidad / cobertura: Una victima por accidente con edad 1..110; IC bootstrap estratificado por desenlace.

### H3

H0: Proporcion de fallecimiento igual en usuarios de moto y otros vehiculos. H1: Las proporciones difieren.

Unidad / cobertura: Una victima por accidente; conductores/pasajeros con vehiculo conocido.

### H4

H0: Coeficiente de noche igual a cero condicionado a los controles. H1: Coeficiente de noche distinto de cero.

Unidad / cobertura: Todas las victimas de desarrollo con covariables completas; dependencia dentro de accidente ajustada.

# Inferencia: resultados

| Hip. / prueba | Efecto | IC 95 % | p Holm | Decisión |
|---|---|---|---|---|
| H1 / Chi cuadrado independencia | V de Cramer: 0,073 | 0,071 a 0,075 | < 1e-300 | Rechazar H0 |
| H2 / Mann-Whitney bilateral, correccion de empates | Correlacion biserial de rangos: 0,161 | 0,153 a 0,168 | < 1e-300 | Rechazar H0 |
| H3 / Z bilateral de dos proporciones | Diferencia de riesgos moto menos otros: -0,004 | -0,005 a -0,002 | 1.93e-06 | Rechazar H0 |
| H4 / Wald z de GLM binomial; SE agrupados por accidente | Odds ratio ajustado noche frente a pleno dia: 1,849 | 1,799 a 1,902 | < 1e-300 | Rechazar H0 |

Estadísticos, grados de libertad cuando corresponden y tamaños muestrales se incluyen en contrastes_fase2.csv. Valores p guardados como cero corresponden a subdesbordamiento numérico y se comunican como muy pequeños, no probabilidad exactamente cero.

## Inferencia: conclusión

Los cuatro contrastes rechazan sus hipótesis nulas con Holm, pero los efectos no tienen la misma magnitud. Sexo muestra asociación pequeña; edad difiere con superposición; la diferencia de usuarios de moto es pequeña y depende del denominador; nocturnidad conserva asociación condicional en el GLM.

Los registros no provienen de muestreo probabilístico y no permiten extrapolar a toda circulación vial. Los intervalos y valores p dependen de supuestos y no capturan subregistro. Grandes cantidades hacen detectable una diferencia pequeña. La clasificación posterior debe evaluar utilidad fuera del entrenamiento, no usar significancia como sinónimo de predicción.

Se llevan edad, sexo, vehículo, rol, entorno y tiempo al modelado junto con localización y condiciones del evento. Se excluyen las variables que contienen el resultado, los IDs y la atribución posterior de causa; no se hacen nuevos contrastes hasta encontrar resultados favorables.

# Diseño experimental y correcciones

La tarea clasifica fallecimiento registrado (1) frente a lesiones leves/graves (0). La unidad es una participación real; las víctimas de un mismo accidente permanecen juntas. No se usan IDs, gravedad, conteos de muertos/heridos o atribución posterior de causa para predecir.

El proceso tiene dos etapas registradas. Primero se compararon logística, Bayes categórico, árbol, LightGBM y Dummy con 24 variables: 13 configuraciones y 39 ajustes en cortes 2021, 2022 y 2023, entrenando solo con años anteriores. Después se revis? preparación/contexto y se probaron ocho configuraciones de LightGBM (24 ajustes), sin ampliar la grilla según prueba.

Ambas etapas usan entrenamiento 2017-2023; enero-junio 2024 calibra sigmoid y julio-diciembre 2024 fija el umbral para F1 de fallecidos. La selección usa AP media de validación. La ronda final exige mejora media y en al menos dos cortes. La elección y los umbrales se congelaron antes de abrir 2026.

2025 ya había sido evaluado al diseñar la mejora y su comparación final es retrospectiva. La nueva prueba original fue enero-septiembre 2026. Los protocolos y congelamientos originales se conservan como evidencia. Reejecutar ahora los resultados conocidos no constituye una prueba ciega nueva.

Se conserva un único modelo serializado para uso: LightGBM natural, 31 predictores, 400 árboles, tasa 0,04, 15 hojas, mínimo 300 casos por hoja, L2=25 y semilla 42. Las tablas y el código de alternativas permanecen porque comparar familias es obligatorio, no como otras entregas o modelos para elegir.

## Comparación de familias y línea base

| Familia inicial | AP | AUC | Precisión | Recall | F1 macro |
|---|---|---|---|---|---|
| LightGBM | 0,302 | 0,806 | 31,78 % | 40,58 % | 0,651 |
| Logistica | 0,285 | 0,801 | 27,68 % | 46,57 % | 0,641 |
| Arbol | 0,276 | 0,779 | 27,92 % | 42,55 % | 0,638 |
| Bayes | 0,240 | 0,775 | 27,13 % | 34,62 % | 0,623 |
| Dummy | 0,067 | 0,500 | 0,00 % | 0,00 % | 0,483 |

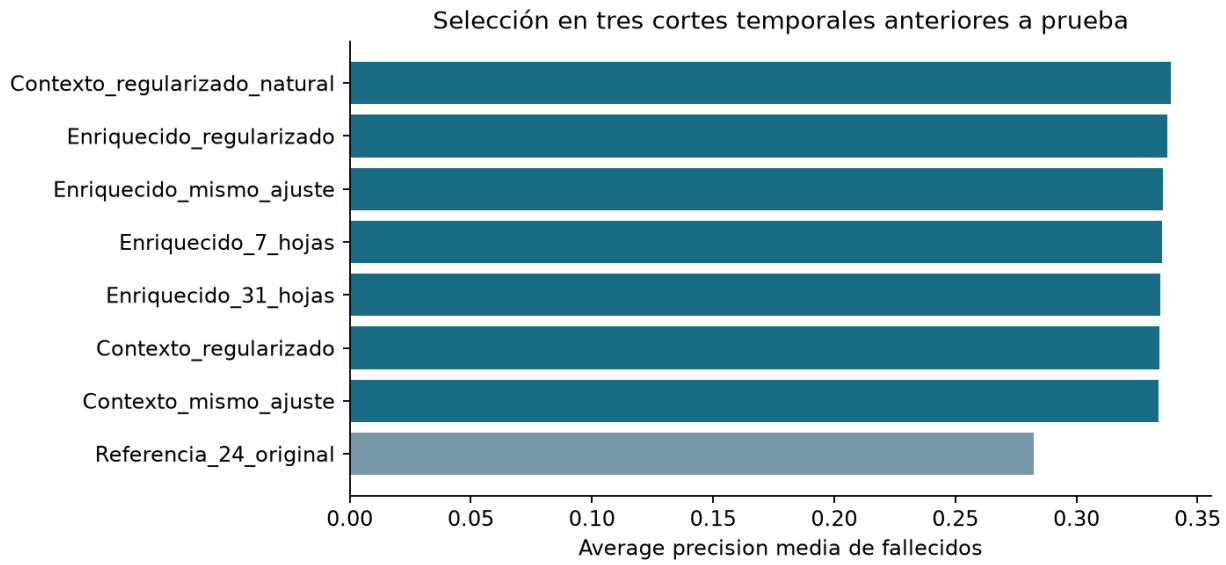
Comparación inicial sobre las mismas 89.593 víctimas de 2025, con 24 predictores por familia. Son resultados de una etapa anterior, no rivales entrenados con las 31 entradas finales. Se cubren logística, árbol, Bayes y boosting; el modelo final se compara directamente contra la referencia LightGBM de 24 variables con idénticos años de ajuste.

La búsqueda inicial compar? pesos naturales/balanceados y distintas complejidades; la final añadió contexto y regularización. No se fuerza una proporción 50/50 ni se balancea validación/prueba. La opción elegida aprende con prevalencia natural y un umbral calibrado con otro período. Los pesos no garantizan mejor ordenamiento.

## Búsqueda temporal de la opción final

| Configuración | AP CV | AUC CV | Cortes mejores |
|---|---|---|---|
| Contexto_regularizado_natural | 0,339 | 0,832 | 3 / 3 |
| Enriquecido_regularizado | 0,337 | 0,831 | 3 / 3 |
| Enriquecido_mismo_ajuste | 0,336 | 0,830 | 3 / 3 |
| Enriquecido_7_hojas | 0,336 | 0,830 | 3 / 3 |
| Enriquecido_31_hojas | 0,335 | 0,828 | 3 / 3 |
| Contexto_regularizado | 0,334 | 0,830 | 3 / 3 |
| Contexto_mismo_ajuste | 0,334 | 0,829 | 3 / 3 |
| Referencia_24_original | 0,283 | 0,791 | 0 / 3 |

La mayor AP media correspondi? a Contexto_regularizado_natural, que mejora la referencia en tres cortes. Las variantes con marca aproximada y trazado descompuesto no quedaron en el ganador. La tabla completa se conserva, sin modelos serializados descartados.



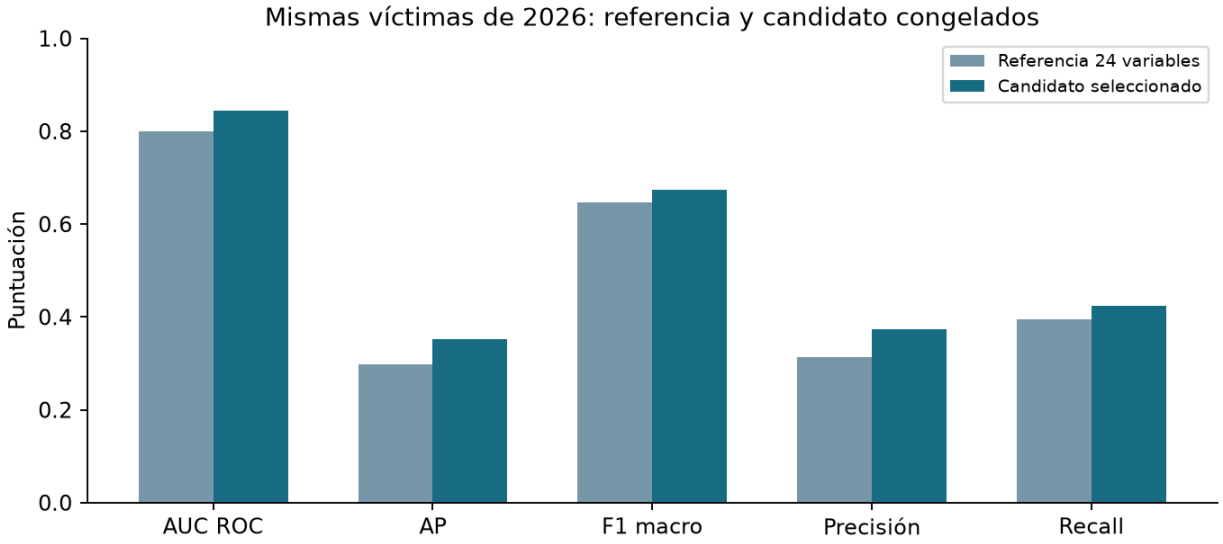

Se compararon ocho configuraciones en tres cortes anteriores a prueba. La variante elegida supera la referencia en los tres cortes; la grilla no se amplio mirando 2026.

# Evaluación posterior y comparación

| Evaluación / modelo | AUC | AP | F1 macro | Precisión | Recall |
|---|---|---|---|---|---|
| 2025 retrospectivo / Referencia | 0,806 | 0,302 | 0,651 | 31,78 % | 40,58 % |
| 2026 posterior / Referencia | 0,799 | 0,297 | 0,647 | 31,32 % | 39,50 % |
| 2025 retrospectivo / Final | 0,847 | 0,361 | 0,679 | 38,26 % | 42,98 % |
| 2026 posterior / Final | 0,845 | 0,352 | 0,675 | 37,34 % | 42,36 % |

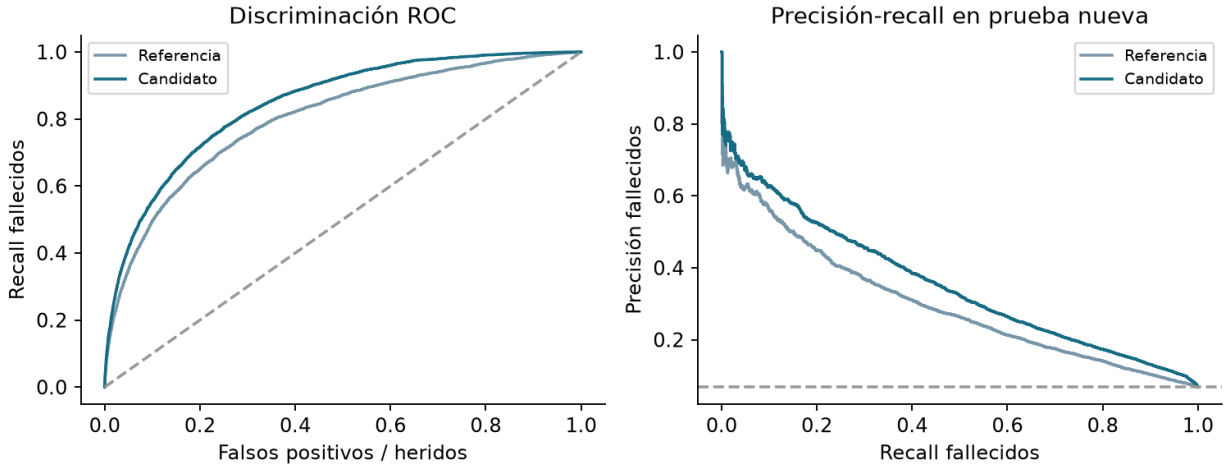
El modelo final obtiene exactitud 91,22 %, exactitud balanceada 68,58 %, F1 de fallecidos 0,397, Brier 0,0526 y log loss 0,1906.

La nueva prueba tiene 67.591 víctimas y 4.610 fallecidos. AUC 0,845 no es 84,5% de aciertos ni de fallecidos detectados. El umbral principal es 0,214245. Una referencia siempre herido alcanza exactitud cercana al 93% sin detectar fallecidos; no se usa exactitud como criterio principal.



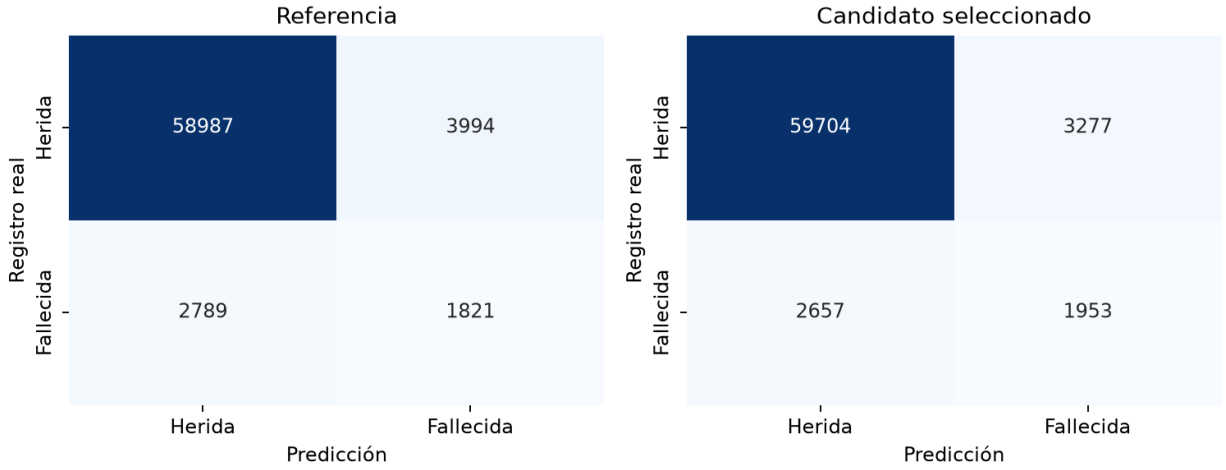

Sobre las mismas victimas de enero a septiembre de 2026, la version de 31 variables mejora AUC, AP, F1 macro, precision y recall. Los umbrales se fijaron con 2024 y se conserva prevalencia natural.

# Curvas ROC y precisión-recall



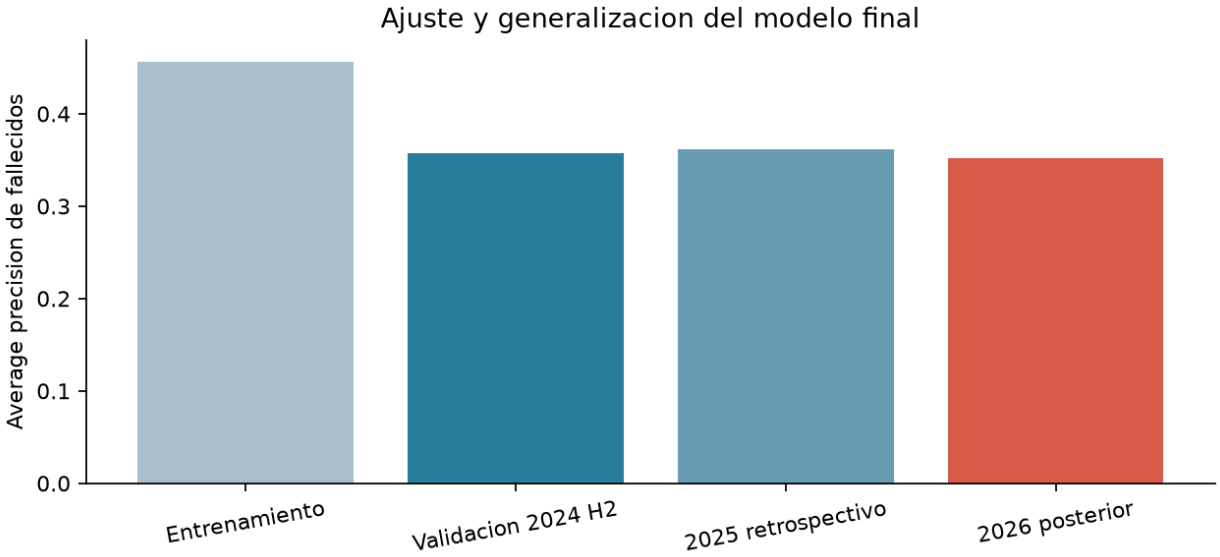

La curva precision-recall del candidato muestra mejor ordenamiento de la clase minoritaria. La prevalencia sigue influyendo en precision y AP; AUC 0,845 no equivale a detectar el 84,5% de fallecidos.

# Aciertos y errores del modelo final



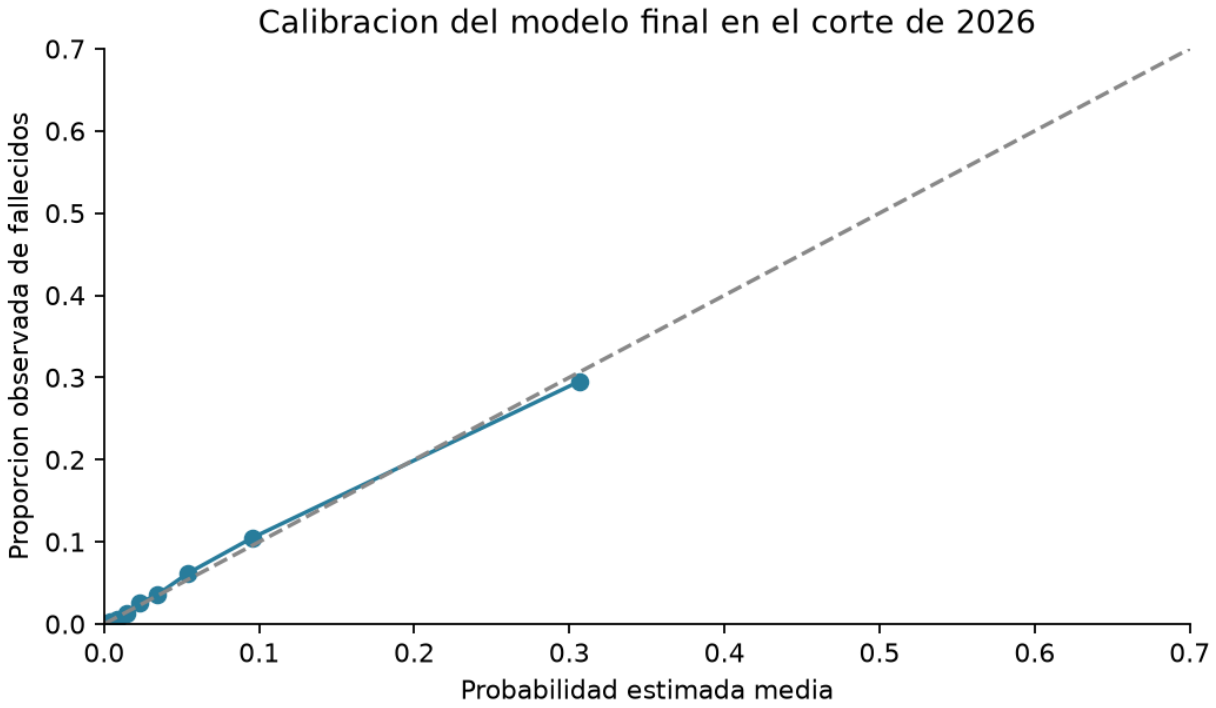

El modelo final detecta 1.953 de 4.610 fallecidos y omite 2.657; produce 3.277 falsas alarmas. Frente a la referencia son 132 detecciones mas y 717 falsas alarmas menos, sin cambiar reglas con prueba.

## Sobreajuste y generalización



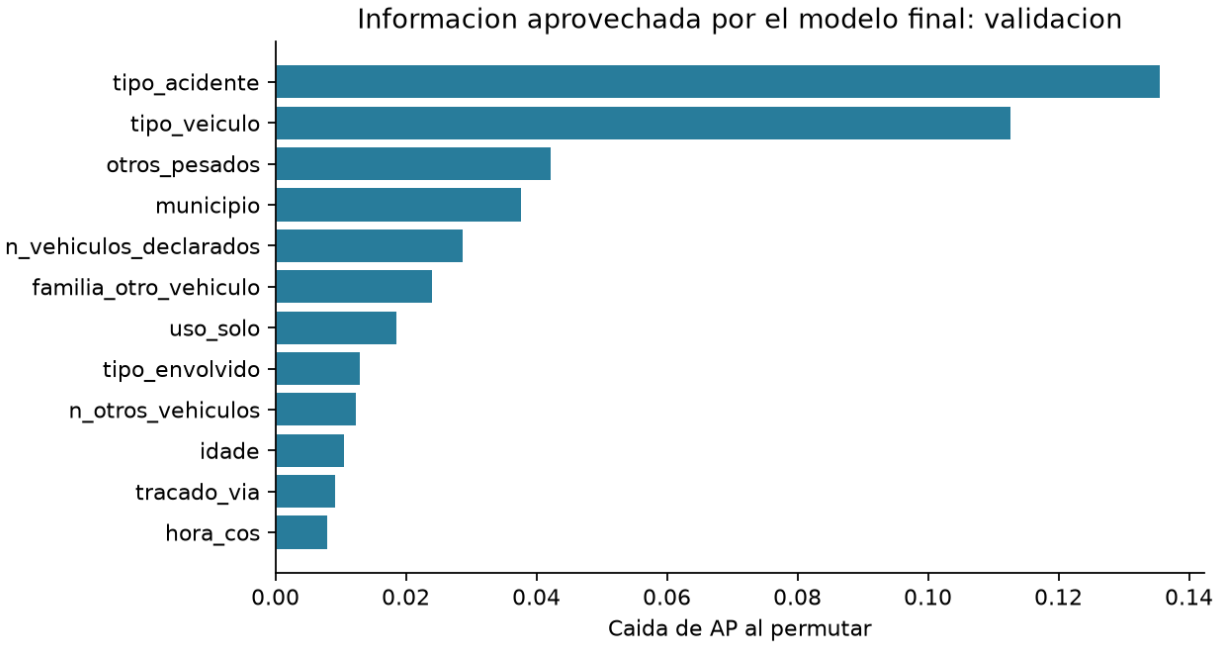

AP de entrenamiento 0,456 frente a 0,358 en validacion y 0,352 en 2026 muestra optimismo del ajuste. La estabilidad entre periodos posteriores es favorable, sin garantizar que desaparezcan sobreajuste o cambios de registro.

## Calibración



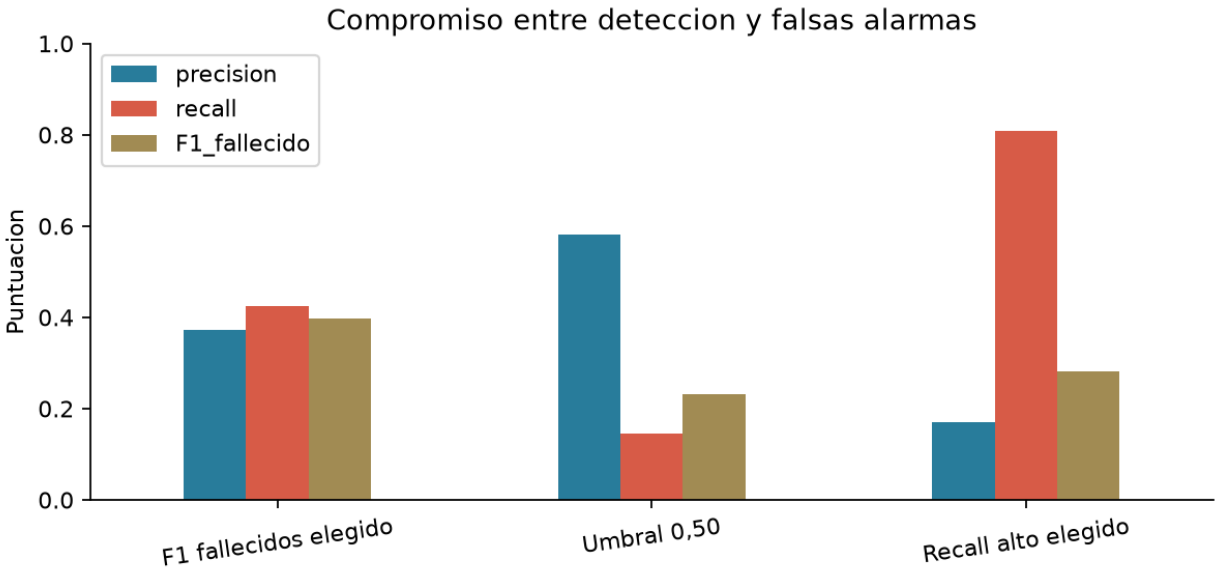

La sigmoid se ajusto en 2024 H1 con prevalencia natural. El grafico evalua fiabilidad por grupos de puntuaciones; no implica certeza individual. Brier y log loss complementan, sin aislar calibracion de todos los otros componentes.

## Interpretación y relación con inferencia




La importancia se calcula en 10.000 casos de validacion, con dos repeticiones; no se eligen variables usando prueba. Las variables correlacionadas pueden sustituirse y compartir importancia. Utilidad predictiva no demuestra causalidad.

## Desbalance y umbrales




El umbral principal detecta 42,36% de fallecidos con precision 37,34%. La regla de mayor deteccion alcanza 80,95% con precision 17,03%. Ambas se definieron con validacion; ninguna representa una politica clinica aprobada.

## Casos mal predichos e incertidumbre

| Error | Edad | Rol | Vehículo | P(fallecido) |
|---|---|---|---|---|
| FN | 25.0 | CONDUTOR | MOTOCICLETA | 0,002 |
| FN | 31.0 | CONDUTOR | MOTOCICLETA | 0,003 |
| FN | 25.0 | CONDUTOR | MOTOCICLETA | 0,003 |
| FN | 22.0 | PASSAGEIRO | AUTOMOVEL | 0,004 |
| FN | 20.0 | PASSAGEIRO | MOTOCICLETA | 0,004 |
| FN | 40.0 | CONDUTOR | MOTONETA | 0,004 |

Son ejemplos con alta confianza equivocada, no una explicación causal de por qu? ocurri? el desenlace. La tabla completa de veinte casos y las métricas por sexo, edad, rol, vehículo, contexto y UF se acompañan en CSV. La prevalencia y el tamaño por grupo condicionan las diferencias; no se cambian umbrales por grupo mirando prueba.

| Cambio final - referencia | IC 95% inferior | IC 95% superior |
|---|---|---|
| delta_AP | 0,0473 | 0,0624 |
| delta_ROC_AUC | 0,0412 | 0,0499 |
| delta_F1_macro | 0,0216 | 0,0327 |
| delta_precision | 0,0501 | 0,0698 |
| delta_recall | 0,0165 | 0,0413 |

Los IC provienen de 300 remuestras pareadas de accidentes completos y son marginales. Los cinco cambios analizados son positivos en esos intervalos; no incluyen todos los sesgos de cobertura o dependencia temporal/geográfica.

# Conclusión general y límites

Respuesta consolidada: las características del siniestro y del contexto vehicular permiten clasificar el desenlace mejor que referencias sencillas. Sobre las mismas víctimas de 2026, AUC sube de 0,799 a 0,845 y F1 macro de 0,647 a 0,675. Se detectan 132 fallecidos más y se generan 717 falsas alarmas menos con reglas fijadas anteriormente.

El modelo final aún omite 2.657 de 4.610 fallecidos y genera 3.277 falsas alarmas. Al bajar el umbral se alcanza recall 80,95% con precisión 17,03%. No existe una única regla óptima sin definir costos de errores; no se presenta el modelo como una solución clínica validada.

El optimismo de entrenamiento se mantiene: AP 0,456 frente a 0,358 en validación y 0,352 en 2026. Faltan velocidad de impacto, elementos de seguridad, exposición y seguimiento clínico. Las variables se observan en un siniestro ya ocurrido; no predicen riesgo previo de accidentarse. No se generaliza automáticamente a todo Brasil ni Paraguay.

Se declara asistencia de IA en programación, análisis y redacción. El grupo debe revisar y comprender el material y asumir sus decisiones e interpretaciones. Los legajos y las contribuciones personales/historial del grupo deben completarse por los integrantes; no se inventan aprobaciones o autorías.