Mejores datos para continuar el estudio de gravedad

Mantuvimos el tema: accidentes de tránsito y gravedad de las víctimas. Para poder avanzar con la predicción, mejoramos la información y adaptamos el alcance.

La tarea que conservamos
Distinguir entre víctimas heridas y fallecidas a partir de las características de la persona, el vehículo y el accidente.

ANTES | PARAGUAY 2021

5.493 filas; 16 perfiles

Eran frecuencias oficiales expandidas por sexo y grupo de edad. No teníamos identificadores para relacionar correctamente todas las tablas por víctima.

AHORA | BRASIL - PRF

31 características

754.098 participaciones reales en 2017-2025, más 67.591 para evaluar 2026. Podemos relacionar a las personas con su accidente y vehículo.

Qué mantuvimos	Qué tuvimos que adaptar
Gravedad: herido o fallecido.	País, población y años disponibles.
Estudiar sexo, edad y vehículo.	Algunas hipótesis y sus grupos de comparación.
Preparar datos, contrastar y modelar.	Uniones reales y evaluación por períodos posteriores.

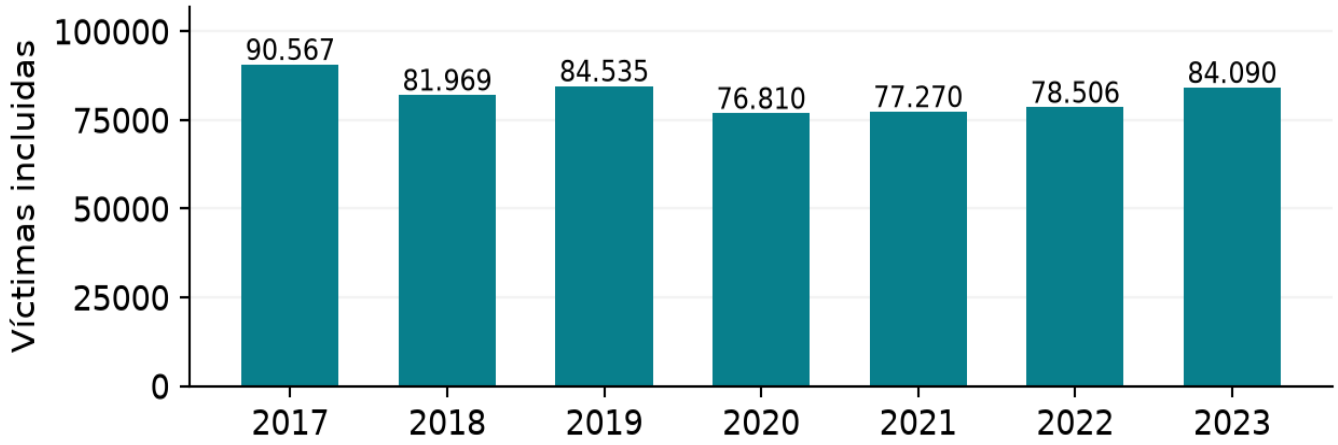
Continuidad no significa que sea exactamente el mismo estudio.
Brasil no responde por Paraguay 2021 ni confirma automáticamente sus hipótesis. Conservamos el problema central, pero cambiamos el alcance para trabajar con mejores datos.

Los conteos anteriores eran reales. La limitación era su nivel de detalle: expandir cantidades no crea nuevas observaciones individuales.

Fase 1 | Qué datos analizamos

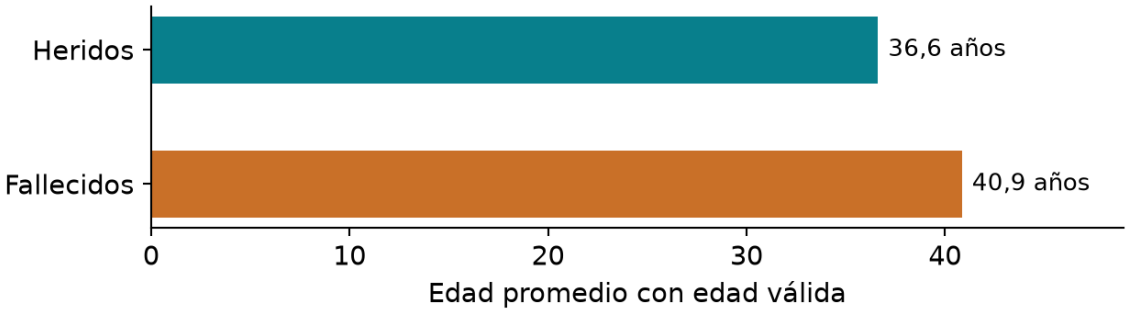
Exploramos los años 2017-2023 para entender los datos antes de evaluar el modelo en períodos posteriores. Cada fila representa la participación de una víctima lesionada en un accidente registrado por PRF.

573.747 víctimas para desarrollar el análisis



Son víctimas heridas o fallecidas, no cantidades de accidentes. El gráfico muestra el volumen disponible por año; por sí solo no mide el riesgo de circular ni explica sus cambios.

La edad aportó información para estudiar la gravedad



Promedios: 36,6 años en heridos y 40,9 en fallecidos. Se calcularon con 517.235 y 36.435 edades válidas, respectivamente. Esta diferencia describe los datos; no demuestra que la edad cause el desenlace.

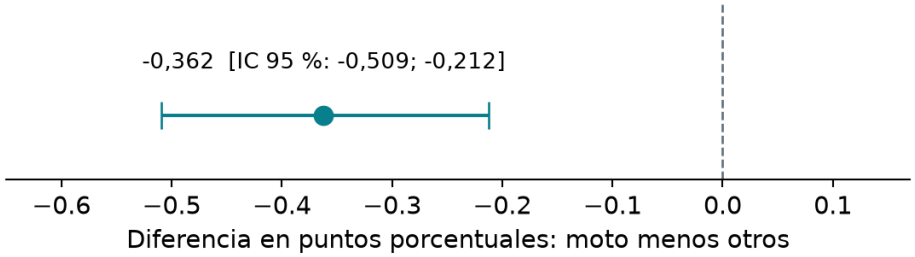
Controles que hicieron posible la Fase 3
- Verificamos las claves del accidente y de la participación: cero duplicados y cero víctimas sin unión en el conjunto seleccionado.
- Las edades imposibles se dejaron como faltantes; no inventamos edades.
- Excluimos ilesos y estados desconocidos del objetivo herido/fallecido.
- No usamos el resultado ni los totales de víctimas como predictores.

Fase 2 | Qué encontramos

Comprobamos cuatro hipótesis usando los datos de desarrollo. Para sexo, edad y motos tomamos una víctima al azar por accidente; para horario ajustamos la dependencia de víctimas del mismo accidente.

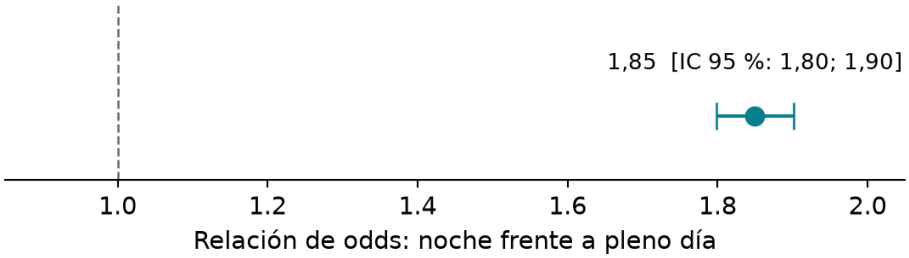
Pregunta y prueba	Resultado e interpretación
Sexo y gravedad Chi cuadrado; n = 383.153	Se encontró asociación, pero pequeña: V de Cramer = 0,073. Una diferencia estadística no implica una gran capacidad predictiva.
Edad y gravedad Mann-Whitney; n = 370.413	Las distribuciones de edad difieren. El tamaño del efecto fue 0,161; la edad ayuda, pero no explica sola la gravedad.

Motos frente a otros vehículos



Entre conductores y pasajeros con vehículo conocido (n = 363.320), la diferencia fue de -0,362 puntos porcentuales. No confirma que las motos tengan mayor proporción de fallecidos en esta muestra. Tampoco demuestra que viajar en moto sea más seguro: no medimos viajes ni kilómetros recorridos.

Noche frente a pleno día, considerando otros factores



En 494.806 víctimas con datos completos, la noche se asoció con mayores odds de fallecimiento: OR = 1,85. No significa 85 % más de probabilidad. La línea representa el intervalo de confianza; la referencia 1 indica ausencia de asociación.

Las cuatro pruebas conservaron evidencia estadística al corregir las comparaciones con Holm (5 %). Son asociaciones observacionales: no prueban causas ni garantizan que una variable mejore por sí sola las predicciones.

Cómo preparamos y evaluamos

Unimos las tablas con el identificador real del accidente. Revisamos duplicados, edades imposibles y faltantes. No inventamos personas ni mezclamos víctimas entre períodos.

PERSONA

Edad, sexo y rol: conductor, pasajero o peatón.

VEHÍCULO Y ACCIDENTE

Tipo y antigüedad, otros vehículos, choque, clima y vía.

TIEMPO Y UBICACIÓN

Horario, día, mes, ruta, municipio y coordenadas.

Cada período tiene una función

2017-2023 573.747 víctimas	Aprender las relaciones de los datos.
2024 | enero-junio 43.522 víctimas	Calibrar: ajustar los porcentajes de riesgo.
2024 | julio-diciembre 47.236 víctimas	Elegir desde qué riesgo clasificar como fallecido.
2025 89.593 víctimas	Comparación retrospectiva: sus resultados ya eran conocidos.
2026 | enero-sept. 67.591 víctimas	Evaluación posterior del modelo que ya habíamos elegido.

Modelos probados

Regresión logística, árbol, Naive Bayes, LightGBM y una referencia que siempre responde herido. Probamos configuraciones con años anteriores y elegimos LightGBM con 31 entradas.

El desbalance sigue presente



Desarrollo: 535.128 heridos y 38.619 fallecidos (aproximadamente 93 % / 7 %).

Consideramos pesos para los fallecidos; el ganador conservó la proporción natural. No elegimos solo por aciertos totales ni usamos muertos/heridos como entradas. La causa del accidente no integra el modelo final.

Qué logró el modelo final

LightGBM de 31 variables | Mismas 67.591 víctimas de enero-septiembre de 2026.

AUC

0,845

Ordenar los casos por riesgo

F1 MACRO

0,675

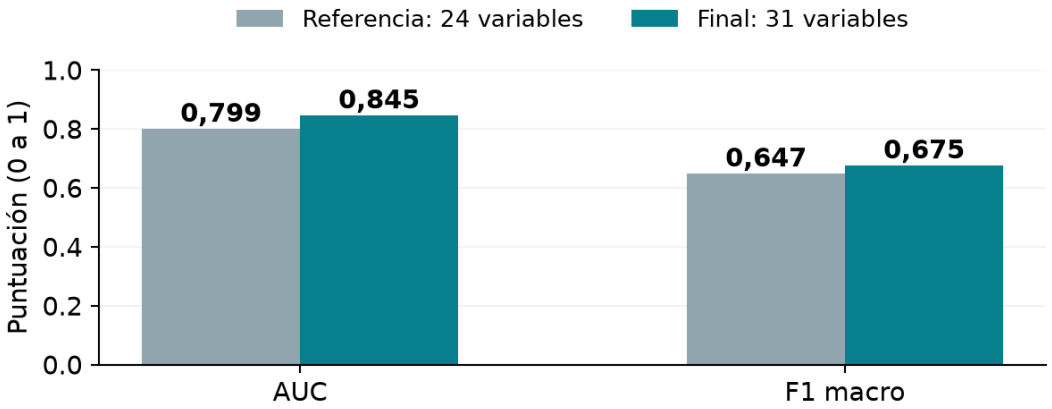
Evaluar ambos grupos por igual

DETECCIÓN

42,4 %

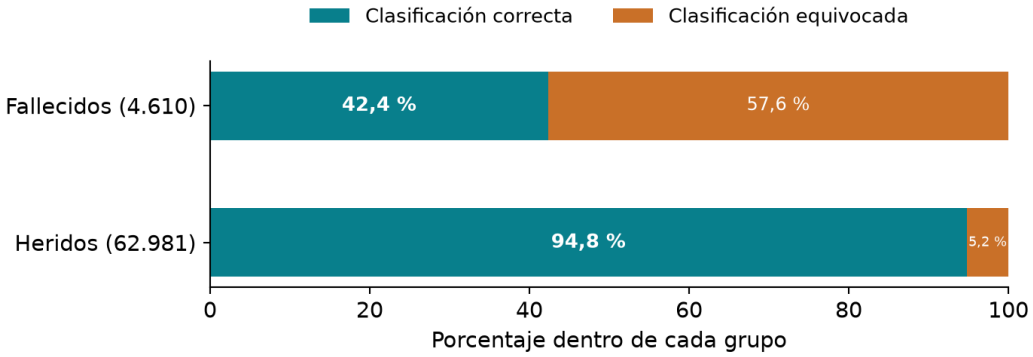
Fallecidos que logra identificar

Comparación dentro de Brasil



La referencia de 24 variables y la versión final usan la misma fuente, población y períodos. La versión final mejora variables y configuración: detecta 132 fallecidos más y produce 717 falsas alarmas menos.

Qué acierta y dónde se equivoca

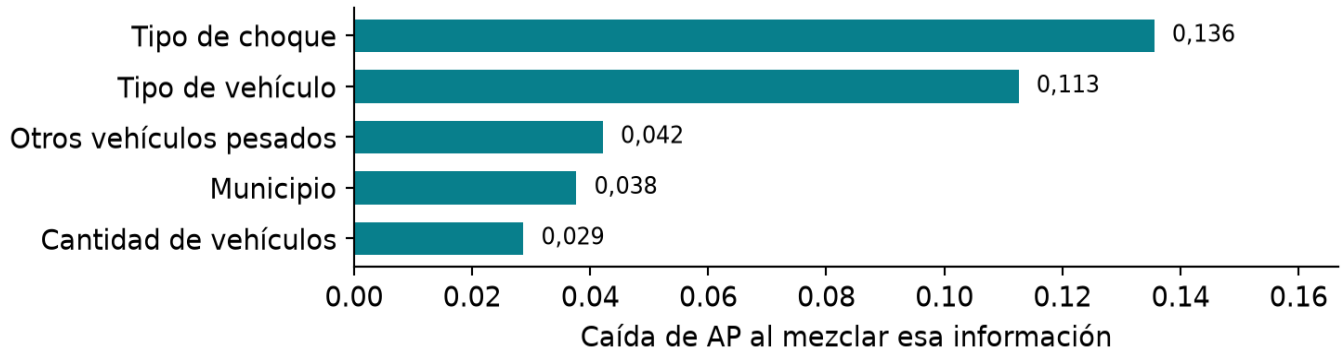


1.953 fallecidos identificados; 2.657 no detectados.
Además, marca erróneamente como fallecidos a 3.277 heridos. Todavía hay errores importantes.

AUC 0,845 no significa 84,5 % de aciertos. Las métricas del proyecto anterior (AUC 0,581 y F1 macro 0,530) proceden de otra población y otra prueba: no son una comparación controlada entre países.

Qué aprendimos y qué cambió

Qué información ayudó más al modelo



Medimos cuánto empeora el modelo al mezclar cada variable en 10.000 casos de validación. Una caída mayor indica más utilidad predictiva; no demuestra una causa.

Continuidad de las hipótesis originales

Proyecto original	Adaptación en Brasil
H1: Interior / Asunción-Central	Ese contraste no se repitió. Se usa ubicación, pero no son las mismas zonas.
H2: sexo	Nueva H1: asociación entre sexo y gravedad.
H3: mayor gravedad en motos	Nueva H3: cambiaron grupos y contraste; no confirma la dirección original.
H4: edad y adultos mayores	Nueva H2: distribución de edad. No se repitió la prueba específica de 60 años o más.
Horario como contexto	Nueva H4: noche considerando otras variables. Es una incorporación.

Conclusión y límites
Continuamos el estudio de gravedad con mejores registros y una evaluación temporal. El rendimiento es útil para el trabajo académico, pero todavía omite muchos fallecidos. Faltan velocidad de impacto, casco/cinturón y seguimiento clínico; no está validado para atención médica ni para Paraguay.

Fuentes: INE de Paraguay y registros oficiales de la Policía Rodoviária Federal de Brasil (2017 a septiembre de 2026). Elaboración del grupo a partir de los datos, pruebas y evaluaciones del proyecto.