CIENCIA DE DATOS - PROYECTO INTEGRADOR

Fase 2 - Inferencia estadística

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Período 2017-2025

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Qué contiene este material

Resultados calculados con registros individuales y evaluación temporal. Borrador de apoyo académico con asistencia de IA: el equipo debe revisar, comprender y asumir las decisiones metodológicas y las interpretaciones antes de presentar.

El modelo estima un desenlace registrado entre víctimas lesionadas atendidas por PRF. No predice quién sufrirá un accidente, no establece causas y no está validado para uso médico ni para Paraguay.

Fecha: 31 de octubre de 2026.

Índice de secciones

1. Correcciones y diseño inferencial
2. Hipótesis nulas y alternativas
3. Resultados y tamaños de efecto
4. Verificación de supuestos
5. Bootstrap frente al intervalo clásico
6. Asociación ajustada y límites
7. Conclusión de la fase 2

Correcciones y diseño inferencial

Correcciones respecto del proyecto anterior: se usan fichas reales, se conserva edad ausente sin inventar edades, se enlazan vehículo y accidente por claves y se considera dependencia entre víctimas. No se atribuye al docente una devolución nueva que no fue proporcionada.

H1-H3 usan una víctima elegida al azar por accidente, con semilla 42 y selección independiente del desenlace. Esto evita tratar pasajeros del mismo siniestro como muestras independientes, pero cambia la ponderación: representa una víctima aleatoria por accidente con lesionados, no cada víctima del total con igual peso.

La muestra contiene 383.598 accidentes. H4 utiliza 494.806 víctimas con covariables completas y errores robustos agrupados por 334.129 accidentes. Se requiere independencia aproximada entre accidentes; puede quedar dependencia temporal y geográfica.

Se cubren cuatro familias: chi cuadrado de independencia, comparación de rangos Mann-Whitney, diferencia de proporciones y regresión binomial ajustada. No se fuerzan pruebas de normalidad sobre una respuesta binaria.

Hipótesis nulas y alternativas

Alfa 0,05 y familia de cuatro contrastes declarados antes del cálculo, con corrección de Holm. Pruebas bilaterales; intervalos del 95 % marginales, no simultáneos. No se afirma aceptación de H0 ni se deduce causalidad.

H1

H0: Sexo y desenlace son independientes en una victima aleatoria por accidente. H1: Existe asociacion entre sexo y desenlace.

Unidad / cobertura: Una victima aleatoria por accidente; sexo conocido; IC bootstrap multinomial.

H2

H0: Distribuciones de edad iguales entre fallecidos y heridos. H1: Las distribuciones de edad difieren.

Unidad / cobertura: Una victima por accidente con edad 1..110; IC bootstrap estratificado por desenlace.

H3

H0: Proporcion de fallecimiento igual en usuarios de moto y otros vehiculos. H1: Las proporciones difieren.

Unidad / cobertura: Una victima por accidente; conductores/pasajeros con vehiculo conocido.

H4

H0: Coeficiente de noche igual a cero condicionado a los controles. H1: Coeficiente de noche distinto de cero.

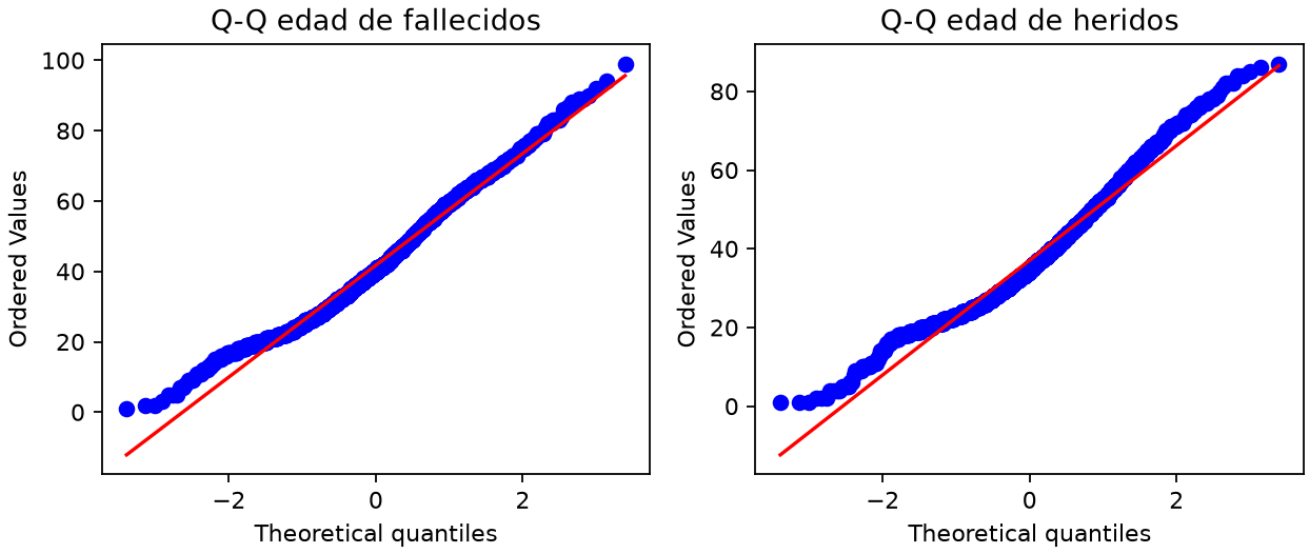
Unidad / cobertura: Todas las victimas de desarrollo con covariables completas; dependencia dentro de accidente ajustada.

Resultados y tamaños de efecto

Hip. / prueba	Efecto	IC 95 %	p Holm	Decisión
H1 / Chi cuadrado independencia	V de Cramer: 0,073	0,071 a 0,075	< 1e-300	Rechazar H0
H2 / Mann-Whitney bilateral, correccion de empates	Correlacion biserial de rangos: 0,161	0,153 a 0,168	< 1e-300	Rechazar H0
H3 / Z bilateral de dos proporciones	Diferencia de riesgos moto menos otros: -0,004	-0,005 a -0,002	1.93e-06	Rechazar H0
H4 / Wald z de GLM binomial; SE agrupados por accidente	Odds ratio ajustado noche frente a pleno dia: 1,849	1,799 a 1,902	< 1e-300	Rechazar H0

Estadísticos, grados de libertad cuando corresponden y tamaños muestrales se incluyen en contrastes_fase2.csv. Valores p guardados como cero corresponden a subdesbordamiento numérico y se comunican como muy pequeños, no probabilidad exactamente cero.

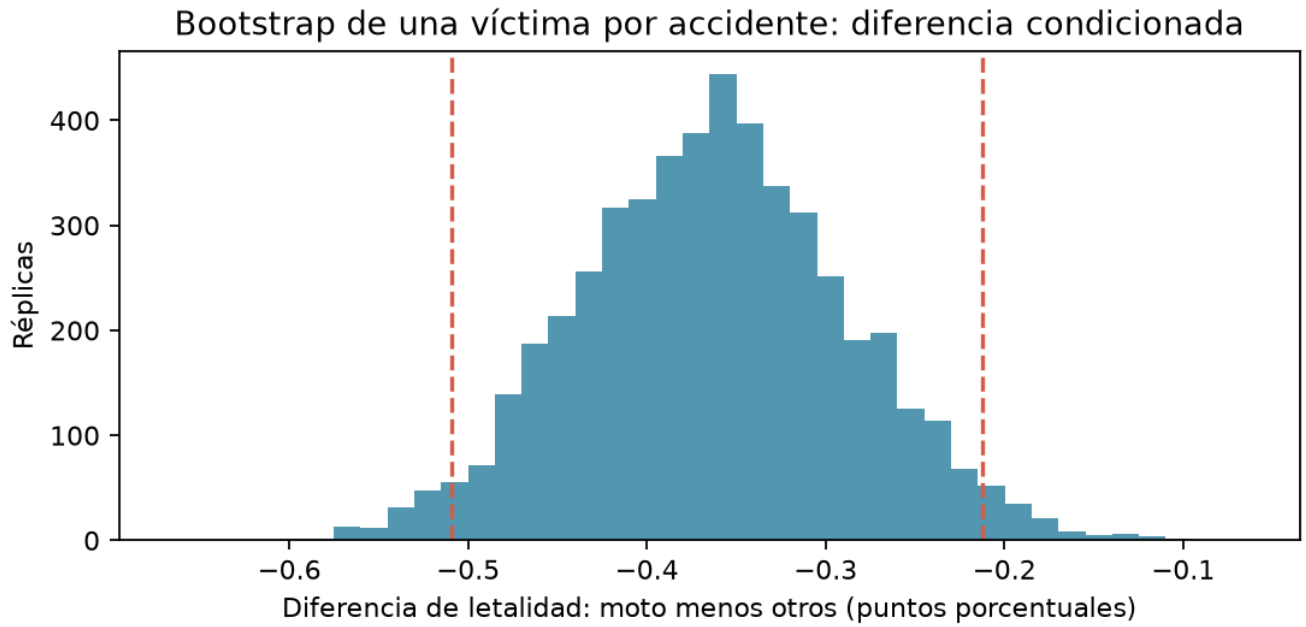
Verificación de supuestos



Q-Q sobre submuestras de edad; Shapiro en hasta 5.000 por grupo rechaza normalidad. Levene evalúa dispersión, sin ser un requisito de Mann-Whitney. La prueba de rangos compara distribuciones, no se interpreta exclusivamente como prueba de medianas. Las tablas de supuestos conservan valores p y recuentos esperados.

H1 tiene frecuencias esperadas suficientes. H3 tiene suficientes fallecidos y no fallecidos por grupo. En H4 se verifican convergencia y rango de diseño completo; se usa sandwich agrupado. Ninguna de estas comprobaciones garantiza representatividad o elimina confusión.

Bootstrap frente al intervalo clásico



Para la diferencia de letalidad moto menos otros, IC bootstrap: -0,51 % a -0,21 % puntos porcentuales; IC clásico: -0,51 % a -0,21 %. Se hicieron 5.000 remuestras empíricas Bernoulli por grupo, con una víctima por accidente.

La diferencia es pequeña y negativa en esta población condicionada a lesión registrada. No significa que usar moto sea más seguro por viaje. Se excluyen ilesos, hay diferentes tipos de siniestro y otros confusores; el denominador es decisivo.

Asociación ajustada y límites

Variable	OR	IC 95 %	p
intercepto	0,010	0,009 a 0,011	< 1e-300
noche	1,849	1,799 a 1,902	< 1e-300
edad_por_10	1,095	1,059 a 1,132	7.65e-08
edad_por_10_cuadrado	1,007	1,003 a 1,010	0.00039
masculino	1,736	1,684 a 1,790	3.43e-272
usuario_moto	1,134	1,099 a 1,169	3.02e-15
peaton	5,728	5,490 a 5,977	< 1e-300
rural	2,398	2,325 a 2,474	< 1e-300
anio_desde_2017	0,999	0,992 a 1,005	0.676

Noche frente a pleno día tiene OR ajustado aproximadamente 1,85. Se controla edad cuadrática, sexo, usuario de moto, peatón, ruralidad y tendencia anual. OR es razón de odds, no multiplicador directo de probabilidades; pueden faltar confusores y las ausencias pueden seleccionar casos.

Conclusión de la fase 2

Los cuatro contrastes rechazan sus hipótesis nulas con Holm, pero los efectos no tienen la misma magnitud. Sexo muestra asociación pequeña; edad difiere con superposición; la diferencia de usuarios de moto es pequeña y depende del denominador; nocturnidad conserva asociación condicional en el GLM.

Los registros no provienen de muestreo probabilístico y no permiten extrapolar a toda circulación vial. Los intervalos y valores p dependen de supuestos y no capturan subregistro. Grandes cantidades hacen detectable una diferencia pequeña. La clasificación posterior debe evaluar utilidad fuera del entrenamiento, no usar significancia como sinónimo de predicción.

Se llevan edad, sexo, vehículo, rol, entorno y tiempo al modelado junto con localización y condiciones del evento. Se excluyen las variables que contienen el resultado, los IDs y la atribución posterior de causa; no se hacen nuevos contrastes hasta encontrar resultados favorables.