CIENCIA DE DATOS - PROYECTO INTEGRADOR

Informe integrador - Tres fases

Factores asociados a la gravedad de las víctimas en siniestros de tránsito

Carreteras federales de Brasil - PRF - Período 2017-2025

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos pendientes de completar por el grupo.

Qué contiene este material

Resultados calculados con registros individuales y evaluación temporal. Borrador de apoyo académico con asistencia de IA: el equipo debe revisar, comprender y asumir las decisiones metodológicas y las interpretaciones antes de presentar.

El modelo estima un desenlace registrado entre víctimas lesionadas atendidas por PRF. No predice quién sufrirá un accidente, no establece causas y no está validado para uso médico ni para Paraguay.

Fecha: 31 de octubre de 2026.

Índice de secciones

1. Problema y objetivos

2. Fuentes y construcción

3. Calidad de los datos

4. Desbalance y edad

5. Cambios temporales

6. Inferencia: diseño

7. Inferencia: hipótesis

8. Inferencia: resultados

9. Inferencia: conclusión

10. Diseño experimental y desbalance

11. Búsqueda y selección temporal

12. Prueba final de 2025

13. Aporte de las variables

14. Discriminación y clase minoritaria

15. Aciertos y errores

16. Sobreajuste y generalización

17. Calibración de puntuaciones

18. Qué variables aprendió a utilizar

19. Umbrales: detección frente a falsas alarmas

20. Conclusión y comparación con el trabajo anterior

Problema y objetivos

Contexto y relevancia

PRF publica registros administrativos de siniestros en carreteras federales y sus involucrados. Comprender qué características distinguen lesiones no fatales y fallecimientos registrados permite formular hipótesis y evaluar predicción académica. El trabajo anterior de Paraguay solo disponía de totales agrupados: expandirlos no creaba información individual.

Pregunta principal

¿Qué características personales, vehiculares y del siniestro se asocian con el fallecimiento registrado frente a lesiones no fatales en víctimas de siniestros atendidos por PRF en carreteras federales de Brasil entre 2017 y 2025?

Objetivo general

Analizar asociaciones entre características individuales y del siniestro con el desenlace y evaluar la capacidad de modelos para clasificar víctimas heridas o fallecidas registradas, mediante un procedimiento reproducible y sin filtraciones del resultado.

Objetivos específicos

- Construir una tabla individual de víctimas con sus características personales, vehiculares y del siniestro mediante claves reales y controles de unión.
- Evaluar la calidad, las ausencias y los patrones de edad, sexo, vehículo, lugar y tiempo en 2017-2023.
- Contrastar cuatro hipótesis con tamaños de efecto, intervalos y corrección de multiplicidad, considerando víctimas del mismo accidente.
- Comparar modelos de varias familias con validación temporal, calibración y tratamiento explícito del desbalance.
- Medir en 2025 el aporte de las nuevas variables frente a sexo/edad y referencias triviales, comunicando errores y límites.

Fuentes y construcción

Se descargaron 18 ZIP CSV y 2 diccionarios PDF el 31/10/2026. Los archivos contienen 632.713 accidentes distintos y 1.654.197 filas en la exportación de personas. Se descartaron del objetivo ilesos y desenlaces desconocidos; 144.628 filas con pesid=0 no se cuentan como individuos identificados.

Se conservan 754.098 víctimas con desenlace válido: 703.273 heridas y 50.825 fallecidas. La unión personas.id a accidentes.id es muchos a uno, sin expansión ni víctimas sin pareja. Las claves de víctimas son únicas; los datos de vehículo ya están asociados en personas. No se inventó una tercera fuente independiente.

Partición	Víctimas	Fallecidos	Accidentes
calibracion_2024_H1	43.522	2.911	29.517
desarrollo_2017_2023	573.747	38.619	383.598
prueba_2025	89.593	6.043	61.391
umbral_2024_H2	47.236	3.252	31.903

No hay accidentes compartidos entre particiones. pesid identifica una participación, no identidad civil longitudinal. Se inicia en 2017 por el cambio al sistema BAT y se excluye 2026 por ser un año en curso.

Fuente y licencia de datos: PRF los presenta como datos abiertos reutilizables. Se conserva atribución; la licencia del sitio web no se confunde con una licencia adicional de cada CSV. URLs exactas, tamaños y SHA-256 están en descargas_prf.json.

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes

Calidad de los datos

El CSV original usa Latin-1 y punto y coma; las salidas usan UTF-8. Se normalizan mayúsculas, espacios y acentos de categorías, conservando la semántica. Se verifican hashes, claves, fechas y cardinalidad de la unión. La bitácora registra afectados por regla y por año.

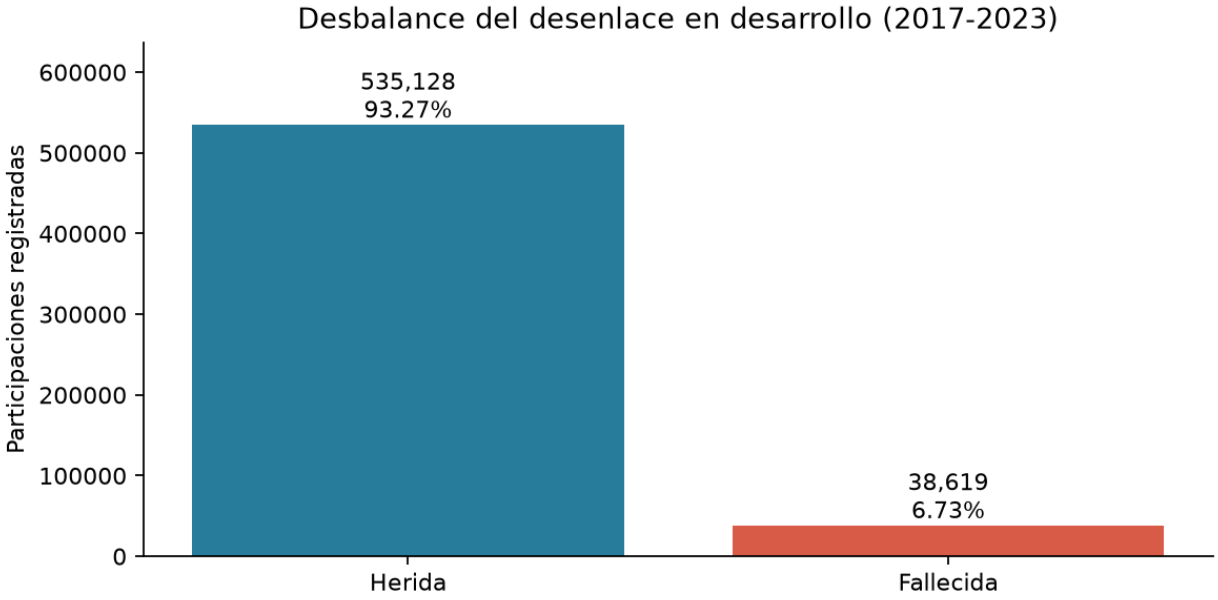
Edad cero se considera ambigua y se trata como faltante sin eliminar la víctima, al igual que edades negativas o mayores de 110. Se invalida año de vehículo cero o posterior al siniestro y se calcula antigüedad. Coordenadas fuera de límites geográficos amplios y posiciones imposibles se conservan como ausencia, no se imputan como cero.

Las categorías desconocidas se conservan. Medianas, escalado, categorías y discretización se aprenden dentro de cada entrenamiento. Los faltantes pueden depender de gravedad, rol y calidad de registro; no se presume mecanismo completamente aleatorio.

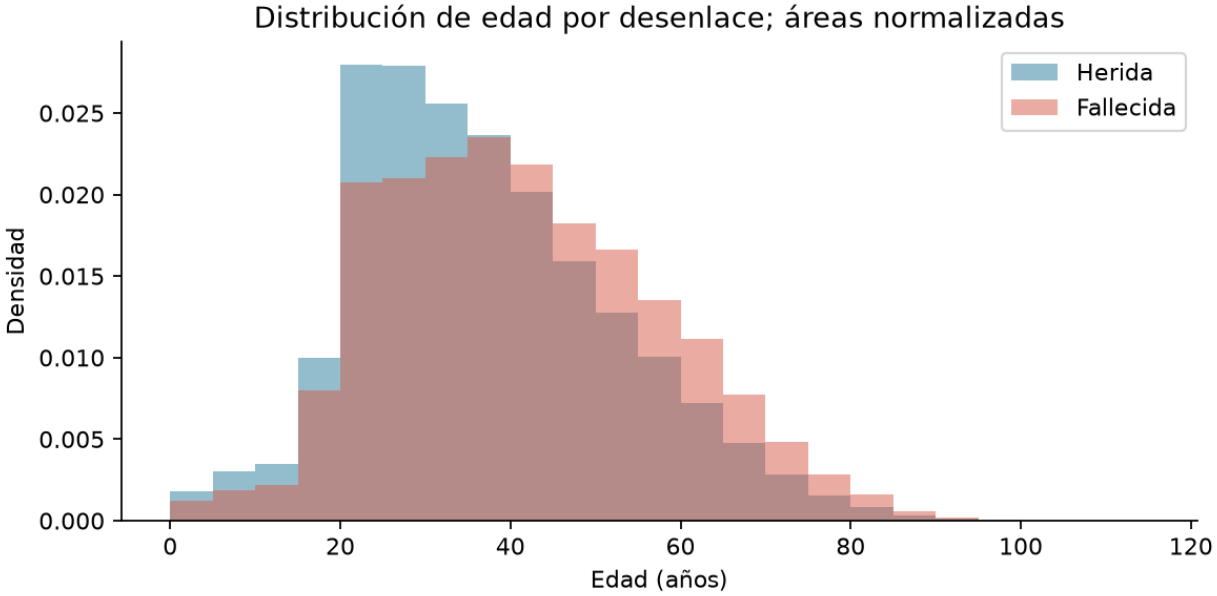
Se obtienen 24 predictores: edad, antigüedad de vehículo, hora y ciclos horarios/mensuales, ubicación, sexo, rol, tipo de vehículo, UF, BR, municipio, tipo de evento, fase del día, sentido, clima, calzada, trazado, suelo y día semanal. IDs y campos que revelan gravedad se excluyen; causa principal también se excluye por atribución retrospectiva.

Columnas iguales entre años no garantizan categorías idénticas: las causas y trazados cambian. No se borra un extremo plausible solo por exceder un umbral IQR. Falta exposición por viaje, velocidad previa, casco/cinturón y atención posterior; no se estima riesgo de accidente por usuario.

Desbalance y edad

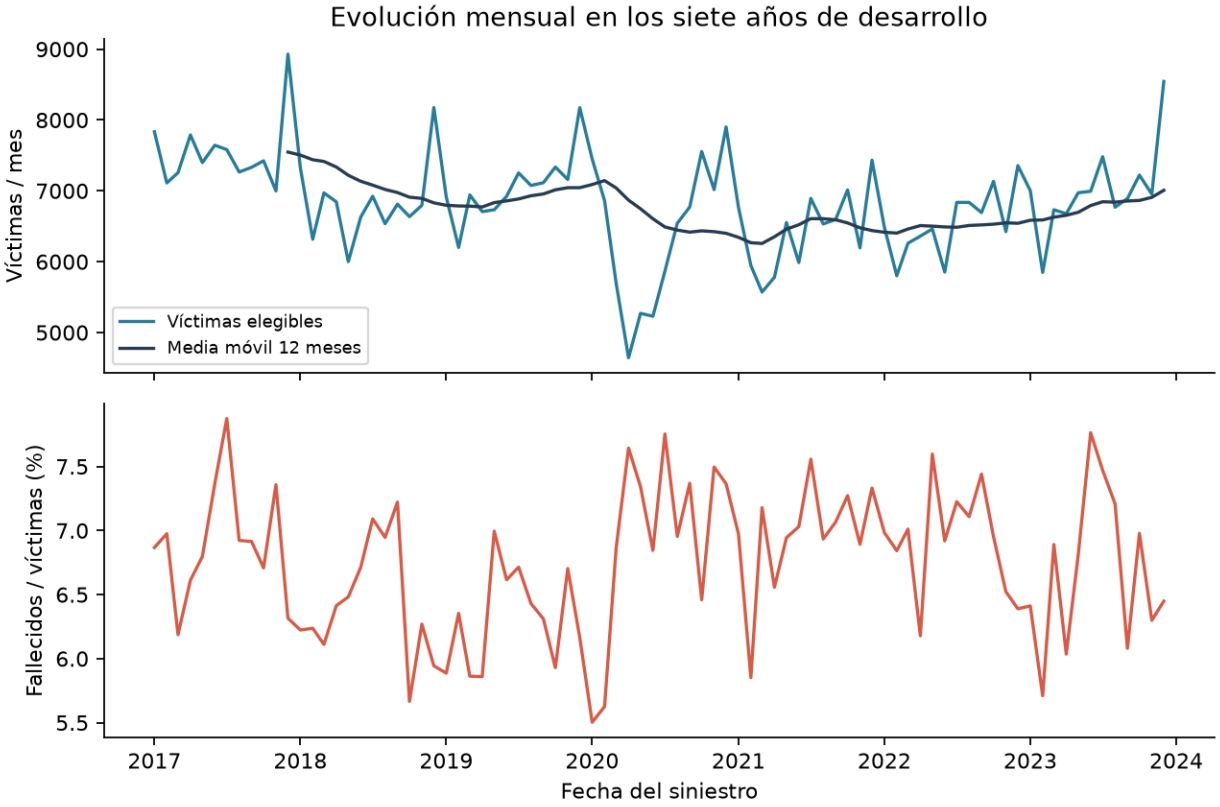


En desarrollo hay 38,619 fallecidos entre 573,747 víctimas (6.73%). La clase mayoritaria domina el total de aciertos, por lo que evaluar solo exactitud ocultaría los errores de fallecidos.



La mediana de edad registrada es 35 años en heridos y 39 en fallecidos. Se comparan densidades para que la mayor cantidad de heridos no oculte la distribución de fallecidos; edad faltante se conserva en los modelos mediante imputación.

Cambios temporales



El volumen y la proporción de fallecimientos no permanecen idénticos todos los años. La serie corresponde a víctimas heridas o fallecidas registradas, sin medir exposición al tránsito; cambios de movilidad y registro pueden afectar las diferencias. Se respeta el orden temporal al validar.

Inferencia: diseño

Correcciones respecto del proyecto anterior: se usan fichas reales, se conserva edad ausente sin inventar edades, se enlazan vehículo y accidente por claves y se considera dependencia entre víctimas. No se atribuye al docente una devolución nueva que no fue proporcionada.

H1-H3 usan una víctima elegida al azar por accidente, con semilla 42 y selección independiente del desenlace. Esto evita tratar pasajeros del mismo siniestro como muestras independientes, pero cambia la ponderación: representa una víctima aleatoria por accidente con lesionados, no cada víctima del total con igual peso.

La muestra contiene 383.598 accidentes. H4 utiliza 494.806 víctimas con covariables completas y errores robustos agrupados por 334.129 accidentes. Se requiere independencia aproximada entre accidentes; puede quedar dependencia temporal y geográfica.

Se cubren cuatro familias: chi cuadrado de independencia, comparación de rangos Mann-Whitney, diferencia de proporciones y regresión binomial ajustada. No se fuerzan pruebas de normalidad sobre una respuesta binaria.

Inferencia: hipótesis

Alfa 0,05 y familia de cuatro contrastes declarados antes del cálculo, con corrección de Holm. Pruebas bilaterales; intervalos del 95 % marginales, no simultáneos. No se afirma aceptación de H0 ni se deduce causalidad.

H1

H0: Sexo y desenlace son independientes en una victima aleatoria por accidente. H1: Existe asociacion entre sexo y desenlace.

Unidad / cobertura: Una victima aleatoria por accidente; sexo conocido; IC bootstrap multinomial.

H2

H0: Distribuciones de edad iguales entre fallecidos y heridos. H1: Las distribuciones de edad difieren.

Unidad / cobertura: Una victima por accidente con edad 1..110; IC bootstrap estratificado por desenlace.

H3

H0: Proporcion de fallecimiento igual en usuarios de moto y otros vehiculos. H1: Las proporciones difieren.

Unidad / cobertura: Una victima por accidente; conductores/pasajeros con vehiculo conocido.

H4

H0: Coeficiente de noche igual a cero condicionado a los controles. H1: Coeficiente de noche distinto de cero.

Unidad / cobertura: Todas las victimas de desarrollo con covariables completas; dependencia dentro de accidente ajustada.

Inferencia: resultados

Hip. / prueba	Efecto	IC 95 %	p Holm	Decisión
H1 / Chi cuadrado independencia	V de Cramer: 0,073	0,071 a 0,075	< 1e-300	Rechazar H0
H2 / Mann-Whitney bilateral, correccion de empates	Correlacion biserial de rangos: 0,161	0,153 a 0,168	< 1e-300	Rechazar H0
H3 / Z bilateral de dos proporciones	Diferencia de riesgos moto menos otros: -0,004	-0,005 a -0,002	1.93e-06	Rechazar H0
H4 / Wald z de GLM binomial; SE agrupados por accidente	Odds ratio ajustado noche frente a pleno dia: 1,849	1,799 a 1,902	< 1e-300	Rechazar H0

Estadísticos, grados de libertad cuando corresponden y tamaños muestrales se incluyen en contrastes_fase2.csv. Valores p guardados como cero corresponden a subdesbordamiento numérico y se comunican como muy pequeños, no probabilidad exactamente cero.

Inferencia: conclusión

Los cuatro contrastes rechazan sus hipótesis nulas con Holm, pero los efectos no tienen la misma magnitud. Sexo muestra asociación pequeña; edad difiere con superposición; la diferencia de usuarios de moto es pequeña y depende del denominador; nocturnidad conserva asociación condicional en el GLM.

Los registros no provienen de muestreo probabilístico y no permiten extrapolar a toda circulación vial. Los intervalos y valores p dependen de supuestos y no capturan subregistro. Grandes cantidades hacen detectable una diferencia pequeña. La clasificación posterior debe evaluar utilidad fuera del entrenamiento, no usar significancia como sinónimo de predicción.

Se llevan edad, sexo, vehículo, rol, entorno y tiempo al modelado junto con localización y condiciones del evento. Se excluyen las variables que contienen el resultado, los IDs y la atribución posterior de causa; no se hacen nuevos contrastes hasta encontrar resultados favorables.

Diseño experimental y desbalance

Desarrollo 2017-2023: 573.747 víctimas. Tres cortes de búsqueda entrenan hasta 2020/2021/2022 y validan respectivamente 2021/2022/2023. Cada transformación se aprende en el entrenamiento de ese corte.

Se elige por AP media de fallecidos, sin consultar prueba. El mejor de cada familia se reajusta en desarrollo. Enero-junio 2024 calibra puntuaciones mediante sigmoid; julio-diciembre 2024 elige el umbral que maximiza F1 de fallecidos. Se fija además un punto para recall >=80 % en esa validación y se compara con 0,50.

La selección y los umbrales se escriben antes de predecir 2025; la prueba se evalúa una vez y no modifica decisiones. El perfilado de fuentes sí había observado cantidades y cobertura de todos los años; se declara esa auditoría previa.

Se comparan 13 configuraciones, 39 ajustes CV, de logística, Bayes categórico, árbol y LightGBM; también dos modelos con solo sexo/edad y Dummy. La búsqueda completa está en grilla_predefinida.json. Bayes discretiza numéricas en seis intervalos de entrenamiento; árboles no necesitan escalado pero comparten preparación documentada.

Pesos de clase: logística natural frente a balanced y LightGBM natural frente a raíz de heridos/fallecidos, siempre calculados en entrenamiento. No se fabrican fallecidos ni se balancea prueba. Los pesos pueden perjudicar la calibración; se corrige con un período independiente de prevalencia natural.

Búsqueda y selección temporal

Configuración	AP CV media	SD	AUC CV
LightGBM_hojas15_pesoraiz	0,283	0,003	0,791
LightGBM_hojas15_pesonatural	0,282	0,005	0,792
LightGBM_hojas31_pesonatural	0,282	0,004	0,790
LightGBM_hojas31_pesoraiz	0,278	0,003	0,787
Logistica_natural_C1	0,263	0,004	0,785
Arbol_profundidad10	0,260	0,004	0,768
Logistica_balanceada_C01	0,251	0,005	0,785
Logistica_balanceada_C1	0,246	0,011	0,782
Arbol_profundidad6	0,239	0,003	0,755
Bayes_alpha1	0,222	0,002	0,761
Bayes_alpha10	0,218	0,005	0,758
LightGBM_solo_sexo_edad	0,101	0,002	0,612
Logistica_solo_sexo_edad	0,100	0,002	0,612

La variante ganadora fue LightGBM con 15 hojas, 240 árboles, tasa 0,06, mínimo 120 casos por hoja, regularización L2=8 y peso positivo raíz de la razón de clases. La tabla completa conserva la grilla, los cortes y los tiempos. No se eligió el ganador mirando 2025.

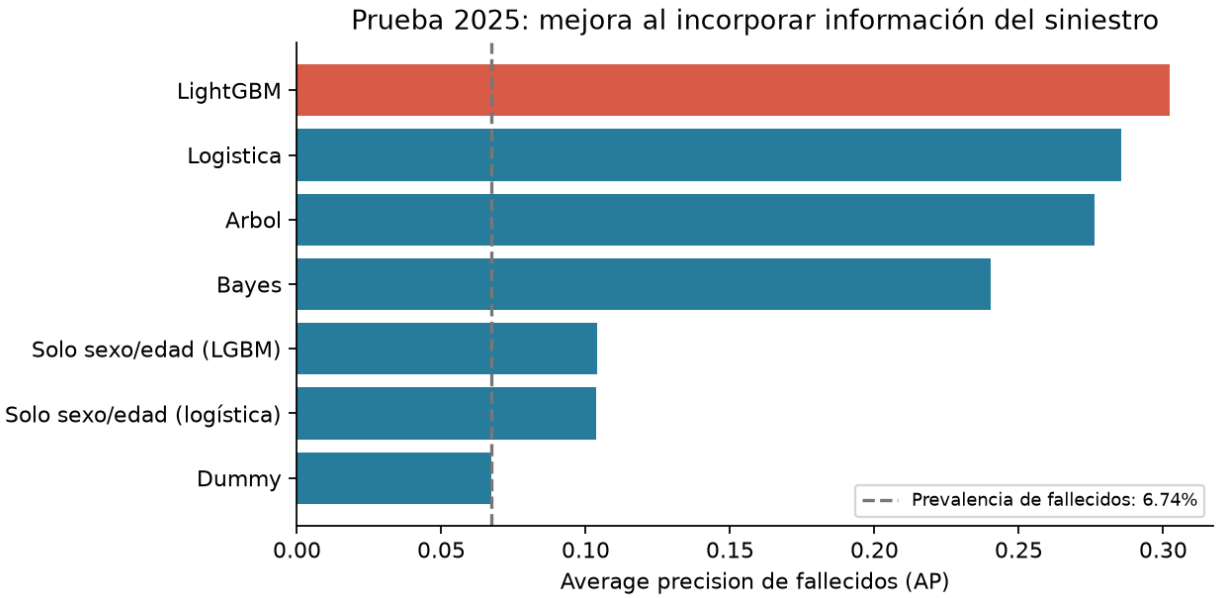
Prueba final de 2025

Modelo	AP	ROC AUC	Precisión	Recall	F1 macro	Exactitud
LightGBM	0,302	0,806	31,78 %	40,58 %	0,651	90,12 %
Logistica	0,285	0,801	27,68 %	46,57 %	0,641	88,19 %
Arbol	0,276	0,779	27,92 %	42,55 %	0,638	88,72 %
Bayes	0,240	0,775	27,13 %	34,62 %	0,623	89,32 %
LightGBM_sexo_edad	0,104	0,619	10,77 %	35,18 %	0,512	75,97 %
Logistica_sexo_edad	0,104	0,620	10,90 %	34,77 %	0,514	76,43 %
Dummy	0,067	0,500	0,00 %	0,00 %	0,483	93,26 %

Las filas sexo_edad usan únicamente esas dos variables; los demás usan 24 predictores. La prueba conserva 83.550 heridos y 6.043 fallecidos entre 89.593 víctimas. Los intervalos por remuestreo de accidentes conservan dependencia de víctimas del mismo evento.

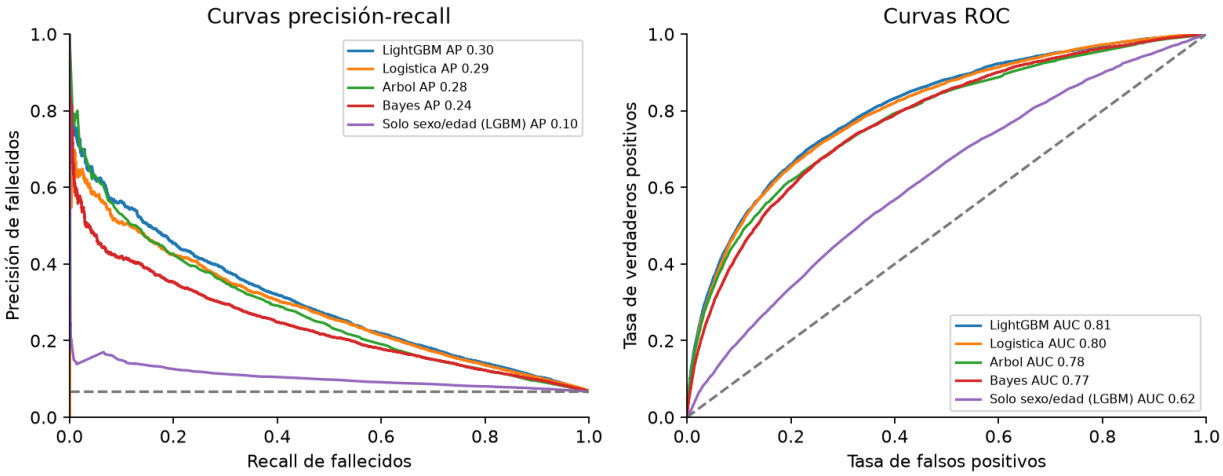
Una regla siempre herido obtiene 93,26 % de exactitud y recall de fallecidos cero. AP no es porcentaje de aciertos: su referencia para puntuación constante es la prevalencia. Precisión responde qué proporción de alertas de fallecimiento acertó; recall responde qué proporción de fallecidos reales se detectó.

Aporte de las variables



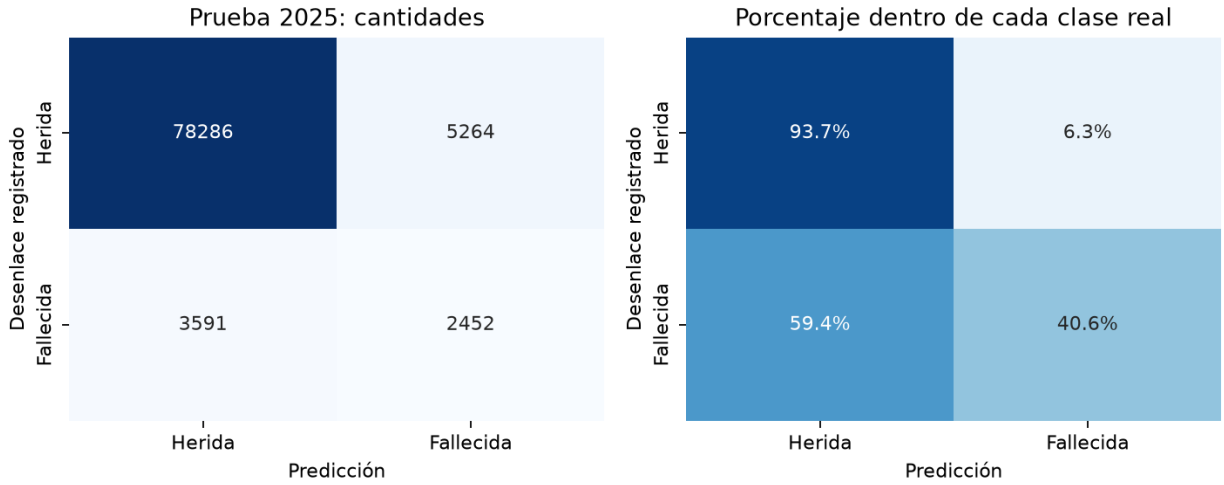
El modelo seleccionado alcanza AP=0.302, frente a 0.104 de LightGBM con solo sexo y edad y 0.067 de un puntaje constante. Se comparan las mismas víctimas de 2025; AP no es porcentaje de aciertos ni precisión en un único umbral.

Discriminación y clase minoritaria



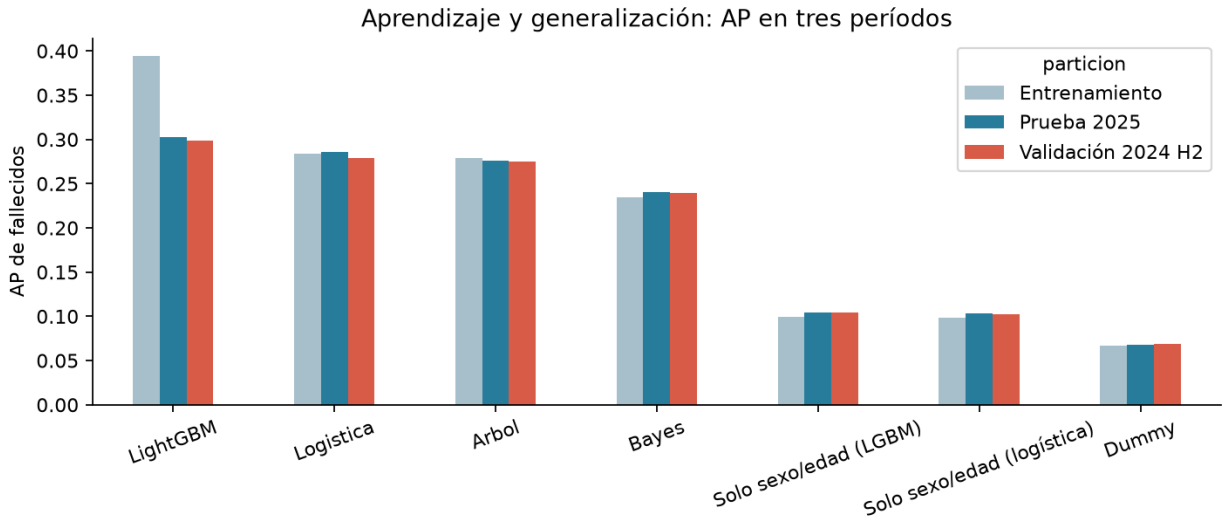
El aumento de recall exige aceptar más falsas alarmas. La curva PR se concentra en la clase minoritaria y su referencia depende de la prevalencia; AUC-ROC resume ordenamiento de ambas clases. Ninguna curva garantiza utilidad clínica.

Aciertos y errores



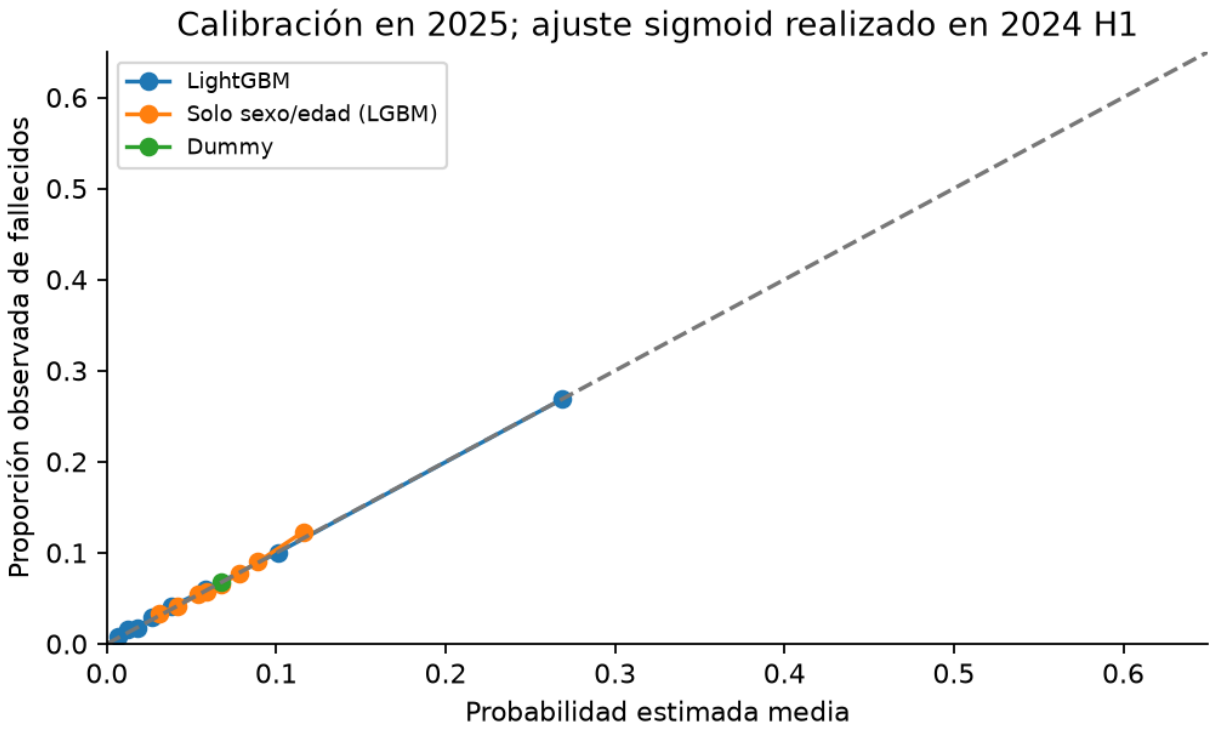
Se detectan 2,452 de 6,043 fallecimientos (40.6%); quedan 3,591 sin detectar. Hay 5,264 falsas alarmas entre heridos; 31.8% de las predicciones de fallecimiento son correctas.

Sobreajuste y generalización



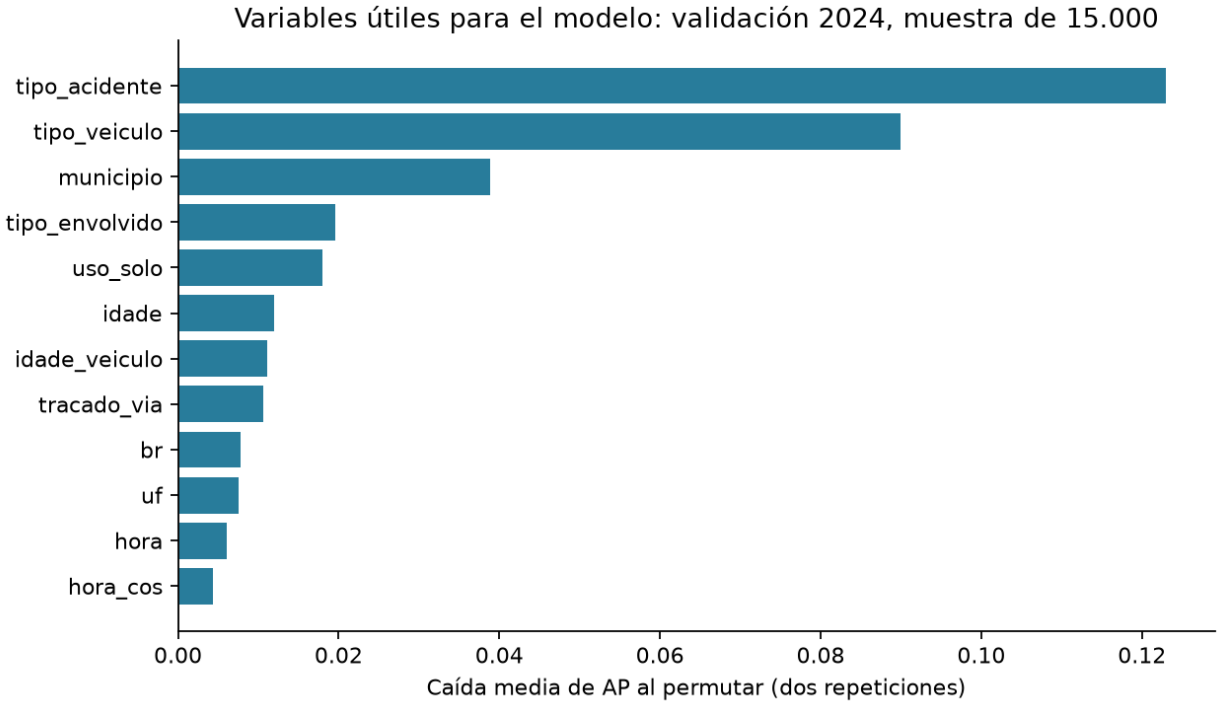
Entrenamiento mide ajuste sobre casos vistos; validación de 2024 también se utiliza para elegir el umbral. La prueba de 2025 es posterior y no se usa para modificar el modelo. Las diferencias pueden reflejar sobreajuste y cambios de población/registro, no solo tamaño de muestra.

Calibración de puntuaciones



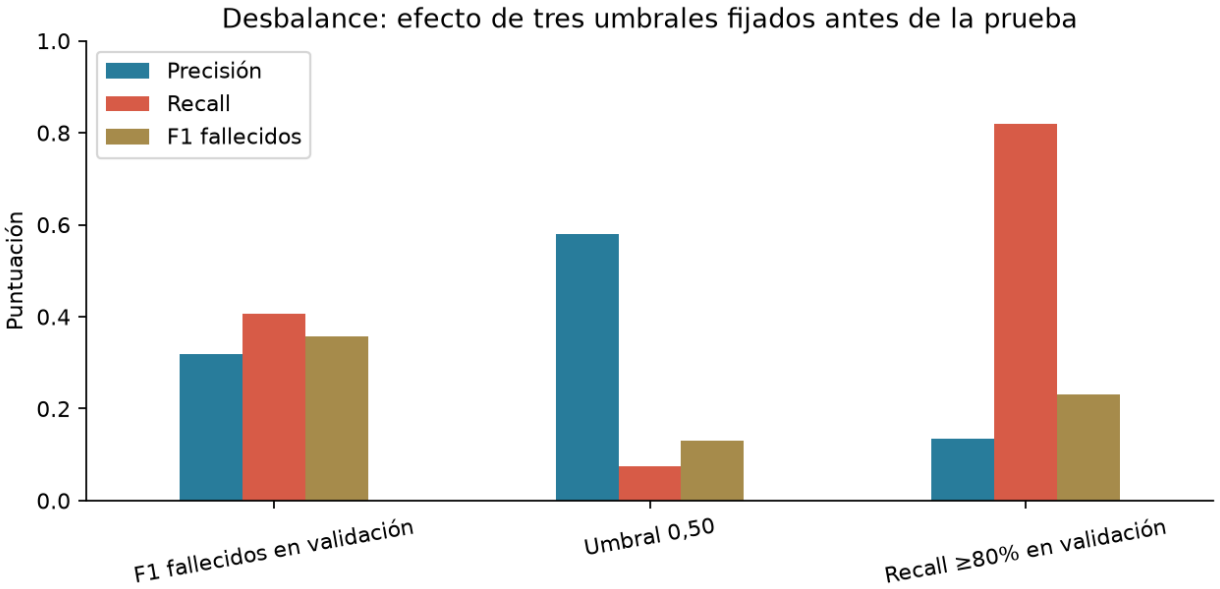
La calibración usa datos distintos de los empleados para elegir el umbral. El Brier de prueba es 0.0544; valores menores son mejores. Cercanía a la diagonal describe grupos de predicciones, no certeza sobre una persona.

Qué variables aprendió a utilizar



La caída al permutar mide utilidad predictiva condicionada al modelo, no causalidad. Las variables correlacionadas pueden sustituirse y mostrar baja importancia individual. Se calcula en validación y no se elimina ninguna variable según el resultado de prueba.

Umbrales: detección frente a falsas alarmas



Bajar el umbral incrementa la detección y las falsas alarmas. El punto llamado recall 80% se eligió en validación; su recall en 2025 puede ser distinto. No es una meta clínica aprobada ni una selección realizada usando la prueba.

Conclusión y comparación con el trabajo anterior

Respuesta a la pregunta: sí hay capacidad predictiva adicional al incorporar características vehiculares y del siniestro. En el mismo Brasil de 2025, AUC pasa de 0,619 con sexo/edad a 0,806; AP de 0,104 a 0,302, y F1 macro de 0,512 a 0,651. El IC bootstrap pareado de la mejora de AP es aproximadamente 0,187 a 0,211.

Frente al documento anterior de Paraguay, AUC 0,581 y F1 macro 0,530 son referencias descriptivas. País, población, prevalencia, variables y división son diferentes; no es una prueba causal de mejora. El recall anterior era 45,41 % y el principal actual 40,58 %: no todos los indicadores mejoraron al mismo umbral.

El modelo sigue perdiendo 3.591 de 6.043 fallecidos al umbral principal y genera 5.264 falsas alarmas. El punto de mayor detección encuentra 81,98 % pero tiene precisión 13,51 % y 31.721 falsas alarmas. No hay un único umbral óptimo para todos los objetivos: los costos reales no fueron definidos por una institución usuaria.

AP de entrenamiento 0,395, validación 0,298 y prueba 0,302 muestra optimismo del ajuste y buena proximidad entre los dos períodos posteriores, sin garantizar estabilidad futura. Ubicación y tipo de evento son útiles, pero no están disponibles antes de que exista el siniestro: esto no es predicción del riesgo de accidentarse ni mortalidad clínica al ingreso.

Persisten cobertura parcial, falta de exposición y seguimiento, ausencias, cambios de registro y dependencia geográfica/temporal. La finalidad es académica; cualquier aplicación real requeriría validar disponibilidad de variables, calibración, grupos, costos y otro período de evaluación independiente. No se reajusta este experimento con 2025 como si continuara siendo una prueba nueva.

Reproducibilidad e integridad

Código, datos preparados, modelos, tablas, notebooks y protocolo acompañan el informe. Se declara asistencia de IA en programación, análisis y redacción; el grupo debe verificar y comprender el material y adoptar sus propias decisiones e interpretaciones. No se fabrican contribuciones personales, legajos ni aprobación docente del cambio de dataset.