CIENCIA DE DATOS · PROYECTO INTEGRADOR

Fase 1 · Preparación y análisis exploratorio

Pronóstico mensual de siniestros de tránsito registrados por la Patrulla Caminera

Fuentes, calidad, limpieza, estadística descriptiva y diez visualizaciones interpretadas.

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos: no informados. Completar antes de la entrega.

Alcance

Paraguay, zona Central e Interior. Cuadros oficiales del INE con fuente Patrulla Caminera. Serie 2016-2024; desarrollo 2016-2022, calibración 2023 y prueba 2024.

Estado del material

Resultados calculados y reproducibles. Borrador de apoyo académico con asistencia de IA; el grupo debe revisar, comprender y asumir las decisiones metodológicas y la interpretación antes de entregar.

Fecha de elaboración: 31 de octubre de 2026.

Índice

03 Problema, pregunta y objetivos

04 Justificación, alcance y límites

05 Inventario, selección y calidad

06 Limpieza e integración reproducible

07 Diccionarios y transformaciones

08 Descripción univariada

09 Evolución y distribución

10 Calendario y asociación bivariada

11 Comparación anual y correlaciones

12 Calendario completo y composición

13 Estacionalidad y duración del mes

14 Conclusión y puente inferencial

15 Fuentes y reproducción

16 Integridad académica y revisión

Problema, pregunta y objetivos

Contexto y decisión

Los datos proceden de registros de la Patrulla Caminera publicados en cuadros del INE. Anticipar cantidades mensuales puede orientar planificación de recursos, sin convertir los registros institucionales en una medición completa de todos los accidentes del país.

Pregunta principal

¿Con qué precisión se pueden pronosticar los siniestros mensuales registrados por la Patrulla Caminera en zona Central e Interior durante doce meses, a partir de su historial y el calendario, frente a referencias sencillas?

Objetivo general

Evaluar la capacidad de modelos temporales y de aprendizaje automático para pronosticar doce cantidades mensuales de siniestros de tránsito registrados por la Patrulla Caminera, con trazabilidad y comparación honesta contra referencias.

Objetivos específicos

- Construir una serie mensual verificable desde los cuadros oficiales, conservando originales, versiones y procedencia por celda.
- Describir distribución, evolución temporal, composición y posibles patrones del período de desarrollo.
- Contrastar cuatro hipótesis de calendario, semestres, tendencia y dependencia de corto plazo, con supuestos y corrección múltiple.
- Comparar modelos de familias distintas mediante validación cronológica a doce meses y evaluar 2024 sin reajustar decisiones a sus resultados.
- Interpretar errores y límites, y producir una proyección reproducible posterior al último dato con su fecha de corte claramente indicada.

Justificación, alcance y límites

Justificación

El cambio de objetivo aprovecha la unidad realmente observada: una cantidad mensual. Evita expandir cuadros agregados a supuestas fichas individuales. La utilidad del proyecto está en medir qué mejora aporta un modelo y cuándo sus errores impiden usarlo con confianza.

Unidad de análisis y población observada

Una fila representa un mes calendario de registros de la Caminera en Central e Interior. La clave natural es año-mes. La fecha en el CSV usa el primer día solo para representar el período; no es la fecha de un accidente.

Alcance

Se consolidan 108 meses de 2016-2024. Las fases exploratoria e inferencial usan exclusivamente 84 meses de 2016-2022. Se reserva 2023 para calibrar una banda empírica y 2024 para evaluar pronósticos emitidos desde diciembre de 2023.

Limitaciones previstas

- No hay identificadores de accidente, persona o vehículo; no se realiza clasificación individual.
- La coincidencia aritmética entre fuentes no prueba estabilidad de cobertura o esfuerzo de registro.
- Los datos de 2024 ya eran visibles en la auditoría de fuentes; se separan del ajuste y de las pruebas inferenciales, pero no constituyen una prueba externa ciega.
- El número de períodos es limitado y los meses están temporalmente relacionados. No se supone causalidad ni riesgo por viaje.
- Un pronóstico con corte en diciembre de 2024 no es una estimación actualizada de 2027.

Inventario, selección y calidad

Se leyeron 7 archivos. Se extrajeron 168 filas mensuales y se conservaron 108 períodos únicos. Los 60 registros repetidos son versiones coincidentes; no son accidentes adicionales.

Partición	Meses	Uso
2016-2022	84	Exploración, hipótesis y validación
2023	12	Calibración de banda empírica, sin elegir modelos
2024	12	Evaluación final a doce meses

Perfilado y selección

Se selecciona el mismo cuadro de tipología por año, con alcance publicado equivalente. Otros PDF, tablas de víctimas, motociclistas y procedimientos se descartan del objetivo principal porque tienen distintas unidades o universos y no deben sumarse al total.

La consolidación concatena ediciones y resuelve la repetición de la clave temporal; no es una unión por persona. Todas las versiones originales quedan disponibles. Exactitud aparente se evalúa por sumas y coincidencias, no contra un registro externo de casos.

Dimensión de calidad	Resultado
Completitud	108 de 108 meses esperados; objetivo sin faltantes
Consistencia	Siete componentes suman el total en cada fila
Unicidad	Una fila por año-mes tras resolver versiones
Actualidad	Último dato: diciembre 2024
Cobertura	Estabilidad institucional no demostrada con estas tablas

Limpieza e integración reproducible

Decisión	Cantidad	Fundamento
Seleccion	7	Siete cuadros de tipologia con mismo alcance publicado; resto no se suma.
Extraccion	168	Filas mensuales; se excluyen titulos, fuentes y totales anuales.
Guiones a cero	100	Solo en componentes categoricos; las sumas por fila y ano se conservan. No se imputan meses.
Versiones repetidas	60	Coinciden todos los conteos; se conserva la edicion mas reciente y se guardan todas las versiones.
Normalizar fecha	108	Primer dia representa el mes, no una fecha de accidente individual.
Atipicos	0	No se eliminan ni winsorizan meses validos; los cambios pueden ser reales.
Imputar objetivo	0	No hay faltantes ni meses inventados.
Separar tiempo	108	84 desarrollo; 12 calibracion; 12 prueba.

El guion se trata como cero solo en componentes categóricos donde se verifican las sumas. No se convierte automáticamente cualquier símbolo ausente a cero. No se imputan meses ni se fabrican personas.

Atípicos

El criterio IQR señala 8 meses en desarrollo. Se conservan: un cambio real no es un error por ser extremo. El mecanismo de ausencia del objetivo no se clasifica como MCAR/MAR/MNAR porque no hay valores faltantes observados; el subregistro potencial es otra limitación.

Diccionarios y transformaciones

Campo	Significado	Unidad / uso
fecha	Clave mensual real	Mes, único
accidentes	Total registrado	Siniestros/mes; objetivo
choque…atropellamiento	Siete componentes del total	Descriptivos; no predictores del mismo mes
ano, mes, semestre	Calendario	Derivados determinísticos
dias_mes	Duración del período	Días; conocida anticipadamente
tasa_diaria_mes	Total / días	Descriptiva, excluida del modelo contemporáneo
archivo, hoja, celdas, edicion	Procedencia	No predictores
particion	Desarrollo/calibración/prueba	Asignada por fecha

El diccionario completo final informa tipos, rangos, cardinalidad y porcentaje de faltantes por campo en output/tables/diccionario_final.csv. El diccionario original describe B (año/mes), C (total) y D:J (tipos).

Variables para pronosticar

Cinco rezagos (1, 2, 3, 6 y 12 meses), dos medias anteriores (3 y 12 meses), seno/coseno del mes y días del mes. Todos se construyen con historia disponible. El primer año sirve para formar rezagos; no se rellena con ceros.

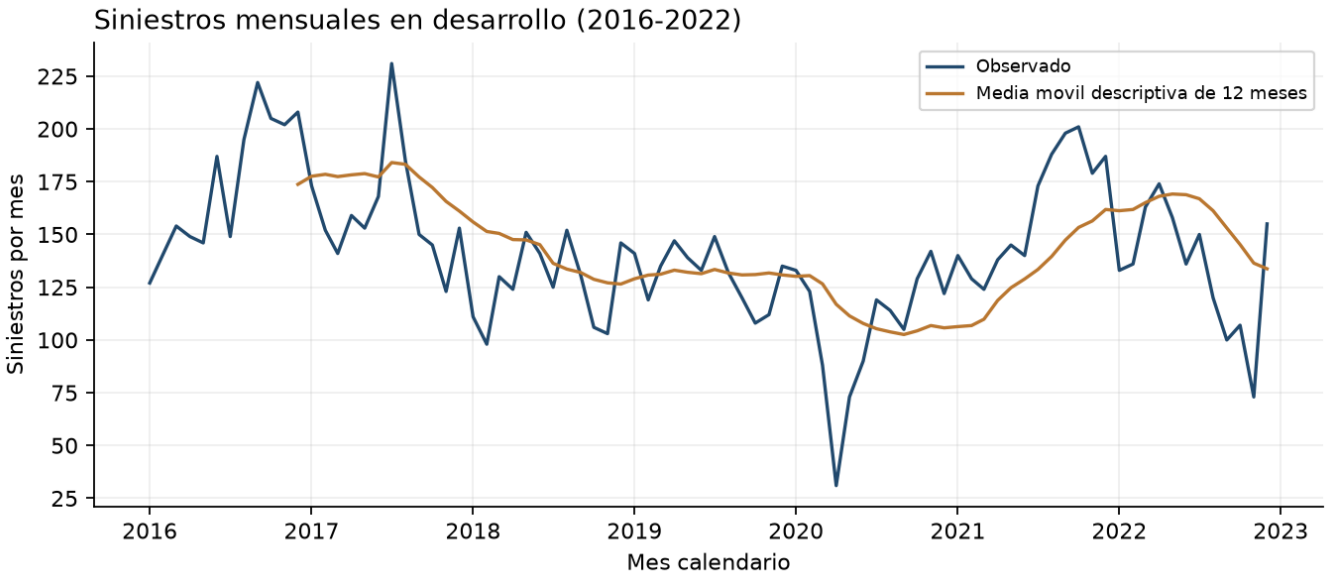
La media anterior de tres meses usa t-1, t-2 y t-3, nunca el resultado del mes a predecir. Para horizontes futuros, la recursión utiliza predicciones donde ya no existen observaciones conocidas.

Descripción univariada

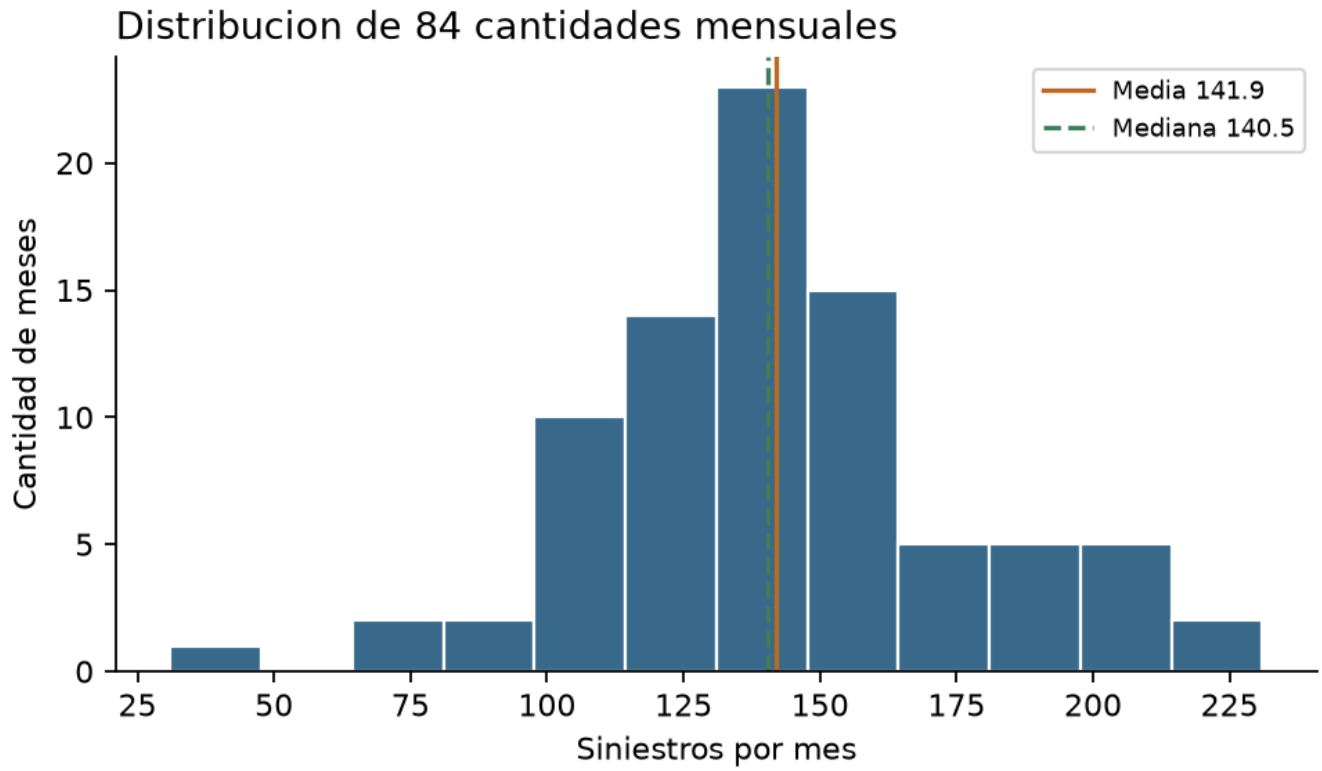
Estadístico de accidentes/mes	Valor
Media	141,93
Mediana	140,50
Moda	141,00
Desvío	34,13
CV	0,24
Mínimo	31,00
Máximo	231,00
IQR	31,25
P5	91,20
P25	123,00
P50	140,50
P75	154,25
P95	201,85
Asimetría	0,05
Curtosis de exceso	1,05

La media de 141,93 y la mediana de 140,50 son cercanas. La asimetría global baja no implica estabilidad temporal ni normalidad independiente. Se describe también la tasa diaria y la dispersión entre años.

Evolución y distribución

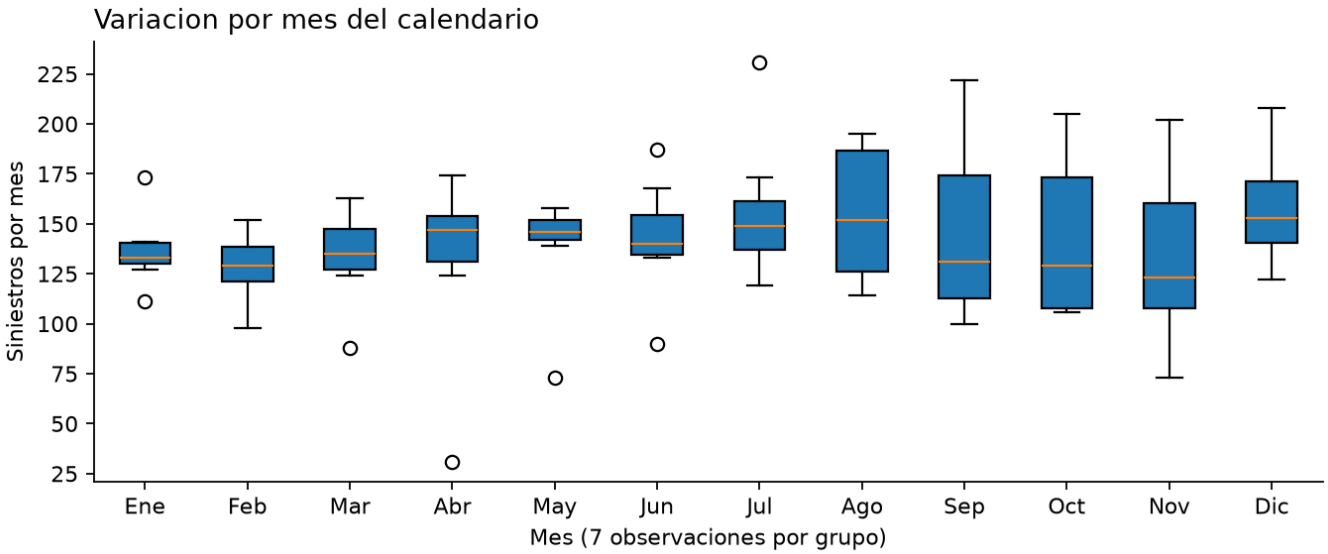


Los conteos van de 31 a 231 por mes. La media movil describe el historial; no se usa para pronosticar el mismo mes.

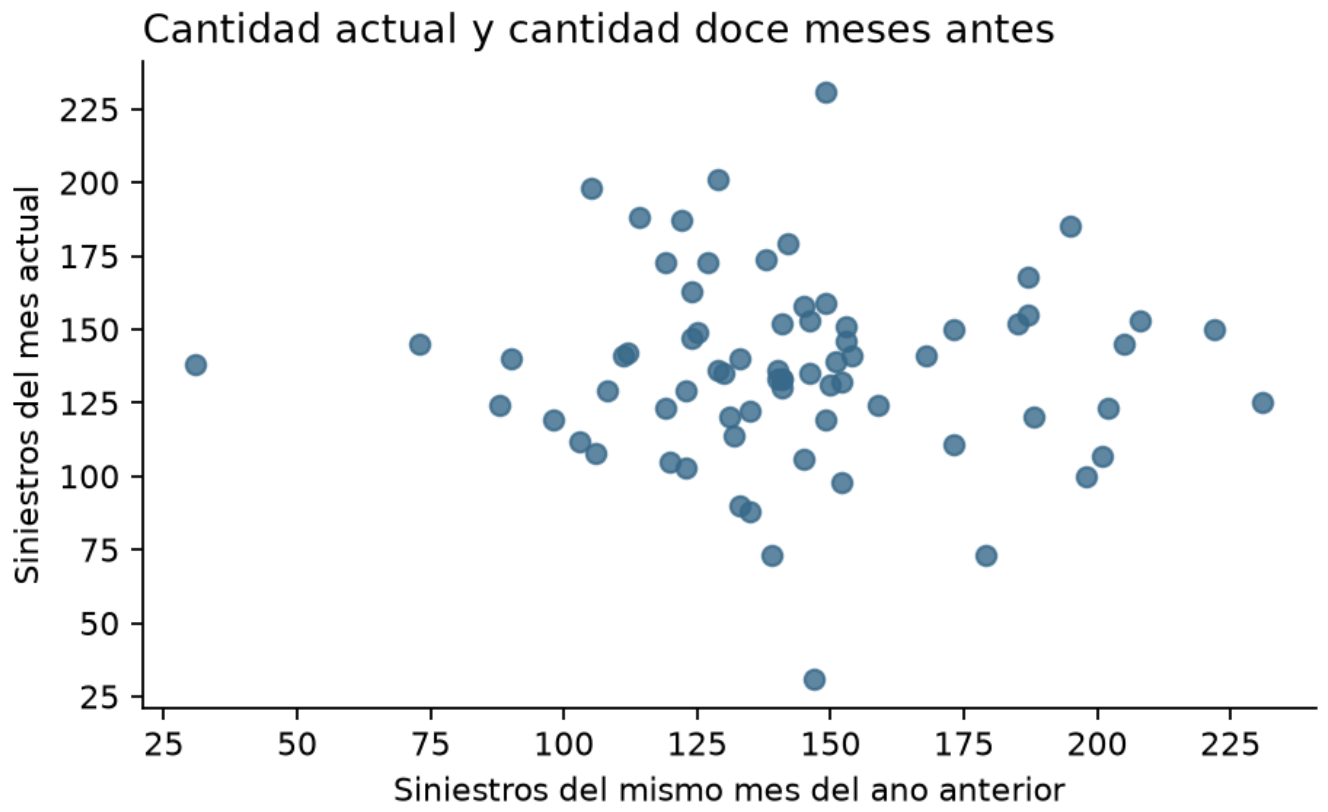


La asimetria es 0.05. La media resume el nivel, pero mezcla anos con contextos distintos; tambien se informa la mediana.

Calendario y asociación bivariada

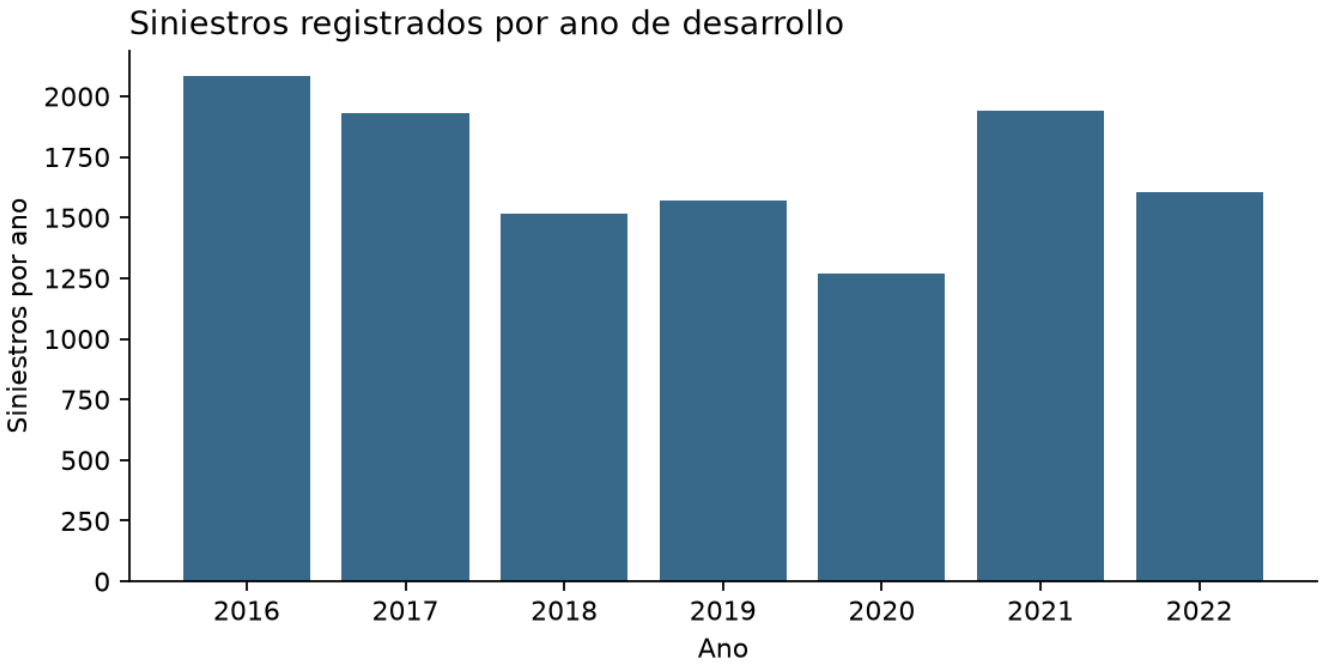


Cada caja resume siete anos del mismo mes. La superposicion muestra que el mes del calendario por si solo no determina el conteo.

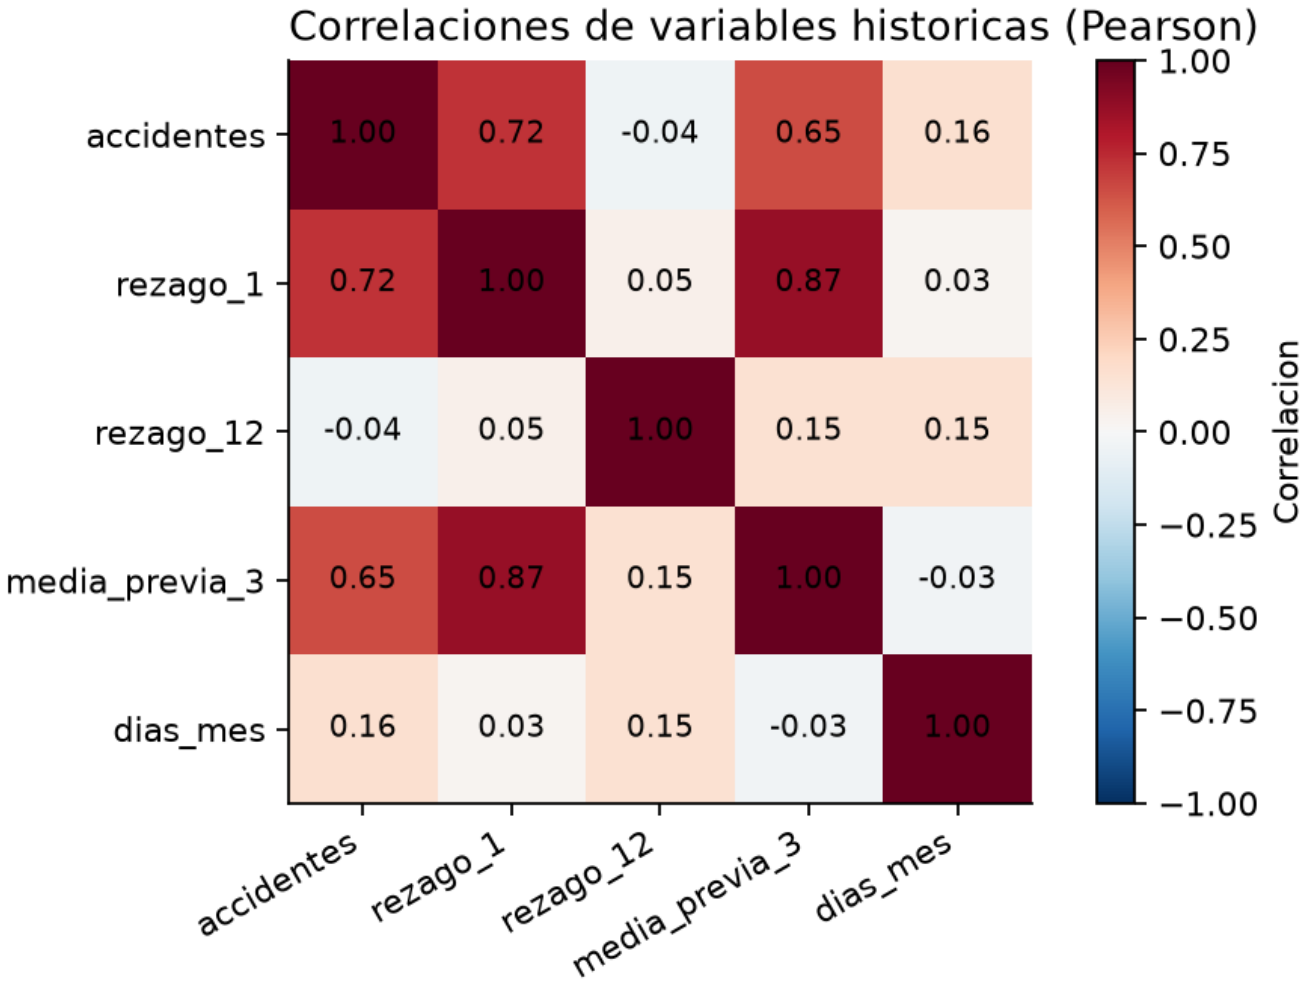


La correlacion de Pearson es -0.04; la de Spearman es -0.00. No demuestran causalidad ni sustituyen la validacion de pronosticos.

Comparación anual y correlaciones

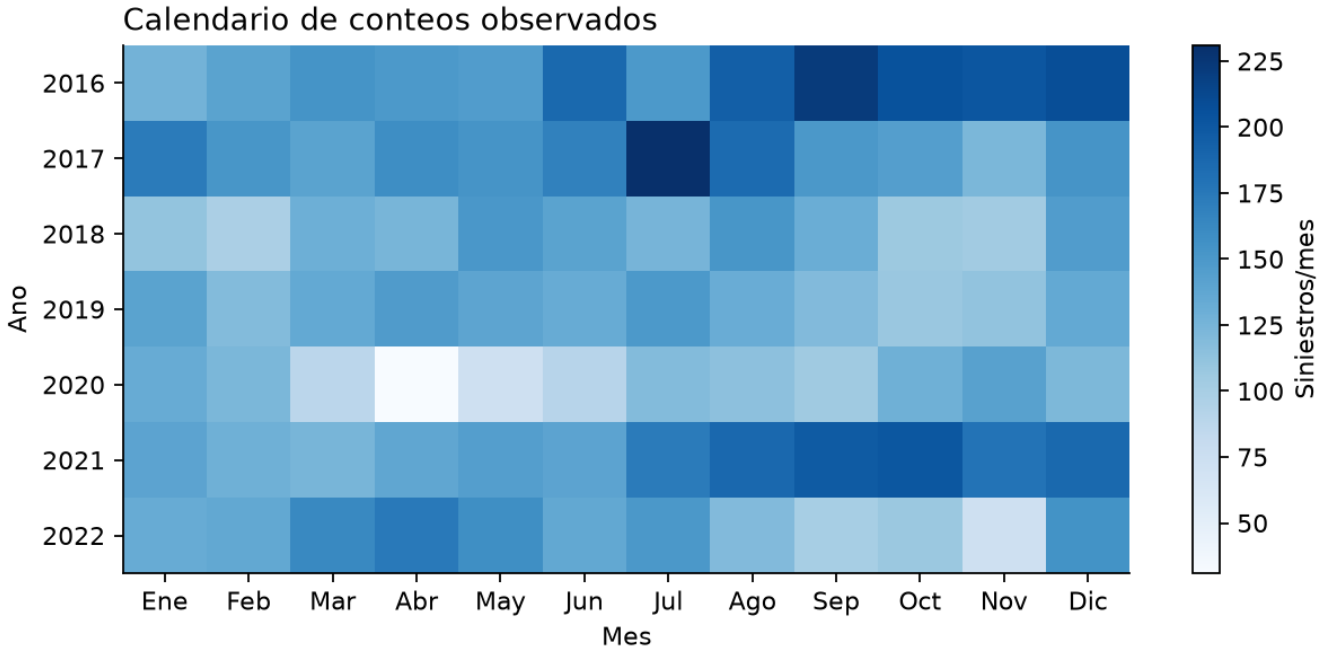


El total anual minimo es 1269 y el maximo 2085. La variacion requiere considerar cambios reales y posibles cambios en registro o cobertura.

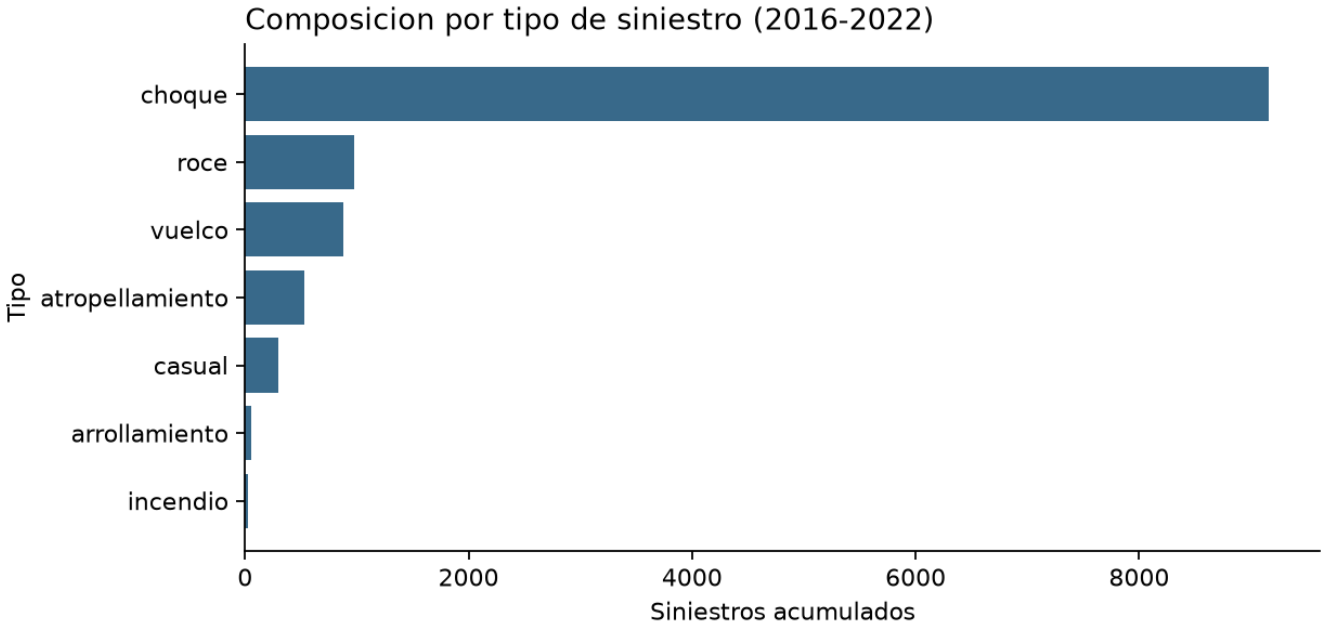


Los rezagos y medias anteriores pueden estar correlacionados entre si. Se excluyen los componentes del total del mismo mes para no filtrar la respuesta.

Calendario completo y composición

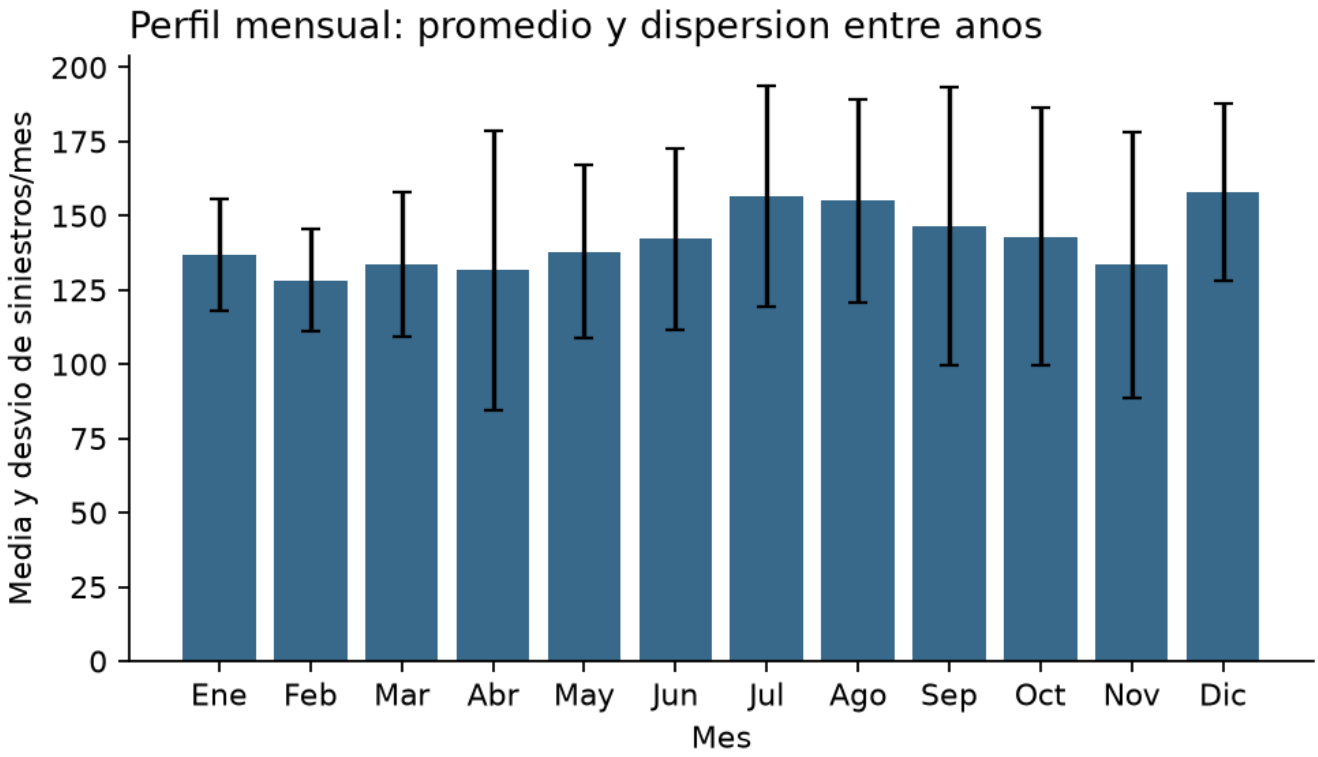


El calendario distingue anos y meses con niveles diferentes. No se rellenan con cero periodos ausentes; los 84 periodos de desarrollo estan publicados.

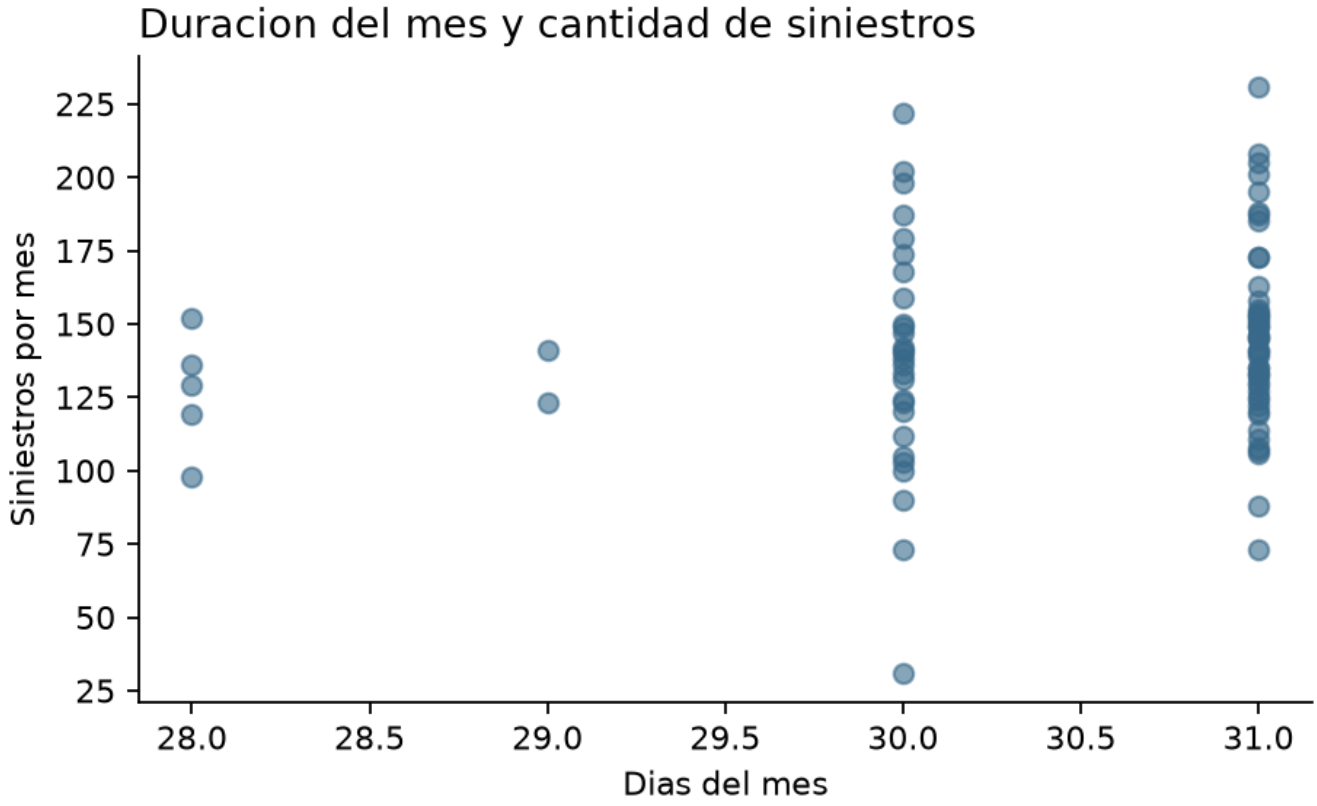


Las dos categorias mas frecuentes concentran 85.0% del total. Son 2 de 7 categorias (28,6%), no exactamente el 20%.

Estacionalidad y duración del mes



Las barras de error representan dispersion entre anos, no intervalos de confianza ni bandas de pronostico. La estacionalidad se contrasta en la Fase 2.



Un mes mas largo ofrece mas dias de observacion, pero dias del mes no equivale a kilometros recorridos o volumen de transito. No se estima riesgo por viaje.

Conclusión y puente inferencial

Respuesta parcial: existen suficientes períodos y una unidad coherente para comparar pronósticos mensuales. La descripción por sí sola no prueba que un modelo pueda anticipar doce meses con precisión.

Patrones y anomalías documentados

- Los extremos de desarrollo son 31 siniestros (2020-04-01) y 231 (2017-07-01); se conservan ambos.
- Los niveles varían entre años y el episodio de 2020 merece examen; no se le asigna una causa exclusivamente desde el gráfico.
- Las dos clases de siniestro más frecuentes concentran 85,0% del total de desarrollo.
- Las correlaciones entre cantidades actuales y rezagadas no equivalen a capacidad de pronóstico; pueden depender del régimen temporal.

Hipótesis que pasan a Fase 2

ID	Hipótesis preliminar
H1	Hay un patrón mensual alineado entre años
H2	Los semestres difieren en sus promedios dentro del año
H3	Hay tendencia monótona en promedios anuales
H4	El mes previo aporta asociación condicional al controlar otras variables

La muestra temporal pequeña y la posible variación de cobertura condicionan la inferencia. Se preservan las reservas cronológicas para no usar sus resultados al escoger pruebas o predictores.

Fuentes y reproducción

Fuentes primarias y trazabilidad

Catálogo del INE: https://www.ine.gov.py/tabulado/16/anuario. Siete cuadros 12.2.2 descargados el 31/10/2026; sus fuentes internas son MOPC / Patrulla Caminera. Cada original se conserva en data/raw con su SHA-256 y URL exacta en catalogo_fuentes.json e inventario_fuentes.csv.

Edición / archivo conservado	Filas mensuales	Tamaño (KB)
INE_2017_tipologia_2016_2017.xlsx	24	320,2
INE_2018_tipologia_2017_2018.xlsx	24	320,2
INE_2019_tipologia_2018_2019.xlsx	24	323,9
INE_2021_tipologia_2020_2021.xlsx	24	321,2
INE_2022_tipologia_2021_2022.xlsx	24	41,2
INE_2023_tipologia_2022_2023.xlsx	24	43,1
INE_2024_tipologia_2023_2024.xlsx	24	47,8

Licencia: el acceso a los cuadros es público; no se encontró en sus hojas una licencia específica que pueda afirmarse sin revisión adicional. Se conserva atribución a las instituciones.

Referencias metodológicas

- Hyndman y Athanasopoulos, Forecasting: Principles and Practice, capítulo 5: https://otexts.com/fpp3/toolbox.html
- Documentación de statsmodels: covarianza HAC, pruebas de diagnóstico y suavizado exponencial. https://www.statsmodels.org/stable/
- Documentación de scikit-learn: Ridge, RandomForestRegressor, SVR, métricas y escalado. https://scikit-learn.org/stable/

Las versiones exactas ejecutadas están en requirements.txt y output/entorno.json. La consigna de la asignatura se utilizó como referencia de estructura, sin inventar devoluciones docentes ni resultados.

Integridad académica y revisión

Declaración de asistencia de IA

Se empleó un asistente de IA para proponer el diseño, redactar y ejecutar código, preparar auditorías y gráficos, calcular resultados y redactar este borrador. No se declara que el grupo haya realizado por sí solo esas tareas.

La sección 11 de la consigna reserva al grupo las decisiones metodológicas y la interpretación. Antes de entregar, sus integrantes deben revisar este material, comprender el código, contrastar los resultados y adoptar o ajustar justificadamente las decisiones. La generación de estos archivos no sustituye ese trabajo ni la exposición del grupo.

Correcciones y revisión humana

No se recibió una nueva devolución de la profesora sobre este enfoque. Las listas de cambios describen modificaciones técnicas respecto del proyecto anterior, no observaciones docentes inventadas. Los legajos y cualquier requisito institucional adicional permanecen pendientes.

Cómo reproducir

Desde la carpeta del proyecto: python src/run_all.py. Los originales están incluidos y se verifican por hash. El flujo crea CSV, tablas, figuras, modelos, notebooks y HTML; la generación de PDF requiere reportlab. La consulta de datos y el entrenamiento no necesitan acceso a internet.

Integridad de la evaluación

No se modifica el modelo elegido después de mirar 2024. La repetición reproducible conserva el protocolo; una futura modificación metodológica deberá identificarse como un experimento nuevo, sin reutilizar 2024 como si nunca hubiera sido consultado.