Fase 2 · Análisis inferencial

Pronóstico mensual de siniestros de tránsito registrados por la Patrulla Caminera

Cuatro hipótesis, cuatro familias, diagnósticos, intervalos y corrección por comparaciones múltiples.

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos: no informados. Completar antes de la entrega.

Alcance

Paraguay, zona Central e Interior. Cuadros oficiales del INE con fuente Patrulla Caminera. Serie 2016-2024; desarrollo 2016-2022, calibración 2023 y prueba 2024.

Estado del material

Resultados calculados y reproducibles. Borrador de apoyo académico con asistencia de IA; el grupo debe revisar, comprender y asumir las decisiones metodológicas y la interpretación antes de entregar.

Fecha de elaboración: 31 de octubre de 2026.

Índice

03 Cambios y formulación de hipótesis

04 Supuestos y estructura temporal

05 Contrastes de calendario y semestres

06 Tendencia y regresión condicional

07 Bootstrap y sensibilidad

08 Resumen, conclusión y puente predictivo

09 Fuentes y reproducción

10 Integridad académica y revisión

Cambios y formulación de hipótesis

Cambios respecto del proyecto anterior

- Se reemplaza gravedad individual por cantidad mensual y se conserva la unidad agregada real.
- Se consolidan versiones coincidentes en lugar de expandir frecuencias a personas.
- Se excluyen prueba y calibración de la exploración y los contrastes.
- La dependencia temporal se trata con bloques anuales, referencias circulares y covarianza HAC; no se invoca independencia de miles de filas expandidas.

Marco de contrastación

Cuatro hipótesis primarias bilaterales, alfa 0,05 y Bonferroni para la familia completa (umbral individual equivalente 0,0125). Las decisiones se toman con p ajustado; no rechazar H0 no significa aceptarla.

ID	H0 y alternativa
H1	H0: sin alineación mensual de rangos entre años; H1: existe alineación
H2	H0: diferencias semestrales simétricas centradas en cero; H1: centro distinto
H3	H0: rho(año, promedio anual)=0; H1: rho distinto de cero
H4	H0: beta del rezago 1=0 con controles; H1: beta distinto de cero

Los desplazamientos circulares son referencias aproximadas que preservan orden temporal, no una aleatorización experimental. Las pruebas de supuestos son diagnósticos, no un filtro para buscar significación.

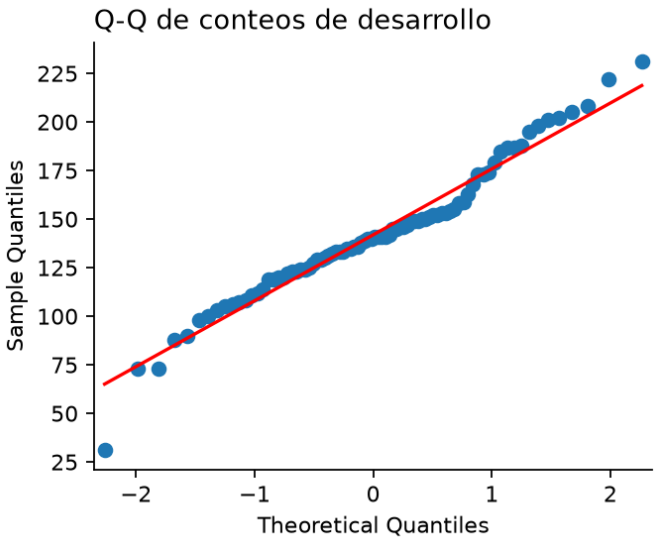
Supuestos y estructura temporal

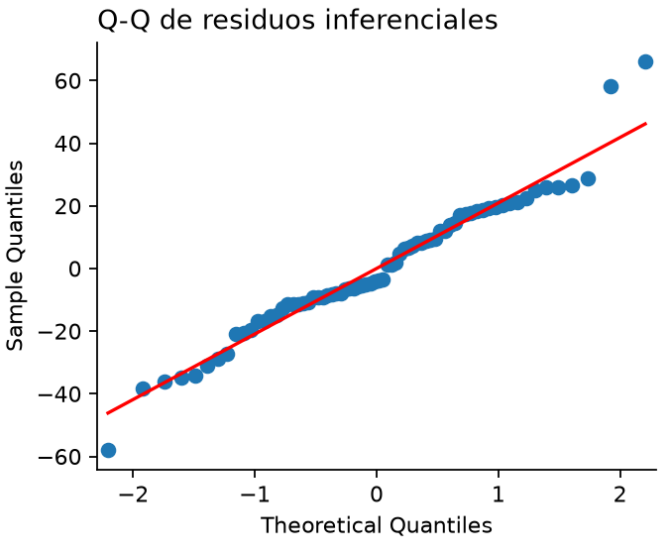
Se usan siete años como bloques para calendario y semestres. Los meses dentro de un año no se consideran doce réplicas independientes de personas. Friedman es una comparación por rangos de medidas apareadas; sustituye una ANOVA de grupos independientes inadecuada para esta estructura.

Diagnóstico	Variable	p
Shapiro-Wilk	Conteos mensuales	0,0898
Shapiro-Wilk	Diferencias de semestres por ano	0,7339
Shapiro-Wilk	Residuos OLS	0,1025
Levene (mediana)	Promedios de semestres	0,4039
Ljung-Box(1)	Residuos OLS	0,7899
Ljung-Box(6)	Residuos OLS	0,5864
Ljung-Box(12)	Residuos OLS	0,6954

Shapiro-Wilk no rechaza normalidad en estas muestras, pero eso no la demuestra. Wilcoxon se predefinió por el pequeño número de pares; no necesita homogeneidad de varianzas. Levene se informa como diagnóstico, no como supuesto obligatorio de esa prueba.

Ljung-Box sobre residuos no garantiza independencia ni exogeneidad. HAC corrige la covarianza ante dependencia débil; no corrige variables omitidas, no estacionariedad arbitraria ni cambios de cobertura.





Contrastes de calendario y semestres

H1 · Calendario mensual

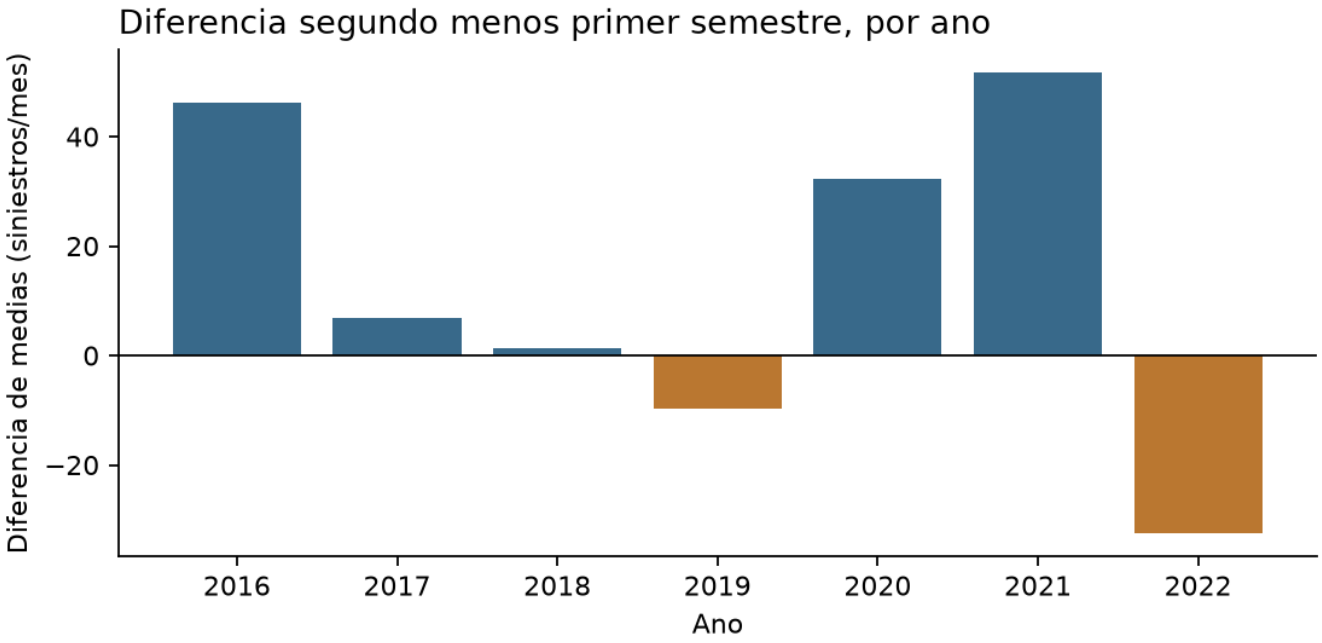
Friedman Q=10,49 (11 grados de libertad como referencia). p circular=0,4462; p clásico=0,4866. W de Kendall=0,136, IC bootstrap aproximado [0,093; 0,579].

No se rechaza H0 tras corrección. No es evidencia de ausencia de estacionalidad: solo siete ciclos y cambios de nivel limitan la potencia. La referencia circular rota cada secuencia anual sin mezclar sus doce valores al azar. El IC percentil de W puede excluir cero por su sesgo y soporte no negativo en muestras pequeñas; no se interpreta como otra prueba de significación.

H2 · Semestres apareados por año

Wilcoxon W=8, n=7 pares, sin grados de libertad paramétricos. p=0,3750; p ajustado=1,0000. La diferencia media segundo menos primer semestre es 13,71 siniestros/mes.

IC bootstrap para esa diferencia media: [-7,43; 34,14]. El IC de la media y el contraste de centro simétrico de Wilcoxon no son exactamente el mismo estimando; esa distinción impide interpretar automáticamente uno como inversión del otro.



Cada barra conserva el emparejamiento dentro del año. Las diferencias cambian de signo; el promedio global no implica un aumento constante.

Tendencia y regresión condicional

H3 · Tendencia monótona anual

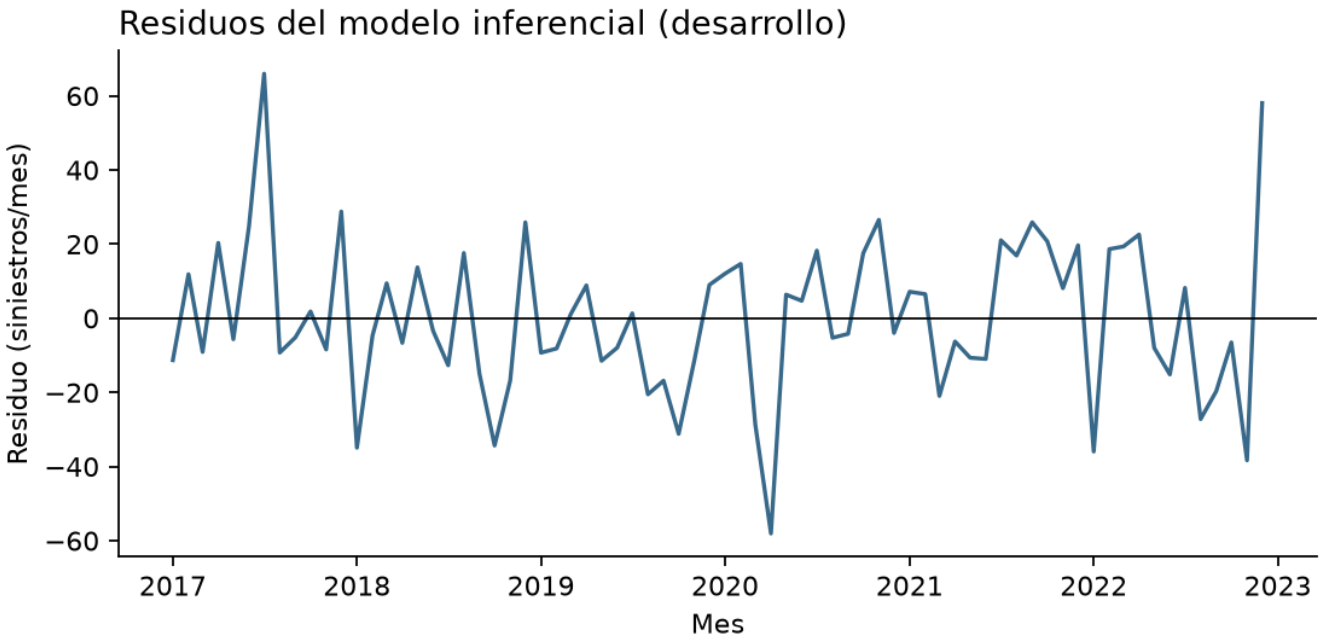
Rho de Spearman=-0,286; p circular=0,7143. La referencia que permuta años como independientes da p=0,5560. No se rechaza H0.

Con siete rotaciones la resolución mínima de p es 1/7: este contraste es conservador y no puede alcanzar el umbral Bonferroni. Se documenta esta falta de potencia en lugar de reemplazar la prueba por otra que dé significación. No demuestra estabilidad ni ausencia de tendencia.

H4 · Asociación condicional con el mes anterior

Sobre 72 filas tras formar el rezago doce, beta del rezago uno=0,575, IC HAC 95% [0,432; 0,719]. t=8,025, gl=64, p ajustado=1,16e-10.

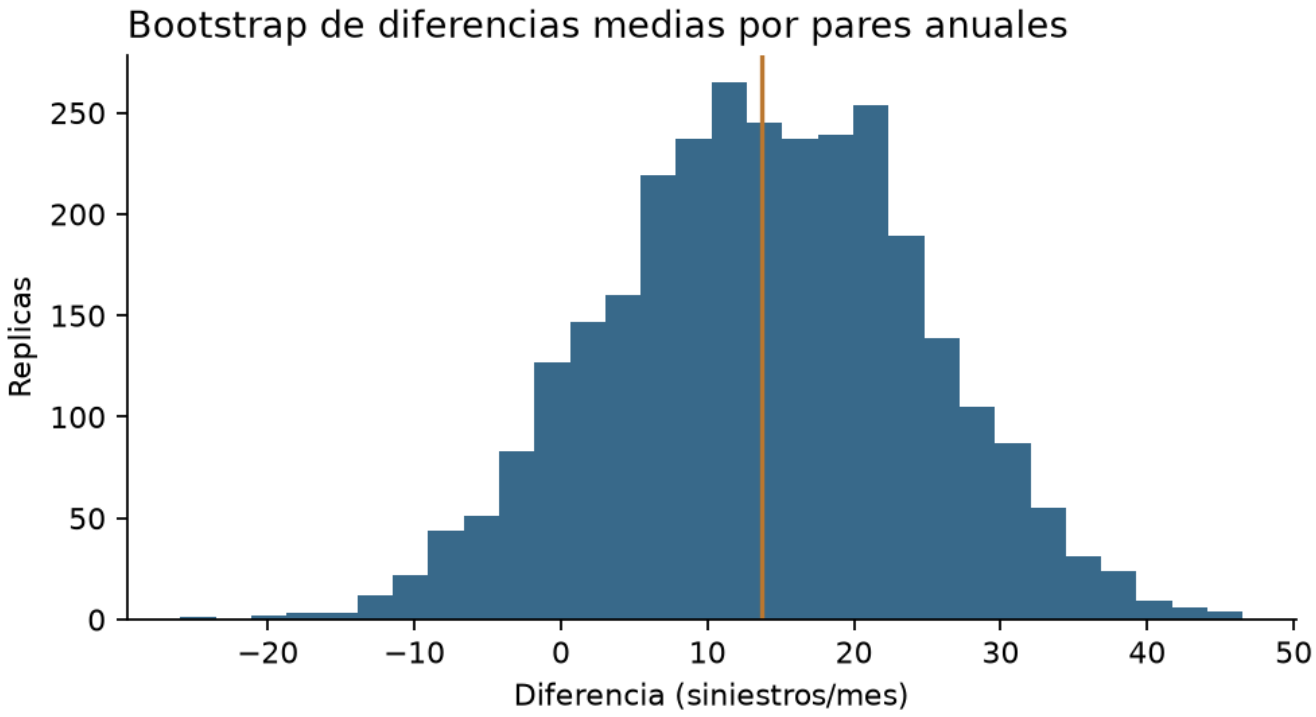
Se rechaza H0 bajo los supuestos de la regresión. Se controlan rezago doce, seno/coseno del mes, tendencia, días del mes e indicador histórico de 2020. La asociación no es causal ni garantiza pronósticos de doce pasos. Los meses de 2023 y 2024 no entran en este ajuste.



Los residuos corresponden al modelo inferencial, no al SVR que se seleccionará en la Fase 3.

Bootstrap y sensibilidad

Para la diferencia media semestral, el IC clásico t es [-14,83; 42,26] y el bootstrap de pares anuales es [-7,43; 34,14]. Ambos estiman el mismo parámetro medio; ambos dependen de la aproximación de independencia entre años.



Se remuestrean años completos con sus dos semestres emparejados, 3.000 veces, con semilla fija. No se crean víctimas ni meses nuevos como observaciones independientes.

Regresión y sensibilidad

Para beta del rezago uno: IC OLS [0,394; 0,757], IC HAC [0,432; 0,719] e IC bootstrap de bloques de doce residuos [0,406; 0,747].

El bootstrap residual mantiene el diseño fijo y aproxima dependencia de corto plazo; no resuelve la endogeneidad de rezagos. La tabla de sensibilidad HAC(6)/HAC(12) se conserva y no se utiliza para escoger el p más pequeño.

Resumen, conclusión y puente predictivo

ID	Estadístico	p primario	p ajustado	Efecto	Decisión
H1	10,493	0,4462	1,0000	0,136	No rechazar H0
H2	8,000	0,3750	1,0000	13,714	No rechazar H0
H3	-0,286	0,7143	1,0000	-0,286	No rechazar H0
H4	8,025	2,91e-11	1,16e-10	0,575	Rechazar H0

Los intervalos del 95% informados son marginales por contraste, no intervalos simultáneos para toda la familia. Las decisiones múltiples se basan en los valores p ajustados.

Interpretación práctica

La evidencia más clara es asociación temporal de corto plazo. El calendario y las diferencias de semestre no presentan evidencia concluyente bajo los contrastes predefinidos. Se mantienen variables de calendario como controles predictivos, pero su utilidad se decidirá por validación, no por exigir $p<0,05$.

Confusores y representatividad

- Volumen de tránsito, kilómetros recorridos y esfuerzo de fiscalización no están medidos.
- Cambios de cobertura o registro pueden alterar cantidades sin alterar el riesgo por viaje.
- 2020 representa un contexto distinto; el indicador no identifica por sí solo una causa.
- La muestra temporal es pequeña: no se extienden conclusiones a todos los accidentes no registrados.

Puente a la Fase 3

Se evaluarán rezagos y medias previas junto con calendario, con escalado ajustado dentro de cada entrenamiento. Los resultados inferenciales no se usarán para seleccionar columnas mirando el año de prueba. La comparación temporal determinará si la asociación se transforma en capacidad predictiva.

Fuentes y reproducción

Fuentes primarias y trazabilidad

Catálogo del INE: https://www.ine.gov.py/tabulado/16/anuario. Siete cuadros 12.2.2 descargados el 31/10/2026; sus fuentes internas son MOPC / Patrulla Caminera. Cada original se conserva en data/raw con su SHA-256 y URL exacta en catalogo_fuentes.json e inventario_fuentes.csv.

Edición / archivo conservado	Filas mensuales	Tamaño (KB)
INE_2017_tipologia_2016_2017.xlsx	24	320,2
INE_2018_tipologia_2017_2018.xlsx	24	320,2
INE_2019_tipologia_2018_2019.xlsx	24	323,9
INE_2021_tipologia_2020_2021.xlsx	24	321,2
INE_2022_tipologia_2021_2022.xlsx	24	41,2
INE_2023_tipologia_2022_2023.xlsx	24	43,1
INE_2024_tipologia_2023_2024.xlsx	24	47,8

Licencia: el acceso a los cuadros es público; no se encontró en sus hojas una licencia específica que pueda afirmarse sin revisión adicional. Se conserva atribución a las instituciones.

Referencias metodológicas

- Hyndman y Athanasopoulos, Forecasting: Principles and Practice, capítulo 5: https://otexts.com/fpp3/toolbox.html
- Documentación de statsmodels: covarianza HAC, pruebas de diagnóstico y suavizado exponencial. https://www.statsmodels.org/stable/
- Documentación de scikit-learn: Ridge, RandomForestRegressor, SVR, métricas y escalado. https://scikit-learn.org/stable/

Las versiones exactas ejecutadas están en requirements.txt y output/entorno.json. La consigna de la asignatura se utilizó como referencia de estructura, sin inventar devoluciones docentes ni resultados.

Integridad académica y revisión

Declaración de asistencia de IA

Se empleó un asistente de IA para proponer el diseño, redactar y ejecutar código, preparar auditorías y gráficos, calcular resultados y redactar este borrador. No se declara que el grupo haya realizado por sí solo esas tareas.

La sección 11 de la consigna reserva al grupo las decisiones metodológicas y la interpretación. Antes de entregar, sus integrantes deben revisar este material, comprender el código, contrastar los resultados y adoptar o ajustar justificadamente las decisiones. La generación de estos archivos no sustituye ese trabajo ni la exposición del grupo.

Correcciones y revisión humana

No se recibió una nueva devolución de la profesora sobre este enfoque. Las listas de cambios describen modificaciones técnicas respecto del proyecto anterior, no observaciones docentes inventadas. Los legajos y cualquier requisito institucional adicional permanecen pendientes.

Cómo reproducir

Desde la carpeta del proyecto: python src/run_all.py. Los originales están incluidos y se verifican por hash. El flujo crea CSV, tablas, figuras, modelos, notebooks y HTML; la generación de PDF requiere reportlab. La consulta de datos y el entrenamiento no necesitan acceso a internet.

Integridad de la evaluación

No se modifica el modelo elegido después de mirar 2024. La repetición reproducible conserva el protocolo; una futura modificación metodológica deberá identificarse como un experimento nuevo, sin reutilizar 2024 como si nunca hubiera sido consultado.