Fase 3 · Modelado y evaluación

Pronóstico mensual de siniestros de tránsito registrados por la Patrulla Caminera

Comparación temporal de familias, errores de entrenamiento y prueba, interpretación y límites de generalización.

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos: no informados. Completar antes de la entrega.

Alcance

Paraguay, zona Central e Interior. Cuadros oficiales del INE con fuente Patrulla Caminera. Serie 2016-2024; desarrollo 2016-2022, calibración 2023 y prueba 2024.

Estado del material

Resultados calculados y reproducibles. Borrador de apoyo académico con asistencia de IA; el grupo debe revisar, comprender y asumir las decisiones metodológicas y la interpretación antes de entregar.

Fecha de elaboración: 31 de octubre de 2026.

Índice

03 Tarea y diseño temporal

04 Familias, grillas y referencias

05 Selección por validación

06 Aprendizaje, brechas y generalización

07 Evaluación final: métricas e interpretación

08 Predicciones y casos peor estimados

09 Residuos y error por horizonte

10 Interpretación de variables

11 Calibración, incertidumbre y uso

12 Proyección retrospectiva y modelo guardado

13 Conclusión y respuesta consolidada

14 Fuentes y reproducción

15 Integridad académica y revisión

Tarea y diseño temporal

Tarea: regresión de conteos mensuales a doce pasos. No corresponde usar accuracy, F1 ni matriz de confusión. Los pronósticos son valores esperados continuos; no se redondean antes de evaluar.

Bloque	Qué se hace	Qué se evita
2016-2022	EDA, cuatro contrastes y búsqueda temporal	Mirar 2024 para elegir variables o parámetros
Cortes 2019-2022	Cuatro pronósticos de doce meses: 48 errores/configuración	K-fold aleatorio o actualización con valores futuros reales
2023	Calibrar el radio de una banda después de elegir el modelo	Usarlo para cambiar la familia ganadora
2024	Evaluar una vez todas las familias con parámetros fijados	Cambiar al ganador por su desempeño de prueba

Los entrenamientos de validación contienen 36, 48, 60 y 72 meses respectivamente; después del rezago doce quedan 24, 36, 48 y 60 filas supervisadas. El ajuste final para evaluar 2024 usa 96 meses hasta diciembre de 2023 y 84 filas supervisadas.

Prevención de filtraciones

Las medias se desplazan un mes. StandardScaler se ajusta solo dentro de cada entrenamiento. Choques, tipos de siniestro, tasa diaria del propio mes y resultados reales de meses futuros no se usan como entradas. Los doce pasos se generan recursivamente con predicciones.

La prueba es interna y temporal: 2024 no participa del ajuste ni la selección. Sus cantidades ya se habían visto en la auditoría de disponibilidad, por lo que no se presenta como una validación externa ciega.

Familias, grillas y referencias

Se compararon 22 especificaciones fijas: dos referencias y veinte configuraciones de cuatro familias aprendidas. Cada especificación se evaluó en los mismos cuatro cortes. Criterio primario: menor MAE medio; los empates se resuelven por el orden predefinido.

Familia	Configuraciones predefinidas
Referencia estacional	Repite los doce meses del año previo
Referencia media12	Repite la media de los doce últimos meses
Ridge	alpha: 0,1; 1; 10; 100. Escalado dentro de Pipeline
Random Forest	250 árboles; profundidad 3 o sin límite; hoja mínima 2, 5 o 10
SVR RBF	C: 1, 10, 100; epsilon: 5 o 15; gamma=scale; escalado
ETS	Tendencia ninguna/aditiva; estacionalidad ninguna/aditiva; tendencia amortiguada cuando existe

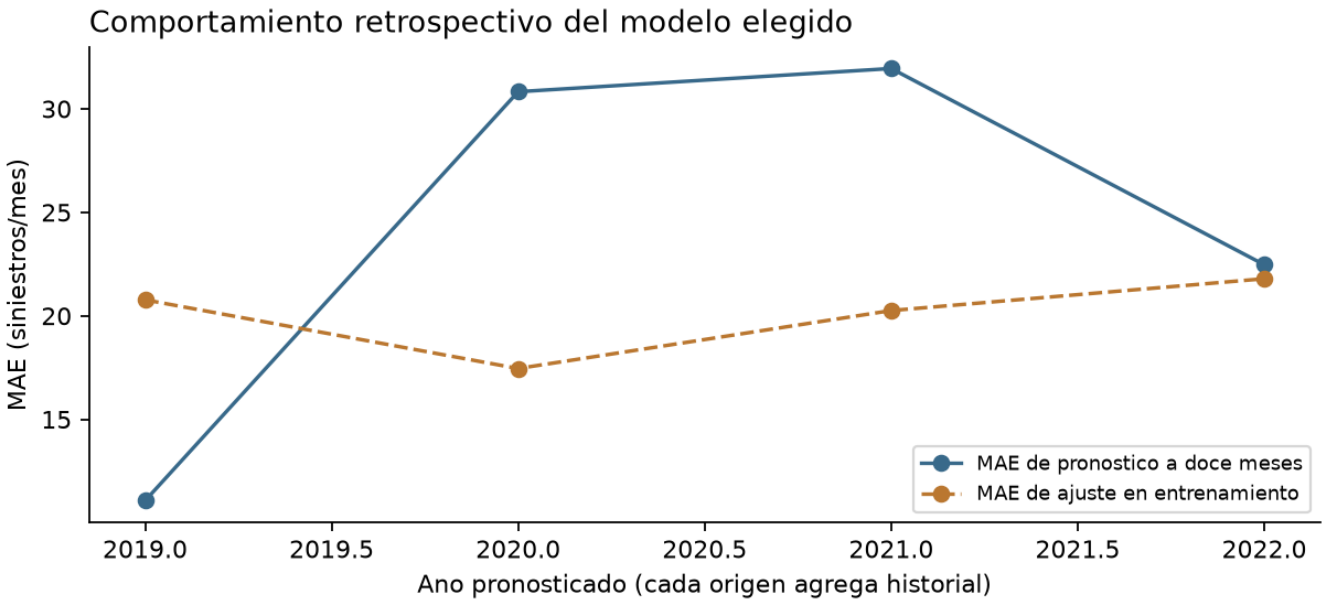
Ridge representa un modelo lineal regularizado; Random Forest, árboles; SVR, un método de margen con núcleo; ETS, una familia temporal clásica. La semilla es 20261031. No se ampliaron grillas después de ver prueba.

La búsqueda completa por corte, los parámetros, tamaños de entrenamiento y advertencias están en los CSV y JSON de output. Se conservan especificaciones y selección congelada previas a la prueba.

Selección por validación

Familia	MAE validación	RMSE validación	Parámetros elegidos
SVR	24,08	33,38	{"C": 1.0, "epsilon": 15.0, "gamma": "scale"}
Ridge	26,24	35,15	{"alpha": 100.0}
Random Forest	30,44	40,77	{"max_depth": 3, "min_samples_leaf": 2, "n_estimators": 250}
ETS	31,00	42,01	{"trend": "add", "seasonal": null, "damped_trend": true}
Referencia media12	31,47	42,32	{}
Referencia estacional	37,23	49,07	{}

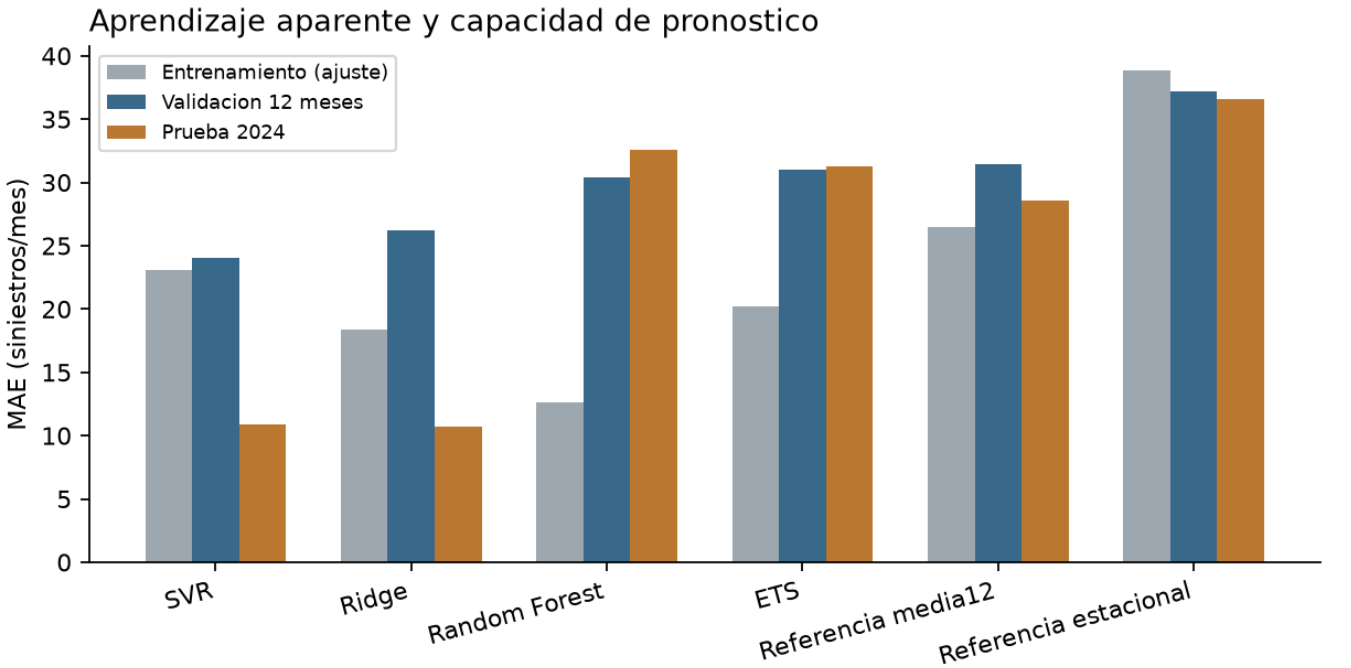
Se eligió SVR, con C=1, epsilon=15 y gamma=scale, por su menor MAE de validación (24,08). La elección precede a 2023 y 2024.



Cada punto cambia el año pronosticado y agrega historia. No es una curva de aprendizaje con un conjunto de validación fijo; los saltos reflejan también cambios del fenómeno.

Aprendizaje, brechas y generalización

Familia	MAE ajuste	MAE CV	MAE prueba	R^2 prueba
SVR	23,06	24,08	10,87	-0,48
Ridge	18,36	26,24	10,67	-0,18
Random Forest	12,59	30,44	32,61	-6,67
ETS	20,19	31,00	31,30	-6,14
Referencia media12	26,46	31,47	28,58	-5,14
Referencia estacional	38,85	37,23	36,58	-10,72



El ajuste de entrenamiento usa predicciones a un paso con antecedentes reales; validación y prueba son pronósticos a doce pasos. Las brechas son diagnósticas y no una medida pura de sobreajuste, porque cambian el horizonte y los períodos.

Random Forest presenta ajuste mucho más favorable que su validación y prueba, compatible con sobreajuste y falta de generalización. SVR está fuertemente regularizado y produce un perfil casi plano: su mejora corresponde sobre todo a estimar el nivel, no a recuperar cada oscilación mensual.

Evaluación final: métricas e interpretación

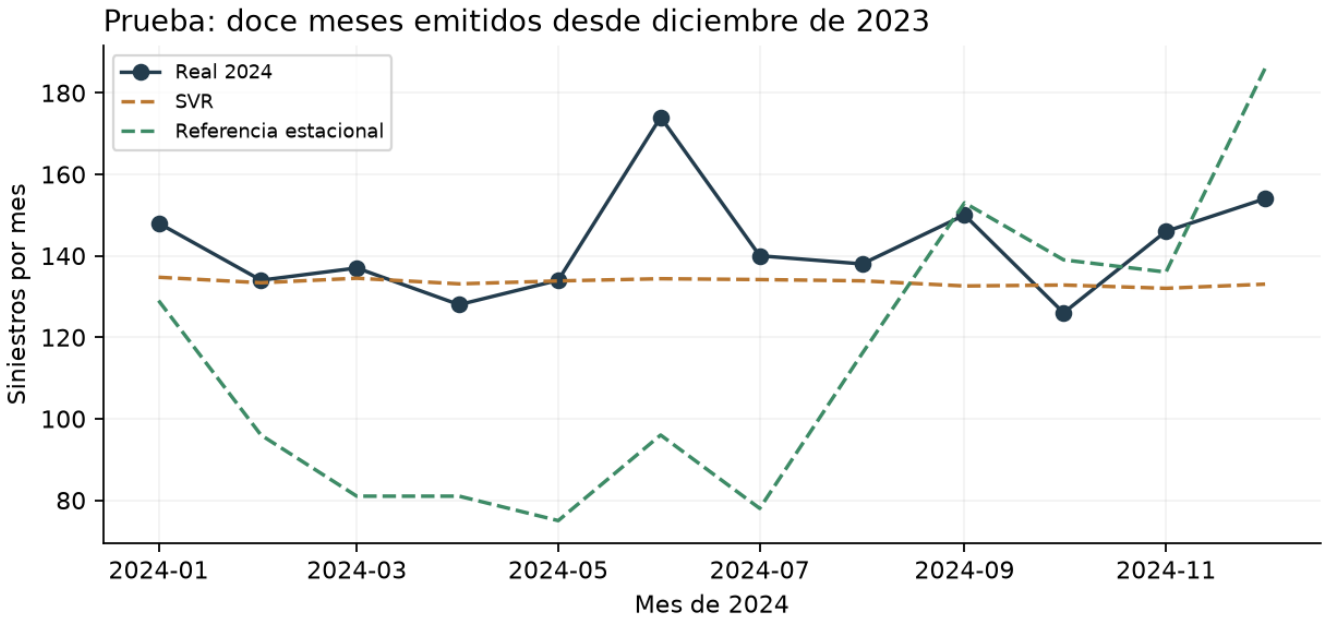
Métrica seleccionada	Resultado 2024
MAE	10,87 siniestros/mes
RMSE	15,32 siniestros/mes
MAPE	7,13%
R^2	-0,477
Sesgo medio	-8,89 siniestros/mes
Total real	1.709
Total predicho	1.602,36
Error de total	-106,64

La reducción de MAE frente a la referencia estacional es 70,28%; frente a la media12 es 61,96%. Eso no equivale a un porcentaje de exactitud.

El R^2 negativo indica que el error cuadrático supera el de una constante igual a la media real de 2024. Esa media se conoce después de observar el año y no es una referencia operativa disponible al pronosticar. Aun así, el resultado evidencia escasa explicación de las variaciones mensuales.

Ridge obtiene un MAE de prueba ligeramente menor que SVR. No se cambia la selección: elegirlo después de observar 2024 contaminaría la evaluación. Su resultado se muestra para transparencia, no para retocar al ganador.

Predicciones y casos peor estimados

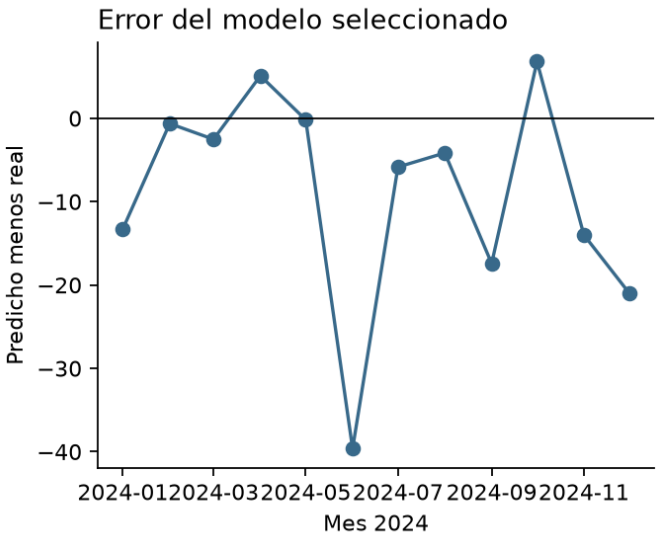


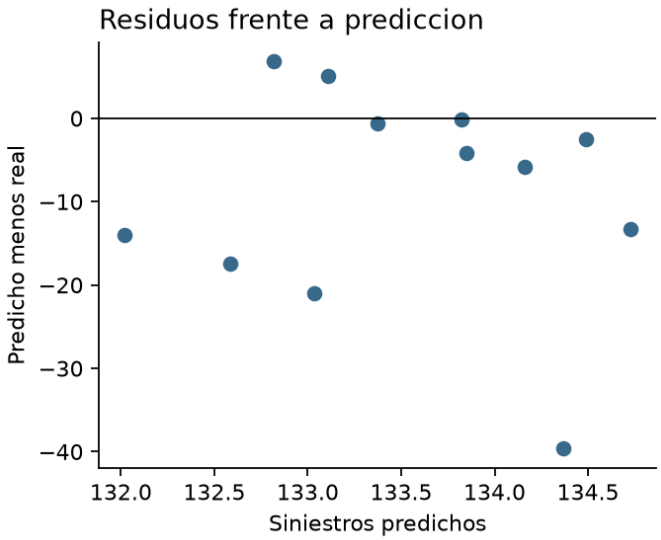
Las doce predicciones se emiten desde un único origen: diciembre de 2023. No se actualiza el modelo con los valores reales de enero, febrero u otros meses de 2024.

Mes	Real	Predicho	Error absoluto
2024-06	174	134,37	39,63
2024-12	154	133,04	20,96
2024-09	150	132,59	17,41
2024-11	146	132,02	13,98
2024-01	148	134,73	13,27

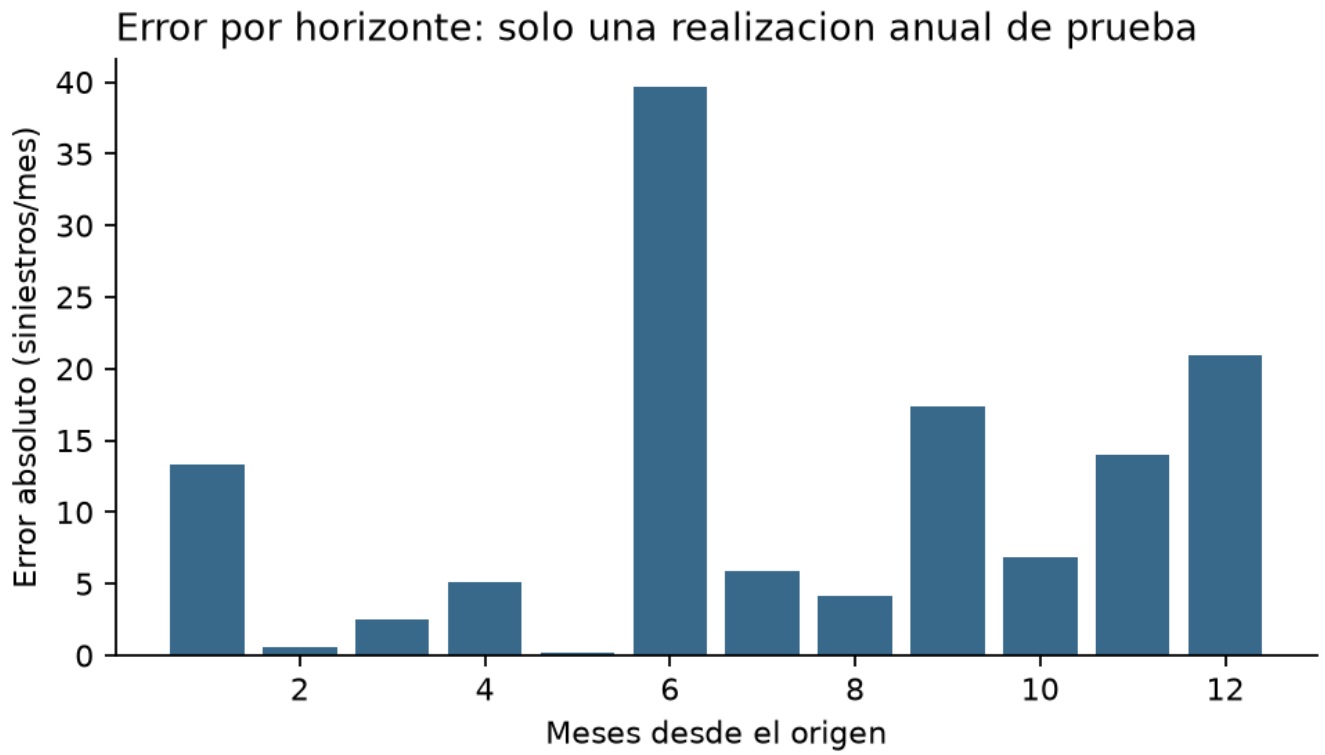
Los meses peor predichos concentran picos que el perfil plano no anticipa. No se atribuyen sus causas a clima, movilidad o fiscalización porque esas variables no están observadas en el dataset.

Residuos y error por horizonte



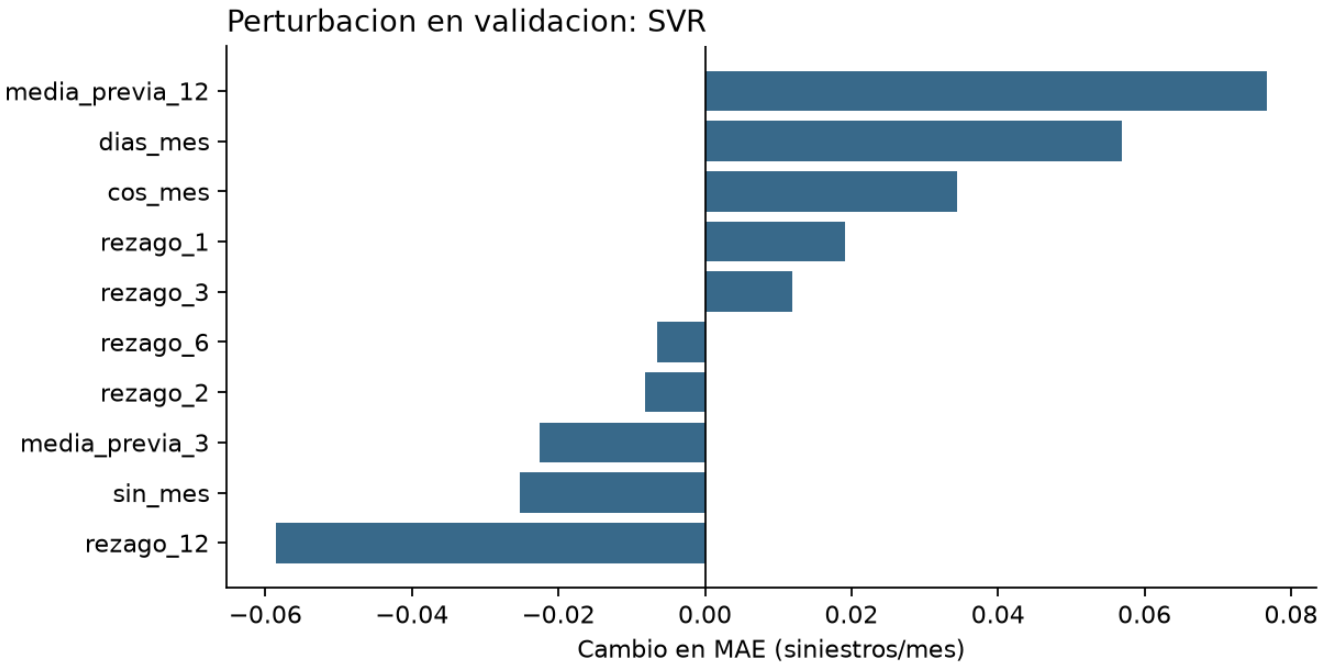


Error definido como predicho menos real: negativo indica subestimación. El sesgo global es negativo, coherente con un total anual subestimado. Doce residuos de prueba son pocos para diagnosticar dependencia con potencia suficiente.



Hay una sola observación por horizonte en la prueba anual. No se afirma que el modelo siempre empeore o mejore a determinado número de meses.

Interpretación de variables



La perturbación se calcula en los cuatro cortes de validación, reemplazando una entrada por valores históricos de su distribución y ejecutando la recursión. No usa prueba para seleccionar variables. Las perturbaciones pueden romper relaciones entre rezagos: son diagnóstico, no efecto causal.

En SVR los cambios medios de MAE por variable son menores a 0,1 siniestros/mes y su dispersión es comparable o mayor. No hay evidencia robusta de una variable claramente dominante mediante este diagnóstico. El modelo es casi constante y fuertemente regularizado.

Relación con Fases 1 y 2

La asociación inferencial con el mes previo no se convierte automáticamente en capacidad de pronóstico anual: al avanzar doce pasos, cada predicción alimenta la siguiente. La inferencia condicional y la generalización fuera de muestra responden preguntas diferentes.

Se conservan coeficientes estandarizados de Ridge e importancias de impureza de Random Forest como diagnósticos de esas familias, sin atribuirlos al SVR ganador.

Calibración, incertidumbre y uso

El modelo seleccionado se entrenó hasta 2022 para pronosticar 2023, sin usar ese año al elegir hiperparámetros. Se tomó el máximo de sus doce errores absolutos: radio 61,27 siniestros/mes. Es el orden 12 de ceil((12+1)×0,9).

La banda contiene 100% de los doce valores de 2024. Es amplia y su cobertura observada en un solo año no prueba una garantía del 90% en futuros períodos.

La construcción se inspira en cuantiles de errores de calibración, pero los errores temporales y por horizonte no son necesariamente intercambiables. Se etiqueta como banda empírica aproximada, no como intervalo conformal con cobertura demostrada.

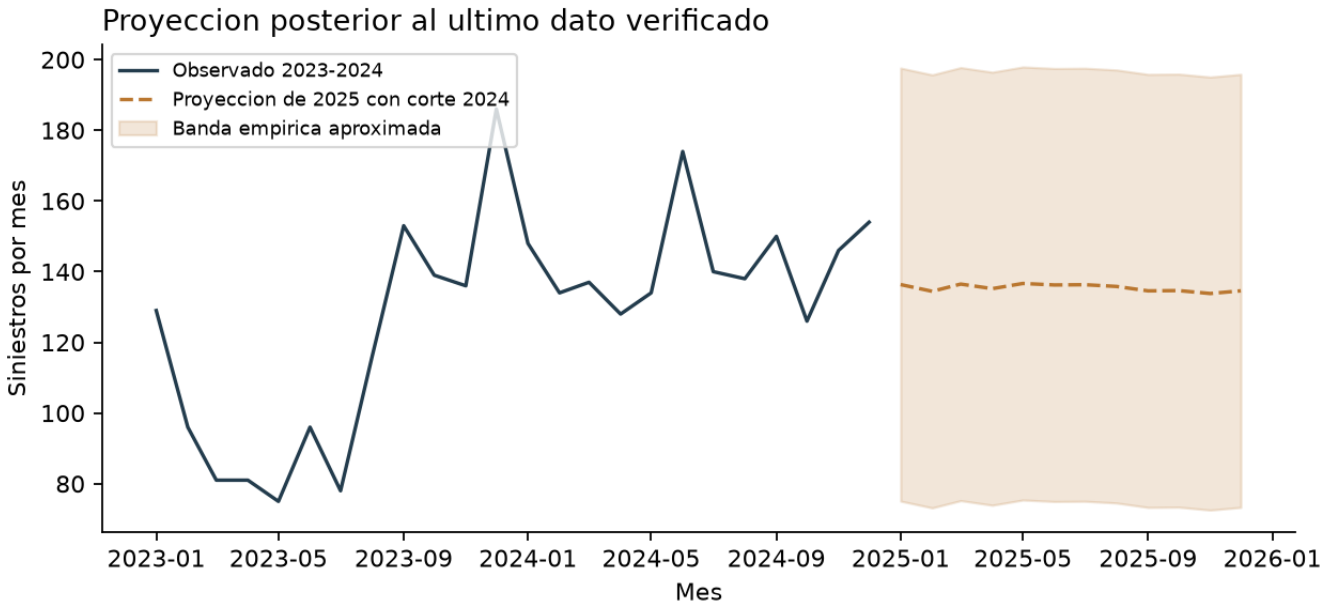
Incertidumbre del total anual

No se suman los extremos mensuales ni se combinan varianzas como si los doce errores fueran independientes. Se informa un total puntual y se omite un intervalo anual formal: un único bloque anual de calibración no permite sostenerlo con fiabilidad.

Aplicación práctica

La mejora frente a referencias no compensa la incapacidad de anticipar picos. Puede servir como ejercicio de planificación agregada con revisión humana, no como asignación automática de recursos ni promesa de seguridad para una ruta o persona.

Proyección retrospectiva y modelo guardado



Después de cerrar la evaluación, se reajustó la misma especificación SVR con 2016-2024. La proyección posterior al último dato suma 1.625,09 siniestros para 2025. No se evaluó con datos reales de 2025 y no es un pronóstico actualizado de 2027.

Mes 2025	Pronóstico	Banda inferior	Banda superior
2025-01	136,35	75,07	197,62
2025-02	134,44	73,17	195,71
2025-03	136,49	75,21	197,76
2025-04	135,19	73,92	196,46
2025-05	136,66	75,39	197,94
2025-06	136,24	74,96	197,51
2025-07	136,31	75,03	197,58
2025-08	135,82	74,54	197,09
2025-09	134,57	73,29	195,84
2025-10	134,65	73,37	195,92
2025-11	133,82	72,54	195,09
2025-12	134,58	73,31	195,85

El archivo modelo_pronostico.joblib contiene el reajuste de producción; modelo_evaluado_2024.joblib conserva el ajuste que realmente produjo las métricas de prueba. El script de inferencia acepta historial nuevo mensual completo y mantiene los parámetros elegidos.

Conclusión y respuesta consolidada

Respuesta final

Con este diseño, SVR mejora las dos referencias operativas en 2024 y reduce el MAE a 10,87. Sin embargo, su R^2 de -0,477 y su perfil casi plano muestran que no anticipa satisfactoriamente las fluctuaciones mensuales. El resultado es una mejora relativa de nivel, no evidencia de alta capacidad predictiva.

Qué aprendió y qué no

El criterio temporal favoreció un modelo de muy baja flexibilidad. No reproduce picos y subestima el total de 2024. Random Forest muestra que memorizar mejor el entrenamiento no asegura pronosticar mejor. No se ocultaron resultados negativos ni se cambió la especificación para mejorar prueba.

Limitaciones y continuación

- Solo nueve años de datos, cuatro cortes de validación, un año de calibración y uno de prueba.
- Faltan exposición vial, cambios de registro y factores externos conocidos anticipadamente.
- No hay validación externa o multianual posterior a 2024; deben conseguirse datos comparables recientes.
- Evaluar otro dataset o nuevos predictores sería un experimento nuevo y necesitaría otra reserva temporal.
- No deben asignarse recursos únicamente con estas predicciones ni extrapolarse a víctimas individuales.

Lista de correcciones aplicada desde Fase 2

La selección se basa en validación predictiva, no solo en significación inferencial. Se respetan autocorrelación e incertidumbre. Las variables contemporáneas del objetivo quedan excluidas y se informa cuándo los resultados inferenciales no se traducen en generalización.

Fuentes y reproducción

Fuentes primarias y trazabilidad

Catálogo del INE: https://www.ine.gov.py/tabulado/16/anuario. Siete cuadros 12.2.2 descargados el 31/10/2026; sus fuentes internas son MOPC / Patrulla Caminera. Cada original se conserva en data/raw con su SHA-256 y URL exacta en catalogo_fuentes.json e inventario_fuentes.csv.

Edición / archivo conservado	Filas mensuales	Tamaño (KB)
INE_2017_tipologia_2016_2017.xlsx	24	320,2
INE_2018_tipologia_2017_2018.xlsx	24	320,2
INE_2019_tipologia_2018_2019.xlsx	24	323,9
INE_2021_tipologia_2020_2021.xlsx	24	321,2
INE_2022_tipologia_2021_2022.xlsx	24	41,2
INE_2023_tipologia_2022_2023.xlsx	24	43,1
INE_2024_tipologia_2023_2024.xlsx	24	47,8

Licencia: el acceso a los cuadros es público; no se encontró en sus hojas una licencia específica que pueda afirmarse sin revisión adicional. Se conserva atribución a las instituciones.

Referencias metodológicas

- Hyndman y Athanasopoulos, Forecasting: Principles and Practice, capítulo 5: https://otexts.com/fpp3/toolbox.html
- Documentación de statsmodels: covarianza HAC, pruebas de diagnóstico y suavizado exponencial. https://www.statsmodels.org/stable/
- Documentación de scikit-learn: Ridge, RandomForestRegressor, SVR, métricas y escalado. https://scikit-learn.org/stable/

Las versiones exactas ejecutadas están en requirements.txt y output/entorno.json. La consigna de la asignatura se utilizó como referencia de estructura, sin inventar devoluciones docentes ni resultados.

Integridad académica y revisión

Declaración de asistencia de IA

Se empleó un asistente de IA para proponer el diseño, redactar y ejecutar código, preparar auditorías y gráficos, calcular resultados y redactar este borrador. No se declara que el grupo haya realizado por sí solo esas tareas.

La sección 11 de la consigna reserva al grupo las decisiones metodológicas y la interpretación. Antes de entregar, sus integrantes deben revisar este material, comprender el código, contrastar los resultados y adoptar o ajustar justificadamente las decisiones. La generación de estos archivos no sustituye ese trabajo ni la exposición del grupo.

Correcciones y revisión humana

No se recibió una nueva devolución de la profesora sobre este enfoque. Las listas de cambios describen modificaciones técnicas respecto del proyecto anterior, no observaciones docentes inventadas. Los legajos y cualquier requisito institucional adicional permanecen pendientes.

Cómo reproducir

Desde la carpeta del proyecto: python src/run_all.py. Los originales están incluidos y se verifican por hash. El flujo crea CSV, tablas, figuras, modelos, notebooks y HTML; la generación de PDF requiere reportlab. La consulta de datos y el entrenamiento no necesitan acceso a internet.

Integridad de la evaluación

No se modifica el modelo elegido después de mirar 2024. La repetición reproducible conserva el protocolo; una futura modificación metodológica deberá identificarse como un experimento nuevo, sin reutilizar 2024 como si nunca hubiera sido consultado.