CIENCIA DE DATOS · PROYECTO INTEGRADOR

Informe integrador · Tres fases

Pronóstico mensual de siniestros de tránsito registrados por la Patrulla Caminera

Del dato agregado a la evaluación honesta de un pronóstico mensual.

Integrantes

Alan Alcaraz · Leandro Ferreira · Jorge Rios

Legajos: no informados. Completar antes de la entrega.

Alcance

Paraguay, zona Central e Interior. Cuadros oficiales del INE con fuente Patrulla Caminera. Serie 2016-2024; desarrollo 2016-2022, calibración 2023 y prueba 2024.

Estado del material

Resultados calculados y reproducibles. Borrador de apoyo académico con asistencia de IA; el grupo debe revisar, comprender y asumir las decisiones metodológicas y la interpretación antes de entregar.

Fecha de elaboración: 31 de octubre de 2026.

Índice

03 Pregunta, objetivo y decisión

04 Alcance y reservas temporales

05 Fuentes, calidad y limpieza

06 Diccionario y variables derivadas

07 Distribución y evolución

08 Asociaciones y composición

09 Hipótesis y supuestos

10 Resultados inferenciales

11 Bootstrap y limitaciones inferenciales

12 Diseño de la comparación predictiva

13 Modelos y selección

14 Entrenamiento, validación y prueba

15 Métricas finales y sus límites

16 Pronósticos evaluados y errores

17 Interpretación y coherencia entre fases

18 Incertidumbre y proyección

19 Respuesta final y trabajo futuro

20 Fuentes y reproducción

21 Integridad académica y revisión

Pregunta, objetivo y decisión

Contexto y decisión

Los datos proceden de registros de la Patrulla Caminera publicados en cuadros del INE. Anticipar cantidades mensuales puede orientar planificación de recursos, sin convertir los registros institucionales en una medición completa de todos los accidentes del país.

Pregunta principal

¿Con qué precisión se pueden pronosticar los siniestros mensuales registrados por la Patrulla Caminera en zona Central e Interior durante doce meses, a partir de su historial y el calendario, frente a referencias sencillas?

Objetivo general

Evaluar la capacidad de modelos temporales y de aprendizaje automático para pronosticar doce cantidades mensuales de siniestros de tránsito registrados por la Patrulla Caminera, con trazabilidad y comparación honesta contra referencias.

Objetivos específicos

- Construir una serie mensual verificable desde los cuadros oficiales, conservando originales, versiones y procedencia por celda.
- Describir distribución, evolución temporal, composición y posibles patrones del período de desarrollo.
- Contrastar cuatro hipótesis de calendario, semestres, tendencia y dependencia de corto plazo, con supuestos y corrección múltiple.
- Comparar modelos de familias distintas mediante validación cronológica a doce meses y evaluar 2024 sin reajustar decisiones a sus resultados.
- Interpretar errores y límites, y producir una proyección reproducible posterior al último dato con su fecha de corte claramente indicada.

Alcance y reservas temporales

Justificación

El cambio de objetivo aprovecha la unidad realmente observada: una cantidad mensual. Evita expandir cuadros agregados a supuestas fichas individuales. La utilidad del proyecto está en medir qué mejora aporta un modelo y cuándo sus errores impiden usarlo con confianza.

Unidad de análisis y población observada

Una fila representa un mes calendario de registros de la Caminera en Central e Interior. La clave natural es año-mes. La fecha en el CSV usa el primer día solo para representar el período; no es la fecha de un accidente.

Alcance

Se consolidan 108 meses de 2016-2024. Las fases exploratoria e inferencial usan exclusivamente 84 meses de 2016-2022. Se reserva 2023 para calibrar una banda empírica y 2024 para evaluar pronósticos emitidos desde diciembre de 2023.

Limitaciones previstas

- No hay identificadores de accidente, persona o vehículo; no se realiza clasificación individual.
- La coincidencia aritmética entre fuentes no prueba estabilidad de cobertura o esfuerzo de registro.
- Los datos de 2024 ya eran visibles en la auditoría de fuentes; se separan del ajuste y de las pruebas inferenciales, pero no constituyen una prueba externa ciega.
- El número de períodos es limitado y los meses están temporalmente relacionados. No se supone causalidad ni riesgo por viaje.
- Un pronóstico con corte en diciembre de 2024 no es una estimación actualizada de 2027.

Fuentes, calidad y limpieza

Se leyeron 7 archivos. Se extrajeron 168 filas mensuales y se conservaron 108 períodos únicos. Los 60 registros repetidos son versiones coincidentes; no son accidentes adicionales.

Partición	Meses	Uso
2016-2022	84	Exploración, hipótesis y validación
2023	12	Calibración de banda empírica, sin elegir modelos
2024	12	Evaluación final a doce meses

Perfilado y selección

Se selecciona el mismo cuadro de tipología por año, con alcance publicado equivalente. Otros PDF, tablas de víctimas, motociclistas y procedimientos se descartan del objetivo principal porque tienen distintas unidades o universos y no deben sumarse al total.

La consolidación concatena ediciones y resuelve la repetición de la clave temporal; no es una unión por persona. Todas las versiones originales quedan disponibles. Exactitud aparente se evalúa por sumas y coincidencias, no contra un registro externo de casos.

Dimensión de calidad	Resultado
Completitud	108 de 108 meses esperados; objetivo sin faltantes
Consistencia	Siete componentes suman el total en cada fila
Unicidad	Una fila por año-mes tras resolver versiones
Actualidad	Último dato: diciembre 2024
Cobertura	Estabilidad institucional no demostrada con estas tablas

Diccionario y variables derivadas

Campo	Significado	Unidad / uso
fecha	Clave mensual real	Mes, único
accidentes	Total registrado	Siniestros/mes; objetivo
choque…atropellamiento	Siete componentes del total	Descriptivos; no predictores del mismo mes
ano, mes, semestre	Calendario	Derivados determinísticos
dias_mes	Duración del período	Días; conocida anticipadamente
tasa_diaria_mes	Total / días	Descriptiva, excluida del modelo contemporáneo
archivo, hoja, celdas, edicion	Procedencia	No predictores
particion	Desarrollo/calibración/prueba	Asignada por fecha

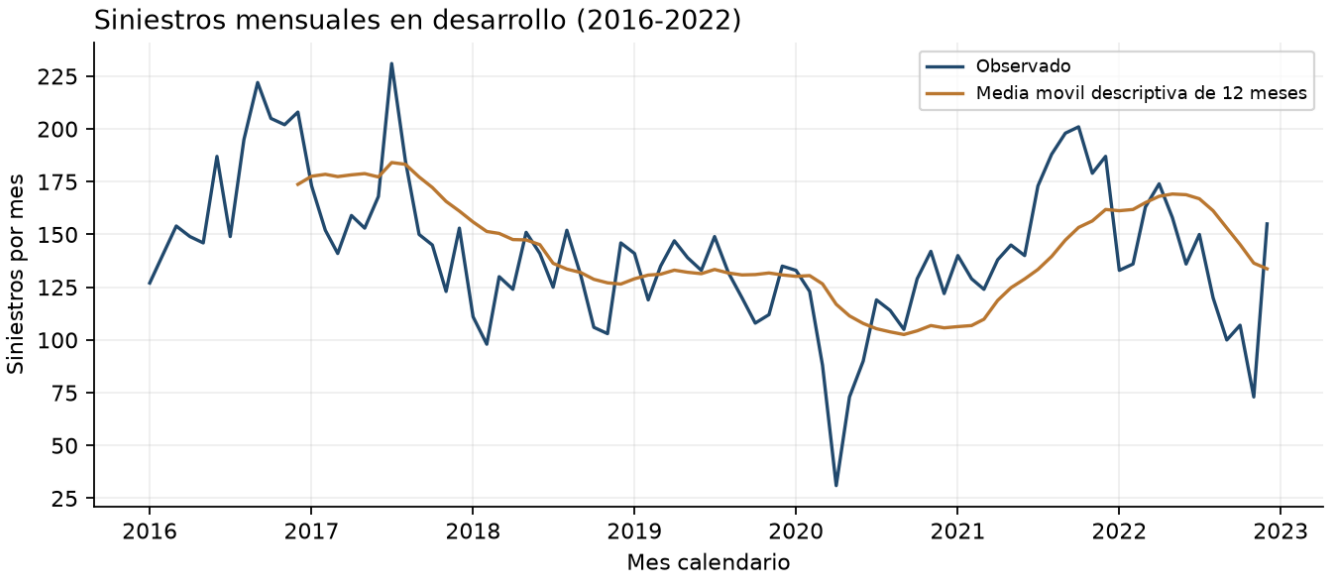
El diccionario completo final informa tipos, rangos, cardinalidad y porcentaje de faltantes por campo en output/tables/diccionario_final.csv. El diccionario original describe B (año/mes), C (total) y D:J (tipos).

Variables para pronosticar

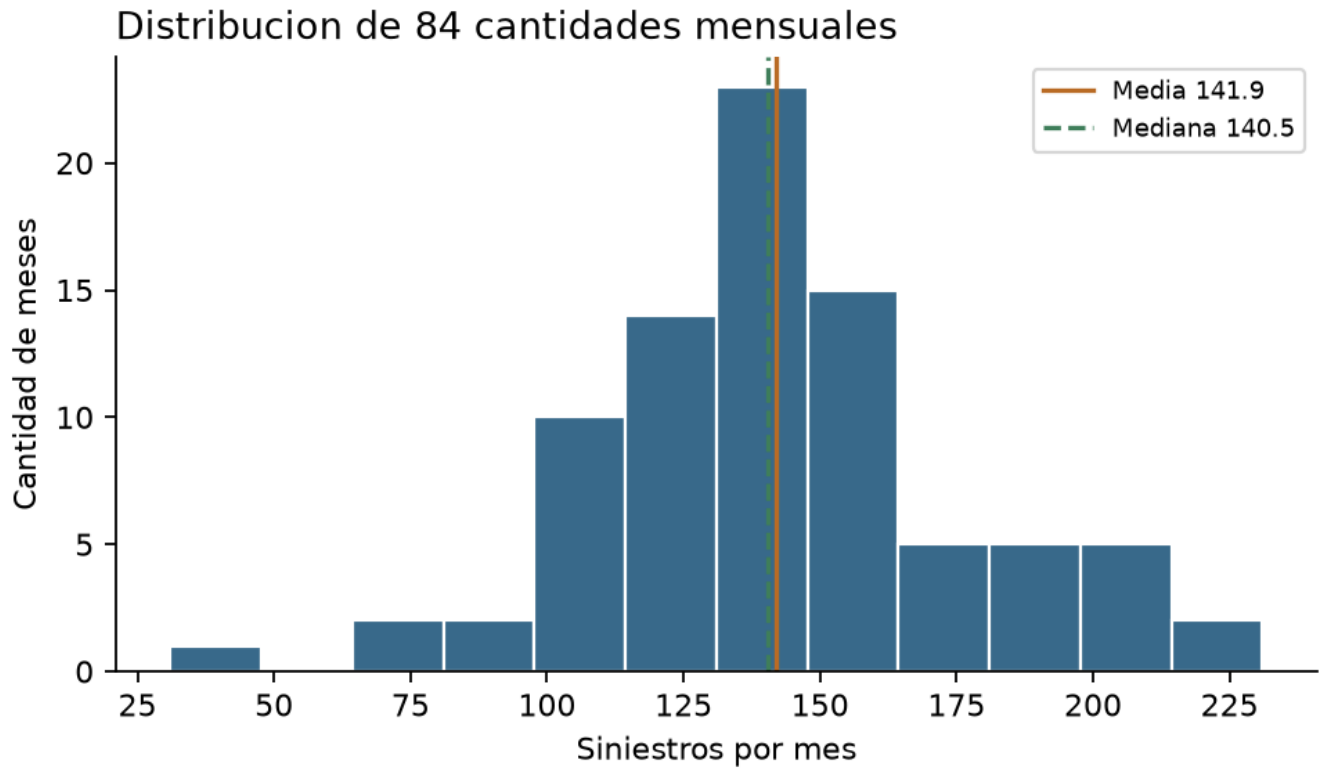
Cinco rezagos (1, 2, 3, 6 y 12 meses), dos medias anteriores (3 y 12 meses), seno/coseno del mes y días del mes. Todos se construyen con historia disponible. El primer año sirve para formar rezagos; no se rellena con ceros.

La media anterior de tres meses usa t-1, t-2 y t-3, nunca el resultado del mes a predecir. Para horizontes futuros, la recursión utiliza predicciones donde ya no existen observaciones conocidas.

Distribución y evolución

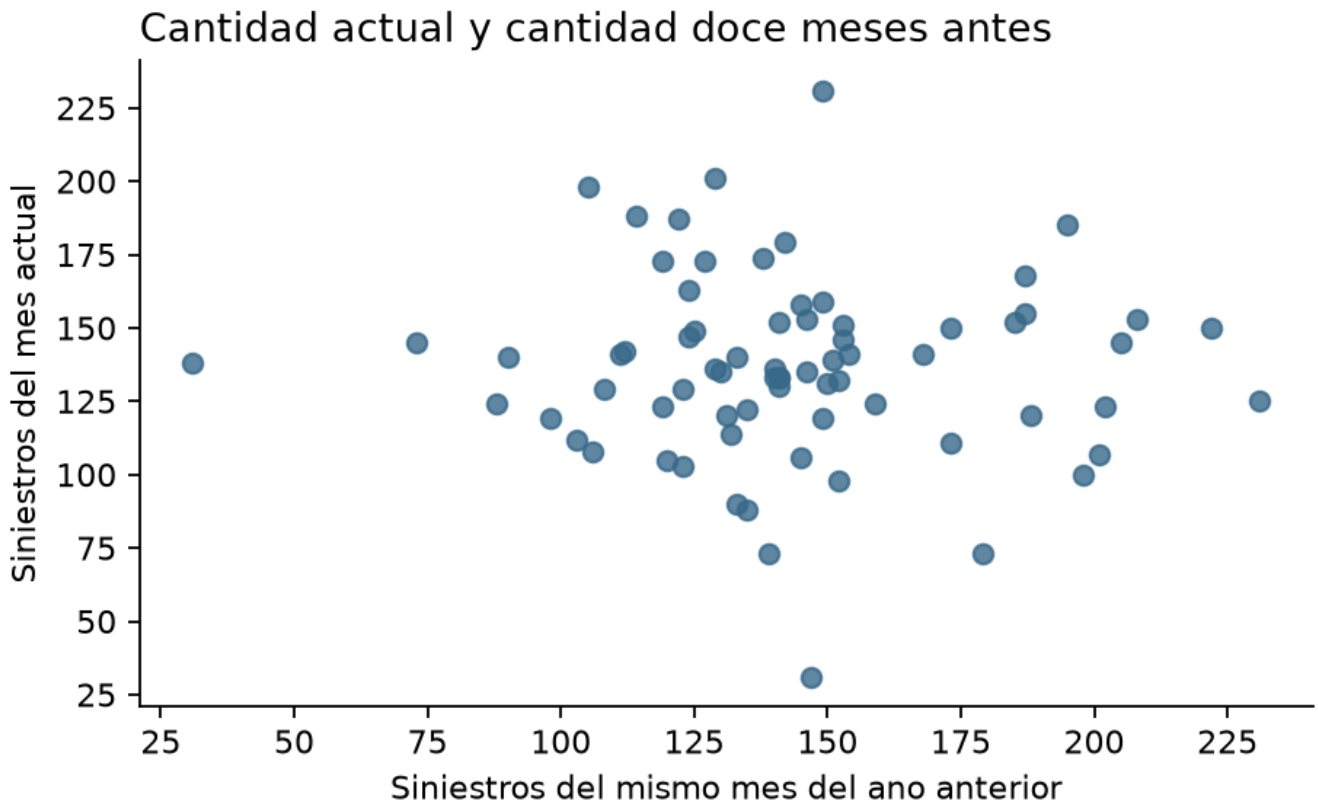


Los conteos van de 31 a 231 por mes. La media movil describe el historial; no se usa para pronosticar el mismo mes.

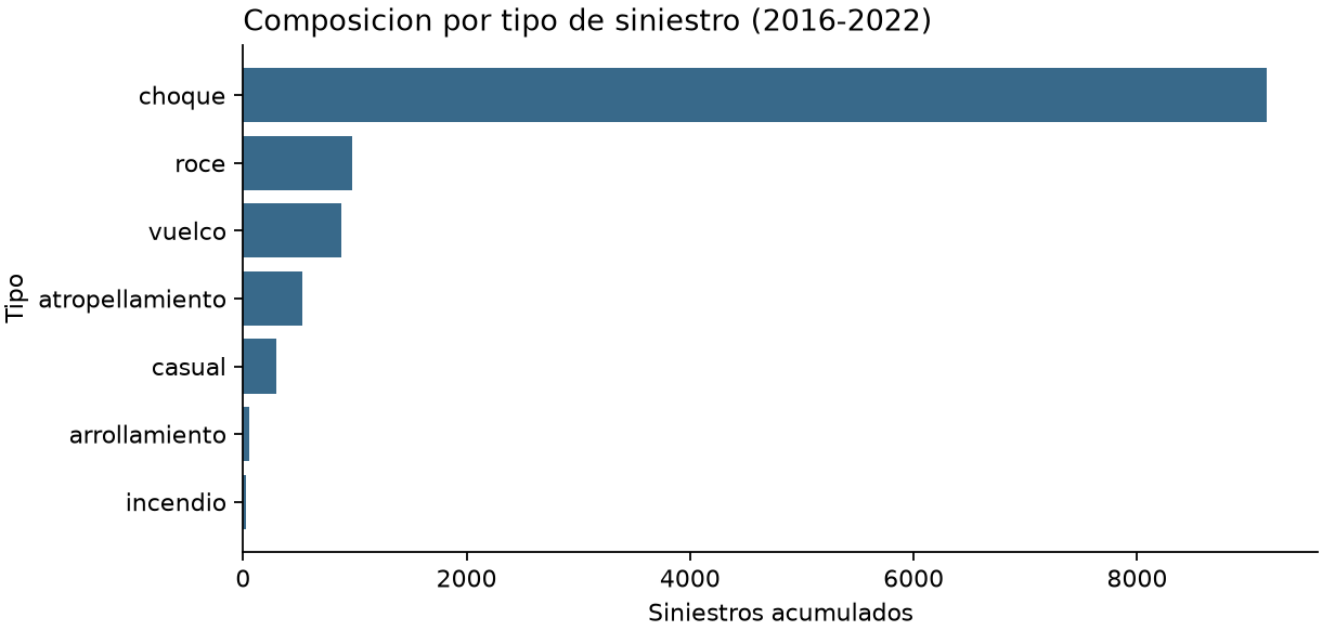


La asimetria es 0.05. La media resume el nivel, pero mezcla anos con contextos distintos; tambien se informa la mediana.

Asociaciones y composición



La correlacion de Pearson es -0.04; la de Spearman es -0.00. No demuestran causalidad ni sustituyen la validacion de pronosticos.



Las dos categorias mas frecuentes concentran 85.0% del total. Son 2 de 7 categorias (28,6%), no exactamente el 20%.

Hipótesis y supuestos

Cambios respecto del proyecto anterior

- Se reemplaza gravedad individual por cantidad mensual y se conserva la unidad agregada real.
- Se consolidan versiones coincidentes en lugar de expandir frecuencias a personas.
- Se excluyen prueba y calibración de la exploración y los contrastes.
- La dependencia temporal se trata con bloques anuales, referencias circulares y covarianza HAC; no se invoca independencia de miles de filas expandidas.

Marco de contrastación

Cuatro hipótesis primarias bilaterales, alfa 0,05 y Bonferroni para la familia completa (umbral individual equivalente 0,0125). Las decisiones se toman con p ajustado; no rechazar H0 no significa aceptarla.

ID	H0 y alternativa
H1	H0: sin alineación mensual de rangos entre años; H1: existe alineación
H2	H0: diferencias semestrales simétricas centradas en cero; H1: centro distinto
H3	H0: rho(año, promedio anual)=0; H1: rho distinto de cero
H4	H0: beta del rezago 1=0 con controles; H1: beta distinto de cero

Los desplazamientos circulares son referencias aproximadas que preservan orden temporal, no una aleatorización experimental. Las pruebas de supuestos son diagnósticos, no un filtro para buscar significación.

Resultados inferenciales

ID	Estadístico	p primario	p ajustado	Efecto	Decisión
H1	10,493	0,4462	1,0000	0,136	No rechazar H0
H2	8,000	0,3750	1,0000	13,714	No rechazar H0
H3	-0,286	0,7143	1,0000	-0,286	No rechazar H0
H4	8,025	2,91e-11	1,16e-10	0,575	Rechazar H0

Los intervalos del 95% informados son marginales por contraste, no intervalos simultáneos para toda la familia. Las decisiones múltiples se basan en los valores p ajustados.

Interpretación práctica

La evidencia más clara es asociación temporal de corto plazo. El calendario y las diferencias de semestre no presentan evidencia concluyente bajo los contrastes predefinidos. Se mantienen variables de calendario como controles predictivos, pero su utilidad se decidirá por validación, no por exigir $p<0,05$.

Confusores y representatividad

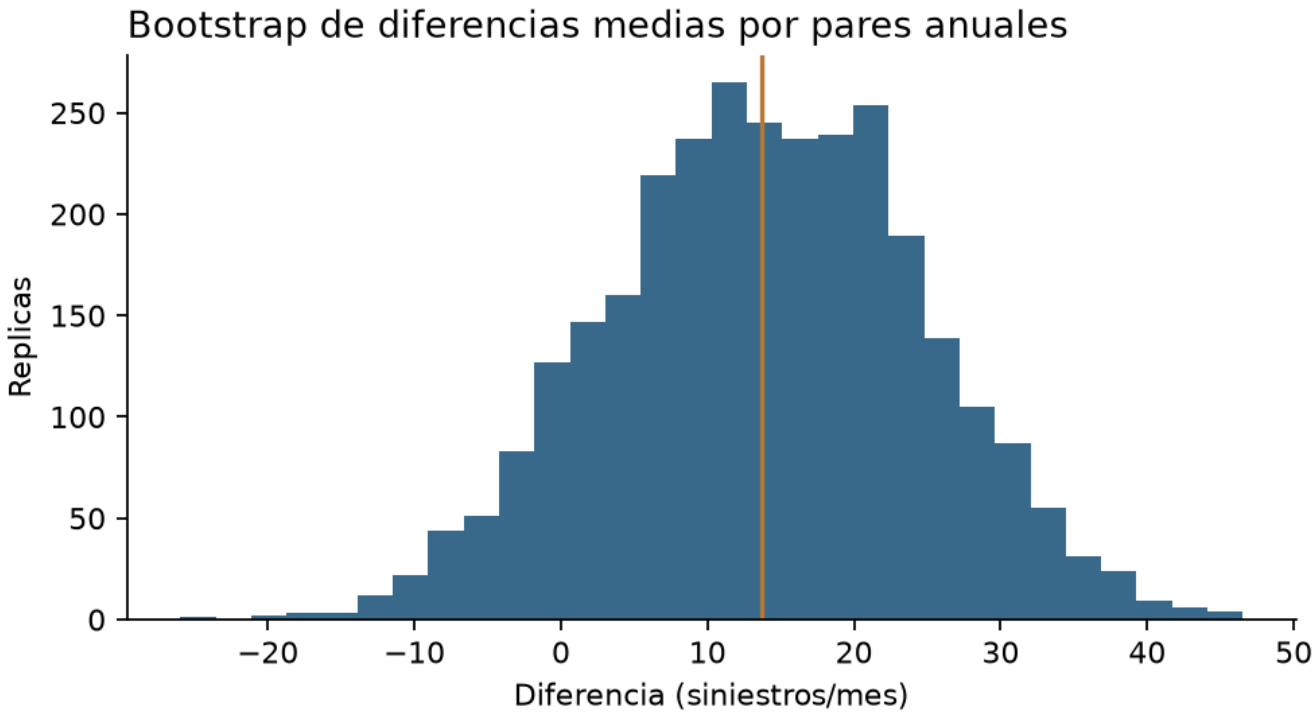
- Volumen de tránsito, kilómetros recorridos y esfuerzo de fiscalización no están medidos.
- Cambios de cobertura o registro pueden alterar cantidades sin alterar el riesgo por viaje.
- 2020 representa un contexto distinto; el indicador no identifica por sí solo una causa.
- La muestra temporal es pequeña: no se extienden conclusiones a todos los accidentes no registrados.

Puente a la Fase 3

Se evaluarán rezagos y medias previas junto con calendario, con escalado ajustado dentro de cada entrenamiento. Los resultados inferenciales no se usarán para seleccionar columnas mirando el año de prueba. La comparación temporal determinará si la asociación se transforma en capacidad predictiva.

Bootstrap y limitaciones inferenciales

Para la diferencia media semestral, el IC clásico t es [-14,83; 42,26] y el bootstrap de pares anuales es [-7,43; 34,14]. Ambos estiman el mismo parámetro medio; ambos dependen de la aproximación de independencia entre años.



Se remuestrean años completos con sus dos semestres emparejados, 3.000 veces, con semilla fija. No se crean víctimas ni meses nuevos como observaciones independientes.

Regresión y sensibilidad

Para beta del rezago uno: IC OLS [0,394; 0,757], IC HAC [0,432; 0,719] e IC bootstrap de bloques de doce residuos [0,406; 0,747].

El bootstrap residual mantiene el diseño fijo y aproxima dependencia de corto plazo; no resuelve la endogeneidad de rezagos. La tabla de sensibilidad HAC(6)/HAC(12) se conserva y no se utiliza para escoger el p más pequeño.

Diseño de la comparación predictiva

Tarea: regresión de conteos mensuales a doce pasos. No corresponde usar accuracy, F1 ni matriz de confusión. Los pronósticos son valores esperados continuos; no se redondean antes de evaluar.

Bloque	Qué se hace	Qué se evita
2016-2022	EDA, cuatro contrastes y búsqueda temporal	Mirar 2024 para elegir variables o parámetros
Cortes 2019-2022	Cuatro pronósticos de doce meses: 48 errores/configuración	K-fold aleatorio o actualización con valores futuros reales
2023	Calibrar el radio de una banda después de elegir el modelo	Usarlo para cambiar la familia ganadora
2024	Evaluar una vez todas las familias con parámetros fijados	Cambiar al ganador por su desempeño de prueba

Los entrenamientos de validación contienen 36, 48, 60 y 72 meses respectivamente; después del rezago doce quedan 24, 36, 48 y 60 filas supervisadas. El ajuste final para evaluar 2024 usa 96 meses hasta diciembre de 2023 y 84 filas supervisadas.

Prevención de filtraciones

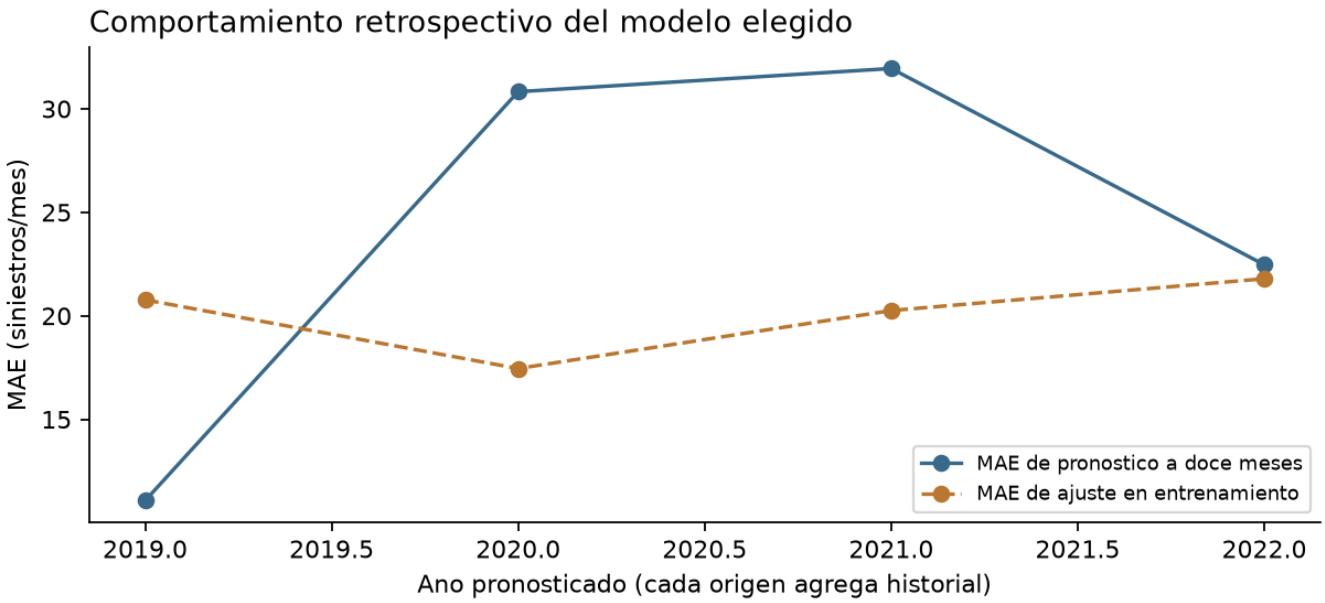
Las medias se desplazan un mes. StandardScaler se ajusta solo dentro de cada entrenamiento. Choques, tipos de siniestro, tasa diaria del propio mes y resultados reales de meses futuros no se usan como entradas. Los doce pasos se generan recursivamente con predicciones.

La prueba es interna y temporal: 2024 no participa del ajuste ni la selección. Sus cantidades ya se habían visto en la auditoría de disponibilidad, por lo que no se presenta como una validación externa ciega.

Modelos y selección

Familia	MAE validación	RMSE validación	Parámetros elegidos
SVR	24,08	33,38	{"C": 1.0, "epsilon": 15.0, "gamma": "scale"}
Ridge	26,24	35,15	{"alpha": 100.0}
Random Forest	30,44	40,77	{"max_depth": 3, "min_samples_leaf": 2, "n_estimators": 250}
ETS	31,00	42,01	{"trend": "add", "seasonal": null, "damped_trend": true}
Referencia media12	31,47	42,32	{}
Referencia estacional	37,23	49,07	{}

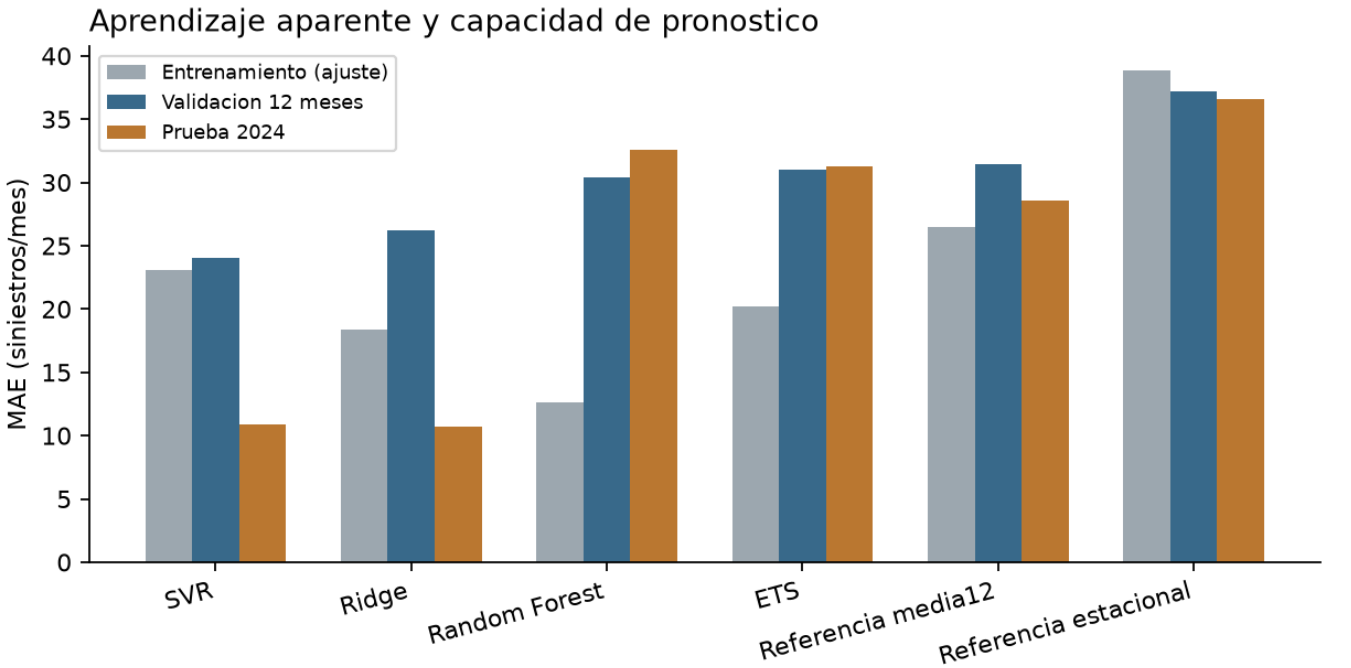
Se eligió SVR, con C=1, epsilon=15 y gamma=scale, por su menor MAE de validación (24,08). La elección precede a 2023 y 2024.



Cada punto cambia el año pronosticado y agrega historia. No es una curva de aprendizaje con un conjunto de validación fijo; los saltos reflejan también cambios del fenómeno.

Entrenamiento, validación y prueba

Familia	MAE ajuste	MAE CV	MAE prueba	R^2 prueba
SVR	23,06	24,08	10,87	-0,48
Ridge	18,36	26,24	10,67	-0,18
Random Forest	12,59	30,44	32,61	-6,67
ETS	20,19	31,00	31,30	-6,14
Referencia media12	26,46	31,47	28,58	-5,14
Referencia estacional	38,85	37,23	36,58	-10,72



El ajuste de entrenamiento usa predicciones a un paso con antecedentes reales; validación y prueba son pronósticos a doce pasos. Las brechas son diagnósticas y no una medida pura de sobreajuste, porque cambian el horizonte y los períodos.

Random Forest presenta ajuste mucho más favorable que su validación y prueba, compatible con sobreajuste y falta de generalización. SVR está fuertemente regularizado y produce un perfil casi plano: su mejora corresponde sobre todo a estimar el nivel, no a recuperar cada oscilación mensual.

Métricas finales y sus límites

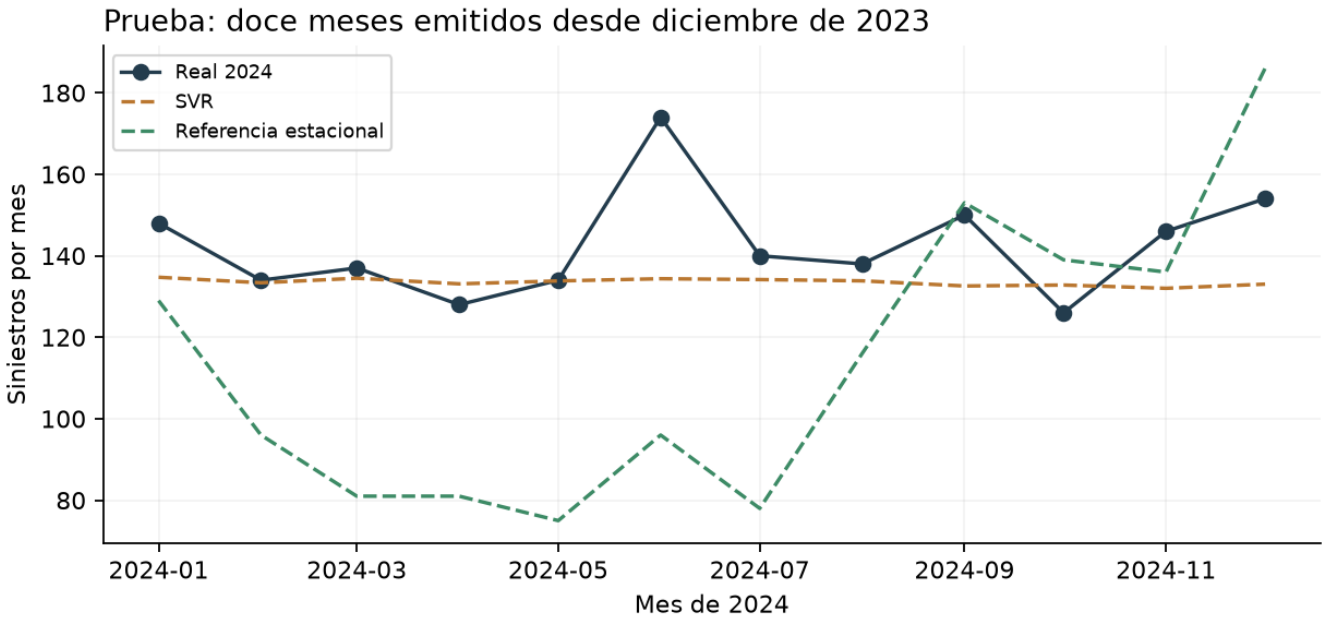
Métrica seleccionada	Resultado 2024
MAE	10,87 siniestros/mes
RMSE	15,32 siniestros/mes
MAPE	7,13%
R^2	-0,477
Sesgo medio	-8,89 siniestros/mes
Total real	1.709
Total predicho	1.602,36
Error de total	-106,64

La reducción de MAE frente a la referencia estacional es 70,28%; frente a la media12 es 61,96%. Eso no equivale a un porcentaje de exactitud.

El R^2 negativo indica que el error cuadrático supera el de una constante igual a la media real de 2024. Esa media se conoce después de observar el año y no es una referencia operativa disponible al pronosticar. Aun así, el resultado evidencia escasa explicación de las variaciones mensuales.

Ridge obtiene un MAE de prueba ligeramente menor que SVR. No se cambia la selección: elegirlo después de observar 2024 contaminaría la evaluación. Su resultado se muestra para transparencia, no para retocar al ganador.

Pronósticos evaluados y errores

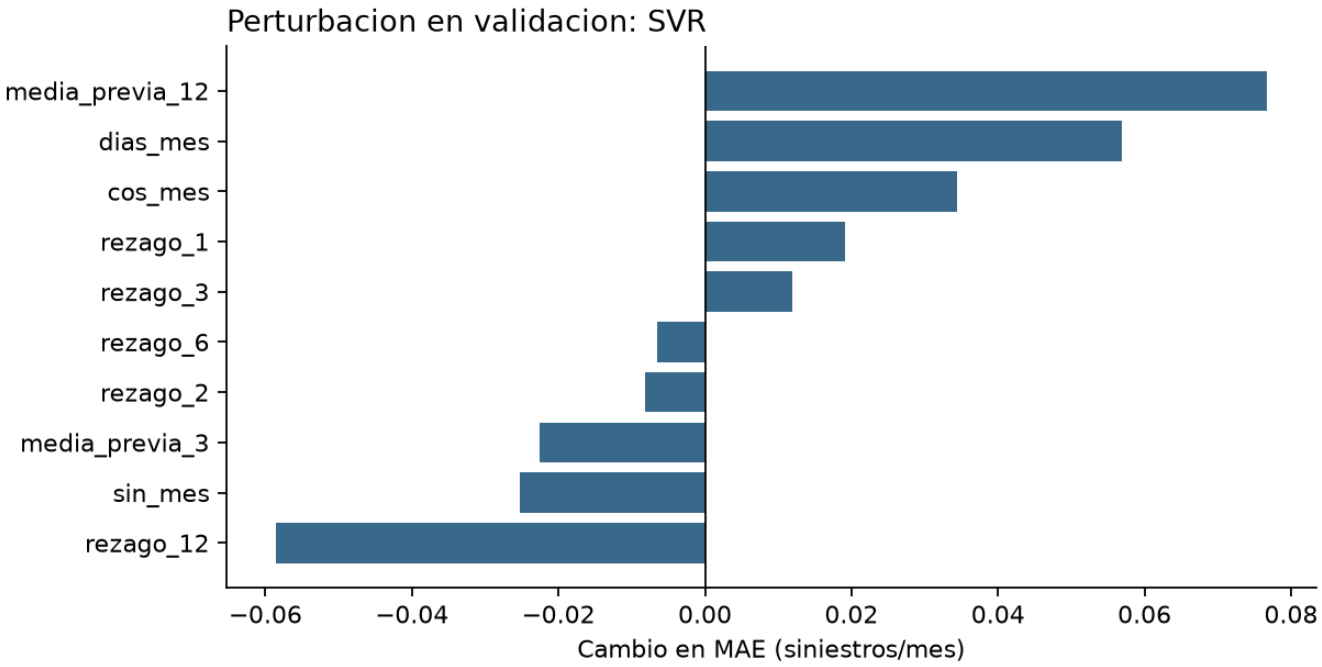


Las doce predicciones se emiten desde un único origen: diciembre de 2023. No se actualiza el modelo con los valores reales de enero, febrero u otros meses de 2024.

Mes	Real	Predicho	Error absoluto
2024-06	174	134,37	39,63
2024-12	154	133,04	20,96
2024-09	150	132,59	17,41
2024-11	146	132,02	13,98
2024-01	148	134,73	13,27

Los meses peor predichos concentran picos que el perfil plano no anticipa. No se atribuyen sus causas a clima, movilidad o fiscalización porque esas variables no están observadas en el dataset.

Interpretación y coherencia entre fases



La perturbación se calcula en los cuatro cortes de validación, reemplazando una entrada por valores históricos de su distribución y ejecutando la recursión. No usa prueba para seleccionar variables. Las perturbaciones pueden romper relaciones entre rezagos: son diagnóstico, no efecto causal.

En SVR los cambios medios de MAE por variable son menores a 0,1 siniestros/mes y su dispersión es comparable o mayor. No hay evidencia robusta de una variable claramente dominante mediante este diagnóstico. El modelo es casi constante y fuertemente regularizado.

Relación con Fases 1 y 2

La asociación inferencial con el mes previo no se convierte automáticamente en capacidad de pronóstico anual: al avanzar doce pasos, cada predicción alimenta la siguiente. La inferencia condicional y la generalización fuera de muestra responden preguntas diferentes.

Se conservan coeficientes estandarizados de Ridge e importancias de impureza de Random Forest como diagnósticos de esas familias, sin atribuirlos al SVR ganador.

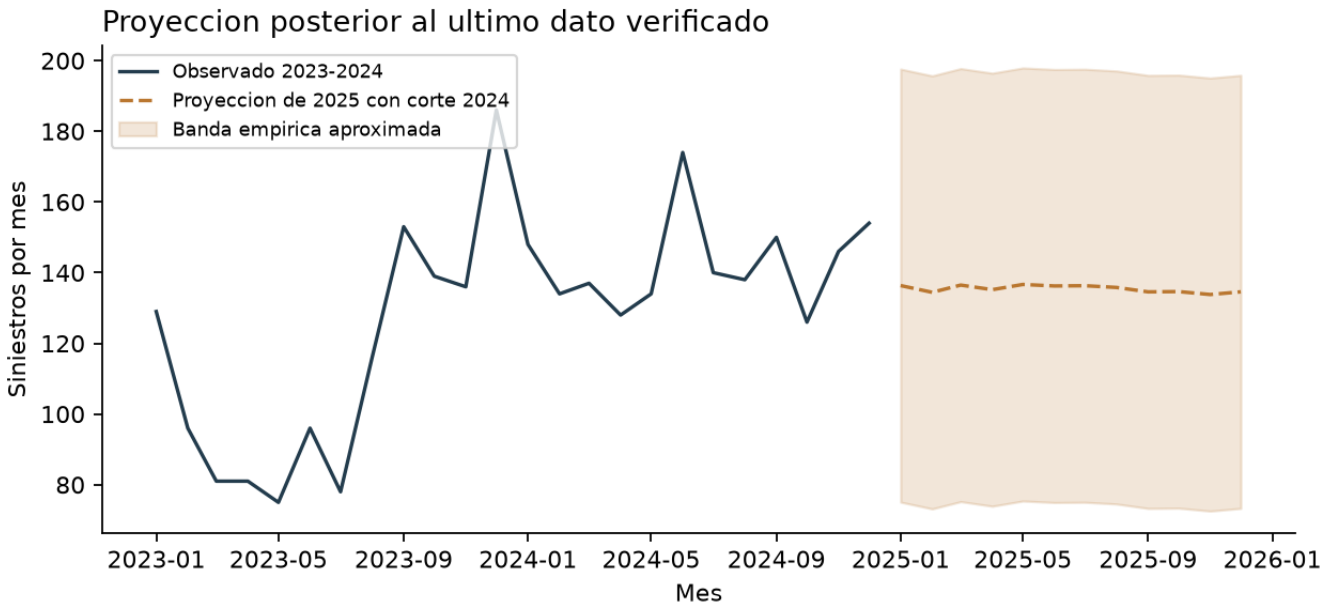
Incertidumbre y proyección

El modelo seleccionado se entrenó hasta 2022 para pronosticar 2023, sin usar ese año al elegir hiperparámetros. Se tomó el máximo de sus doce errores absolutos: radio 61,27 siniestros/mes. Es el orden 12 de ceil((12+1)×0,9).

La banda contiene 100% de los doce valores de 2024. Es amplia y su cobertura observada en un solo año no prueba una garantía del 90% en futuros períodos.

La construcción se inspira en cuantiles de errores de calibración, pero los errores temporales y por horizonte no son necesariamente intercambiables. Se etiqueta como banda empírica aproximada, no como intervalo conformal con cobertura demostrada.

Incertidumbre del total anual



Proyección retrospectiva de 2025 con corte 2024: total 1.625,09. No es una estimación actualizada de 2027.

Respuesta final y trabajo futuro

Respuesta final

Con este diseño, SVR mejora las dos referencias operativas en 2024 y reduce el MAE a 10,87. Sin embargo, su R^2 de -0,477 y su perfil casi plano muestran que no anticipa satisfactoriamente las fluctuaciones mensuales. El resultado es una mejora relativa de nivel, no evidencia de alta capacidad predictiva.

Qué aprendió y qué no

El criterio temporal favoreció un modelo de muy baja flexibilidad. No reproduce picos y subestima el total de 2024. Random Forest muestra que memorizar mejor el entrenamiento no asegura pronosticar mejor. No se ocultaron resultados negativos ni se cambió la especificación para mejorar prueba.

Limitaciones y continuación

- Solo nueve años de datos, cuatro cortes de validación, un año de calibración y uno de prueba.
- Faltan exposición vial, cambios de registro y factores externos conocidos anticipadamente.
- No hay validación externa o multianual posterior a 2024; deben conseguirse datos comparables recientes.
- Evaluar otro dataset o nuevos predictores sería un experimento nuevo y necesitaría otra reserva temporal.
- No deben asignarse recursos únicamente con estas predicciones ni extrapolarse a víctimas individuales.

Lista de correcciones aplicada desde Fase 2

La selección se basa en validación predictiva, no solo en significación inferencial. Se respetan autocorrelación e incertidumbre. Las variables contemporáneas del objetivo quedan excluidas y se informa cuándo los resultados inferenciales no se traducen en generalización.

Fuentes y reproducción

Fuentes primarias y trazabilidad

Catálogo del INE: https://www.ine.gov.py/tabulado/16/anuario. Siete cuadros 12.2.2 descargados el 31/10/2026; sus fuentes internas son MOPC / Patrulla Caminera. Cada original se conserva en data/raw con su SHA-256 y URL exacta en catalogo_fuentes.json e inventario_fuentes.csv.

Edición / archivo conservado	Filas mensuales	Tamaño (KB)
INE_2017_tipologia_2016_2017.xlsx	24	320,2
INE_2018_tipologia_2017_2018.xlsx	24	320,2
INE_2019_tipologia_2018_2019.xlsx	24	323,9
INE_2021_tipologia_2020_2021.xlsx	24	321,2
INE_2022_tipologia_2021_2022.xlsx	24	41,2
INE_2023_tipologia_2022_2023.xlsx	24	43,1
INE_2024_tipologia_2023_2024.xlsx	24	47,8

Licencia: el acceso a los cuadros es público; no se encontró en sus hojas una licencia específica que pueda afirmarse sin revisión adicional. Se conserva atribución a las instituciones.

Referencias metodológicas

- Hyndman y Athanasopoulos, Forecasting: Principles and Practice, capítulo 5: https://otexts.com/fpp3/toolbox.html
- Documentación de statsmodels: covarianza HAC, pruebas de diagnóstico y suavizado exponencial. https://www.statsmodels.org/stable/
- Documentación de scikit-learn: Ridge, RandomForestRegressor, SVR, métricas y escalado. https://scikit-learn.org/stable/

Las versiones exactas ejecutadas están en requirements.txt y output/entorno.json. La consigna de la asignatura se utilizó como referencia de estructura, sin inventar devoluciones docentes ni resultados.

Integridad académica y revisión

Declaración de asistencia de IA

Se empleó un asistente de IA para proponer el diseño, redactar y ejecutar código, preparar auditorías y gráficos, calcular resultados y redactar este borrador. No se declara que el grupo haya realizado por sí solo esas tareas.

La sección 11 de la consigna reserva al grupo las decisiones metodológicas y la interpretación. Antes de entregar, sus integrantes deben revisar este material, comprender el código, contrastar los resultados y adoptar o ajustar justificadamente las decisiones. La generación de estos archivos no sustituye ese trabajo ni la exposición del grupo.

Correcciones y revisión humana

No se recibió una nueva devolución de la profesora sobre este enfoque. Las listas de cambios describen modificaciones técnicas respecto del proyecto anterior, no observaciones docentes inventadas. Los legajos y cualquier requisito institucional adicional permanecen pendientes.

Cómo reproducir

Desde la carpeta del proyecto: python src/run_all.py. Los originales están incluidos y se verifican por hash. El flujo crea CSV, tablas, figuras, modelos, notebooks y HTML; la generación de PDF requiere reportlab. La consulta de datos y el entrenamiento no necesitan acceso a internet.

Integridad de la evaluación

No se modifica el modelo elegido después de mirar 2024. La repetición reproducible conserva el protocolo; una futura modificación metodológica deberá identificarse como un experimento nuevo, sin reutilizar 2024 como si nunca hubiera sido consultado.